

跨模态注意力与条件流匹配

1 跨模态注意力与掩码

设文本表示为 $X \in \mathbb{R}^{N_q \times d_t}$ ，视觉表示为 $Z \in \mathbb{R}^{N_v \times d_v}$ 。以下只考虑一个样本和一个注意力头。批维和头维可以在外层独立重复，不改变本节的矩阵收缩。

对两个模态分别进行线性投影：

$$Q = XW_Q \in \mathbb{R}^{N_q \times d_k}, \quad K = ZW_K \in \mathbb{R}^{N_v \times d_k}, \quad V = ZW_V \in \mathbb{R}^{N_v \times d_o}. \quad (1)$$


其中 $W_Q \in \mathbb{R}^{d_t \times d_k}$ ， $W_K \in \mathbb{R}^{d_v \times d_k}$ ， $W_V \in \mathbb{R}^{d_v \times d_o}$ 。 Q 和 K 使用相同的通道维数，以便计算内积；输出通道数 d_o 可以不同。

记 J_i 为第 i 个文本位置允许访问的视觉位置集合，并假设 $J_i \neq \emptyset$ 。注意力分数、概率和输出分别为

$$\begin{aligned} S &= QK^\top / \sqrt{d_k}, \\ P_{ij} &= \begin{cases} \exp(S_{ij}) / \sum_{l \in J_i} \exp(S_{il}), & j \in J_i, \\ 0, & j \notin J_i, \end{cases} \\ Y_i &= \sum_{j \in J_i} P_{ij} V_j. \end{aligned} \quad (2)$$

S 保存实数分数， P 保存归一化概率；访问集合由布尔掩码表示。输出 $Y \in \mathbb{R}^{N_q \times d_o}$ 的每一行是对应视觉值向量的加权和。

$$Y = PV$$



维度 N_q 为查询数， N_v 为视觉位置数， d_o 为输出通道数。

对象 P 为概率，留白位置不可访问； V, Y 为实数特征。

计算 乘法沿 N_v 求和。格子仅表示轴结构与支持集。

图 1: P 的列轴与 V 的行轴使用相同长度，输出保留查询轴和输出通道轴。

1.1 从概率归一化到反向传播

设标量损失为 L ，上游梯度为 $G_i = \partial L / \partial Y_i$ 。由 $Y_i = \sum_j P_{ij} V_j$ ，先求

$$\frac{\partial L}{\partial P_{ij}} = G_i^\top V_j. \quad (3)$$

下面固定一行 i 。对允许访问的 j, k ，将 softmax 写成分子除以归一化常数，并使用商法则：

$$\begin{aligned} \frac{\partial P_{ij}}{\partial S_{ik}} &= \frac{\exp(S_{ij}) \mathbf{1}[j = k] \sum_l \exp(S_{il}) - \exp(S_{ij}) \exp(S_{ik})}{(\sum_l \exp(S_{il}))^2} \\ &= P_{ij} \mathbf{1}[j = k] - P_{ij} P_{ik} \\ &= P_{ij} (\mathbf{1}[j = k] - P_{ik}). \end{aligned} \quad (4)$$

求和只遍历 J_i 。若 $k \notin J_i$ ，该分数未进入归一化，导数为零。把上式代入链式法则，得到

$$\begin{aligned} D_{ik} &:= \frac{\partial L}{\partial S_{ik}} = \sum_{j \in J_i} (G_i^\top V_j) P_{ij} (\mathbf{1}[j = k] - P_{ik}) \\ &= P_{ik} \left(G_i^\top V_k - \sum_{j \in J_i} P_{ij} G_i^\top V_j \right) \\ &= P_{ik} G_i^\top (V_k - Y_i). \end{aligned} \quad (5)$$

这一形式直接说明每行分数梯度之和为零，因为概率加权的 $V_k - Y_i$ 之和为零。因此，对同一行所有分数加上同一个常数，不改变输出。

进一步对 $S_{ij} = \sum_a Q_{ia} K_{ja} / \sqrt{d_k}$ 求导，可得到矩阵形式：

$$\begin{aligned} \frac{\partial L}{\partial Q_{ia}} &= \sum_j D_{ij} \frac{K_{ja}}{\sqrt{d_k}}, & \frac{\partial L}{\partial Q} &= DK / \sqrt{d_k}, \\ \frac{\partial L}{\partial K_{ja}} &= \sum_i D_{ij} \frac{Q_{ia}}{\sqrt{d_k}}, & \frac{\partial L}{\partial K} &= D^\top Q / \sqrt{d_k}, \\ \frac{\partial L}{\partial V_{jb}} &= \sum_i P_{ij} G_{ib}, & \frac{\partial L}{\partial V} &= P^\top G. \end{aligned} \quad (6)$$

从逐元素求和可以分别检查收缩轴与转置。若视觉编码器需要更新，还需沿 $K = ZW_K$ 和 $V = ZW_V$ 将两个分支的梯度相加。

1.2 数值实现与监督位置

计算 softmax 时，可以先减去本行允许访问分数的最大值，再取指数。该操作利用平移不变性减少指数溢出。全遮蔽行没有归一化分母；本章接口对此抛出异常。其他实现采用特殊约定时，需要同时说明输出和梯度。

注意力掩码决定可以访问哪些位置。监督掩码决定哪些预测计入损失。某个视觉位置即使不承担直接预测目标，仍可能通过被答案位置访问而接收梯度。数据接口因此应分别记录这两类掩码，并独立测试。

例题：两位置注意力的分数梯度

令分数为 $(0, \log 3)$ ，两个标量值为 $(-1, 3)$ 。概率为 $(1/4, 3/4)$ ，输出为 $Y = 2$ 。取目标值为 1，损失 $L = (Y - 1)^2/2$ ，上游梯度 $G = 1$ 。由式(5)得到

$$D_1 = \frac{1}{4}(-1 - 2) = -\frac{3}{4}, \quad D_2 = \frac{3}{4}(3 - 2) = \frac{3}{4}. \quad (7)$$

两项之和为零。若只允许访问第一个位置，则概率固定为 $(1, 0)$ ，分数梯度为零；此时 $Y = -1$ 、 $G = -2$ ，值分支仍有梯度 $(-2, 0)$ 。

1.3 综合习题

问题 1：归一化、访问集合与梯度。沿用单头跨模态注意力的定义。

- (a) 引入温度 $\tau > 0$ ，令允许位置的概率正比于 $\exp(S_{ij}/\tau)$ 。从商法则推导对原始分数 S 的导数，并证明每行分数梯度之和为零。分析 $\tau \rightarrow \infty$ 的概率极限。若最大分数唯一， $\tau \rightarrow 0^+$ 时分数梯度有何极限？说明唯一性条件的作用。
- (b) 完成两位置例题中的值梯度计算。只保留一个允许位置时，哪些梯度变为零，哪些仍可非零？说明条件。
- (c) 假设仅答案位置计入监督损失。用本章梯度表达式说明没有直接监督标签的视觉位置仍能接收梯度，并给出梯度为零的一种情形。
- (d) 实现 `masked_softmax` 与 `softmax_vjp`。接口输入为一维有限实数和布尔掩码；输出长度不变。全遮蔽行抛出异常。用中心差分检验导数，再测试大分数、精确零支持集和常量平移。
- (e) 同时重排 K 、 V 和掩码的视觉位置轴，证明 Y 不变。仅重排 V 时构造一个结果变化的例子。说明这两个测试分别检验了什么。

2 高斯条件流与边缘速度

条件流匹配使用可采样的路径构造回归目标。为分析回归得到的速度场，设 X_0 与 X_1 相互独立，分别服从 $\mathcal{N}(m_0, s_0^2)$ 和 $\mathcal{N}(m_1, s_1^2)$ ，其中 $s_0, s_1 > 0$ 。定义

$$X_t = (1 - t)X_0 + tX_1, \quad U = X_1 - X_0, \quad 0 \leq t \leq 1. \quad (8)$$

给定一个端点对时，路径导数为 U 。模型只能观察 t 和 X_t ，因此需要分析在这些条件下能够预测的量。

2.1 平方回归的条件最优解

固定 t ，令 $h(x) = \mathbb{E}[U | X_t = x]$ 。把预测误差分成两部分：

$$\begin{aligned} \mathbb{E}[(v(x) - U)^2 | X_t = x] &= \mathbb{E}[(v(x) - h(x)) + (h(x) - U)]^2 | X_t = x \\ &= (v(x) - h(x))^2 + 2(v(x) - h(x))\mathbb{E}[h(x) - U | X_t = x] \\ &\quad + \mathbb{E}[(h(x) - U)^2 | X_t = x] \\ &= (v(x) - h(x))^2 + \text{Var}(U | X_t = x). \end{aligned} \quad (9)$$

第二行的交叉项为零，因为 h 是条件均值。最后一项与预测函数 v 无关。因此，平方回归的最优预测为 $v(t, x) = \mathbb{E}[U | X_t = x]$ 。

2.2 由联合矩推导速度场

线性期望和端点独立性分别给出

$$\begin{aligned} m_t &:= \mathbb{E}[X_t] = (1-t)m_0 + tm_1, \\ q_t &:= \text{Var}(X_t) = (1-t)^2 s_0^2 + t^2 s_1^2, \\ c_t &:= \text{Cov}(U, X_t) = \text{Cov}(X_1 - X_0, (1-t)X_0 + tX_1) \\ &= t \text{Var}(X_1) - (1-t) \text{Var}(X_0) \\ &= ts_1^2 - (1-t)s_0^2. \end{aligned} \quad (10)$$

两个交叉协方差因独立性为零。 q_t 在整个区间内为正，后续除法有定义。

为了求条件均值，定义残差

$$R = U - (m_1 - m_0) - \frac{c_t}{q_t}(X_t - m_t). \quad (11)$$

它满足 $\mathbb{E}[R] = 0$ ，并且

$$\begin{aligned} \text{Cov}(R, X_t) &= \text{Cov}(U, X_t) - \frac{c_t}{q_t} \text{Var}(X_t) \\ &= c_t - \frac{c_t}{q_t} q_t = 0. \end{aligned} \quad (12)$$

(R, X_t) 是高斯变量的线性变换，所以仍联合高斯。联合高斯变量的不相关性推出独立性，故 $\mathbb{E}[R | X_t] = 0$ 。对式(11)取条件期望，得到

$$v(t, x) = m_1 - m_0 + \frac{c_t}{q_t}(x - m_t). \quad (13)$$

这里的 c_t/q_t 来自条件回归，它随时刻变化。

2.3 解析流映射

令 $s_t = \sqrt{q_t}$ 。由 $q'_t = 2c_t$ 得到 $s'_t = c_t/s_t$ 。考虑从初值 x_0 出发的映射

$$\Phi_t(x_0) = m_t + \frac{s_t}{s_0}(x_0 - m_0). \quad (14)$$

对时间求导，并把 $\Phi_t - m_t$ 代回去：

$$\begin{aligned} \frac{d\Phi_t}{dt} &= m_1 - m_0 + \frac{c_t}{s_t s_0}(x_0 - m_0) \\ &= m_1 - m_0 + \frac{c_t}{q_t}(\Phi_t - m_t) \\ &= v(t, \Phi_t). \end{aligned} \quad (15)$$

该映射满足 $\Phi_0(x_0) = x_0$ 。若初值服从 $\mathcal{N}(m_0, s_0^2)$ ，其仿射变换在时刻 t 的均值和方差为 m_t, q_t ，与训练路径的边缘分布一致。

训练路径的端点采用独立采样；ODE 映射的末点由初点确定。两种构造的边缘分布一致，端点联合分布可以不同。单条生成轨迹不能由随机抽取的端点对直接确定。

例题：相同端点分布的非恒定路径

令 $m_0 = m_1 = 0, s_0 = s_1 = 1$ 。初始与最终分布均为标准高斯，但中间方差为 $q_t = (1-t)^2 + t^2$ ，在 $t = 1/2$ 时等于 $1/2$ 。因此，解析流为 $\Phi_t(x_0) = \sqrt{q_t} x_0$ 。从 $x_0 = 1$ 出发，轨迹经过 $1/\sqrt{2}$ 后返回 1。相同的端点分布没有唯一确定中间路径。

2.4 数值积分与误差

Euler 方法在当前状态计算速度，再前进一个时间步。中点方法先预测半步状态，再用该位置的速度更新：

$$\begin{aligned} x_{n+1}^{\text{Euler}} &= x_n + h v(t_n, x_n), \\ \tilde{x}_{n+1/2} &= x_n + \frac{h}{2} v(t_n, x_n), \\ x_{n+1}^{\text{midpoint}} &= x_n + h v(t_n + \frac{h}{2}, \tilde{x}_{n+1/2}). \end{aligned} \quad (16)$$

本例中速度场光滑，可以使用解析末点比较误差。比较时固定初值与高斯参数，只改变方法或步数。该实验检验数值积分，不涉及模型训练误差。

2.5 综合习题

问题 2：条件回归、流映射与采样。沿用独立高斯端点和线性路径。

- 从条件平方误差出发求最优速度。先计算 m_t, q_t, c_t ，再构造与 X_t 不相关的高斯残差，逐步推出式(13)。若去掉联合高斯条件，不相关是否足以推出条件残差均值为零？构造一个反例。
- 验证式(14)满足速度场 ODE，求其最终映射。比较 ODE 端点对的协方差与训练端点对的协方差，并解释两者为何可以具有相同边缘分布。
- 令 $m_0 = m_1 = 0, s_0 = s_1 = 1$ 。分析 $t = 0, 1/2, 1$ 的方差和速度。说明由相同的起止分布能否唯一推断中间路径；给出另一条满足相同边界分布的路径。
- 实现 `gaussian_velocity`、`gaussian_flow` 和 `integrate_flow`。时间范围为 $[0, 1]$ ，标准差严格为正。固定 $x_0 = 1.3, m_0 = 0, m_1 = 2, s_0 = s_1 = 1$ ，比较 50 与 100 步 Euler 误差，再与中点法比较。用有限差分验证解析流的时间导数。报告误差与计算次数，不把结果推广到任意学习速度场。

习题解答

问题 1

(a) 对归一化分母使用商法则时, 每个指数导数多出 $1/\tau$, 因此 $\partial P_j / \partial S_k = P_j(1[j=k] - P_k)/\tau$ 。再应用链式法则, 得到 $D_k = P_k G^\top (V_k - Y)/\tau$ 。对 k 求和后, 两项分别为 $G^\top Y/\tau$ 和 $G^\top Y \sum_k P_k/\tau$, 二者相消。分数增加常数时, 分子与分母乘以同一个正数, 概率不变。

当 $\tau \rightarrow \infty$ 时, 每个允许位置的指数趋于 1, 概率趋于 $1/|I|$ 。当最大分数唯一且与其他分数的差至少为 $\Delta > 0$ 时, 非最大位置的概率为 $O(\exp(-\Delta/\tau))$ 。固定有限值向量且上游梯度有界时, 分数梯度也趋于零, 因为指数衰减快于 $1/\tau$ 的增长。若有并列最大值, 对单个原始分数的 Jacobian 元素可以随 $1/\tau$ 增大, 不能沿用唯一最大值的结论。

(b) 原例的值梯度为 $P^\top G = (1/4, 3/4)$ 。只允许第一个位置时, 概率不随分数改变, 因此分数梯度为零。此时上游梯度为 -2 , 值梯度为 $(-2, 0)$ 。若损失在该输出处的导数也为零, 则该行的值梯度相应为零。

(c) 答案查询通过 $P^\top G$ 向视觉值传递梯度。视觉位置没有直接监督标签不会自动删除这一计算路径。若该视觉位置被所有有监督查询遮蔽, 则其值分支在这一层的梯度为零; 其他层或其他损失的路径需要分别检查。

(d) 对允许位置减去最大分数, 计算指数和归一化; 其他位置返回精确的零。向量-Jacobian 乘积为 $P \odot (g - \sum_j P_j g_j)$ 。中心差分检验应使用有限 logits, 保持掩码固定, 并避免把微分一个离散掩码作为该测试的目标。测试还应检查全遮蔽输入按接口抛出异常。

(e) 设排列矩阵为 Π , 使用 $K' = \Pi K$ 、 $V' = \Pi V$ 并同样排列掩码列。则 $S' = S \Pi^\top$, 逐行归一化给出 $P' = P \Pi \Pi^\top$, 所以 $P' V' = P \Pi \Pi^\top \Pi V = P V$ 。只重排值时, 例题的输出从 2 变为 0, 因为权重仍为 $(1/4, 3/4)$, 值变为 $(3, -1)$ 。第一个测试检查一致的轴重排, 第二个测试检查分数与值的对应关系。

问题 2

(a) 条件误差的交叉项为零, 最优预测等于条件均值。利用独立性得到 $q_t = (1-t)^2 s_0^2 + t^2 s_1^2$ 和 $c_t = t s_1^2 - (1-t) s_0^2$ 。残差 $R = U - (m_1 - m_0) - (c_t/q_t)(X_t - m_t)$ 与 X_t 的协方差为零。两者联合高斯, 故条件残差均值, 得到所需速度。

反例可取 X 在 $\{-1, 0, 1\}$ 上等概率分布, $R = X^2 - 2/3$ 。由对称性, $\mathbb{E}[R] = 0$ 且 $\text{Cov}(R, X) = \mathbb{E}[X^3] - (2/3)\mathbb{E}[X] = 0$; 但是 $\mathbb{E}[R | X] = X^2 - 2/3$, 在三个取值处均不等于零。因此, 推导中的联合高斯条件承担了从不相关到独立的关键步骤。

(b) $q'_t = 2c_t$ 给出 $s'_t = c_t/s_t$ 。对仿射映射求导即可得到 $v(t, \Phi_t)$ 。最终映射为 $m_1 + (s_1/s_0)(x_0 - m_0)$, 其与初值的协方差为 $s_0 s_1$; 独立训练端点的协方差为零。边缘分布只规定单个时刻的分布, 不唯一确定两个时刻的联合分布。

(c) 三个时刻的方差分别为 $1, 1/2, 1$; 速度分别为 $-x, 0, x$ 。另一条路径可令 $X_t = X_0$, 始终保持标准高斯, 速度恒为零。它满足相同端点分布, 采用不同的中间分布和端点构造。

(d) 使用解析末点 3.3，分别计算离散解的绝对误差。固定步数时，中点法每步计算两次速度，Euler 法计算一次。报告应同时列方法、步数、速度求值次数和误差。有限差分在内部时刻比较解析流导数与速度场；端点使用单边差分或只检查初末值。测试结果仅适用于本题明确的光滑高斯速度场。

固定参数的标量计算结果如下。此表只比较本题设置，不构成方法一般收敛阶数的证明。

方法	步数	速度求值次数	末点绝对误差
Euler	50	50	0.03299895
Euler	100	100	0.01660381
中点法	50	100	0.00000145
中点法	100	200	0.00000018