

有限轨迹的广义优势估计

1 有限轨迹上的回报估计

设采样缓冲区从时刻 t 起包含 $m \geq 1$ 个连续转移。奖励为 $r_t, \dots, r_{t+m-1}$ ，价值估计为 $V_t, \dots, V_{t+m}$ 。本节首先假设这段数据没有跨越环境重置；终止与时间截断在下一节处理。折扣因子和混合参数满足 $0 \leq \gamma, \lambda \leq 1$ 。

n 步目标包含已经观测到的奖励，以及第 n 步后的价值估计。减去当前价值，得到优势估计

$$A_t^{(n)} = \sum_{j=0}^{n-1} \gamma^j r_{t+j} + \gamma^n V_{t+n} - V_t, \quad 1 \leq n \leq m. \quad (1)$$

这个表达式的边界价值只出现一次。为了得到可以高效递推的形式，定义 TD 残差 $\delta_k = r_k + \gamma V_{k+1} - V_k$ ，并展开两个相邻残差：

$$\begin{aligned} \delta_t + \gamma \delta_{t+1} &= r_t + \gamma V_{t+1} - V_t + \gamma r_{t+1} + \gamma^2 V_{t+2} - \gamma V_{t+1} \\ &= r_t + \gamma r_{t+1} + \gamma^2 V_{t+2} - V_t. \end{aligned} \quad (2)$$

中间的 V_{t+1} 项相消。加入第 j 个残差时，会以同样方式消去上一项的边界价值。对 n 归纳可得

$$A_t^{(n)} = \sum_{j=0}^{n-1} \gamma^j \delta_{t+j}. \quad (3)$$

1.1 有限混合权重

为了组合不同长度的目标，对前 $m-1$ 个目标使用几何权重，将剩余权重赋给最长目标：

$$A_t^{(\lambda, m)} = (1 - \lambda) \sum_{n=1}^{m-1} \lambda^{n-1} A_t^{(n)} + \lambda^{m-1} A_t^{(m)}. \quad (4)$$

当 $0 \leq \lambda < 1$ 时，有限几何和给出

$$\begin{aligned} (1 - \lambda) \sum_{n=1}^{m-1} \lambda^{n-1} + \lambda^{m-1} &= (1 - \lambda) \frac{1 - \lambda^{m-1}}{1 - \lambda} + \lambda^{m-1} \\ &= 1 - \lambda^{m-1} + \lambda^{m-1} = 1. \end{aligned} \quad (5)$$

当 $\lambda = 1$ 时，式(4)直接将全部权重赋给最长目标，不需要使用分母为零的几何和表达式。

代入式(3)后，残差 $\gamma^j \delta_{t+j}$ 出现在所有 $n \geq j+1$ 的目标中。先取 $0 \leq \lambda < 1$ 。对于 $0 \leq j \leq m-2$ ，其权重为

$$\begin{aligned} w_j &= (1 - \lambda) \sum_{n=j+1}^{m-1} \lambda^{n-1} + \lambda^{m-1} \\ &= (1 - \lambda) \lambda^j \frac{1 - \lambda^{m-1-j}}{1 - \lambda} + \lambda^{m-1} \\ &= \lambda^j - \lambda^{m-1} + \lambda^{m-1} = \lambda^j. \end{aligned} \quad (6)$$

最后一个残差只出现在最长目标中，系数为 $w_{m-1} = \lambda^{m-1}$ 。当 $\lambda = 1$ 时，直接检查最长目标可知每个残差的混合权重为一，与 $w_j = \lambda^j$ 一致。由此得到广义优势估计（generalized advantage estimation, GAE）的有限残差形式和后向递推：

$$\begin{aligned} A_t^{(\lambda, m)} &= \sum_{j=0}^{m-1} (\gamma\lambda)^j \delta_{t+j} \\ &= \delta_t + \gamma\lambda \sum_{j=0}^{m-2} (\gamma\lambda)^j \delta_{t+1+j} \\ &= \delta_t + \gamma\lambda A_{t+1}^{(\lambda, m-1)}. \end{aligned} \quad (7)$$

定义缓冲区外的尾项 $A_{t+m}^{(\lambda, 0)} = 0$ 。 $m = 1$ 时只有一个 TD 残差； $\lambda = 0$ 时采用一步估计； $\lambda = 1$ 时采用最长可用目标。这些结论均可直接从有限表达式检验。

2 边界条件与实现

环境真正终止后没有未来回报。外部时间截断只停止本次采样，原任务仍可具有后续价值。实现时因此需要分别控制自举项与残差递推。若时限属于任务定义，剩余时间需纳入状态，耗尽时可构成真正终止。

记 d_k 为真正终止标记， u_k 为外部截断标记。令 V_{k+1}^{final} 表示重置前真实后继观测的价值。定义

$$\begin{aligned} b_k &= 1 - d_k, & c_k &= 1 - (d_k \vee u_k), \\ \delta_k &= r_k + \gamma b_k V_{k+1}^{\text{final}} - V_k, & A_k &= \delta_k + \gamma \lambda c_k A_{k+1}. \end{aligned} \quad (8)$$

b_k 决定未来价值是否保留； c_k 决定当前残差是否能连接到缓冲区下一项。时间截断时， $b_k = 1$ 且 $c_k = 0$ 。在自动重置环境中，重置后的初始观测属于下一条轨迹，不能代替 V_{k+1}^{final} 。




图 1：时间截断保留真实后继价值，优势递推在重置前结束。

例题：真正终止与时间截断

取 $\gamma = 0.9, \lambda = 0.8$ ，奖励为 $(1, 2, 3)$ ，当前价值为 $(0.5, 0.4, 0.2)$ ，最后一步真正终止。TD 残差依次为 $(0.86, 1.78, 2.8)$ 。使用 $\gamma\lambda = 0.72$ ，有

$$\begin{aligned} A_2 &= 2.8, \\ A_1 &= 1.78 + 0.72 \times 2.8 = 3.796, \\ A_0 &= 0.86 + 0.72 \times 3.796 = 3.59312. \end{aligned} \quad (9)$$

价值目标为 $A + V = (4.09312, 4.196, 3)$ 。若末步改为时间截断且真实后继价值为 5，末步残差变为 7.3。此时 $A_1 = 7.036$ ， $A_0 = 5.92592$ ，递推仍不跨越重置。

3 综合习题

问题 1：有限目标、边界与误差传播

沿用本章有限轨迹设定。实现中只缓存奖励、当前价值、真实后继价值和两种边界标记。

- 从式(1)出发推导有限混合目标。解释为何直接截断无限几何混合会缺少权重，并检查 $m = 1$ 与 $\lambda = 1$ 。
- 对例题计算 $\lambda = 0$ 和 $\lambda = 1$ 时的首步优势。说明两个值分别对应什么目标。
- 在时刻 k 发生时间截断，错误使用重置观测使后继价值增加 Δ 。假设此前 j 个转移没有边界，推导 A_{k-j} 的误差。分析 λ 对误差传播的影响。
- 实现 `compute_gae`。输入为五个长度相同的序列以及 γ, λ ；返回优势和价值目标。标记使用布尔值，数值输入有限，缓冲区长度大于零。价值输入在进入函数前已停止梯度。检验单步缓冲区、末步终止、时间截断、两段轨迹相邻及非法形状。
- 用有限混合公式独立验证后向实现。对一个固定轨迹改变 λ ，比较真实后继价值与错误重置价值产生的结果。说明这项测试能检验哪些实现性质，以及它尚未检验哪些训练性质。

习题解答

问题 1

- n 步优势等于前 n 个折扣 TD 残差之和。有限混合必须将权重 λ^{m-1} 赋给最长目标。若只保留 $(1-\lambda)\lambda^{n-1}$ 、 $n \leq m$ ，权重和为 $1-\lambda^m$ ，仍有 λ^m 未分配。当 $m = 1$ 时，唯一目标权重为一。当 $\lambda = 1$ 时，全部权重集中于 m 步目标。
- $\lambda = 0$ 时，首步优势为 $\delta_0 = 0.86$ 。 $\lambda = 1$ 时，完整折扣回报为 $1 + 0.9 \times 2 + 0.9^2 \times 3 = 5.23$ ，减去 $V_0 = 0.5$ 得到 4.73。两者分别对应一步自举目标和本条终止轨迹的完整回报目标。
- 时刻 k 的残差误差为 $\gamma\Delta$ 。此前每向一项，误差乘以 $\gamma\lambda$ ，所以第 $k-j$ 项误差为 $\gamma(\gamma\lambda)^j\Delta$ 。遇到先前的轨迹边界，传播由 $c = 0$ 中断。较小的 λ 减小这类远端误差的权重；这一结论只讨论固定价值误差的传播，不保证整体优势估计方差或训练回报单调改善。
- 从缓冲区末端开始令尾项为零。每步先根据真正终止标记计算自举，再根据两类标记控制递推。返回 A_k 与 $A_k + V_k$ 。测试需使用数值已知的例题和独立混合表达式。时间截断与真正终止的输入可具有相同形状，单靠形状检查无法区分它们的语义。
- 对每个起点单独计算全部 n 步目标，再按有限混合权重组合。将其与后向实现逐项比较，避免两种实现共用同一个递推函数。价值替换实验应符合 (c) 的解析误差。此测试覆盖有限混合、边界与误差传播；完整策略训练的稳定性与回报需要另外运行环境与更新循环。