

多模态学习 与强化学习


理论、架构与实现

视觉语言模型与多模态表征

扩散模型、流匹配与视频生成

策略优化、世界模型与生成式控制

高效训练、推理与实验方法



目录

第 1 章 张量计算与概率优化	1
1.1 张量语义、索引与线性变换	1
1.2 似然、交叉熵与条件期望	2
1.3 随机梯度估计与自动微分	4
1.4 连续时间马尔可夫过程与概率输运	6
1.5 课后习题	7
第 2 章 多模态对齐与条件生成	9
2.1 对比学习与图文表示	9
2.2 视觉条件、注意力与监督对齐	10
2.3 多样本打包、监督权重与视觉定位	13
2.4 实现要求与视觉依赖评估	14
2.5 课后习题	15
第 3 章 现代视觉语言模型架构	17
3.1 视觉编码与跨模态融合	17
3.2 动态分辨率、空间合并与 token 预算	19
3.3 时空位置编码与多层视觉注入	21
3.4 混合注意力、循环状态与稀疏专家	22
3.5 统一理解与生成的序列接口	24
3.6 训练目标、数据组合与实现要求	25
3.7 课后习题	26
第 4 章 扩散模型与流匹配	28
4.1 潜变量模型与变分推断	28
4.2 离散时间高斯扩散与噪声预测	29
4.3 得分函数、随机微分方程与流匹配	32
4.4 数值积分、条件引导与潜空间架构	35
4.5 流映射与少步生成	37
4.6 离散状态扩散与掩码生成	38
4.7 课后习题	40
第 5 章 视频生成与自回归建模	42
5.1 视频表示、时间压缩与生成条件	42
5.2 视频块、注意力结构与时间因果性	43
5.3 自回归训练与 Self Forcing	45
5.4 条件依赖与视频评估	46
5.5 课后习题	47
第 6 章 多模态自监督学习与预测表征	49
6.1 对比目标、二元匹配与数据增强	49
6.2 掩码重建、目标编码器与表征退化	50

6.3	密集表征与 Gram 矩阵约束	51
6.4	预测表征与 V-JEPA 2	53
6.5	多层视频自监督与局部监督权重	54
6.6	表征评价、状态信息与实验要求	55
6.7	课后习题	56
第 7 章	策略梯度与近端策略优化	58
7.1	马尔可夫决策过程与策略梯度	58
7.2	Bellman 方程、时序差分与优势估计	60
7.3	重要性采样与 PPO 目标	63
7.4	训练循环、统计量与实现检查	64
7.5	课后习题	66
第 8 章	值函数方法与离线强化学习	67
8.1	Q-learning、目标网络与 Double DQN	67
8.2	最大熵强化学习与 SAC	69
8.3	模仿学习、分布偏移与数据聚合	71
8.4	离线数据、IQL 与保守价值估计	72
8.5	数据复用与评估协议	75
8.6	课后习题	76
第 9 章	语言模型后训练	78
9.1	序列概率、动作定义与奖励	78
9.2	GRPO、组内优势与 KL 正则化	79
9.3	偏好模型与直接偏好优化	82
9.4	奖励有效性与后训练评估	84
9.5	课后习题	85
第 10 章	世界模型与模型预测控制	87
10.1	动作条件动力学与多步误差	87
10.2	模型预测控制与交叉熵方法	88
10.3	RSSM 与潜空间策略学习	90
10.4	目标条件强化学习与 Hindsight Relabeling	93
10.5	课后习题	95
第 11 章	生成式策略与视觉语言动作模型	96
11.1	动作条件分布与多模态模仿学习	96
11.2	动作扩散与条件流匹配	97
11.3	离散动作编码与联合监督	98
11.4	优势条件策略与经验数据	99
11.5	视频、动作与联合生成模型	101
11.6	执行延迟、动作块衔接与闭环评估	101
11.7	课后习题	103
第 12 章	高效训练、长上下文与推理系统	105
12.1	Transformer 模块与数值尺度	105
12.2	分块 softmax 与精确注意力	106

12.3 GQA、KV cache 与长上下文	107
12.4 推测解码与目标分布保持	108
12.5 低秩适配、混合精度与激活重计算	109
12.6 梯度累积与分布式归约	111
12.7 计算预算、规模定律与性能测量	112
12.8 课后习题	113
第 13 章 实验设计与实现规范	114
13.1 数据划分、统计单位与不确定性	114
13.2 实现接口、梯度检查与数值测试	116
13.3 综合实验与交互任务	117
13.4 自我修正、候选选择与评价器误差	118
13.5 实验交付与结果报告	120
13.6 课后习题	121
附录 A 习题解答与实验判据	122
A.1 张量计算与概率优化	122
A.2 多模态对齐与条件生成	123
A.3 现代视觉语言模型架构	125
A.4 扩散模型与流匹配	126
A.5 视频生成与自回归建模	128
A.6 多模态自监督学习与预测表征	129
A.7 策略梯度与近端策略优化	130
A.8 值函数方法与离线强化学习	132
A.9 语言模型后训练	133
A.10 世界模型与模型预测控制	134
A.11 生成式策略与视觉语言动作模型	136
A.12 高效训练、长上下文与推理系统	137
A.13 实验设计与实现规范	138
附录 B 核心函数参考实现	140
B.1 策略梯度与动作价值目标	140
B.2 SAC 的概率密度与参数更新	141
B.3 生成目标、数值积分与视频分块	143
B.4 语言后训练与模型预测控制	145
B.5 视觉语言架构、预测表征与高效计算	147
B.6 解析流、离散后验与采样校正	153
B.7 测试协议	155
附录 C 公式索引与符号表	156
C.1 公式索引	156
C.2 符号与数值约定	157
参考文献	158

第 1 章 张量计算与概率优化

张量索引与概率目标共同确定训练算法的实现。本章建立广播、梯度、条件期望和概率输运的计算约定，为多模态网络、生成模型及策略优化提供统一的数学基础。

1.1 张量语义、索引与线性变换

张量的形状、数据类型和数值含义共同确定一个计算接口。例如，形状为 $B \times C \times H \times W$ 的浮点张量可以表示像素、标准化图像或潜变量；三者的数值范围与处理方式不同。整数 token ID、布尔掩码和连续特征应分别定义。对每个函数，需要记录输入与输出的形状、轴顺序、值域、广播规则以及梯度需求。

下文以 B 表示批量大小， L 表示 token 序列长度， F 表示视频帧数， d 表示特征维数， h 表示注意力头数， T 表示环境轨迹长度。环境时间记为 t ，连续生成时间记为 τ 。扩散步使用离散索引 k ；涉及端点方向时，另行给出约定。

对象	类型与形状	元素含义
视觉特征 Z_v	浮点, $B \times N_v \times d_v$	指定样本、视觉位置和通道的特征值。
logits U	浮点, $B \times L \times K$	指定位置对词表项的未归一化分数。
标签 Y	整数, $B \times L$	词表 ID；忽略位置使用约定的标记。
监督掩码 M	布尔, $B \times L$	该位置是否参与损失求和。
动作 a	整数或连续向量	由环境动作空间及坐标系定义。

设 $X \in \mathbb{R}^{m \times k}$ 、 $W \in \mathbb{R}^{k \times n}$ ，矩阵乘法为

$$Y_{ij} = \sum_{r=1}^k X_{ir} W_{rj}, \quad Y = XW \in \mathbb{R}^{m \times n}. \quad (1.1)$$

求和消去索引 r ，保留索引 i, j 。在批量序列上应用线性层时，前导轴保持不变：

$$Y_{btj} = \sum_{r=1}^{d_{\text{in}}} X_{btr} W_{rj} + b_j, \quad (B, L, d_{\text{in}}) \longrightarrow (B, L, d_{\text{out}}). \quad (1.2)$$

偏置沿批量轴和序列轴广播，故偏置梯度应沿这两个轴求和。令 $G = \partial \mathcal{L} / \partial Y$ ，则先把上游梯度与局部导数分开。用 β 表示样本索引，避免与偏置 b_j 混淆。固定一个输入元素 $X_{\beta tr}$ ，只有同一样本、同一位置的输出依赖它。因此


$$\frac{\partial Y_{\beta' t' j}}{\partial X_{\beta tr}} = \mathbf{1}[\beta' = \beta] \mathbf{1}[t' = t] W_{rj},$$

$$\frac{\partial \mathcal{L}}{\partial X_{\beta tr}} = \sum_{\beta', t', j} G_{\beta' t' j} \frac{\partial Y_{\beta' t' j}}{\partial X_{\beta tr}} = \sum_j G_{\beta t j} W_{rj}.$$

另一方面，同一个参数 W_{rj} 在所有样本和位置上复用，故其导数需要累加这些位置的贡献。偏置具有相同的复用范围。将样本索引仍写作 b ，三个结果为

$$\frac{\partial \mathcal{L}}{\partial X_{btr}} = \sum_j G_{btj} W_{rj}, \quad \frac{\partial \mathcal{L}}{\partial W_{rj}} = \sum_{b,t} X_{btr} G_{btj}, \quad \frac{\partial \mathcal{L}}{\partial b_j} = \sum_{b,t} G_{btj}. \quad (1.3)$$

$$Y = XW, \quad Y_{ij} = \sum_{k=1}^{d_{\text{in}}} X_{ik} W_{kj}$$



维度 行轴 m 保留； d_{in} 为收缩轴；输出列轴为 d_{out} 。

运算 输入的一行与权重的一列内积得到一个输出元素。格数用于显示轴结构。

图 1.1 线性变换的收缩维度。相同符号对应相同边长，输入行轴在输出中保留。

形状变换与索引操作 `reshape` 改变同一线性元素序列的分组方式；`permute` 改变轴顺序。交换矩阵行列必须执行转置。`gather` 根据整数索引读取元素，输出值的类型与被读取张量一致。以动作选择为例， $I_b \in \{0, \dots, K-1\}$ 与 $Q \in \mathbb{R}^{B \times K}$ 定义 $v_b = Q_{b, I_b}$ 。索引 I 、分数 Q 和输出 v 应分别保留，避免将地址运算误写为数值乘法。

例题 1.1 广播与梯度求和

令 X 的形状为 $(2, 3, 4)$ ， W 的形状为 $(4, 5)$ ， $Y = XW + b$ ，损失为 $\mathcal{L} = \sum_{b,t,j} Y_{btj}$ 。求 Y 的形状与偏置梯度。

解 输出形状为 $(2, 3, 5)$ 。每个 b_j 在 $2 \cdot 3 = 6$ 个位置复用，且所有 $G_{btj} = 1$ ，因此 $\partial \mathcal{L} / \partial b_j = 6$ 。若改用所有输出元素的平均值，则梯度为 $6 / (2 \cdot 3 \cdot 5) = 1/5$ 。损失归约方式直接影响梯度尺度。

1.2 似然、交叉熵与条件期望

对分类 logits $u \in \mathbb{R}^K$ ，定义

$$p_k = \frac{e^{u_k}}{\sum_j e^{u_j}}, \quad \log p_y = u_y - \log \text{sumexp}_j u_j. \quad (1.4)$$

令 $m = \max_j u_j$, 有

$$\text{logsumexp}_j u_j = m + \log \sum_j e^{u_j - m}. \quad (1.5)$$

该恒等变换减少指数溢出。对整行 logits 加相同常数不会改变概率。接着对负对数似然 $\ell = -\log p_y$ 求导, 先分别处理标签分数与归一化项:

$$\begin{aligned} \ell(u, y) &= -u_y + \log \left(\sum_j e^{u_j} \right), \\ \frac{\partial \ell}{\partial u_k} &= -\mathbf{1}[k = y] + \frac{1}{\sum_j e^{u_j}} \frac{\partial}{\partial u_k} \sum_j e^{u_j} = -\mathbf{1}[k = y] + \frac{e^{u_k}}{\sum_j e^{u_j}}. \end{aligned}$$

因此

$$\frac{\partial \ell}{\partial u_k} = p_k - \mathbf{1}[k = y]. \quad (1.6)$$

单个标签只影响指示函数, 归一化项则使所有类别共同参与梯度。对序列, 概率链式分解给出

$$\log p(y_{1:L} | x) = \sum_{t=1}^L \log p(y_t | x, y_{<t}). \quad (1.7)$$

因此序列对数概率通过 token 对数概率求和得到。除以序列长度会改变训练样本的权重。

从 softmax Jacobian 到交叉熵 Hessian 逐项使用商法则, 得到

$$\frac{\partial p_j}{\partial u_k} = \frac{\delta_{jk} e^{u_j} \sum_i e^{u_i} - e^{u_j} e^{u_k}}{(\sum_i e^{u_i})^2} = p_j (\delta_{jk} - p_k), \quad (1.8)$$

$$J_p = \text{diag}(p) - pp^\top, \quad \nabla^2 \ell = J_p. \quad (1.9)$$

对任意向量 a , $a^\top J_p a = \sum_j p_j a_j^2 - (\sum_j p_j a_j)^2 \geq 0$, 因为右侧是分类分布下的方差。因此交叉熵对 logits 为凸函数; 网络参数化后的目标一般没有相同凸性。 $J_p \mathbf{1} = 0$ 表明沿共同平移方向曲率为零。

设真实分类分布为 q , 预测为 p , 则

$$-\sum_j q_j \log p_j = -\sum_j q_j \log q_j + \text{KL}(q \| p). \quad (1.10)$$

固定 q 时, 最小化交叉熵等价于最小化该方向的 KL。要求 $q_j > 0$ 的位置也有 $p_j > 0$, 否则 KL 为无穷大。此支持条件将在重要性采样、SAC 与 DPO 中重复出现。

例题 1.2 两个类别的曲率

设 $p = (1/4, 3/4)$ 。求 J_p 的特征值并解释零特征值。

解 $J_p = \frac{3}{16} \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}$, 特征值为 0 与 3/8。零特征向量为 $(1, 1)$, 对应同时平移两个 logits; 概率保持不变。

平方误差的最优预测 设随机向量 U 具有有限二阶矩，预测器仅能使用 X 。记 $\mu(X) = \mathbb{E}[U | X]$ ，展开

$$\begin{aligned} \mathbb{E}\|f(X) - U\|^2 &= \mathbb{E}\|f(X) - \mu(X)\|^2 + \mathbb{E}\|U - \mu(X)\|^2 \\ &\quad - 2\mathbb{E}\langle f(X) - \mu(X), U - \mu(X) \rangle. \end{aligned} \quad (1.11)$$

交叉项可通过迭代期望逐步化简：

$$\mathbb{E}\langle f(X) - \mu(X), U - \mu(X) \rangle = \mathbb{E}[\langle f(X) - \mu(X), \mathbb{E}[U - \mu(X) | X] \rangle] = 0.$$

最后一个等号使用条件均值的定义。剩余第二项与预测器无关，因而

$$\arg \min_f \mathbb{E}\|f(X) - U\|^2 = \mathbb{E}[U | X]. \quad (1.12)$$

价值回归中的目标为回报，扩散模型中的目标为噪声，条件流匹配中的目标为条件速度。三类目标均满足这一条件期望结构。无法从输入确定的随机性形成不可约误差。生成模型可通过随机初始条件生成不同样本；局部噪声或速度的均方误差目标不要求所有生成终点相同。

例题 1.3 信息缺失与最小均方误差

在固定输入 $X = x$ 下，目标 U 以相同概率取 -2 和 2 。求最优确定性预测及其最小损失。

解

$$\mathbb{E}[(f - U)^2 | X = x] = \frac{1}{2}(f + 2)^2 + \frac{1}{2}(f - 2)^2 = f^2 + 4.$$

最优值为 $f^* = 0$ ，最小损失为 4。若增加条件 $C \in \{-1, 1\}$ ，并且 $U = 2C$ ，则 $\mathbb{E}[U | X, C] = 2C$ ，条件预测的最小损失降为零。该例区分了模型容量不足与输入信息不足；实际实验需分别检验这两种情况。

1.3 随机梯度估计与自动微分

对确定性计算图，反向传播按链式法则累加各条依赖路径；参数在图中复用多少次，就需要累加多少次贡献。随机节点还改变取期望所用的分布，因此不能只检查固定样本上的局部导数。以下两种估计处理的正是这一分布变化。自动微分与序列模型的这种分工，也是 CMU 2026 生成式模型课程的起点。[4] 设 $z \sim p_\theta$ ，函数 $f(z)$ 不显含 θ 。在支持集与参数无关、积分与微分可交换等条件下，

$$\begin{aligned} \nabla_\theta \mathbb{E}_{p_\theta}[f(z)] &= \int f(z) \nabla_\theta p_\theta(z) dz \\ &= \mathbb{E}_{p_\theta}[f(z) \nabla_\theta \log p_\theta(z)]. \end{aligned} \quad (1.13)$$

这是似然比梯度估计，也称 score-function 梯度估计。它适用于离散动作和 token，无须对 f 关于采样结果求导。若 $f = f_\theta$ ，还须加入 $\mathbb{E}[\nabla_\theta f_\theta]$ 。

若 $z = g_\theta(\epsilon)$ 、 $\epsilon \sim p(\epsilon)$ ，且 f 与 g 可微，则有重参数化梯度

$$\nabla_\theta \mathbb{E}_\epsilon[f(g_\theta(\epsilon))] = \mathbb{E}_\epsilon \left[\left(\frac{\partial g_\theta}{\partial \theta} \right)^\top \nabla_z f \right]. \quad (1.14)$$

高斯采样可写成 $z = \mu_\theta + \sigma_\theta \odot \epsilon$ 。VAE 和连续动作 SAC 都使用这种形式。PyTorch 的 `rsample` 在支持重参数化的分布上保留相应梯度路径，普通 `sample` 通常不保留这一路径。[43]

停止梯度算子 $\text{sg}(x)$ 的前向值为 x ，反向导数按零处理。对

$$\mathcal{L}(\theta) = \frac{1}{2} [f_\theta(x) - \text{sg}(y_\theta)]^2 \quad (1.15)$$

自动微分得到 $(f_\theta - y_\theta) \nabla f_\theta$ ；若目标保留梯度，则导数为 $(f_\theta - y_\theta)(\nabla f_\theta - \nabla y_\theta)$ 。TD 更新通常采用前者的半梯度。冻结网络参数仍允许损失对网络输入求导；在 `no_grad` 中执行整个前向会停止该运算的图记录。`eval()` 控制 dropout、批归一化等模块的模式，梯度记录需单独控制。[42]

例题 1.4 参数冻结与输入梯度

令 $f_w(x) = wx$ ， $w = 3$ 固定，输入 $x = \phi^2$ ，损失为 $\mathcal{L} = \frac{1}{2}(f_w(x) - 6)^2$ 。求 $\partial \mathcal{L} / \partial \phi$ 。

解 链式法则给出

$$\frac{\partial \mathcal{L}}{\partial \phi} = (3\phi^2 - 6) \cdot 3 \cdot 2\phi.$$

冻结 w 不影响此导数。在 f_w 的前向外使用 `no_grad` 会使通过 x 的梯度不可用。 $\phi = 1$ 时正确梯度为 -18 ，可直接用作单元测试。

随机计算图中的两项梯度 当 $J(\theta) = \mathbb{E}_{z \sim p_\theta}[f_\theta(z)]$ 时，乘积法则给出

$$\nabla J = \mathbb{E}[f_\theta(z) \nabla \log p_\theta(z)] + \mathbb{E}[\nabla f_\theta(z)]. \quad (1.16)$$

固定采样结果后直接自动微分只得到第二项。用完整离散分布显式求和，可以为 score-function 实现建立精确对照。用重参数化实现时，第一项的分布变化可经样本路径表达，不应再无条件加上一份相同的似然比梯度。

例如 $z \sim \mathcal{N}(\mu, 1)$ ，目标为 z^2 。路径梯度为 $2z$ ，其期望为 2μ 、方差为 4。似然比梯度为 $z^2(z - \mu)$ 。令 $z = \mu + \epsilon$ ，利用高斯奇数矩为零、 $\mathbb{E}\epsilon^2 = 1$ 、 $\mathbb{E}\epsilon^4 = 3$ 、 $\mathbb{E}\epsilon^6 = 15$ ，可以逐项计算。写 $G = \mu^2\epsilon + 2\mu\epsilon^2 + \epsilon^3$ ，则

$$\mathbb{E}G = 2\mu,$$

$$\mathbb{E}G^2 = \mu^4\mathbb{E}\epsilon^2 + 6\mu^2\mathbb{E}\epsilon^4 + \mathbb{E}\epsilon^6 = \mu^4 + 18\mu^2 + 15,$$

$$\text{Var}(G) = \mathbb{E}G^2 - (\mathbb{E}G)^2 = \mu^4 + 14\mu^2 + 15.$$

两种估计均可无偏，但随机误差不同；实际目标不满足可微条件时，路径估计可能不可用。

1.4 连续时间马尔可夫过程与概率输运

离散时间马尔可夫链、扩散过程和确定性流可以使用同一组概率守恒方程描述。本节以 t 作为连续过程的局部时间变量。设连续状态随机过程 $X_t \in \mathbb{R}^d$ 满足 Itô 随机微分方程

$$dX_t = f(X_t, t) dt + g(t) dW_t, \quad (1.17)$$

其中 f 为漂移项, g 为扩散系数, W_t 为标准 Wiener 过程。对任意足够光滑且紧支撑的测试函数 φ , Itô 公式给出

$$d\varphi(X_t) = \nabla \varphi(X_t)^\top dX_t + \frac{1}{2} \text{tr}[g(t)^2 \nabla^2 \varphi(X_t)] dt, \quad (1.18)$$

$$\frac{d}{dt} \mathbb{E}[\varphi(X_t)] = \mathbb{E} \left[f(X_t, t)^\top \nabla \varphi(X_t) + \frac{1}{2} g(t)^2 \Delta \varphi(X_t) \right]. \quad (1.19)$$

这里 $g(t)$ 为标量, 噪声在各坐标上独立同分布。Itô 公式中的二阶项来自二次变差 $dW_i dW_j = \mathbf{1}[i = j]dt$; 随机积分在适当可积性条件下的期望为零。

设 p_t 存在且可微。将期望改写成积分后, 左边为 $\int \varphi \partial_t p_t dx$ 。右边的漂移项对每个坐标分部积分一次:

$$\int f_i p_t \partial_i \varphi dx = - \int \varphi \partial_i (f_i p_t) dx.$$

扩散项需要两次分部积分, 两个负号相消:

$$\int p_t \partial_{ii} \varphi dx = - \int (\partial_i p_t) (\partial_i \varphi) dx = \int \varphi \partial_{ii} p_t dx.$$

紧支撑测试函数, 或使边界通量消失的边界条件, 保证这里没有额外边界项。汇总各坐标后得到

$$\int \varphi [\partial_t p_t + \nabla \cdot (f p_t) - \frac{1}{2} g^2 \Delta p_t] dx = 0.$$

该式对所有这样的 φ 成立, 因而括号内的量在弱意义下为零。这就得到 Fokker-Planck 方程

$$\partial_t p_t(x) = -\nabla \cdot (f(x, t) p_t(x)) + \frac{1}{2} g(t)^2 \Delta p_t(x). \quad (1.20)$$

第一项描述漂移引起的概率质量输运, 第二项描述扩散引起的密度平滑。令 $g(t) = 0$, 式(1.20)退化为连续性方程

$$\partial_t p_t(x) + \nabla \cdot (p_t(x) v_t(x)) = 0, \quad (1.21)$$

流匹配中的速度场以此约束边缘密度。第4章将把扩散项改写为额外的输运项, 由此得到概率流常微分方程, 并明确它与反向随机微分方程的时间约定。

例题 1.5 一维 Ornstein–Uhlenbeck 过程的均值与方差

考虑 $dX_t = -\beta X_t dt + \sigma dW_t$, 且 $X_0 = x_0$ 为常数。求 $m_t = \mathbb{E}[X_t]$ 与 $s_t^2 = \text{Var}(X_t)$ 。

解 对 $\varphi(x) = x$ 使用式(1.19), 有 $\dot{m}_t = -\beta m_t$, 因此

$$m_t = x_0 e^{-\beta t}.$$

对 $\varphi(x) = x^2$, $\nabla\varphi = 2x$ 、 $\Delta\varphi = 2$, 于是

$$\frac{d}{dt}\mathbb{E}[X_t^2] = -2\beta\mathbb{E}[X_t^2] + \sigma^2.$$

记 $q_t = \mathbb{E}[X_t^2]$ 。在 $\beta \neq 0$ 时乘以积分因子 $e^{2\beta t}$, 再从 0 积分至 t :

$$\begin{aligned}\frac{d}{dt}(e^{2\beta t} q_t) &= \sigma^2 e^{2\beta t}, \\ e^{2\beta t} q_t - x_0^2 &= \sigma^2 \int_0^t e^{2\beta u} du = \frac{\sigma^2}{2\beta} (e^{2\beta t} - 1).\end{aligned}$$

因此 $q_t = x_0^2 e^{-2\beta t} + \sigma^2(1 - e^{-2\beta t})/(2\beta)$ 。减去 m_t^2 得

$$s_t^2 = \frac{\sigma^2}{2\beta} (1 - e^{-2\beta t}).$$

当 $\beta \rightarrow 0$ 时, 利用 $1 - e^{-2\beta t} = 2\beta t + O(\beta^2)$, 得到 $s_t^2 \rightarrow \sigma^2 t$, 与 Brownian 运动相符。当 $\beta > 0$ 且 $t \rightarrow \infty$ 时, 边缘分布收敛到 $\mathcal{N}(0, \sigma^2/(2\beta))$ 。该例给出漂移收缩与扩散注入方差的定量关系。

1.5 课后习题

习题 1.1 带掩码分类器的梯度与可辨识性

设 $X \in \mathbb{R}^{B \times T \times d}$, $W \in \mathbb{R}^{d \times C}$, $U = XW + b$ 。每个位置有目标概率 $q_{bt} \in \mathbb{R}^C$ 和固定掩码 $m_{bt} \in \{0, 1\}$ 。对有效位置, $\sum_c q_{btc} = 1$ 。损失为有效位置上的平均交叉熵。

- 写出损失及其对 U, W, b, X 的梯度。先对单个位置求导, 再显式写出批次与时间轴上的归约。说明分母为零时接口应如何处理。
- 从 softmax 的商法则推导 logits Hessian。证明其半正定, 并求全一向量对应的特征值。由此说明 logits 的共同平移为何不可辨识。
- 把单个位置的 logits 当作自由变量。当 q 的每个分量均为正时, 求全部最优 logits; 当 q 为 one-hot 时, 讨论有限最优解是否存在。解释 label smoothing 改变了什么。
- 两微批次分别有 1 个与 3 个有效位置, 逐位置参数梯度分别为 2 与 (6, 6, 6)。计算全批次梯度与直接平均两个微批次均值的结果, 推导一般的累积权重。
- 编程: 实现 `masked_linear_ce_backward`, 手动计算四类梯度。与 float64 自动微分比较; 覆盖软标签、全部无效位置和 logits 加同一大常数。用不同微批次切分验证参数更新一致。

习题 1.2 高斯期望的梯度估计与基线

令 $z = \mu + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, 1)$, 目标为 $J(\mu) = \mathbb{E}[z^2]$ 。比较对同一目标的两类随机梯度估计。

- (a) 直接求 J 与其导数, 再从密度微分推导 score-function 估计 G_s , 从变量替换推导重参数化估计 G_p 。列出交换求导与积分所需的可积性条件。
- (b) 使用标准高斯的二、四、六阶矩, 逐项计算两个估计量的均值与方差。比较 $\mu = 0$ 和大 $|\mu|$ 时的行为。
- (c) 在 G_s 中减去与本次采样无关的标量基线 b 。求方差最优的 b , 并与 $b = J(\mu)$ 比较。解释最优方差基线与期望损失通常不同的原因。
- (d) 编程: 固定同一组基础噪声, 计算三个基线设置和重参数化估计。再用共同噪声对 J 的样本均值做中心有限差分。分别报告样本误差与解析方差, 不把有限样本的排序当作恒等式。
- (e) 若用可训练的 $b_\psi(\mu)$ 实现基线, 说明 actor 梯度与基线拟合梯度应如何分离。构造直接对 $-\log p_\mu(z)(z^2 - b_\psi)$ 反向时未停止 z^2 或 b_ψ 梯度导致额外项的例子。

第 2 章 多模态对齐与条件生成

图文对齐与条件生成具有不同的输入组织和监督目标。本章从对比损失推导特征梯度，并分析多模态序列中的位置、注意力支持、监督掩码与训练数据处理。

2.1 对比学习与图文表示

CLIP 使用成对图像和文本学习全局表示。图像编码器与文本编码器分别输出单位向量 $v_i, t_j \in \mathbb{R}^d$ 。对批量中的 B 个配对样本，定义相似度 logits 与对称交叉熵：

$$S_{ij} = \frac{v_i^\top t_j}{\tau_c}, \quad \tau_c > 0, \quad (2.1)$$

$$\mathcal{L}_{\text{CLIP}} = -\frac{1}{2B} \sum_{i=1}^B \left[\log \frac{e^{S_{ii}}}{\sum_j e^{S_{ij}}} + \log \frac{e^{S_{ii}}}{\sum_j e^{S_{ji}}} \right]. \quad (2.2)$$

第一项对每张图像进行文本分类，第二项对每条文本进行图像分类。令 P^r 为沿行计算的 softmax， P^c 为沿列计算的 softmax，由式(1.6)可得

$$\frac{\partial \mathcal{L}_{\text{CLIP}}}{\partial S_{ij}} = \frac{P_{ij}^r + P_{ij}^c - 2\mathbf{1}[i=j]}{2B}. \quad (2.3)$$

对非配对项，该偏导为正；降低该项 logits 可降低损失。模型参数在所有样本之间共享，因此一次参数更新对每个相似度的净影响还取决于其他样本梯度。批内具有相同语义的样本可能形成假负例。温度减小会改变分类分布的集中程度和梯度尺度，其效果需结合样本分布评估。[11]

特征单位化后，导数还包含分母对输入的依赖。令 $r = \|z\|_2 > 0$ 、 $\hat{z} = z/r$ ，则

$$\begin{aligned} dr &= z^\top dz / r = \hat{z}^\top dz, \\ d\hat{z} &= \frac{dz}{r} - \frac{z}{r^2} dr = \frac{1}{r}(I - \hat{z}\hat{z}^\top)dz. \end{aligned}$$

因此

$$\frac{\partial v}{\partial z} = \frac{1}{\|z\|}(I - vv^\top), \quad z \neq 0. \quad (2.4)$$

其中 $I - vv^\top$ 将梯度投影到单位球面的切空间。特征模长与可学习的 logit scale 具有不同作用；增大未归一化特征模长不会直接增大余弦相似度。

例题 2.1 两对样本的 CLIP 损失

设 $B = 2$ ，相似度矩阵为 $S = \begin{bmatrix} a & b \\ b & a \end{bmatrix}$ 。求损失，并讨论 $a = b$ 与 $B = 1$ 的情况。

解 每个方向的正确分类概率均为 $e^a/(e^a + e^b)$ ，因此

$$\mathcal{L}_{\text{CLIP}} = \log(1 + e^{b-a}).$$

$a = b$ 时损失为 $\log 2$ ； $a - b$ 增大时损失减小。若只有一对样本，则两个 softmax 都只有一个元素，损失和梯度均为零。该结果由批内负例数量决定。

全局图文表示适合检索与分类。视觉问答、文档识别和局部定位还要求保留空间信息、处理可变长度输入，并生成条件化文本。视觉语言模型通常以局部视觉 token 为语言模型提供条件，优化下一 token 的似然。

温度、软标签与多个有效匹配 设 $S_{ij} = a \hat{u}_i^\top \hat{v}_j$ ，其中 $a = e^\eta = 1/\tau$ 。记整个对称目标对分数的导数为 G_{ij} 。沿温度参数的链式法则给出

$$\frac{\partial \mathcal{L}}{\partial \eta} = \sum_{i,j} \frac{\partial \mathcal{L}}{\partial S_{ij}} \frac{\partial S_{ij}}{\partial \eta} = \sum_{i,j} G_{ij} S_{ij}. \quad (2.5)$$

增大 a 会使分布更集中；它同时放大表示梯度的尺度。可分数据上的交叉熵未必具有有限的最优 a ，因此需要记录温度的参数化、约束及优化设置。

当同一图像有多条正确描述时，对角标签不再完整。固定图像 i ，令 q_{ij} 为正确描述上的目标分布，满足 $q_{ij} \geq 0$ 、 $\sum_j q_{ij} = 1$ 。行目标与梯度改为

$$\mathcal{L}_i = - \sum_j q_{ij} \log p_{ij}, \quad \frac{\partial \mathcal{L}_i}{\partial S_{ij}} = p_{ij} - q_{ij}.$$

该目标对各条正确描述分配指定权重。另一种集合似然 $-\log \sum_{j \in \mathcal{P}_i} p_{ij}$ 只要求概率总质量落入正样本集合；它允许所有质量集中到集合内的一条描述。选用哪种目标，取决于训练是否要求覆盖所有描述。两种目标不能仅通过把标签数量改为多个而相互替代。

2.2 视觉条件、注意力与监督对齐

记图像为 I ，视觉编码器为 E_v ，投影模块为 P_ϕ 。一条基本计算路径为

$$Z_v = E_v(I), \quad Z_\ell = P_\phi(Z_v), \quad p_\theta(y_t | I, x, y_{<t}) = \text{LM}_\theta(Z_\ell, x, y_{<t}). \quad (2.6)$$

其中 $Z_v \in \mathbb{R}^{B \times N_v \times d_v}$ 、 $Z_\ell \in \mathbb{R}^{B \times N_v \times d_\ell}$ 。两层投影可写为

$$P_\phi(Z_v) = \text{GELU}(Z_v W_1 + b_1) W_2 + b_2. \quad (2.7)$$

该映射只改变最后一维。视觉 patch 合并会改变 N_v ，应作为独立的重排与合并操作定义。视觉特征沿序列轴嵌入对话模板，具体位置由图像占位符确定。

$$H_v \in \mathbb{R}^{B \times N_v \times d_v} \mapsto Z_v \in \mathbb{R}^{B \times N_v \times d_l}$$



维度 B 为批次, N_v 为视觉 token 数, d_v, d_l 为视觉与语言隐藏维度。

运算 连接模块改变末维; 与文本嵌入拼接后, 统一送入语言模型。

图 2.1 视觉条件进入语言模型的基本路径。图中连接模块保留 N_v ; 具有额外合并操作的模型需另计 token 数。


注意力计算 对单个注意力头, 令 $Q \in \mathbb{R}^{L_q \times d_k}$ 、 $K \in \mathbb{R}^{L_k \times d_k}$ 、 $V \in \mathbb{R}^{L_k \times d_v}$, 则

$$A = \text{softmax}_{\text{key}} \left(\frac{QK^\top}{\sqrt{d_k}} + M_{\text{add}} \right), \quad O = AV. \quad (2.8)$$

A_{ij} 是查询位置 i 对键位置 j 的注意力权重。有效位置的加性掩码为 0, 禁止位置为 $-\infty$ 。每行至少应包含一个允许位置, 否则 softmax 可能产生未定义数值。若查询和键各分量独立、零均值、单位方差, 则内积方差为 d_k , 除以 $\sqrt{d_k}$ 可控制初始化时的尺度。[10]

多头注意力通常将 (B, L, hd_h) 重排为 (B, h, L, d_h) 。先分解最后一维, 再交换序列轴与头轴; 合并各头时执行逆序操作。自注意力取 $L_q = L_k$; 文本交叉注意力中, 查询可以来自视觉位置, 键和值来自文本位置, 输出保留视觉位置轴。

$$S = QK^\top / \sqrt{d_k} + M, \quad P = \text{softmax}_{\text{key}}(S), \quad O = PV$$



维度 省略批次与头轴。 T_q, T_k 分别为查询与键的位置数。

对象 S 为实数得分加支持掩码; P 为每行归一化的概率权重。

运算 第一处收缩 d_k , 第二处收缩 T_k ; softmax 沿键位置轴执行。

图 2.2 注意力的两次矩阵乘法。转置交换键矩阵的两个轴。

因果掩码与监督掩码 因果掩码规定各位置允许访问的上下文。监督掩码规定哪些目标 token 计入交叉熵。prompt 或视觉位置即使不承担直接预测损失，也可作为上下文影响答案损失。

设输入为 $u_0, \dots, u_{L-1}$ ，位置 j 的 logits 预测 u_{j+1} 。以 $y_j = u_{j+1}$ 为标签， m_j 表示该目标是否属于答案，则

$$\mathcal{L}_{\text{SFT}} = - \frac{\sum_{b,j} m_{bj} \log p_{\theta}(y_{bj} | u_{b,\leq j}, I_b)}{\sum_{b,j} m_{bj}}. \quad (2.9)$$

视觉 token、prompt 与 padding 通常不作为答案监督目标；答案与约定的 EOS 参与损失。多轮对话需要按消息角色构造掩码。标签位移仅执行一次，分母仅统计有效监督位置。

$$\mathcal{L} = - \frac{\sum_t m_t \log p(x_{t+1} | x_{\leq t})}{\sum_t m_t}$$

	BOS	图像	问题	回答起始	答案	EOS	PAD
预测目标	图像	问题	回答起始	答案	EOS	PAD	
损失掩码	0	0	0	1	1	0	

图 2.3 下一 token 对齐与回答损失掩码。提示位置可参与上下文计算；损失归约仅包括答案和 EOS 对应的预测。

例题 2.2 下一 token 对齐

输入位置依次为 BOS、图像、问题、回答起始标记、答案、EOS、PAD。仅监督答案与 EOS。确定有效 logits 位置。

解 回答起始标记位置预测答案，答案位置预测 EOS。按输入 logits 的位置编号，监督掩码为 (0, 0, 0, 1, 1, 0)。按原 token 位置保存的回答掩码须左移一位后与 logits 对齐。图像可以展开为多个视觉 token；这一展开只改变索引长度。

冻结参数与视觉梯度 仅训练投影模块时，

$$\nabla_{\phi} \mathcal{L} = \left(\frac{\partial P_{\phi}(Z_v)}{\partial \phi} \right)^{\top} \frac{\partial \mathcal{L}}{\partial Z_{\ell}}. \quad (2.10)$$

$\partial \mathcal{L} / \partial Z_{\ell}$ 依赖语言模型内部运算，因此冻结语言模型参数后仍需保留对其输入的梯度。冻结视觉编码器后可缓存 Z_v ；缓存同时固定视觉表示和相关预处理。改变随机裁剪或图像增强后，需重新检查缓存与标签的一致性。

Qwen3-VL 的长上下文与多模态接口 Qwen3-VL 技术报告给出的原生上下文长度达到 256K token，并统一处理文本、图像与视频交错输入。[12] 因而视觉 token 数量、视频时间位置与文本上下文预算需要共同进入序列长度计算。对长视频，视觉压缩策略不仅影响显存，还影响可供语言模型使用的时空分辨率。实现时应分别记录原始帧数、视觉编码后的 token 数、最终序列长度以及是否发生截断。

2.3 多样本打包、监督权重与视觉定位

变长多模态序列可放入同一个存储区以减少 padding。设每个 token 的样本编号为 e_i 、样本内位置为 p_i ，因果注意力支持为

$$M_{ij} = \mathbf{1}[e_i = e_j] \mathbf{1}[p_j \leq p_i]. \quad (2.11)$$

它同时限制时间方向和样本边界。仅使用全局下三角掩码会允许后面的样本访问前面样本。即使损失只对回答 token 求和，这种跨样本可见性仍然存在。图像占位、视觉位置散射和 RoPE 坐标需同时随打包更新。

监督归约与间接梯度 为明确时间索引，令 $\ell_t = -\log p(u_t | u_{<t}, I)$ 表示预测 token u_t 的损失， m_t 表示该标签是否参与监督。总损失为 $\mathcal{L} = N^{-1} \sum_t m_t \ell_t$ ， $N = \sum_t m_t > 0$ 。设提示 token u_s 的输入嵌入为 e_s 。即使 u_s 不作为监督标签，它仍可影响后续答案的预测，因此

$$\frac{\partial \mathcal{L}}{\partial e_s} = -\frac{1}{N} \sum_{t>s} m_t \frac{\partial \log p(u_t | u_{<t}, I)}{\partial e_s}. \quad (2.12)$$

忽略标签、删除上下文和停止梯度对应不同运算。数据 collator 的测试应分别检查三者。

例题 2.3 两个样本的打包掩码

两个样本长度分别为 2 和 3，样本编号为 (0, 0, 1, 1, 1)。写出允许注意力的矩阵。

解

$$M = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 & 1 \end{pmatrix}.$$

第二个样本对第一个样本的列全部为零。将第一个样本内容替换后，确定性模型对第二个样本的输出应保持不变。

定位任务中的坐标变换 视觉问答中的定位输出可能为像素坐标、归一化坐标或离散坐标 token。若原图尺寸为 (W, H) ，缩放比例为 (s_x, s_y) ，补边偏移为 (b_x, b_y) ，则坐标变换为 $x' = s_x x + b_x, y' = s_y y + b_y$ 。逆变换需先去补边再除尺度。随机裁剪后，目标框与图像必须使用同一变换；被裁掉的目标应按数据协议处理。

训练目标可采用坐标 token 交叉熵或连续框回归。评价 IoU 时，先将预测与真值转换到同一坐标系，再计算交并面积；无效框、越界框和空预测需要预先定义。Qwen3-VL 的空间与视觉工具任务使坐标处理成为完整数据接口的一部分。[12] 正确图像、空图像及关键区域遮蔽构成最小视觉依赖对照；单独观察注意力权重不能建立因果解释。

2.4 实现要求与视觉依赖评估

一个完整 VLM 实验需要保存原始图像、预处理输入、视觉特征、投影输出、拼接序列、位置编码、注意力掩码、位移后的标签和监督掩码。小批量实验先检查有效监督 token 数及各模块梯度，再检验拟合与泛化。

可以按接口正确性、小样本拟合、独立数据泛化和视觉条件依赖分别评估。将图像随机交换、遮挡关键区域或改变空间位置时，应保持问题与其他预处理一致。使用相同问题配对两张仅关键区域不同的图像，能够减少语言先验对评估的影响。图像替换后输出不变仅记录为一个现象；在确认预处理、任务可辨识性和数据因素之前，原因未查明。

资源受限时可降低批量、序列长度和分辨率，或缓存冻结视觉特征。应逐项改变配置。仅投影模块拟合成功支持接口与优化正确性的有限结论，视觉泛化能力需要独立评估。量化、分布式训练、动态分辨率和低秩适配应分别测试。

视觉证据与对比解码 视觉输入的作用还可以从条件概率变化来分析。给定相同文本前缀 h ，分别计算原图 I 与预先定义的扰动图 $\tilde{I}$ 下的分布 $p_I(y | h)$ 、 $p_{\tilde{I}}(y | h)$ 。在两个分布均为正的候选集合 $\mathcal{A}$ 上，定义

$$s(y) = (1 + \lambda) \log p_I(y | h) - \lambda \log p_{\tilde{I}}(y | h), \quad (2.13)$$

$$p_\lambda(y | h) = \frac{\mathbf{1}[y \in \mathcal{A}] p_I(y | h) [p_I(y | h) / p_{\tilde{I}}(y | h)]^\lambda}{\sum_{z \in \mathcal{A}} p_I(z | h) [p_I(z | h) / p_{\tilde{I}}(z | h)]^\lambda}. \quad (2.14)$$

第二行由对第一行取指数再归一化得到。该方法重新加权原图与扰动图之间的概率比。李宏毅 2026 自校正课件将视觉、音频及检索上下文的对比解码放在同一推理框架下讨论；视觉对比解码的原论文还使用候选概率约束，限制原分布中概率过低的 token。[89, 98]

概率比变大只说明两种输入下的预测发生变化。扰动也可能删除正确证据，或改变多个属性。因此应分别测试物体、位置、颜色等可控制变量，并使用同一前缀计算两条分支。对比解码会增加计算量，其效果应与相同推理预算下的直接采样比较。

例题 2.4 对比解码的归一化

候选只有两个 token, $p_I = (0.8, 0.2)$ 、 $p_{\bar{I}} = (0.6, 0.4)$ 。取 $\lambda = 1$ 且不额外过滤候选, 求新分布。

解 未归一化权重为 $(0.8^2/0.6, 0.2^2/0.4) = (16/15, 1/10)$, 总和为 $7/6$, 故新分布为 $(32/35, 3/35)$ 。第一项的概率上升; 只有当第一项对应正确答案时, 这一变化才提高本题正确率。

几何预处理与坐标标签 图像缩放、裁剪与补边会改变空间坐标。若原坐标为列向量 $x = (u, v)^\top$, 缩放矩阵为 $A = \text{diag}(s_u, s_v)$, 平移量为 b , 处理后的坐标为

$$x' = Ax + b, \quad x = A^{-1}(x' - b), \quad s_u, s_v > 0.$$

例如, 先从左上角 c 裁剪, 再缩放并补边 p , 有 $x' = A(x - c) + p$, 所以 $b = p - Ac$ 。检测框的两个角点、点位置和图像应采用同一变换。将坐标归一化到 $[0, 1]$ 时, 还需说明分母使用处理前还是处理后的宽高。单元测试应验证坐标往返与边界点, 不能只检查输出图像尺寸。

2.5 课后习题

习题 2.1 重复正例、温度与对比目标

对一个图像查询, 有两条语义等价的正文本和一条负文本, 分数为 $s = (r, r, 0)$ 。比较单一正例交叉熵、多正例软标签交叉熵和正例集合似然。

- 分别以第一个文本为唯一正例、以 $q = (1/2, 1/2, 0)$ 为目标、以 $\{1, 2\}$ 为正例集合写出三个损失。沿本题的一维分数族化简, 求 $r \rightarrow \infty$ 的极限与对 r 的导数。
- 取消前两个分数相等的限制。对三个目标分别求 $\partial L / \partial s_j$, 分析把正例概率集中到第一个文本时, 各目标如何变化。说明在什么假设下需要均衡多个正例。
- 令 $r = e^\eta c$, $c > 0$ 为固定余弦相似度差。求对逆温度参数 η 的导数, 说明单位化特征是否足以给出有限的最优温度。
- 对完整 $B \times B$ 对称 CLIP 目标, 推导分数梯度和单位化前图像特征的梯度。证明同时置换图文样本保持损失, 只置换文本时需要怎样同步更新监督关系。
- 编程: 实现上述三种单查询目标及对称目标。测试重复文本、全部样本等价、 $B = 1$ 、同时置换和错误置换。用同一重复数据集比较梯度, 不依据不同常数偏置的损失数值直接判断训练效果。

习题 2.2 序列打包、视觉梯度与条件干预

样本的 token 顺序为 (BOS, V , Q , SEP, A , B , EOS), 其中 V 表示一个视觉 token, A, B 为答案。另有一个长度为 4 的独立样本。两样本可分别计算或打包成一条序列。

- 写出第一个样本的 6 个下一 token 标签及监督掩码。把两个样本打包, 写出注意力支持矩阵的分块形式, 并说明跨样本边界的标签是否参与损失。
- 用 $h = (e_V + e_Q)/2$ 、 $L = (h - y)^2/2$ 构造视觉位置没有直接监督但具有非零梯度的例子。把视觉嵌入写成 $e_V = \phi z$, 求 $\partial L / \partial \phi$; 讨论冻结下游模型参数与关闭其计算图的区别。
- 原图坐标先缩放再平移: $x' = s_x x + b_x, y' = s_y y + b_y$ 。推导框坐标的正逆变换。若执行水平翻转或颜色变换, 说明颜色与象限标签需要怎样处理。
- 编程: 实现打包因果掩码、移位标签和有效 token 平均损失。分别计算与打包计算应给出相同的有效 logits 和梯度; 改变第二个样本的内容, 检查第一个样本输出不变。另测试 -100 标签、空监督与仅 EOS 的回答。
- 用合成方块图像建立正确图像、打乱图像和纯文本三个条件。预先给出可以支持“模型使用视觉条件”的配对统计量, 以及不能由该统计量单独支持的泛化结论。

第 3 章 现代视觉语言模型架构

视觉语言模型的架构由视觉采样、特征压缩、跨模态融合、位置表示与语言解码共同确定。本章比较这些选择对信息保留、梯度传播和计算量的影响，并建立可直接实现的张量定义。

3.1 视觉编码与跨模态融合

设图像经过视觉编码器得到 $Z \in \mathbb{R}^{B \times N_v \times d_v}$ ，文本嵌入为 $T \in \mathbb{R}^{B \times N_t \times d}$ 。两类序列的长度、特征维数和位置坐标不同。融合模块需同时规定输出维数、序列排列、可访问位置及位置编码。以下使用行向量约定。

投影后拼接 最直接的连接方式逐位置应用 MLP：

$$U = \sigma(ZW_1 + b_1)W_2 + b_2, \quad U \in \mathbb{R}^{B \times N_v \times d}, \quad (3.1)$$

$$H^0 = \text{concat}_{\text{token}}(T_{\text{prefix}}, U, T_{\text{suffix}}). \quad (3.2)$$

语言模型在长度 $L = N_t + N_v$ 的序列上计算注意力。连接模块可改变通道维数，逐位置 MLP 保留 token 数。视觉 token 的可见性由注意力掩码控制，监督位置由损失掩码控制，两者应独立定义。LLaVA 系列中的投影连接提供了这一类结构的典型实例。[45, 80]


固定查询重采样 若将大量视觉位置压缩到 K 个查询，令可训练查询 $Q_0 \in \mathbb{R}^{K \times d}$ ，定义一次交叉注意力

$$Q = Q_0 W_Q, \quad K_v = Z W_K, \quad V_v = Z W_V, \quad (3.3)$$

$$P = \text{softmax}_{N_v} \left(\frac{Q K_v^\top}{\sqrt{d_k}} \right), \quad U = P V_v \in \mathbb{R}^{B \times K \times d_o}. \quad (3.4)$$

第一式的查询沿批次广播。 $P_{b,r,j}$ 表示第 b 个样本中，第 r 个查询对第 j 个视觉位置的注意力权重。每行归一化为 1，其列和没有这一约束。BLIP-2 使用 Q-Former 进行视觉信息提取；Flamingo 使用 Perceiver Resampler，并在语言网络中加入门控交叉注意力。两者的预训练目标与语言模型接口不同。[46, 47]

重采样的主要注意力计算量为 $O(BKN_v d_k)$ 。下游语言模型的视觉序列长度由 N_v 降至 K ，但 K 个向量所能保留的细粒度信息需要通过定位、计数和 OCR 任务检验。固定长度输出也要求查询区分不同图像、帧和视角，不能省略这些坐标信息。



维度 查询数 K 决定输出长度；输入位置数 N_v 可变化。省略批次轴。

对象 Q, K_v, V_v, U 为特征； P 为沿视觉位置归一化的注意力概率。

运算 第一行包括缩放与 softmax；第二行沿 N_v 收缩。

图 3.1 固定查询重采样。输出保留查询位置轴，压缩后的 token 数与输入视觉 token 数解耦。

交叉注意力的反向传播 注意力反向传播包含矩阵乘法和逐行归一化两类运算。先忽略批次轴，记分数矩阵为 $S = QK_v^\top / \sqrt{d_k}$ 。对输出 $U = PV_v$ 取微分：

$$dU = (dP)V_v + P(dV_v), \quad (3.5)$$

$$\begin{aligned} d\mathcal{L} &= \text{tr}(G_U^\top dU) \\ &= \text{tr}[(G_U V_v^\top)^\top dP] + \text{tr}[(P^\top G_U)^\top dV_v]. \end{aligned} \quad (3.6)$$

两个微分系数分别给出 G_P 与 G_{V_v} 。再考察一行注意力概率。由 $P_j = e^{S_j} / \sum_l e^{S_l}$ ，有

$$\frac{\partial P_j}{\partial S_k} = P_j(\mathbf{1}[j = k] - P_k), \quad (3.7)$$

$$\begin{aligned} (G_S)_k &= \sum_j (G_P)_j P_j(\mathbf{1}[j = k] - P_k) \\ &= P_k \left[(G_P)_k - \sum_j P_j (G_P)_j \right]. \end{aligned} \quad (3.8)$$

最后对 S 取微分， $dS = [(dQ)K_v^\top + Q(dK_v)^\top] / \sqrt{d_k}$ ，再次使用迹的循环性质，即可得到查询与键的梯度。将这些步骤合并如下。令上游梯度 $G_U = \partial \mathcal{L} / \partial U$ 。从 $U = PV_v$ 开始，有

$$G_{V_v} = P^\top G_U, \quad G_P = G_U V_v^\top, \quad (3.9)$$

$$G_S = P \odot [G_P - \text{sum}_j(P \odot G_P)], \quad (3.10)$$

$$G_Q = G_S K_v / \sqrt{d_k}, \quad G_{K_v} = G_S^\top Q / \sqrt{d_k}. \quad (3.11)$$

式(3.10)中的行和保留末轴长度 1，再沿视觉键轴广播。视觉输入梯度同时含键路径和值路径： $G_Z = G_{K_v} W_K^\top + G_{V_v} W_V^\top$ 。只检查输出形状无法发现其中一条梯度路径被意外停止的问题。

例题 3.1 均匀注意力下的梯度

一个查询访问两个标量视觉值, $V_v = (2, 6)^\top$, 两个分数均为 0, 损失为输出值本身。求输出以及对分数和值的导数。

解 $P = (1/2, 1/2)$, $U = 4$ 。 $\partial U / \partial V_v = (1/2, 1/2)$ 。由 softmax 导数, $\partial U / \partial S_j = P_j(V_j - U)$, 所以分数梯度为 $(-1, 1)$ 。两项之和为零, 与 softmax 对共同平移的不变性一致。


3.2 动态分辨率、空间合并与 token 预算

固定方形缩放会改变长宽比; 补边增加无效位置; 动态切块可保留局部分辨率, 但需保存切块坐标和全局关系。原生分辨率处理也通常受到 patch 尺寸、合并因子和最大像素预算的整除约束。图像预处理属于模型定义的一部分。

空间合并的地址映射 设视觉特征为 $Z \in \mathbb{R}^{B \times H_v \times W_v \times d_v}$, H_v, W_v 均能被 s 整除。令 $H' = H_v/s, W' = W_v/s$ 。将相邻 $s \times s$ 位置拼接到通道, 定义

$$U_{b, h'W' + w', (is+j)d_v + c} = Z_{b, sh' + i, sw' + j, c}, \quad (3.12)$$

其中 $0 \leq i, j < s, 0 \leq c < d_v$ 。输出为 $U \in \mathbb{R}^{B \times H' \times W' \times s^2 d_v}$, 随后才使用线性层或 MLP 映射至语言维数。地址映射保留了块内坐标; 平均池化则在同一块内求和并丢弃块内排列。Qwen3-VL 将相邻 2×2 视觉特征合并为一个语言侧视觉 token。[12]



维度 示例取 $B = 1, d_v = 1, s = 2$ 。输出行轴为合并后的空间位置, 列轴为局部位置与通道。

对象 数字为输入坐标的唯一标识。相同颜色表示同一 2×2 空间块。

运算 仅重排阶段可逆; 后续降维投影一般不可逆。

图 3.2 空间合并的坐标映射。原空间坐标转为 token 位置和 token 内部通道, 元素总数保持不变。

例题 3.2 合并后的通道顺序

令单通道特征网格为 $\begin{pmatrix} 0 & 1 & 2 & 3 \\ 4 & 5 & 6 & 7 \end{pmatrix}$ ，取 $s = 2$ 。求合并结果。

解 输出含两个 token，分别为 $(0, 1, 4, 5)$ 与 $(2, 3, 6, 7)$ 。直接将原张量变成 2×4 会产生 $(0, 1, 2, 3)$ 与 $(4, 5, 6, 7)$ ，与式(3.12)的空间邻域不一致。实现应采用 reshape、permute、reshape，并用唯一位置编码测试。

预算与采样分布 若 patch 边长为 p 、合并因子为 s ，单幅图像的视觉 token 数约为

$$N_v = \frac{HW}{p^2 s^2}, \quad L = N_t + \sum_{f=1}^F N_v^{(f)} + N_{\text{special}}. \quad (3.13)$$

等式需满足对齐后的尺寸与具体特殊 token 定义。对于视频，还需联合分配帧数与每帧分辨率。将总预算全部用于更多帧可能降低小字可读性；全部用于空间分辨率则降低时间采样密度。应在相同视觉 token 总数下比较这些方案。

InternVL3.5 的标准切块经过空间合并后使用每块 256 个视觉 token，其 FlashViR 可按图像块选择 256 或 64 个 token。该结构改变不同图像区域的压缩率，实验需同时记录选择结果与视觉任务指标。[48] 设有 n 个图像块， k 个采用高分辨率，则 $N_v = 256k + 64(n - k) = 64n + 192k$ 。在预算约束下，首先需要检查最低开销 $64n$ 。若 $M < 64n$ ，当前图像块集合没有可行压缩配置，必须减少图像块或增大预算。若 $M \geq 64n$ ，才有

$$0 \leq k \leq \min \left\{ n, \left\lfloor \frac{M - 64n}{192} \right\rfloor \right\}. \quad (3.14)$$

把负的上界直接截断成零，会把不可行输入误记为满足预算。相应单元测试应包含 $M = 64n - 1$ 、 $64n$ 和 $256n$ 三个边界。

例题 3.3 视频输入的联合预算

设可用上下文为 8192 token，文本及特殊位置占 2048，每帧视觉 token 为 256。最多能放入多少帧？若改为每帧 576 token，结果如何？

解 视觉预算为 6144，因此两种配置最多分别使用 24 帧和 10 帧。第二种配置剩余 384 token。两种方案的时间覆盖还依赖抽帧间隔，长度计数本身不确定覆盖的视频时长。

3.3 时空位置编码与多层视觉注入

二维图像位置与视频时间位置不能仅由拼接后的序列下标唯一恢复。对偶数维向量，每个通道对使用频率 ω_j ，RoPE 的二维旋转矩阵为

$$R(\omega_j p) = \begin{pmatrix} \cos(\omega_j p) & -\sin(\omega_j p) \\ \sin(\omega_j p) & \cos(\omega_j p) \end{pmatrix}. \quad (3.15)$$

转置将旋转角变为负角。矩阵乘积的左上元素为 $\cos a \cos b + \sin a \sin b = \cos(b - a)$ ，右上元素为 $-\cos a \sin b + \sin a \cos b = -\sin(b - a)$ 。另两个元素同理，因此

$$R(a)^\top R(b) = R(-a)R(b) = R(b - a).$$

将这一恒等式代入经过旋转的查询与键的点积，得到

$$(R(\omega_j p)q_j)^\top (R(\omega_j s)k_j) = q_j^\top R(\omega_j(s - p))k_j. \quad (3.16)$$

点积依赖相对位置差，同时保留内容向量。多维 RoPE 将通道对分配给时间、高度和宽度。频率分配决定每个坐标轴在哪些尺度上变化；交换坐标名称与重新分配频率具有不同计算含义。[13]

Qwen3-VL 的 Interleaved MRoPE 将时空轴交错分配到频率通道，视频帧还配有显式文本时间戳。DeepStack 通过独立 merger 将三个中间视觉层的特征注入语言模型早期层。其原生上下文长度为 262144 token；输入长度上限与各任务有效利用长上下文的程度需分别评价。[12]




图 3.3 Qwen3-VL DeepStack 的多层视觉特征注入。各级特征经对应映射后，与早期语言层中对齐的视觉位置表征融合。

多层注入的梯度分解 用选择矩阵 $E_v \in \{0, 1\}^{L \times N_v}$ 将视觉位置映射到联合序列，设第 r 个注入层为


$$H^{r+1} = F_r(H^r) + E_v M_r(Z^{k_r}). \quad (3.17)$$

这里每个视觉 token 对应一个联合序列位置， E_v 由整数位置构造，无可训练参数。若视觉编码器还产生初始嵌入，设 $H^0 = H^0(\theta_v)$ 。对参数的一次扰动会经过初始嵌入以及各个额外注入接口。令 $J_0 = \partial H^0 / \partial \theta_v$ ，逐接口应用链式法则，得到

$$\nabla_{\theta_v} \mathcal{L} = J_0^\top \frac{\partial \mathcal{L}}{\partial H^0} + \sum_r \left(\frac{\partial Z^{k_r}}{\partial \theta_v} \right)^\top \left(\frac{\partial M_r}{\partial Z^{k_r}} \right)^\top E_v^\top \frac{\partial \mathcal{L}}{\partial H^{r+1}}. \quad (3.18)$$

第一项表示经过初始视觉嵌入的贡献。求各接口偏导时，应将其他注入张量视为独立输入；其上游梯度仍包含接口之后的所有语言层。这样按直接接口求和，可以保留全部路径并避免重复计数。

若只分析新增的注入模块，可单独报告式(3.18)中的求和项；端到端视觉编码器的梯度检查则应包含第一项。同一视觉层被多个接口使用时，各接口贡献在该层相加。联合序列长度保持不变，额外开销来自中间特征存储和 merger 计算。



对象 三条路径共用视觉特征 u 。 a, b, c, d 为本例中的标量系数。

梯度 每条从 u 到损失的可微路径都贡献一个链式法则项。

边界 冻结系数的参数梯度仍可保留输入梯度；分支上的停止梯度会删除相应路径。

图 3.4 多层视觉注入的完整梯度路径。初始嵌入与后续注入分别产生贡献，汇总时不重复计算同一接口。

例题 3.4 非均匀采样的速度估计

物体在 0, 1, 9 秒的位置分别为 0, 2, 18 米。求两段速度，并说明帧序号编码遗漏的量。

解 使用实际时间差得到 $2/1 = 2$ 与 $16/8 = 2$ 米每秒。连续帧下标仅给出两个相同的索引间隔。时间戳使模型可以区分 1 秒与 8 秒；仍需训练和评测检验其是否利用了这项信息。

3.4 混合注意力、循环状态与稀疏专家

现代 VLM 可沿用稠密 Transformer，也可采用注意力与线性时间序列模块的混合结构。Qwen3.5-397B-A17B 的官方配置使用 60 层，每四层含三层 Gated DeltaNet 和一层门控注意力，各层配有

MoE。397B 表示总参数规模，17B 表示报告的激活参数规模；加载权重的存储需求需按总参数及实际分片方式估计。[49]

从一次梯度更新得到 delta rule 设 $k_t, q_t \in \mathbb{R}^{d_k}$ 、 $v_t \in \mathbb{R}^{d_v}$ ，矩阵状态 $S_t \in \mathbb{R}^{d_v \times d_k}$ 。先以门控系数 α_t 衰减旧状态： $\tilde{S}_t = \alpha_t S_{t-1}$ 。对局部目标

$$\ell_t(S) = \frac{1}{2} \|Sk_t - v_t\|_2^2 \quad (3.19)$$

求导。令 $e = Sk_t - v_t$ ，则 $d\ell = e^\top (dS)k_t = \text{tr}(ke^\top dS)$ ，所以 $\nabla_S \ell = ek_t^\top$ 。在 $\tilde{S}_t$ 处作步长 β_t 的更新，得到

$$\begin{aligned} S_t &= \tilde{S}_t + \beta_t(v_t - \tilde{S}_t k_t)k_t^\top \\ &= \alpha_t S_{t-1}(I - \beta_t k_t k_t^\top) + \beta_t v_t k_t^\top, \quad o_t = S_t q_t. \end{aligned} \quad (3.20)$$

该式给出 Gated DeltaNet 的核心状态更新结构；具体实现还包含归一化、分块并行、输出门控和投影。[50]


在 $\|k_t\| = 1$ 时，沿当前键方向的残差乘以 $1 - \beta_t$ ，与其正交的状态分量仅受衰减控制。 $\beta_t = 1$ 时 $S_t k_t = v_t$ ；若没有键归一化，这一结论一般不成立。循环状态大小与历史 token 数无关，但全注意力层的 KV cache 仍随长度增长。这一递推还说明了分块并行的代数依据。定义 $A_t = \alpha_t(I - \beta_t k_t k_t^\top)$ 、 $B_t = \beta_t v_t k_t^\top$ ，于是 $S_t = S_{t-1}A_t + B_t$ 。连续两个时间步满足

$$S_{t+1} = (S_{t-1}A_t + B_t)A_{t+1} + B_{t+1} \quad (3.21)$$

$$= S_{t-1}(A_t A_{t+1}) + (B_t A_{t+1} + B_{t+1}). \quad (3.22)$$

因此两个仿射变换可合成为 $(A_t A_{t+1}, B_t A_{t+1} + B_{t+1})$ 。矩阵乘法的结合律保证组合运算具有结合性，可用于并行扫描。实际高效实现还需利用低秩结构，避免显式物化所有 $d_k \times d_k$ 矩阵。

$$e_t = v_t - \alpha_t S_{t-1} k_t, \quad S_t = \alpha_t S_{t-1} + \beta_t e_t k_t^\top$$



 $\alpha_t S_{t-1}$
 $d_v \times d_k$

+


β_t

 e_t
 $d_v \times 1$

×


 $k_t^\top$
 $1 \times d_k$

=


 S_t
 $d_v \times d_k$

维度 状态大小由 d_v, d_k 确定，与已处理序列长度无关。

对象 e_t 为当前键的预测残差； α_t 为衰减系数， β_t 为更新系数。

运算 外积产生与状态同形的更新；预测 $S_t k_t$ 仍沿键特征轴收缩。

图 3.5 带衰减的 delta-rule 状态更新。秩一更新和状态矩阵具有相同的行列尺寸。

例题 3.5 状态更新的方向性

取 $S_{t-1} = I_2$ 、 $\alpha = 1$ 、 $\beta = 1$ 、 $k = (1, 0)^\top$ 、 $v = (2, 3)^\top$ 。求 S_t 及对查询 $(0, 1)^\top$ 的输出。

解 $S_{t-1}k = (1, 0)^\top$ ，更新外积为 $\begin{pmatrix} 1 & 0 \\ 3 & 0 \end{pmatrix}$ ，因此 $S_t = \begin{pmatrix} 2 & 0 \\ 3 & 1 \end{pmatrix}$ 。第一列被更新，第二列保持原值；查询 $(0, 1)^\top$ 输出 $(0, 1)^\top$ 。

MoE 的离散路由 对隐藏向量 h 计算专家分数 $z = hW_r$ ，获得概率 $p = \text{softmax}(z)$ 。Top- k 产生整数专家索引 $I = (i_1, \dots, i_k)$ ，在选中专家内归一化后输出

$$\tilde{p}_r = \frac{p_{i_r}}{\sum_{u=1}^k p_{i_u}}, \quad f(h) = \sum_{r=1}^k \tilde{p}_r f_{i_r}(h). \quad (3.23)$$

索引、路由权重与专家输出是不同类型的张量。在选中集合固定的局部区域内，梯度可以通过选中权重传播，但还需检查归一化是否使权重退化。对于式(3.23)中的 Top-1， $\tilde{p}_1 = p_{i_1}/p_{i_1} = 1$ ，其对路由分数的导数为零。此时，普通任务损失不能通过该权重训练路由器；未归一化门控、辅助损失或其他路由设计会改变这一结论。通常的 Top- k 整数索引在集合切换处不连续。专家容量、负载均衡和通信决定实际吞吐量，参数稀疏性不能直接转换为同等比例的运行加速。第12章进一步分析其内存和分布式实现。

3.5 统一理解与生成的序列接口

视觉问答中的图像是输入条件，图像生成中的图像则是预测对象。共享网络需要明确每个位置的角色，并为离散文本与连续图像分别定义预测头。Transfusion 在混合模态序列上联合使用文本自回归预测和图像去噪目标。文本采用因果注意力，同一图像内的潜变量采用双向注意力。[76, 97]

设联合序列由有序块组成，每个文本 token 单独构成一块，每幅图像的所有潜变量 token 构成一块。记位置 i 所在块为 $b(i)$ ，图像位置指示量为 v_i 。一种块因果注意力支持为


$$M_{ij} = \mathbf{1}[b(j) < b(i)] + \mathbf{1}[b(j) = b(i)]\mathbf{1}[i = j \text{ 或 } v_i v_j = 1]. \quad (3.24)$$

两项支持互斥。文本位置只能访问当前及此前文本输入和完整的先前图像；同一待生成图像内的带噪位置可以相互访问。训练中的文本输入仍需与标签错开一位。若把答案 token 本身放进其预测上下文，即使块级掩码正确，也会发生标签泄漏。

以流匹配图像头为例，设 $\mathcal{T}$ 为监督文本位置， $\mathcal{V}$ 为连续图像目标位置。可定义

$$\mathcal{L} = \lambda_T \frac{\sum_{i \in \mathcal{T}} -\log p_\theta(y_i | H)}{|\mathcal{T}|} + \lambda_V \frac{\sum_{i \in \mathcal{V}} \|v_{\theta, i} - u_i\|^2}{|\mathcal{V}|}. \quad (3.25)$$

这里的流匹配形式是对共享接口的教学实现；Transfusion 原报告使用扩散去噪损失。两项损失通过共享隐藏状态反向传播，但量纲、监督数量和归约方式不同。一般不能直接把这一加权和解释为精确的联合负对数似然。实际采样还需分别规定文本终止、图像尺寸标记、图像数值积分及后续文本的生成顺序。



维度 行为查询位置, 列为被读取的键位置。彩色单元格表示允许的读取关系。

运算 $M = 0$ 的位置在 softmax 前加 $-\infty$; $M = 1$ 的位置保留计算得到的分数。

条件 图像块内部双向读取不允许此前的文本位置读取未来图像。

图 3.6 交错文本与图像块的注意力掩码。块间因果顺序与图像块内部的双向注意力同时满足。

语音输入的时间对齐 语音也可以通过连续编码特征或离散音频 token 接入同一序列接口。语义表示侧重内容相关特征; 神经音频编码器还需保留用于波形重建的信息。二者对应不同训练目标, 实际表征中可能同时含有多类信息。[94]

若长度为 D 秒的音频以间隔 Δ 秒产生一帧特征, 再合并 s 帧, 则输入长度约为 $N_a = \lceil D/(s\Delta) \rceil$, 末尾填充规则另行规定。文本与音频通常没有一一对应的时位置。需要精确时间定位的任务, 应在输入或位置编码中保留音频时间信息。跨模态注意力可以处理两个变长序列, 额外的对齐监督由训练目标确定。用音频长度测试缓存和掩码时, 应同时检查静音、末尾不完整分块与流式输入边界。

3.6 训练目标、数据组合与实现要求

Qwen3-VL 采用连接模块对齐、全参数预训练及长上下文扩展等阶段, 并在后训练中使用监督微调、蒸馏和强化学习。其视觉编码器基于 SigLIP-2 架构。[12] 将预训练来源、实际训练参数与损失归约分开记录, 才能复现实验中的变量。

设第 i 个样本有 N_i 个监督 token, token 损失为 ℓ_{it} 。一种连续插值归约是

$$\mathcal{L}_\eta = \frac{\sum_i N_i^{-\eta} \sum_{t=1}^{N_i} \ell_{it}}{\sum_i N_i^{1-\eta}}, \quad 0 \leq \eta \leq 1. \quad (3.26)$$

$\eta = 0$ 对所有监督 token 等权; $\eta = 1$ 对样本平均损失等权; $\eta = 1/2$ 使样本总权重正比于 $\sqrt{N_i}$ 。InternVL3.5 采用平方根长度重加权; 它同时报告随机 JPEG 压缩增强, 以提高对图像质量变化的适应性。[48] 这些做法分别改变监督权重和图像输入分布, 消融实验需要分别控制。

例题 3.6 两种回答长度的有效权重

两个回答长度为 16 与 64，假设各自平均 token 损失相同。计算三种 η 下的样本权重比。

解 权重比为 $16^{1-\eta} : 64^{1-\eta}$ 。当 $\eta = 0, 1/2, 1$ 时分别为 $1 : 4, 1 : 2, 1 : 1$ 。先在每个微批次内归一化再平均，通常不能恢复整批次的这一比例。

混合数据目标写为

$$\mathcal{L} = \lambda_{\text{text}} \mathbb{E}_{D_{\text{text}}} \ell + \lambda_{\text{vi}} \mathbb{E}_{D_{\text{vi}}} \ell + \lambda_{\text{vid}} \mathbb{E}_{D_{\text{vid}}} \ell. \quad (3.27)$$

数据采样比例、监督长度和式(3.26)共同确定实际梯度权重。训练日志应记录每类样本数、监督 token 数、图像块数、视频帧数及触及长度上限的比例。

实现验证分为三个层次。张量测试检查空间合并、图像位置散射、注意力支持和回答移位；梯度测试检查 merger、视觉编码器与语言模型的更新集合；任务实验检查正确图像、打乱图像、遮蔽目标区域和文本基线。固定视觉特征的实验能评价接口与优化，不足以测量端到端视觉表征学习。对未改善的任务，应先报告观察结果；原因未查明时不得从注意力可视化推断因果机制。

3.7 课后习题

习题 3.1 视觉压缩的信息损失与预算

视觉特征为 $U \in \mathbb{R}^{B \times H \times W \times d}$ 。方案一先拼接每个 $s \times s$ 邻域，再线性投影；方案二使用 K 个固定查询对全部视觉位置做一次交叉注意力。

- 写出方案一的指标映射与 reshape-permute-reshape 次序。取 $B = 2, H = 4, W = 6, d = 3, s = 2$ ，求各步形状；区分拼接操作和后续线性投影的可逆性。
- 在方案二中，假设键和值由逐位置线性映射产生，且没有额外位置编码。证明同时置换输入位置不会改变输出。给出两个位置关系不同、但这种重采样器无法区分的输入。
- 加入固定空间坐标编码后，分别分析只置换视觉内容和同时置换内容与坐标的结果。推导重采样输出对视觉输入的键路径与值路径梯度。
- 8 个图像块分别保留 64 或 256 个 token。总预算为 1280 时，求最多保留高分辨率表示的块数。推广到一般 (n, M) ，写出无可行解的条件，并检查 $M = 500$ 。
- 编程：实现空间拼接及其逆操作、单头重采样和预算检查。用唯一整数编码测试轴顺序，用位置置换测试不变性，用有限差分测试两条梯度路径。设计同一 token 预算下的计数与相对位置对照实验。

习题 3.2 多层视觉注入的总导数

共享视觉编码器输出 $u = \phi x$ 。一个标量网络使用初始视觉输入和两个注入位置： $h_0 = u$, $h_1 = ah_0 + bu$, $h_2 = ch_1 + du$, 损失 $L = (h_2 - y)^2/2$ 。

- (a) 画出计算依赖，并沿三个使用 u 的位置分别求对 ϕ 的梯度贡献。再从最终展开式直接求导，验证两种结果一致。
- (b) 取 $x = \phi = 1, a = 2, b = 3, c = 4, d = 5, y = 0$ 。计算输出、损失和三个梯度贡献。若遗漏初始视觉输入路径，会得到什么结果？
- (c) 将 bu 改为 $\text{sg}(bu)$ ，比较前向输出和 ϕ, b 的梯度。随后只冻结 a, c 的参数，保持原计算图，重新分析 ϕ 梯度。
- (d) 推广到向量视觉编码器和多个注入位置，使用各接口处的偏导与接口 Jacobian 写出总梯度。说明为什么不能把已经含有下游依赖的总导数再次相加。
- (e) 编程：实现未隔离、注入隔离和下游参数冻结三种设置。半梯度的有限差分必须固定哪一个前向数值？为每种设置列出应有梯度、应为零和不应创建梯度的参数集合。

第 4 章 扩散模型与流匹配

扩散模型与流匹配通过局部预测目标学习分布变换。本章推导变分目标、反向过程、条件速度场与概率密度演化，并比较采样离散化、条件引导和潜空间实现。

4.1 潜变量模型与变分推断

潜变量模型以联合分布 $p_\theta(x, z) = p(z)p_\theta(x | z)$ 表示数据。边缘似然 $p_\theta(x) = \int p(z)p_\theta(x | z) dz$ 通常难以精确计算。引入可采样的近似后验 $q_\phi(z | x)$ ，利用 Jensen 不等式有

$$\begin{aligned} \log p_\theta(x) &= \log \mathbb{E}_{q_\phi(z|x)} \frac{p_\theta(x, z)}{q_\phi(z | x)} \\ &\geq \mathbb{E}_q[\log p_\theta(x | z)] - \text{KL}(q_\phi(z | x) \| p(z)) \equiv \mathcal{L}_{\text{ELBO}}(x). \end{aligned} \quad (4.1)$$

下界的差值可以由 Bayes 公式直接求出。将 $p_\theta(z | x) = p_\theta(x, z)/p_\theta(x)$ 代入 KL:

$$\text{KL}(q \| p_\theta(z | x)) = \mathbb{E}_q[\log q(z | x) - \log p_\theta(x, z) + \log p_\theta(x)] \quad (4.2)$$

$$= \log p_\theta(x) - \mathbb{E}_q \log \frac{p_\theta(x, z)}{q(z | x)}. \quad (4.3)$$

最后一个期望就是式(4.1)的下界。因此

$$\log p_\theta(x) - \mathcal{L}_{\text{ELBO}}(x) = \text{KL}(q_\phi(z | x) \| p_\theta(z | x)). \quad (4.4)$$

因此证据下界 (ELBO) 的紧致程度取决于近似后验与真实后验的差异。变分自编码器 (VAE) 同时优化编码器与解码器。[24]

对角高斯后验的 KL 也可逐坐标计算。设 $q_\phi = \mathcal{N}(\mu, \text{diag}(\sigma^2))$ ，先验为 $p(z) = \mathcal{N}(0, I)$ 。展开两者的对数密度，有

$$\log q(z) - \log p(z) = \frac{1}{2} \sum_j \left[z_j^2 - \frac{(z_j - \mu_j)^2}{\sigma_j^2} - \log \sigma_j^2 \right], \quad (4.5)$$

$$\mathbb{E}_q[z_j^2] = \mu_j^2 + \sigma_j^2, \quad \mathbb{E}_q[(z_j - \mu_j)^2] = \sigma_j^2. \quad (4.6)$$

将两个二阶矩代入，得到

$$\text{KL}(q_\phi \| p) = \frac{1}{2} \sum_j (\mu_j^2 + \sigma_j^2 - 1 - \log \sigma_j^2). \quad (4.7)$$

采样用 $z = \mu + \sigma \odot \epsilon$ 、 $\epsilon \sim \mathcal{N}(0, I)$ 。若网络输出 $\ell = \log \sigma^2$ ，标准差为 $e^{\ell/2}$ 。把 e^ℓ 直接当作标准差会改变后验方差与 KL 所描述的分布。

固定方差的高斯解码器使负对数似然包含平方重建误差，其权重由观测方差确定。加入感知损失、对抗损失或任意调整重建项与 KL 的相对权重后，应分别陈述实际训练目标与概率模型，避免将所有组合损失统称为同一个 ELBO。

例题 4.1 一维 VAE 的 KL

设 $q(z | x) = \mathcal{N}(1, 4)$ ，先验为标准正态。求 KL 及重参数化样本。

解 式(4.7)给出

$$\text{KL}(q \| p) = \frac{1}{2}(1 + 4 - 1 - \log 4) = 2 - \log 2 \approx 1.30685.$$

重参数化为 $z = 1 + 2\epsilon$ 。若保存的是对数方差 $\ell = \log 4$ ，则 $e^{\ell/2} = 2$ 。

4.2 离散时间高斯扩散与噪声预测

本节使用 x_0 表示数据， x_K 表示接近先验的噪声变量。定义前向马尔可夫链

$$q(x_k | x_{k-1}) = \mathcal{N}(\sqrt{\alpha_k}x_{k-1}, \beta_k I), \quad \alpha_k = 1 - \beta_k, \quad \bar{\alpha}_k = \prod_{j=1}^k \alpha_j. \quad (4.8)$$

先计算条件均值与方差的递推。若上一步满足 $x_{k-1} | x_0 \sim \mathcal{N}(m_{k-1}, v_{k-1}I)$ ，新噪声与过去独立，则

$$m_k = \sqrt{\alpha_k}m_{k-1}, \quad m_0 = x_0, \quad (4.9)$$

$$v_k = \alpha_k v_{k-1} + \beta_k, \quad v_0 = 0. \quad (4.10)$$

均值递推给出 $m_k = \sqrt{\alpha_k}x_0$ 。对方差使用归纳法：若 $v_{k-1} = 1 - \bar{\alpha}_{k-1}$ ，则

$$v_k = \alpha_k(1 - \bar{\alpha}_{k-1}) + (1 - \alpha_k) = 1 - \bar{\alpha}_k.$$

线性变换和独立高斯噪声仍产生高斯变量，因此完整条件分布为

$$q(x_k | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_k}x_0, (1 - \bar{\alpha}_k)I), \quad x_k = \sqrt{\bar{\alpha}_k}x_0 + \sqrt{1 - \bar{\alpha}_k}\epsilon. \quad (4.11)$$

训练可直接采样任意时间步，无需显式执行 k 次前向转移。[25]

高斯后验的推导 由 Bayes 公式， $q(x_{k-1} | x_k, x_0) \propto q(x_k | x_{k-1})q(x_{k-1} | x_0)$ 。两个因子都是关于 x_{k-1} 的高斯函数，乘积可通过二次项配方求出。

令 $z = x_{k-1}$ ，条件后验的负对数密度在常数项之外为

$$-\log q(z | x_k, x_0) = \frac{\|x_k - \sqrt{\alpha_k}z\|^2}{2\beta_k} + \frac{\|z - \sqrt{\bar{\alpha}_{k-1}}x_0\|^2}{2(1 - \bar{\alpha}_{k-1})} + C \quad (4.12)$$

$$= \frac{1}{2}A\|z\|^2 - b^\top z + C, \quad (4.13)$$

$$A = \frac{\alpha_k}{\beta_k} + \frac{1}{1 - \bar{\alpha}_{k-1}} = \frac{1 - \bar{\alpha}_k}{\beta_k(1 - \bar{\alpha}_{k-1})}, \quad (4.14)$$

$$b = \frac{\sqrt{\alpha_k}}{\beta_k} x_k + \frac{\sqrt{\alpha_{k-1}}}{1 - \bar{\alpha}_{k-1}} x_0. \quad (4.15)$$

使用 $\frac{1}{2} A \|z\|^2 - b^\top z = \frac{A}{2} \|z - b/A\|^2 - \|b\|^2/(2A)$, 得到协方差 $A^{-1}I$ 与均值 b/A 。将 A 和 b 展开, 得到

$$\tilde{\beta}_k = \frac{\beta_k(1 - \bar{\alpha}_{k-1})}{1 - \bar{\alpha}_k}, \quad (4.16)$$

$$\tilde{\mu}_k(x_k, x_0) = \frac{\sqrt{\alpha_{k-1}}\beta_k}{1 - \bar{\alpha}_k} x_0 + \frac{\sqrt{\alpha_k}(1 - \bar{\alpha}_{k-1})}{1 - \bar{\alpha}_k} x_k. \quad (4.17)$$

$k = 1$ 时后验关于已知 x_0 退化, 训练目标通常单独使用数据重建或解码项处理该边界。

逆向模型写为 $p_\theta(x_{0:K}) = p(x_K) \prod_{k=1}^K p_\theta(x_{k-1} | x_k)$ 。将第一个小节的变分后验替换为整条前向链, 负 ELBO 为

$$\mathbb{E}_q \left[-\log p(x_K) - \sum_{k=1}^K \log p_\theta(x_{k-1} | x_k) + \sum_{k=1}^K \log q(x_k | x_{k-1}) \right].$$

对 $k \geq 2$ 使用 Bayes 恒等式

$$\log q(x_k | x_{k-1}) = \log q(x_{k-1} | x_k, x_0) + \log q(x_k | x_0) - \log q(x_{k-1} | x_0).$$

最后两项沿时间求和后相消; $k = 1$ 的 $\log q(x_1 | x_0)$ 也被抵消, 只留下 $\log q(x_K | x_0)$ 。再按条件分布整理期望, 得到

$$\begin{aligned} \mathcal{L}_{\text{VLB}} &= \mathbb{E}_q[-\log p_\theta(x_0 | x_1)] + \mathbb{E}_{x_0} \text{KL}(q(x_K | x_0) \| p(x_K)) \\ &\quad + \sum_{k=2}^K \mathbb{E}_q \text{KL}(q(x_{k-1} | x_k, x_0) \| p_\theta(x_{k-1} | x_k)). \end{aligned} \quad (4.18)$$

固定逆向方差为 $\sigma_k^2 I$ 后, 每个 KL 中依赖均值的项为 $\|\tilde{\mu}_k - \mu_\theta\|^2/(2\sigma_k^2)$ 。利用式(4.11)消去 x_0 , 采用噪声预测参数化

$$\mu_\theta(x_k, k) = \frac{1}{\sqrt{\alpha_k}} \left[x_k - \frac{\beta_k}{\sqrt{1 - \bar{\alpha}_k}} \epsilon_\theta(x_k, k) \right], \quad (4.19)$$

便得到加权噪声回归

$$\mathbb{E} \left[\frac{\beta_k^2}{2\sigma_k^2 \alpha_k (1 - \bar{\alpha}_k)} \|\epsilon - \epsilon_\theta(x_k, k)\|^2 \right]. \quad (4.20)$$

将 $x_0 = (x_k - \sqrt{1 - \bar{\alpha}_k} \epsilon)/\sqrt{\bar{\alpha}_k}$ 代入均值后, x_k 的系数为

$$\frac{\beta_k + \alpha_k(1 - \bar{\alpha}_{k-1})}{\sqrt{\alpha_k}(1 - \bar{\alpha}_k)} = \frac{1 - \bar{\alpha}_k}{\sqrt{\alpha_k}(1 - \bar{\alpha}_k)} = \frac{1}{\sqrt{\alpha_k}}.$$

噪声系数为 $-\beta_k \sqrt{1 - \bar{\alpha}_k}/[\sqrt{\alpha_k}(1 - \bar{\alpha}_k)]$, 约分后等于 $-\beta_k/\sqrt{\alpha_k(1 - \bar{\alpha}_k)}$ 。因此真实与预测均值之差为

$$\tilde{\mu}_k - \mu_\theta = \frac{\beta_k}{\sqrt{\alpha_k(1 - \bar{\alpha}_k)}} (\epsilon_\theta - \epsilon),$$


平方后除以 $2\sigma_k^2$, 恰得式(4.20)。时间权重来自方差与参数化, 不能仅依据“预测噪声”这一名称确定。

DDPM 常用的简化训练目标为

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{x_0, k, \epsilon} \|\epsilon - \epsilon_\theta(x_k, k)\|^2. \quad (4.21)$$

去除时间权重改变了有限容量模型在不同噪声水平之间的优化分配。给定 (x_k, k) 的平方损失最优解为 $\mathbb{E}[\epsilon | x_k, k]$ ；单次加噪使用的随机噪声不必能从噪声图像中唯一恢复。

$$x_k = \sqrt{\bar{\alpha}_k} x_0 + \sqrt{1 - \bar{\alpha}_k} \epsilon, \quad \mathcal{L} = \|\epsilon_\theta(x_k, k) - \epsilon\|^2$$



维度 $x_0, \epsilon, x_k, \hat{\epsilon}$ 具有相同的数据张量形状；时间系数沿非批次轴广播。

目标 训练标签是本次采样的 ϵ ；平方损失的最优函数为条件均值。

图 4.1 DDPM 的直接加噪与噪声预测训练。中间变量通过显式高斯路径构造。

例题 4.2 直接加噪与数据恢复

取标量 $x_0 = 2$ 、 $\bar{\alpha}_k = 0.64$ 、 $\epsilon = -1$ 。计算 x_k ，并在已知真实噪声时恢复 x_0 。

解 $x_k = 0.8 \times 2 + 0.6 \times (-1) = 1$ 。由式(4.11)反解

$$x_0 = \frac{x_k - \sqrt{1 - \bar{\alpha}_k} \epsilon}{\sqrt{\bar{\alpha}_k}} = \frac{1 + 0.6}{0.8} = 2.$$

这一恒等式适用于检查加噪系数、时间索引与批次广播。使用预测噪声时，数据恢复误差为 $-\sqrt{(1 - \bar{\alpha}_k)/\bar{\alpha}_k}(\epsilon_\theta - \epsilon)$ 。

生成时从 $x_K \sim p(x_K)$ 出发，依次采样 $x_{k-1} = \mu_\theta(x_k, k) + \sigma_k z$ ，并根据最终解码分布处理最后一步。DDIM 采用与同类噪声预测模型相容的另一类采样构造；训练目标与采样器需要共同核对，不能只替换循环方向。[26]

实现检查包括 $\bar{\alpha} = 1$ 与接近零时的行为、真实噪声恢复测试、独立时间步的批次广播，以及打乱时间条件后预测误差的变化。所有加噪系数应沿非批次轴广播，保留每个样本各自的时间参数。

4.3 得分函数、随机微分方程与流匹配

连续密度的得分函数定义为 $s_\tau(x) = \nabla_x \log p_\tau(x)$ 。若条件扰动为 $x = a_\tau x_{\text{data}} + \sigma_\tau \epsilon$ ，则

$$\nabla_x \log p_\tau(x | x_{\text{data}}) = -\frac{x - a_\tau x_{\text{data}}}{\sigma_\tau^2} = -\frac{\epsilon}{\sigma_\tau}. \quad (4.22)$$

为连接条件得分与边缘得分，先对边缘密度积分求导。在允许交换积分与微分、且 $p_\tau(x) > 0$ 的位置，

$$\nabla_x \log p_\tau(x) = \frac{\int p(x_0) \nabla_x p_\tau(x | x_0) dx_0}{p_\tau(x)} \quad (4.23)$$

$$= \int \frac{p(x_0) p_\tau(x | x_0)}{p_\tau(x)} \nabla_x \log p_\tau(x | x_0) dx_0 \quad (4.24)$$

$$= \mathbb{E}[\nabla_x \log p_\tau(x | x_0) | x]. \quad (4.25)$$

中间一行的密度比为后验 $p(x_0 | x)$ 。代入高斯扰动的条件得分，得到

$$s_\tau(x) = \mathbb{E}[\nabla_x \log p_\tau(x | x_{\text{data}}) | x] = -\frac{\mathbb{E}[\epsilon | x]}{\sigma_\tau}. \quad (4.26)$$

这将噪声预测与得分估计联系起来。

反向 SDE 与概率流 ODE 设正向时间从数据流向噪声，前向随机微分方程为

$$dx = f(x, \tau) d\tau + g(\tau) dW_\tau.$$

在适当的正则性条件下，其密度满足 Fokker-Planck 方程

$$\partial_\tau p = -\nabla \cdot (fp) + \frac{1}{2} g^2 \Delta p. \quad (4.27)$$

反向 SDE 在递减的 τ 上写为

$$dx = [f - g^2 s_\tau] d\tau + g d\bar{W}_\tau, \quad d\tau < 0. \quad (4.28)$$

若另定义递增的反向时钟 $u = T - \tau$ ，漂移相应写为 $-f + g^2 s_\tau$ 。实现必须先确定时间坐标，避免仅凭公式中的减号确定积分方向。[27]

利用 $ps_\tau = \nabla p$ ，式(4.27)可重写为连续性方程

$$\partial_\tau p = -\nabla \cdot [(f - \frac{1}{2} g^2 s_\tau) p].$$

因此概率流常微分方程为

$$\frac{dx}{d\tau} = f(x, \tau) - \frac{1}{2} g(\tau)^2 s_\tau(x). \quad (4.29)$$

精确得分与相应正则条件下，它与前向 SDE 具有相同的单时刻边缘密度。两者的联合路径分布不同，有限步长数值模拟还会引入各自的离散误差。

条件路径与边缘速度场 流匹配 (Flow Matching) 直接学习确定性输运的速度场。以下重新约定端点: x_0 为噪声, x_1 为数据, 生成方向为 $\tau: 0 \rightarrow 1$ 。采样端点对, 定义线性条件路径

$$x_\tau = (1 - \tau)x_0 + \tau x_1, \quad u_\tau = x_1 - x_0. \quad (4.30)$$

条件流匹配目标为

$$\mathcal{L}_{\text{CFM}} = \mathbb{E}_{x_0, x_1, \tau} \|v_\theta(x_\tau, \tau) - u_\tau\|^2. \quad (4.31)$$

训练样本由显式路径构造, 无需数值积分模型; 生成仍需积分 $dx/d\tau = v_\theta(x, \tau)$ 。最优回归函数为

$$v_\tau(x) = \mathbb{E}[u_\tau | x_\tau = x]. \quad (4.32)$$

同一位置可能来自不同端点对, 因此边缘速度通常随位置和时间变化。线性条件路径并不要求每条边缘流轨迹为直线, 也不自动确定最优输运耦合。[28, 29]




图 4.2 两个等概率条件路径在中间位置相交的示意。回归网络在该位置拟合条件速度的平均。

为了证明边缘速度生成正确的边缘密度, 取光滑、紧支撑测试函数 φ :

$$\begin{aligned} \frac{d}{d\tau} \mathbb{E}[\varphi(x_\tau)] &= \mathbb{E}[\nabla \varphi(x_\tau) \cdot u_\tau] = \int \nabla \varphi(x) \cdot v_\tau(x) p_\tau(x) dx \\ &= - \int \varphi(x) \nabla \cdot (p_\tau v_\tau) dx. \end{aligned} \quad (4.33)$$

由此得到弱形式的连续性方程

$$\partial_\tau p_\tau + \nabla \cdot (p_\tau v_\tau) = 0. \quad (4.34)$$

从该方程进一步得到由 ODE 生成的密度, 需要适当的速度场可积性、解的存在性与唯一性条件。

还需说明使用条件速度标签为何能够训练边缘速度。写 $v_\theta - u = (v_\theta - v_\tau) + (v_\tau - u)$ 并展开平方, 交叉项为

$$\mathbb{E}[(v_\theta - v_\tau)^\top (v_\tau - u)] \quad (4.35)$$

$$= \mathbb{E}_{x_\tau, \tau} [(v_\theta - v_\tau)^\top \mathbb{E}[v_\tau - u | x_\tau, \tau]] = 0. \quad (4.36)$$

最后一步使用 $v_\tau = \mathbb{E}[u \mid x_\tau, \tau]$ 。因此

$$\mathbb{E}\|v_\theta - u\|^2 = \mathbb{E}\|v_\theta - v_\tau\|^2 + \mathbb{E}\|u - v_\tau\|^2. \quad (4.37)$$

右侧第二项与 θ 无关，所以可采样的条件回归与不可直接取得标签的边缘速度回归具有相同参数梯度。这里“条件”指路径端点；文本、类别或动作等外部条件 c 可以额外加入速度网络 $v_\theta(x, \tau, c)$ 。

线性路径上也可写 $u_\tau = (x_1 - x_\tau)/(1 - \tau)$ 。该表达在终点具有显式奇异分母；实现中直接使用 $x_1 - x_0$ 可避免不必要的数值除法。

例题 4.3 高斯端点的边缘速度

设 $x_0 \sim \mathcal{N}(0, 1)$, $x_1 \sim \mathcal{N}(m, s^2)$ ，端点相互独立。求线性路径的边缘密度与速度场。

解 令 $q_\tau = (1 - \tau)^2 + \tau^2 s^2$ ，则 $x_\tau \sim \mathcal{N}(\tau m, q_\tau)$ 。又有 $\mathbb{E}[u] = m$ 与 $\text{Cov}(u, x_\tau) = \tau s^2 - (1 - \tau)$ 。高斯条件均值公式给出

$$v_\tau(x) = m + \frac{\tau s^2 - (1 - \tau)}{q_\tau}(x - \tau m). \quad (4.38)$$

当 $m = 0, s = 1$ 时，两个端点具有相同分布，但中间方差为 $(1 - \tau)^2 + \tau^2$ ，在 $\tau = 1/2$ 处降至 $1/2$ 。相同端点分布并不唯一确定中间路径。

得分与速度的参数化关系 考虑更一般的高斯路径 $x_\tau = a_\tau x_1 + b_\tau \epsilon$ ，其中 $\epsilon \sim \mathcal{N}(0, I)$ 。对固定 τ ，条件得分为 $-(x - a_\tau x_1)/b_\tau^2$ 。先取给定 x 的条件期望，再整理：

$$b_\tau^2 s_\tau(x) = -x + a_\tau \mathbb{E}[x_1 \mid x].$$

同时 $\epsilon = (x - a_\tau x_1)/b_\tau$ 。分别解出两个条件均值，得到

$$\mathbb{E}[x_1 \mid x] = \frac{x + b_\tau^2 s_\tau(x)}{a_\tau}, \quad \mathbb{E}[\epsilon \mid x] = -b_\tau s_\tau(x).$$

路径导数为 $\dot{x}_\tau = \dot{a}_\tau x_1 + \dot{b}_\tau \epsilon$ 。取条件期望后逐项代入上述结果：

$$v_\tau(x) = \dot{a}_\tau \frac{x + b_\tau^2 s_\tau(x)}{a_\tau} - \dot{b}_\tau b_\tau s_\tau(x).$$

合并得分项，在 $a_\tau \neq 0$ 且条件得分有定义的区间内，

$$v_\tau(x) = \frac{\dot{a}_\tau}{a_\tau} x + \left(\frac{\dot{a}_\tau b_\tau^2}{a_\tau} - \dot{b}_\tau b_\tau \right) s_\tau(x). \quad (4.39)$$

端点需单独处理。噪声、数据、得分和速度预测之间的转换依赖同一概率路径及其系数；改变损失权重后，有限模型的拟合结果也可能变化。

4.4 数值积分、条件引导与潜空间架构

对于 ODE $\dot{x} = v_\theta(x, \tau)$, Euler 更新为

$$x_{n+1} = x_n + h v_\theta(x_n, \tau_n). \quad (4.40)$$

Heun 方法先计算预测点, 再平均两次速度:

$$\tilde{x} = x_n + h v_\theta(x_n, \tau_n), \quad x_{n+1} = x_n + \frac{h}{2} [v_\theta(x_n, \tau_n) + v_\theta(\tilde{x}, \tau_n + h)]. \quad (4.41)$$

由精确解的 Taylor 展开,

$$x(\tau + h) = x + h v + \frac{h^2}{2} (\partial_\tau v + J_v v) + O(h^3).$$

Euler 只保留前两项, 单步截断误差为 $O(h^2)$ 。在 Heun 的第二次速度评估中展开 $v(x + h v, \tau + h) = v + h(\partial_\tau v + J_v v) + O(h^2)$, 可见其更新保留了二阶项, 单步误差为 $O(h^3)$ 。有限区间内约有 $1/h$ 步; 结合 Lipschitz 稳定性估计, 得到下面的全局阶数。适当光滑条件下, 固定积分区间的全局离散误差分别为 $O(h)$ 和 $O(h^2)$ 。网络误差、训练分布覆盖及终点奇异性可能主导实际结果。比较采样器时, 应报告网络函数评估次数 (NFE); 一次 Heun 步通常需要两次速度评估。

例题 4.4 相同步数下的 Euler 与 Heun

求解 $\dot{x} = -x$, $x(0) = 1$, 积分至 $\tau = 1$, 使用 10 个等长步。

解 精确值为 $e^{-1} \approx 0.36787944$ 。Euler 递推乘子为 0.9, 故 $x_{10} = 0.9^{10} \approx 0.34867844$; Heun 乘子为 $1 - 0.1 + 0.1^2/2 = 0.905$, 故 $x_{10} = 0.905^{10} \approx 0.36854098$ 。两种方法的 NFE 分别为 10 与 20, 该比较固定了步数, 尚未固定计算预算。




图 4.3 解析方程 $\dot{x} = -x$ 的数值积分。曲线由递推公式计算, 不涉及模型训练。

无分类器引导 无分类器引导 (CFG) 训练时以一定概率将条件替换为预先定义的空条件, 使同一模型同时估计有条件与无条件预测。以得分为例, 采用

$$s_w(x, \tau, c) = s_\emptyset(x, \tau) + w [s_c(x, \tau) - s_\emptyset(x, \tau)]. \quad (4.42)$$

取 $w = 0$ 表示无条件预测, $w = 1$ 表示普通条件预测。部分代码使用另一种偏移后的系数, 需要依据实际公式换算。[30]

Bayes 公式给出 $s_c - s_\emptyset = \nabla_x \log p_\tau(c | x)$ 。在固定时刻, s_w 对应形式密度 $p_\tau(x)^{1-w} p_\tau(x | c)^w$ 的对数梯度, 只要其归一化存在。然而, 一组逐时刻形式密度未必与修改后的整条生成动力学一致, 不能由此直接确定最终采样分布。较大的 w 也可能降低多样性或放大条件预测误差。

若速度与得分的变换在条件分支间具有相同系数, 则可采用 $v_w = v_\emptyset + w(v_c - v_\emptyset)$ 。应在同一参数化下进行线性组合, 不应直接将噪声预测与速度预测相加。空条件的定义、训练丢弃概率与推理输入必须一致。

潜空间扩散与 DiT 潜空间生成首先通过编码器 E 将图像映射为 $z = E(x)$, 在潜变量上训练生成过程, 最后用解码器 D 还原。潜空间缩放常数需在训练、采样和解码中一致; 若训练使用 $\tilde{z} = cz$, 解码应使用 $D(\tilde{z}/c)$ 。编码器丢失的信息无法仅靠潜变量的生成精度恢复。[31]

扩散 Transformer (DiT) 将潜变量 $X \in \mathbb{R}^{B \times C \times H \times W}$ 分成边长为 p 的图像块:

$$X \longrightarrow P \in \mathbb{R}^{B \times N \times C p^2} \longrightarrow Z \in \mathbb{R}^{B \times N \times d}, \quad N = \frac{HW}{p^2}. \quad (4.43)$$

输出投影与逆分块恢复与训练目标相同的张量形状。时间或条件向量可通过自适应层归一化的平移、缩放与残差门控注入; 文本条件也可通过交叉注意力输入, 其中图像 token 产生查询, 文本 token 产生键和值。具体配置需按模型定义核对。[32]

普通全注意力的得分张量具有 $B \times h \times N \times N$ 的形状, 显式存储量为 $O(BhN^2)$ 。前馈网络的主要计算量约为 $O(BNd^2)$ 。高效注意力实现可以降低中间矩阵的实际存储, 不改变全连接注意力的语义; 复杂度与实测显存应分别报告。

实现与实验可以依次检查潜变量重建、目标参数化、时间采样、条件丢弃、采样方向和逆分块。比较模型容量、采样器或 CFG 时, 每次只改变指定变量, 并固定数据划分与生成种子。降低训练损失、改善生成分布与增强条件依赖应分别测量。

连续流的密度变化 对足够光滑且可逆的 ODE 流, 连续性方程为 $\partial_\tau p + v \cdot \nabla p + p \nabla \cdot v = 0$ 。沿轨迹 x_τ 使用链式法则:

$$\frac{d}{d\tau} \log p_\tau(x_\tau) = \partial_\tau \log p_\tau + v \cdot \nabla \log p_\tau \quad (4.44)$$

$$= -\nabla \cdot v_\theta(x_\tau, \tau). \quad (4.45)$$

因此 $\log p_1(x_1) = \log p_0(x_0) - \int_0^1 \nabla \cdot v_\theta(x_\tau, \tau) d\tau$ 。线性例 $v(x) = ax$ 给出 $x_1 = e^a x_0$ 、 $\log p_1(x_1) = \log p_0(x_0) - a$, 与普通变量变换一致。速度回归损失、生成采样和密度评估由不同计算组成。

高维散度可用随机向量 ξ 的迹估计: 若 $\mathbb{E}[\xi \xi^\top] = I$, 则 $\mathbb{E}[\xi^\top J_v \xi] = \text{tr } J_v$ 。这需要 Jacobian-向量乘积并引入额外方差。只训练流匹配并不要求每步计算散度; 概率流密度评估需要另行承担该计算。

时间采样也决定目标权重。若期望为 $\int_0^1 w(\tau)\ell(\tau)d\tau$, 改用密度 $q(\tau) > 0$ 采样可用 $w(\tau)\ell(\tau)/q(\tau)$ 保持同一目标。未作修正的时间重采样改变优化分配。训练图像、视频和动作模型时, 均应保存时间分布、参数化、潜变量尺度与采样器配置; CMU 10-799 的训练目标与求解器内容以这一接口相连接。[4, 29]

4.5 流映射与少步生成

学习速度场以后, 生成样本仍需多次数值积分。另一类方法直接近似有限时间内的流映射, 或近似一条轨迹到目标端点的映射。CMU 2026 的蒸馏课程将一致性模型与流映射放在同一框架下讨论。[77, 95]

记 $\Phi_{s,t}(x)$ 为在时间 s 从位置 x 出发、沿同一速度场积分到 t 的结果。存在唯一解时, 先积分到中间时刻再继续积分, 与直接积分到终点相同:

$$\Phi_{s,t} = \Phi_{u,t} \circ \Phi_{s,u}, \quad \Phi_{t,t} = \text{id}. \quad (4.46)$$

在本章噪声到数据的时间约定下, 定义端点映射 $f(x, \tau) = \Phi_{\tau,1}(x)$ 。沿轨迹应用链式法则,

$$f(x_\tau, \tau) = x_1, \quad (4.47)$$

$$0 = \frac{d}{d\tau} f(x_\tau, \tau) = \partial_\tau f(x_\tau, \tau) + J_x f(x_\tau, \tau) v(x_\tau, \tau). \quad (4.48)$$

边界条件为 $f(x, 1) = x$ 。它可通过参数化 $f_\theta(x, \tau) = x + (1 - \tau)F_\theta(x, \tau)$ 精确满足。采用其他时间方向或非零数据端点时, 应相应修改边界。

从轨迹约束到训练目标 使用固定教师速度场, 把 x_τ 积分一小步至 $\hat{x}_{\tau+h}$ 。由流映射的组合性质, 两点的终点映射应相同, 故可训练

$$\mathcal{L}_{\text{distill}} = \mathbb{E} \left[w(\tau, h) \|f_\theta(x_\tau, \tau) - \text{sg}(f_\theta(\hat{x}_{\tau+h}, \tau + h))\|^2 \right]. \quad (4.49)$$

其中 $\bar{\theta}$ 是目标网络参数。教师的积分误差、速度误差和端点映射的近似误差分别影响目标。应先验证解析速度场上的流映射, 再比较相同 NFE 下的生成误差; 单步输出和教师多步输出的接近程度需要单独报告。

条件流匹配使用的端点插值通常不能直接作为教师 ODE 轨迹。两者具有相同的单时刻边缘密度, 但同一随机样本在不同时刻的耦合可以不同。式(4.48)约束的是同一 ODE 轨迹上的值, 训练配对必须与所用方法的推导一致。

例题 4.5 相同端点分布下的流映射

令式(4.38)中 $m = 0, s = 1$ ，并记 $q_\tau = (1 - \tau)^2 + \tau^2$ 。求 $\Phi_{s,t}$ 与 $f(x, \tau)$ 。


解 速度为 $v_\tau(x) = \dot{q}_\tau x / (2q_\tau)$ 。对非零轨迹积分，

$$\log \left| \frac{x_t}{x_s} \right| = \int_s^t \frac{\dot{q}_\tau}{2q_\tau} d\tau = \frac{1}{2} \log \frac{q_t}{q_s}.$$

零轨迹也满足连续延拓，所以 $\Phi_{s,t}(x) = \sqrt{q_t/q_s} x$ ， $f(x, \tau) = x/\sqrt{q_\tau}$ 。一条条件直线可取端点 $x_0 = 1, x_1 = -1$ ，它在中点经过零；这条直线上的 f 并非常数。对应的边缘 ODE 从正初值出发始终保持正号。

$$q_t = (1 - t)^2 + t^2, \quad v_t(x) = \frac{2t-1}{q_t} x$$

— 概率流 ODE: $x_t = \sqrt{q_t}$
 - - 条件路径: $x_0 = 1, x_1 = -1$



条件 端点独立采样于 $\mathcal{N}(0, 1)$ ，时间方向为噪声端 0 到数据端 1。

对象 条件路径由一对端点确定；ODE 速度是给定当前位置后的条件平均速度。

结果 两种过程可具有相同的单时刻边缘分布，同时保留不同的轨迹耦合。

图 4.4 条件插值路径与概率流轨迹。图中的条件路径经过零点；从 $x_0 = 1$ 出发的解析 ODE 轨迹始终为正。

4.6 离散状态扩散与掩码生成

文字 token 和离散动作类别属于有限状态空间。直接在整数 ID 上加高斯噪声，会引入依赖编号的距离。离散扩散改用类别间的马尔可夫转移；掩码扩散则把部分位置转移到专门的吸收状态。
 [78, 96]

设类别集合为 $\{1, \dots, V\}$, $Q_k(i, j) = q(x_k = j \mid x_{k-1} = i)$ 。采用行概率约定, Q_k 的元素非负且每行和为一。令 $\bar{Q}_k = Q_1 \cdots Q_k$, 由全概率公式,

$$q(x_k = j \mid x_0 = i) = \sum_l q(x_{k-1} = l \mid x_0 = i) Q_k(l, j) \quad (4.50)$$

$$= \bar{Q}_k(i, j). \quad (4.51)$$

条件后验也可精确计算。固定端点 i, j , 先写联合概率, 再除以边缘概率:

$$q(x_{k-1} = l \mid x_k = j, x_0 = i) = \frac{\bar{Q}_{k-1}(i, l) Q_k(l, j)}{\bar{Q}_k(i, j)}. \quad (4.52)$$

该式仅适用于分母为正的条件事件。对 l 求和时, 分子之和恰为分母, 因此后验归一化。

模型可以预测干净类别的条件分布 $p_\theta(x_0 = i \mid x_k = j)$, 再构造反向核:

$$p_\theta(x_{k-1} = l \mid x_k = j) = \sum_i q(x_{k-1} = l \mid x_k = j, x_0 = i) p_\theta(x_0 = i \mid x_k = j). \quad (4.53)$$

求和必须限制在前向可达的 i 上, 预测分布也应在这集合内归一化。不能给不可能的条件事件任意指定后验, 然后仍将结果解释为 Bayes 反转。


吸收掩码的后验 额外引入掩码状态 m , 每一步以概率 β_k 将尚未掩码的 token 变成 m , 掩码状态保持不变。记 $\kappa_k = \prod_{r=1}^k (1 - \beta_r)$ 为保留概率。给定干净类别 i 和 $x_k = m$, 上一步只有两种可能:

$$q(x_{k-1} = i \mid x_k = m, x_0 = i) = \frac{\kappa_{k-1} \beta_k}{1 - \kappa_k}, \quad (4.54)$$

$$q(x_{k-1} = m \mid x_k = m, x_0 = i) = \frac{1 - \kappa_{k-1}}{1 - \kappa_k}. \quad (4.55)$$

前者表示本步才被掩码, 后者表示此前已经被掩码。两项相加为一。对已知未被掩码的位置, 原类别可直接保留; 对掩码位置, 模型依据可见上下文估计干净 token。训练损失的时间权重和推理解掩码次序属于具体方法定义。任意置信度排序或重复重掩码都会改变有限步采样过程, 需单独评价。

$$q(x_1 \mid x_2 = m, x_0 = a) = \text{Normalize}(\bar{Q}_1[a, :] \odot Q_2[:, m]^\top)$$



维度 三个分量依次表示前一时刻的状态 a, b, m ; m 为吸收状态。

对象 左侧为先验状态概率与当前观测的似然。乘积总和为 0.6。

边界 条件事件概率为零时, 后验未定义; 添加小常数会改变原概率模型。

图 4.5 离散扩散反向核的一次 Bayes 更新。先相乘得到未归一化概率, 再沿前一时刻状态轴归一化。

连续时间的转移率 对于行概率 p_t ，设转移率矩阵 R_t 的非对角元素非负，且 $R_t(i, i) = -\sum_{j \neq i} R_t(i, j)$ 。小时间间隔满足 $Q_{t, t+h} = I + hR_t + o(h)$ ，于是

$$\dot{p}_t = p_t R_t, \quad \dot{p}_t(j) = \sum_{i \neq j} p_t(i) R_t(i, j) - p_t(j) \sum_{i \neq j} R_t(j, i). \quad (4.56)$$

右侧分别表示流入和流出概率。固定递增反向时钟 $u = T - t$ ，对 $i \neq j$ ，Bayes 公式给出

$$R_u^{\text{rev}}(j, i) = \frac{p_t(i) R_t(i, j)}{p_t(j)}, \quad p_t(j) > 0. \quad (4.57)$$

具体地，先对一段长度为 h 的反向转移应用 Bayes 公式。对 $i \neq j$ ，

$$\Pr(X_{t-h} = i | X_t = j) = \frac{p_{t-h}(i) \Pr(X_t = j | X_{t-h} = i)}{p_t(j)} \quad (4.58)$$

$$= h \frac{p_t(i) R_t(i, j)}{p_t(j)} + o(h). \quad (4.59)$$

其中使用了 $p_{t-h}(i) = p_t(i) + O(h)$ 与非对角转移概率 $hR_t(i, j) + o(h)$ 。除以 h 并取极限，即得式(4.57)。随后通过负行和定义反向转移率矩阵的对角元素。离散流匹配也通过转移率控制概率变化，但其条件路径与训练目标需要重新推导；连续速度场的向量加法不能直接用于类别 ID。[79]

实现时，先在三状态系统中枚举联合概率，验证式(4.52)与反向核的归一化。再测试吸收状态、零概率事件以及一个大时间步导致 $I + hR$ 出现负元素的情况。最后才引入长序列掩码网络。

4.7 课后习题

习题 4.1 高斯前向链、后验配方与训练权重

一维 DDPM 的两步前向链满足 $x_k = \sqrt{\alpha_k} x_{k-1} + \sqrt{\beta_k} \varepsilon_k$ ，其中 $\alpha_k = 1 - \beta_k$ 、 $\varepsilon_1, \varepsilon_2$ 独立标准正态， $\beta_1 = 0.1, \beta_2 = 0.2$ 。

- 逐步代入得到 x_2 关于 $x_0, \varepsilon_1, \varepsilon_2$ 的表达式。求条件均值和方差，并说明为什么可以将两项噪声合并为一个标准高斯变量。
- 从 $q(x_2 | x_1)q(x_1 | x_0)$ 的指数项开始，收集 x_1 的二次项和一次项，完成配方。给出 $q(x_1 | x_2, x_0)$ 的参数，并计算 $x_0 = 1, x_2 = 0$ 的结果。
- 设逆向方差固定为真实后验方差。用噪声预测参数化逆向均值，把两个高斯之间的 KL 写成噪声 MSE。逐步求出本题第二步的权重。
- 从路径联合概率推导扩散的变分下界，说明第二步 KL、第一步解码项和终端先验项各来自哪一项。第一步后验方差为零时，为什么不能直接把上一问的公式延用到 $k = 1$ ？
- 编程：实现直接加噪、后验参数和加权噪声目标。用相同噪声检查重建恒等式；用独立采样检查条件矩。分别测试批次时间索引、时间端点以及预测真噪声时的均值误差。

习题 4.2 条件流匹配的最优速度与一致性映射

独立端点为 $X_0 \sim \mathcal{N}(0, 1)$ 、 $X_1 \sim \mathcal{N}(m, s^2)$ ，其中 $s > 0$ 。训练路径为 $X_t = (1-t)X_0 + tX_1$ ，目标速度为 $U = X_1 - X_0$ ， $t \in [0, 1]$ 。

- 求 X_t 的均值 μ_t 、方差 q_t 以及 $\text{Cov}(U, X_t)$ 。由高斯条件分布求平方损失的最优速度 $v^*(x, t)$ 和给定 X_t 后的不可约回归误差。
- 令 $Y_t = (x_t - tm)/\sqrt{q_t}$ 。对 ODE $\dot{x}_t = v^*(x_t, t)$ 逐项求导，证明 Y_t 不变，并求任意两个时刻间的流映射 $\Phi_{a,b}(x)$ 。
- 取 $m = 0, s = 1$ 。计算 $t = 1/2$ 时的速度和边缘方差，并比较训练中连接端点 $(X_0, X_1) = (1, -1)$ 的直线与从 $x_0 = 1$ 出发的 ODE 轨迹。解释为什么条件路径上的点不能直接当作同一 ODE 轨迹的配对点。
- 求从时刻 t 映射到数据端点的一致性函数 $f(x, t)$ 。直接验证边界条件及 $\partial_t f + v^* \partial_x f = 0$ 。若只约束相邻时刻输出相同而不设边界条件，会出现什么退化解？
- 编程：实现解析速度、流映射和一致性函数。验证组合律 $\Phi_{b,c} \circ \Phi_{a,b} = \Phi_{a,c}$ ；比较相同 NFE 下 Euler 与 Heun 的点态误差。另训练小网络拟合条件速度，分别评估回归误差和终点分布误差。

习题 4.3 吸收态扩散的反向概率

状态空间为 $\{a, b, \text{mask}\}$ ，数据概率为 $(0.4, 0.6, 0)$ 。前向过程只允许 a, b 转为吸收态。第一步后保留原符号的概率为 $\kappa_1 = 0.8$ ，第二步后为 $\kappa_2 = 0.4$ 。

- 写出每一步的行随机转移矩阵 Q_1, Q_2 与累积矩阵 $\bar{Q}_2$ ，验证各行和为 1。第二步的条件存活概率与 κ_2 有何关系？
- 给定 $X_0 = a, X_2 = \text{mask}$ ，从 Bayes 公式计算 X_1 的后验。再去掉 X_0 条件，求 $p(X_1 | X_2 = \text{mask})$ 。
- 设网络预测 $p_\theta(X_0 | X_2)$ 。写出通过该预测混合精确条件后验的反向核。给出后验分母为零的输入，并说明程序应如何处理其支持。
- 将前向过程改为连续时间， a, b 以相同速率 λ 转为 mask 。写出生成矩阵 R 、精确存活概率和反向时间中的非零速率。分析 $I + \Delta t R$ 何时不是概率矩阵。
- 编程：实现有限状态后验与反向混合。比较枚举联合概率的参考实现，覆盖零概率事件。再比较矩阵指数与 Euler 一步，并检验反向核的非负性和归一化。

第 5 章 视频生成与自回归建模

视频生成需要同时处理时间压缩、空间结构和条件一致性。本章分析时空自编码器、视频 Transformer、首帧条件以及自回归训练，并建立可检验的短视频实验。

5.1 视频表示、时间压缩与生成条件

视频张量可写为 $X \in \mathbb{R}^{B \times C \times F \times H \times W}$ ，其中 F 为帧数。帧索引表示数组中的位置，时间戳表示实际采样时间。非均匀采样、可变帧率及不同播放速率要求显式区分这两项量。

视频预测通常具有条件不确定性。例如，同一首帧中的物体可能向相反方向运动。在平方像素损失下，确定性模型的最优输出为各像素的条件均值，多种轨迹的平均可能形成分散的像素分布。概率生成模型通过随机变量表示多种未来；评价时应同时测量单次样本的时序一致性与条件分布的覆盖。

视频 VAE 在时间与空间上压缩数据。以 Wan 报告的一个配置为例，空间压缩率为 8，潜变量通道数为 16，时间压缩率为 4，并对首帧单独计数。对于 $F = 1 + 4k$ ，形状为

$$B \times 3 \times (1 + 4k) \times H \times W \longrightarrow B \times 16 \times (1 + k) \times \frac{H}{8} \times \frac{W}{8}. \quad (5.1)$$

这里要求相应空间尺寸满足模型的输入对齐条件。时间因果卷积控制编码器可使用的帧范围；潜变量仍可能依赖多个历史帧，不能将其解释为互不相关的单帧编码。[33]




图 5.1 Wan 视频 VAE 的形状变换。输入帧数和空间尺寸需满足对应配置的对齐条件。

例题 5.1 视频 token 数与注意力规模

输入视频包含 81 帧，分辨率为 256×256 。采用式(5.1)的压缩方式，并在潜空间使用 $1 \times 2 \times 2$ 的视频块。求潜变量形状与 token 数。

解 省略批次维度，潜变量为 $16 \times 21 \times 32 \times 32$ 。分块后

$$N = \frac{21}{1} \frac{32}{2} \frac{32}{2} = 5376, \quad N^2 = 28\,901\,376.$$

每个注意力头的完整得分矩阵含约 2.89×10^7 个元素。此计数只描述得分矩阵规模，实际内存还取决于数据类型、批次、头数及注意力实现。

文本到视频与图像到视频 文本到视频 (T2V) 对文本条件生成视频；图像到视频 (I2V) 还约束初始图像或指定图像。Wan 使用视频扩散 Transformer，训练目标采用流匹配，并结合文本与图像条件机制。其 I2V 系统包含图像特征、首帧相关潜变量及条件掩码等结构，具体输入方式需与对应配置一致。[33]

小规模实验可将首帧作为独立条件，仅生成后续帧，或在联合生成中约束已知区域。对后者，已知区域在中间时刻应与同一噪声路径相容；若未知区域处于噪声状态而未知区域始终替换为无噪声真值，输入分布会偏离按该路径定义的联合状态。训练目标、条件通道和推理约束必须共同定义。

Wan2.2 的模型配置 Wan2.2 的 A14B 视频模型采用按噪声水平选择的高噪声与低噪声专家。其路由变量为去噪时间或与时间对应的噪声水平，区别于按 token 内容选择专家的路由机制。切换阈值属于推理配置，必须与实际调度器的时间参数一致。[3, 99]

同系列 TI2V-5B 使用另一套稠密模型配置，并配有时间压缩率为 4、空间压缩率为 16×16 的 Wan2.2-VAE。A14B 的专家结构与 5B 的 VAE 配置应分别记录。[100] 对首帧单独处理、随后每四帧形成一个潜时间位置的输入 $F = 1 + 4k$ ，潜网格为 $(1 + k) \times (H/16) \times (W/16)$ ；额外的视频分块决定最终 token 数。任意帧数下还需按预处理定义记录填充或截断，不能无条件使用 $F/4$ 。

与空间压缩率为 8×8 的配置比较，保持帧数和潜空间分块方式相同， 16×16 压缩使空间 token 数减少至四分之一。全注意力的 token 对数随之减少至十六分之一；这是计数关系，整体时延仍取决于通道宽度、模型规模和实现。

5.2 视频块、注意力结构与时间因果性

令视频块尺寸为 (p_f, p_h, p_w) ，并设 $F = F'p_f$ 、 $H = H'p_h$ 、 $W = W'p_w$ 。分块包含明确的轴变换：

$$\begin{aligned} B \times C \times F \times H \times W &\rightarrow B \times C \times F' \times p_f \times H' \times p_h \times W' \times p_w \\ &\rightarrow B \times F' \times H' \times W' \times C \times p_f \times p_h \times p_w \\ &\rightarrow B \times N \times (Cp_fp_hp_w), \quad N = F'H'W'. \end{aligned} \quad (5.2)$$

第二步是轴置换，第三步才合并相邻维度。直接对原始内存作一次 `reshape` 通常不会保持所需的视频块内部顺序。逆变换应逐步撤销这些操作。

例题 5.2 小规模视频的分块

视频形状为 $B \times 1 \times 8 \times 16 \times 16$ ，视频块为 $1 \times 4 \times 4$ 。求分块结果，并给出顺序检查方法。

解 $N = 8 \times 4 \times 4 = 128$ ，每块含 16 个像素，结果为 $B \times 128 \times 16$ 。令原始元素值为 $x[f, h, w] = 256f + 16h + w$ ，则每个位置具有唯一整数编码。对分块和逆分块作往返计算，要求所有位置与数值完全相同。这项测试同时检查时间、行列与块内坐标。

视频 Transformer 可以使用全时空注意力、分解时空注意力或块级因果注意力。位置编码需指定时间与空间轴的含义，文本交叉注意力需保留视频查询与文本键值的维度关系。计算复杂度取决于实际可访问的 token 对，不能仅由网络名称确定。

分解注意力的计算量 设压缩后有 F' 个时间位置，每个时间位置有 S 个空间 token。全时空注意力包含 $(F'S)^2$ 个查询-键对。若先在每帧内作空间注意力，再在每个空间位置作时间注意力，则两步的配对数为

$$F'S^2 + S(F')^2 = F'S(F' + S). \quad (5.3)$$

前一项由 F' 个 $S \times S$ 矩阵组成；后一项由 S 个 $F' \times F'$ 矩阵组成。两次运算之间有轴置换，但 token 总数不变。分解结构限制了单层的信息交互形式，不能仅根据较低计数推断它与全注意力具有相同表示能力。ViViT 和视频扩散课程中的时空分解结构提供了比较这一设计的实例。[81]

例题 5.3 时间采样的不可识别性

设连续运动为 $x(t) = \sin(2\pi ft)$ ，只在 $t = n\Delta$ 观察位置。频率 f 与 $f + k/\Delta$ 是否可由这些样本区分？

解 对任意整数 k, n ,

$$\sin[2\pi(f + k/\Delta)n\Delta] = \sin(2\pi fn\Delta + 2\pi kn) = \sin(2\pi fn\Delta).$$

因此样本完全相同。恢复高频运动需要更密集采样、不同采样时刻或额外先验。保持相同视觉 token 总数而改变帧数，会同时改变可分辨的时间变化范围。

需要分别定义三种时间依赖：视频 VAE 的时间因果性约束编码感受野；联合扩散或流模型在一次去噪中可以同时访问未来帧的当前噪声表示；自回归模型按照视频块分解联合分布

$$p(X_{1:K} | c) = \prod_{k=1}^K p(X_k | X_{<k}, c). \quad (5.4)$$

这些机制作用于不同计算阶段，可以在同一系统中同时出现。说明“因果模型”时，应明确指代的模块、变量与允许的信息范围。

5.3 自回归训练与 Self Forcing

教师强制训练使用真实历史 $X_{<k}$ 预测下一个视频块。部署时，模型可能使用先前生成的历史 $\hat{X}_{<k}$ 。两种条件分布不同，前序误差会影响后续状态。

Self Forcing 在训练中执行自回归生成，将模型生成的历史反馈给后续生成步骤，并对产生的视频序列施加分布匹配目标。报告包含少步生成、KV cache、截断梯度等计算处理，并讨论分布匹配蒸馏（DMD）、Score Identity Distillation（SiD）和对抗式目标（GAN）等具体选择。理解方法时需要同时跟踪生成历史、监督来源与梯度边界。[34]




图 5.2 自回归训练中的历史来源。Self Forcing 还需配合明确的视频分布目标与梯度截断方案。

设训练样本的真实历史与模型生成历史已出现差异，原始数据中的后续视频未必仍是后者的有效条件样本。因此，将任意生成历史与原始配对未来直接做像素回归，需要额外论证该监督关系。仅向真实历史加入独立噪声，也不保证覆盖模型自身生成误差的分布。

KV cache 保存历史注意力的键和值，可减少重复计算。它的内容由网络状态与输入历史确定；是否足以支持物理预测取决于表征与训练目标。交互系统在获得真实新观测后，还需要明确缓存保留、替换或更新的规则。

例题 5.4 历史误差下的条件目标

一维物体按 $x_{k+1} = x_k + v$ 运动。真实位置为 $x_k = 3$ ，速度 $v = 1$ ；模型生成的历史末位置为 $\hat{x}_k = 2.5$ 。比较真实数据下一位置与该生成状态对应的动力学下一位置。

解 真实下一位置为 4；从生成状态继续演化得到 3.5。若把生成状态 2.5 与原配对目标 4 组合，目标隐含的位移变为 1.5。采用这种训练对时，需要说明该损失意在纠正状态误差、匹配数据分布还是学习局部动力学，并据此选择监督定义。

自生成历史下的梯度 令 $\widehat{X}_k = G_\theta(\epsilon_k, \widehat{X}_{<k}, c)$ 。对序列损失 $L(\widehat{X}_{1:K})$ ，完整链式导数含直接生成项和历史依赖项：

$$\frac{d\widehat{X}_k}{d\theta} = \frac{\partial G_\theta}{\partial \theta} + \sum_{j < k} \frac{\partial G_\theta}{\partial \widehat{X}_j} \frac{d\widehat{X}_j}{d\theta}. \quad (5.5)$$

这一递推来自全微分： $d\widehat{X}_k = (\partial G / \partial \theta) d\theta + \sum_{j < k} (\partial G / \partial \widehat{X}_j) d\widehat{X}_j$ 。逐时间步代入即可展开所有早期参数路径。停止历史梯度把相应 $d\widehat{X}_j$ 置为零，但前向仍使用同一生成值。训练输入分布与梯度截断方式是两项独立选择。Self Forcing 使用的少步采样与分布匹配蒸馏需要教师监督，其成本不能由普通下一帧重建实验替代。[34]

例题 5.5 历史梯度截断的影响

令 $\hat{x}_1 = \theta\epsilon$ 、 $\hat{x}_2 = \theta\hat{x}_1$ ，损失为 $\frac{1}{2}\hat{x}_2^2$ 。比较完整梯度与对 $\hat{x}_1$ 停止梯度的结果。

解 完整前向为 $\hat{x}_2 = \theta^2\epsilon$ ，梯度为 $2\theta^3\epsilon^2$ 。停止历史梯度时 $\partial\hat{x}_2/\partial\theta = \hat{x}_1$ ，梯度为 $\theta^3\epsilon^2$ 。两种前向值相同，更新目标的梯度不同。

一步目标与多步目标 对标量真实动力学 $x_{t+1} = ax_t$ ，用模型 $\hat{x}_{t+1} = \theta\hat{x}_t$ ，并固定初始分布 $\mathbb{E}[x_0^2] = \sigma_x^2$ 。一步回归风险为 $L_1 = (\theta - a)^2\sigma_x^2$ 。第 H 步自由预测的风险则为

$$L_H = \mathbb{E}[(\theta^H x_0 - a^H x_0)^2] = (\theta^H - a^H)^2 \sigma_x^2, \quad (5.6)$$

$$\frac{dL_H}{d\theta} = 2H\theta^{H-1}(\theta^H - a^H)\sigma_x^2. \quad (5.7)$$

同一个局部误差在不同 H 下产生不同风险与梯度。当 $|a| > 1$ 时，多步误差可迅速放大；当 $\theta = 0, H > 1$ 时，末步损失的梯度可能为零。加入中间步损失可改变这种优化退化，但不能由一步训练误差直接确定长视频质量。

已知首帧的相容噪声路径 令已知区域掩码为 M 、真实已知内容为 X^* ，线性流时间约定为噪声到数据。已知区域的中间状态应为 $M \odot [(1 - \tau)\epsilon + \tau X^*]$ ，其速度为 $M \odot (X^* - \epsilon)$ 。只有在终点 $\tau = 1$ ，它与干净真值完全一致。首帧作为额外无噪声条件输入属于另一种条件架构，两种输入方式需分别定义和训练。

5.4 条件依赖与视频评估

可控小球数据集应同时保存图像、真实状态、动作、时间戳及轨迹标识。运动规律需明确边界反射、周期边界或终止条件，并按完整轨迹划分训练与验证集，避免相邻帧泄漏到不同集合。

首先验证模型能拟合一个固定小批量，再扩展到训练分布。生成实验至少保留无条件或空条件、正确条件、打乱条件和反向运动条件。固定初始噪声可以减少配对比较中的采样差异。模型是否使用条件，需要由这些干预对生成结果的影响确定。

对于非负单物体图像 I_{ij} ，可以用质心估计位置：

$$\hat{x} = \frac{\sum_{i,j} j I_{ij}}{\sum_{i,j} I_{ij} + \varepsilon}, \quad \hat{y} = \frac{\sum_{i,j} i I_{ij}}{\sum_{i,j} I_{ij} + \varepsilon}. \quad (5.8)$$

若总亮度为零，位置不可定义，应输出无效标记。对正亮度，分母中的 ε 会使质心轻微偏向坐标原点；可先用亮度阈值判定有效性，再对有效图像使用原始总亮度归一化。该估计还需检查可见性与物体数量。全黑图像和双物体图像可能产生无意义或具有歧义的质心。运动速度还应除以实际帧间时间差。

评价可包括方向一致性、速度误差、边界行为、条件响应、可见物体比例与重建误差。像素 MSE 对多模态未来的评价有限；少量低分辨率合成序列上的视频分布指标也可能估计不稳定。应优先采用与数据生成机制一致、定义明确的指标，并保存完整固定测试集中的成功与失败结果。

5.5 课后习题

习题 5.1 视频采样、时空压缩与可见信息

输入视频形状为 $B \times 3 \times 81 \times 256 \times 256$ 。设因果 VAE 的第一帧单独编码，其后每 4 帧对应一个潜时间位置；空间压缩率为 8，潜通道数为 16。Transformer 使用 $1 \times 2 \times 2$ 潜空间块。

- 逐步求潜变量形状、块向量宽度和 token 数。计算全注意力每头的得分元素数，再计算空间后时间分解注意力的元素数。说明两种架构的计算量相近或不同是否意味着函数完全等价。
- 给出视频 patchify 的精确元素映射与逆映射。若空间压缩率改为 16，保持其余教学假设，重新计算 token 数；说明哪些真实模型参数还需要独立核对。
- 写出时间因果编码、联合视频去噪、自回归视频块三个场景的可见信息范围。对每个场景说明，读取后续位置何时属于目标允许的条件，何时造成未来观测泄漏。
- 位置函数为 $x(t) = \sin(2\pi ft)$ ，采样间隔为 Δ 。证明 f 与 $f + k/\Delta$ 给出相同的离散样本。由此说明增大模型规模能否消除固定采样产生的不可辨识性。
- 编程：实现 patchify 往返及因果支持测试。对固定时长视频改变采样帧数，对固定帧数视频改变时间戳，比较速度估计。禁止以全黑帧的零质心作为有效位置参与统计。

习题 5.2 自生成历史的梯度与监督一致性

真实一维运动满足 $x_{t+1} = ax_t$ ，初始状态方差为 σ_x^2 ，均值为零。预测器为 $\hat{x}_{t+1} = \theta \hat{x}_t$ 。

- (a) 分别推导在真实一步输入上训练的均方误差，以及从同一初态开放环预测 H 步的末端均方误差。求两者梯度，分析 $\theta = 0, H > 1$ 时的差别。
- (b) 对两步预测和损失 $L = (\hat{x}_2 - x_2)^2/2$ ，分别求完整梯度与在 $\hat{x}_1$ 处停止梯度的半梯度。用 $x_0 = 1, a = 1, \theta = 2$ 验证前向相同而梯度不同。
- (c) 若训练时向真实历史加入偏移 δ ，但仍把未偏移轨迹的下一状态作为标签，求平方损失下的目标关系。给出何时可以解释为去噪，何时与闭环动力学目标不一致。
- (d) 已知首帧为 x^* ，线性流路径使用固定噪声 ε 。写出已知区域在时刻 τ 的状态与速度，并证明直接用干净首帧覆盖中间生成变量会改变训练分布。
- (e) 编程：比较 teacher forcing、完整展开和停止历史梯度三种实现，固定初值与参数验证解析结果。然后在小球视频上分别记录一步误差、多步位置误差和边界行为；完整 Self Forcing 报告中的分布匹配目标需单独实现，不能用本题线性 MSE 结果代替其复现。

第 6 章 多模态自监督学习与预测表征

自监督学习通过跨视图一致性、掩码预测和结构约束学习表征。不同目标保留的信息不同。本章从目标函数的最优解与退化解出发，分析全局语义、局部结构及动作相关信息的评价方法。

6.1 对比目标、二元匹配与数据增强

第2章的 CLIP 在一个批次内归一化匹配概率。给定图像表示 u_i 和文本表示 v_j ，另一种选择对每一对样本定义二元匹配标签 $y_{ij} \in \{-1, +1\}$ 。令 $s_{ij} = \exp(t)u_i^\top v_j + b$ ，SigLIP 类目标为

$$\mathcal{L}_{\text{sig}} = \frac{1}{B} \sum_{i,j} \log(1 + \exp(-y_{ij}s_{ij})). \quad (6.1)$$

批次中共有 B^2 对，归一化常数与正负样本抽样方式须明确。对单对损失求导：

$$\ell(s, y) = \text{softplus}(-ys), \quad (6.2)$$

$$\frac{\partial \ell}{\partial s} = -y \text{sigmoid}(-ys), \quad \frac{\partial^2 \ell}{\partial s^2} = \text{sigmoid}(s) \text{sigmoid}(-s). \quad (6.3)$$

二元匹配没有跨列的 softmax 分母，但同一个表示仍参与多个正负对，其参数梯度仍然耦合。缺失或重复语义标注会影响负样本的有效性。

对于一组没有信息的特征，所有 logits 退化为常数 b 。若正样本占比为 π_+ ，平均二元损失为

$$L(b) = -\pi_+ \log \text{sigmoid}(b) - (1 - \pi_+) \log[1 - \text{sigmoid}(b)].$$

求导后， $L'(b) = \text{sigmoid}(b) - \pi_+$ ，且 $L''(b) = \text{sigmoid}(b)[1 - \text{sigmoid}(b)] > 0$ 。令一阶导数为零，得到唯一的有限最优点 $\text{sigmoid}(b) = \pi_+$ ；这里要求 $0 < \pi_+ < 1$ 。解出 b ，即

$$b^* = \log \frac{\pi_+}{1 - \pi_+}. \quad (6.4)$$

每幅图像仅有一个批内匹配文本时， $\pi_+ = 1/B$ 。学习偏置可用于表示这一类先验；改变负样本抽样而保持所有其他设置不变，会改变最优常数偏置。

例题 6.1 正负样本比例与偏置

取 $B = 4$ ，假设所有图文相似度均为零。求最优偏置以及平均每对的二元交叉熵。

解 $\pi_+ = 1/4$ ， $b^* = \log(1/3)$ 。平均每对损失为 $-\frac{1}{4} \log \frac{1}{4} - \frac{3}{4} \log \frac{3}{4} \approx 0.562335$ 。式(6.1)按 B 而非 B^2 归一化，因此该式的总值为 4×0.562335 。

SigLIP 2 将图文匹配与描述生成、自蒸馏及掩码预测结合，并提供支持不同长宽比和分辨率的 NaFlex 变体。这些监督分别作用于图文语义、图像内部表征和局部位置。[51] 在小规模实现中应先验证单个目标，再逐项加入辅助目标，记录每一项的梯度范数与下游变化。

负样本抽样与目标保持 若原目标是所有正负对的损失总和，而每个负对仅以概率 q 独立纳入计算，则对被选负对使用权重 $1/q$ ，可保持期望不变：

$$\mathbb{E} \left[\frac{I_{ij}}{q} \ell_{ij} \right] = \frac{\Pr(I_{ij} = 1)}{q} \ell_{ij} = \ell_{ij}.$$

该式要求抽样概率已知且为正。直接减少负对数量而不重加权，则改变了正负类别先验和目标。采用难负样本抽样时，选择概率可能依赖当前模型，需要分别规定抽样分布和所希望优化的总体风险。

增强定义的不变性 设 g 为随机图像变换，同一图像两次增强为 $x^{(1)} = g_1(x)$ 、 $x^{(2)} = g_2(x)$ 。一致性目标趋向于减小 $f(x^{(1)})$ 与 $f(x^{(2)})$ 的差异。若任务需要的变量被某种增强改变，该一致性约束可能删除任务信息。例如水平翻转改变左右关系；大范围裁剪改变物体数量；颜色变换改变颜色问答的标签。增强选择应依据任务不变性，而非仅依据图像分类设置。

在图文训练中，增强后的图像与原文本是否仍匹配，需要显式定义。多视图的正对应可采用交叠区域、几何变换后的坐标或不变语义标签。纯粹依赖文件来源相同，不能保证局部语义一致。

6.2 掩码重建、目标编码器与表征退化

掩码自编码器 (MAE) 仅将可见图像块输入编码器，用解码器重建被掩码的像素块。设可见集合 $\mathcal{V}$ 、掩码集合 $\mathcal{M}$ ，目标为

$$\mathcal{L}_{\text{MAE}} = \frac{1}{|\mathcal{M}|} \sum_{j \in \mathcal{M}} \|D_\psi(E_\theta(X_\mathcal{V}), j) - X_j\|^2. \quad (6.5)$$

在像素目标下，给定可见信息的最优预测为条件均值。使用归一化像素、离散码或教师特征会改变监督变量。MAE 的非对称编码器—解码器结构可以减少高掩码率下编码器的计算。[52]

指数移动平均教师 令在线参数为 θ_k ，教师参数采用

$$\bar{\theta}_k = m\bar{\theta}_{k-1} + (1-m)\theta_k = m^k\bar{\theta}_0 + (1-m) \sum_{i=1}^k m^{k-i}\theta_i. \quad (6.6)$$

展开式显示历史权重的几何衰减。教师通常在优化器更新后执行一次无梯度参数更新；每个微批次执行一次会改变等效时间常数。当初始化影响可以忽略时，滞后 j 的权重为 $(1-m)m^j$ 。由几何级数 $\sum_{j \geq 0} m^j = 1/(1-m)$ 对 m 求导，得到 $\sum_{j \geq 0} jm^j = m/(1-m)^2$ 。因此平均滞后为 $(1-m) \sum_j jm^j = m/(1-m)$ 个更新步。令 $m^h = 1/2$ ，得到半衰期 $h = \log(1/2)/\log m$ 。

DINO 类方法将在线预测分布与停止梯度的教师分布作交叉熵匹配，并结合多视图、教师温度和输出分布处理；BYOL 类方法使用预测器进行连续表征回归。教师 EMA 是训练机制之一，不能仅凭 EMA 排除常量解。[53, 54, 86]

例题 6.2 EMA 的更新频率

取 $m = 0.99$ 。求初始教师权重衰减到一半所需的更新次数。若每次优化器更新包含 4 个微批次，教师却在每个微批次后更新，初始权重在一次优化器步中的系数是多少？

解 半衰期约为 $\log(1/2)/\log 0.99 \approx 68.97$ 。后一设置的系数为 $0.99^4 \approx 0.960596$ ，与每次优化器步只更新一次的 0.99 不同。比较实验时须固定教师更新时钟。

方差与协方差约束 若 $z_i = z'_i = c$ 对所有样本成立，则 $\sum_i \|z_i - z'_i\|^2 = 0$ ，表征却无法区分任何输入。VICReg 将一致性与维度标准差下限、跨维协方差约束结合。设 $Z \in \mathbb{R}^{B \times d}$ ，中心化 $Z_c = Z - \mathbf{1}\bar{z}^\top$ ，则

$$C = Z_c^\top Z_c / (B - 1), \quad s_j = \sqrt{C_{jj} + \varepsilon}, \quad (6.7)$$

$$\mathcal{L}_{\text{var}} = \frac{1}{d} \sum_j \max(0, \nu - s_j), \quad \mathcal{L}_{\text{cov}} = \frac{1}{d} \sum_{j \neq k} C_{jk}^2. \quad (6.8)$$

对常用的 $\nu > \sqrt{\varepsilon}$ ，常量表示的方差项为正。然而在精确常量表示处， $Z_c = 0$ ，方差对 Z 的一阶导数也为零。因此正的惩罚值本身不能保证从每个退化初始化出发都存在非零更新方向。维度完全重复时，非对角协方差通常增大。然而较高维方差与低协方差仍不能单独保证任务语义。批次太小时协方差估计也会产生较大的随机误差。[55] 中心化还带来一个代数限制。令 $H = I - \mathbf{1}\mathbf{1}^\top/B$ ，则 $Z_c = HZ$ ， $\text{rank}(H) = B - 1$ ，所以

$$\text{rank}(C) = \text{rank}(Z_c^\top Z_c) \leq \min(d, B - 1).$$

当 $d \geq B$ 时，有限批次协方差无法成为所有对角元素均为正的满秩对角矩阵。实验中的方差、协方差权重需要结合批次大小理解，不能要求互相矛盾的精确等式同时成立。

6.3 密集表征与 Gram 矩阵约束

图像级分类允许将空间位置聚合为单个向量，定位与深度估计需要逐位置特征。设归一化 patch 表征 $Z \in \mathbb{R}^{N \times d}$ ，其 Gram 矩阵为 $G = ZZ^\top$ ，其中 G_{ij} 表示两个空间位置的余弦相似度。DINOv3 使用 Gram anchoring 稳定密集特征的空间关系。[56]




图 6.1 掩码预测表征的学生-教师计算图。V-JEPA 2.1 进一步对可见位置设置距离加权目标。

为分析这一机制，考虑停止梯度的目标 Gram 矩阵 G_T ，采用归一化平方 Frobenius 目标

$$\mathcal{L}_G = \frac{1}{N^2} \|ZZ^\top - G_T\|_F^2. \quad (6.9)$$

令 $A = ZZ^\top - G_T$ 。当 G_T 对称时， $A = A^\top$ 。用微分计算

$$d\mathcal{L}_G = \frac{2}{N^2} \text{tr}[A^\top(dZ Z^\top + Z dZ^\top)] \quad (6.10)$$

$$= \frac{4}{N^2} \text{tr}[(AZ)^\top dZ], \quad (6.11)$$

$$\frac{\partial \mathcal{L}_G}{\partial Z} = \frac{4}{N^2} (ZZ^\top - G_T)Z. \quad (6.12)$$

若 Z 来自未归一化特征 $F_i/\|F_i\|$ ，还需乘上单位化的 Jacobian $(I - z_i z_i^\top)/\|F_i\|$ 。不能将式(6.12)直接当作对 F 的梯度。

不变性与可识别性 对任何正交矩阵 R ， $(ZR)(ZR)^\top = ZZ^\top$ 。因此 Gram 目标对全局特征坐标的正交旋转不敏感。它约束空间位置之间的关系，无法单独确定每个通道对应的语义。对平移、裁剪或分辨率不同的两幅图像，比较 Gram 矩阵前仍需建立空间对应；直接比较相同下标可能比较不同区域。

例题 6.3 相同 Gram 矩阵的不同特征

令 $Z = I_2$ ， $R = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$ ，教师特征为 Z ，学生特征为 ZR 。比较逐元素特征 MSE 与 Gram 损失。

解 二者 Gram 矩阵均为 I_2 ，故式(6.9)为零。特征差的平方 Frobenius 范数为 4，逐元素 MSE 为 1。固定线性探针可能受到通道旋转影响；重新训练探针可补偿可逆旋转。


6.4 预测表征与 V-JEPA 2

联合嵌入预测架构 (JEPA) 在表征空间训练预测, 目标可以省去像素解码。V-JEPA 2 将视频中的可见区域输入在线编码器, 再由预测器预测被遮蔽位置的目标表征; 目标编码器通过指数移动平均更新。[39]

令可见位置集合为 $\mathcal{V}$ 、目标位置有序索引为 $\mathcal{M} = (m_1, \dots, m_K)$ 。可写为

$$Z_{\mathcal{V}} = E_{\theta}(X_{\mathcal{V}}), \quad \hat{Z}_{\mathcal{M}} = P_{\theta}(Z_{\mathcal{V}}, \mathcal{M}), \quad \mathcal{L}_{\text{JEPA}} = \frac{1}{K} \sum_{r=1}^K \|\hat{Z}_r - \text{sg}(E_{\bar{\theta}}(X)_{m_r})\|_1. \quad (6.13)$$

目标槽位 r 与原视频位置 m_r 具有不同索引语义。目标通过整数索引从完整表征中读取, 布尔可见掩码则表示允许输入的区域。



对象 目标位置为整数索引; 每个预测槽位 r 对齐原位置 m_r 。

梯度 预测误差更新在线路径; 目标表征停止梯度, 目标编码器按 EMA 更新。

图 6.2 JEPA 的表征预测。动作条件训练另行加入动作和机器人状态, 不能由无动作预训练目标推导。

指数移动平均与停止梯度稳定目标的变化, 但仅凭损失形式不能排除常量表征等退化解。可测量批次表征方差、协方差有效秩、预测误差和下游任务结果。低表征误差也可能与任务相关信息缺失同时出现, 尤其在小物体、精细接触或摄像机变化场景中, 需要任务相关对照。

V-JEPA 2-AC 在视频表征预训练之后使用带动作记录的机器人数据训练动作条件模型, 并结合机器人状态等条件。该阶段的“无任务标签”不排除动作数据的存在。应分别说明预训练的视频来源、动作条件数据及目标任务信息。

动作条件预测可表示为

$$\hat{z}_{t+1} = F_{\theta}(z_{\leq t}, a_{\leq t}, q_{\leq t}), \quad (6.14)$$

其中 q_t 表示机器人状态。实际模型可使用块级因果 Transformer。对目标图像编码得到 z_g , 通过采样规划近似最小化

$$\min_{a_{0:H-1}} \|\hat{z}_H - z_g\|_1, \quad (6.15)$$

再执行首个动作并重新观察。目标表征距离的控制有效性取决于编码器是否保留任务所需变量, 以及目标是否可达、摄像机条件是否匹配、不同物理状态是否发生表征混淆。模型内距离与真实任务成功率应分别报告。

6.5 多层视频自监督与局部监督权重

V-JEPA 2.1 在掩码位置预测之外，对可见位置加入距离加权的教师特征监督；它还同时监督多个中间层，并使用图像与视频各自的 patch 嵌入。其目标编码器接收完整输入，在线编码器仅接收可见位置。[57]

设第 ℓ 层的预测与教师目标为 $\hat{z}_i^\ell, z_{T,i}^\ell$ ，可见位置为 $\mathcal{V}$ ，掩码位置为 $\mathcal{M}$ 。用报告中的加权结构可写为

$$\mathcal{L}_{\text{mask}}^\ell = \frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} \|\hat{z}_i^\ell - \text{sg}(z_{T,i}^\ell)\|_1, \quad (6.16)$$

$$\mathcal{L}_{\text{ctx}}^\ell = \frac{1}{|\mathcal{V}|} \sum_{i \in \mathcal{V}} \lambda_i \|\hat{z}_i^\ell - \text{sg}(z_{T,i}^\ell)\|_1, \quad (6.17)$$

$$\lambda_i = \frac{\lambda}{\sqrt{d_{\min}(i, \mathcal{M})}}, \quad \mathcal{L} = \sum_{\ell} (\mathcal{L}_{\text{mask}}^\ell + \mathcal{L}_{\text{ctx}}^\ell). \quad (6.18)$$

距离按时空块坐标定义，可见集合与掩码集合不相交，所用最小距离须严格为正。更改距离单位会改变有效监督强度。各层先归一化再拼接，由轻量 MLP 合并为预测器输入。[57]

报告采用四个层级的教师目标，并区分常规训练与较高分辨率的后期训练。在公开的 2026 年技术报告配置中，前一阶段使用 16 帧、 256×256 的视频；后期阶段扩展到 64 帧、 384×384 ，图像分辨率也相应提高。[57] 这会改变每次更新的 token 数与时间覆盖范围。比较监督目标时，应固定训练阶段和输入预算，避免把分辨率变化的影响归入损失设计。

L1 预测与条件中位数 式(6.18)采用 L1 距离，其统计最优解与像素平方误差不同。对一个条件随机标量 $Y | X = x$ ，定义 $R(a) = \mathbb{E}[|Y - a| | x]$ 。在分布连续处，

$$R'(a) = \Pr(Y < a | x) - \Pr(Y > a | x) \quad (6.19)$$

$$= 2F_{Y|x}(a) - 1. \quad (6.20)$$

零导数对应条件中位数。当 Y 有原子概率时，用次梯度条件表示为 $\Pr(Y \leq a | x) \geq 1/2$ 且 $\Pr(Y \geq a | x) \geq 1/2$ 。逐通道 L1 距离由各通道的条件中位数最小化；平方 L2 距离则由条件均值最小化。两种损失对不确定目标的预测不必相同。

例题 6.4 均值与中位数的不同预测

在相同可见上下文下，教师特征的一个通道以概率 0.9 取 0，以概率 0.1 取 10。求平方误差与绝对误差的最优常数预测。

解 平方误差风险为 $0.9a^2 + 0.1(10 - a)^2$ ，导数为 $2a - 2$ ，最优值为 $a = 1$ 。对 $0 \leq a \leq 10$ ，绝对误差风险为 $0.9a + 0.1(10 - a) = 1 + 0.8a$ ，最小值在 $a = 0$ 取得。使用 L1 目标时，不能把最优预测直接解释为教师特征的条件均值。

目标、距离与索引 可见位置的监督目标与完整上下文教师输出对齐。若教师也只接收被遮蔽输入，目标将改变；若对可见输入进行无条件复制，模型可能仅拟合局部相等关系。实现应保存完整位置索引，分别统计 $\mathcal{L}_{\text{mask}}$ 与 $\mathcal{L}_{\text{ctx}}$ ，并确保目标编码器没有反向梯度。

多层目标的梯度对共享编码器相加。各层使用 L1 总和还是维度平均，会改变隐层宽度对权重的影响；不同层维数不相同尤其需要明确。图像和视频分配到不同设备时，跨设备归约还要保留预定的模态混合比例，详见第12章。

例题 6.5 空间距离对应的上下文监督

一维 patch 序列的位置为 0, 1, 2, 3, 4，仅位置 2 被掩码，取距离为索引差的绝对值， $\lambda = 0.5$ 。求可见位置的权重。

解 位置 0, 1, 3, 4 到掩码位置的最小距离为 2, 1, 1, 2，故权重为 $(0.5/\sqrt{2}, 0.5, 0.5, 0.5/\sqrt{2})$ 。它们的和约为 1.7071。式(6.18)以可见位置数 4 归一化；改为除以权重和会改变目标的绝对尺度。

6.6 表征评价、状态信息与实验要求

冻结编码器后训练线性探针，测量任务信息的线性可读性；训练非线性探针增大读出函数类；端到端微调允许表征本身变化。三种协议应分别报告训练数据、参数量和训练预算。对空间任务可测量位置误差、深度误差或分割指标；对视频则加入速度、方向和时间顺序判别。

有效秩与信息缺失 设协方差特征值为 $\lambda_j \geq 0$ ，归一化 $p_j = \lambda_j / \sum_k \lambda_k$ 。有效秩可定义为

$$r_{\text{eff}} = \exp \left(- \sum_{j: p_j > 0} p_j \log p_j \right). \quad (6.21)$$

若所有特征值为零，需单独返回退化标记，避免 0/0。有效秩接近维数表明方差分布较均匀，但与动作控制所需的充分状态仍有区别。

例题 6.6 预测表征与控制信息

环境状态为 $s = (x, v)$ ，动力学为 $x' = x + v$ ， $v' = v + a$ 。编码器仅保留位置 $z = x$ 。证明存在相同表征与相同动作而后继表征不同的状态。

解 取 $(x, v) = (0, 1)$ 与 $(0, -1)$ ，动作均为 0。当前表征均为 0，下一表征分别为 1 与 -1。因此单个 z 无法定义确定性 Markov 转移；两帧历史在该环境中可恢复速度。减小训练集上的平均预测损失不能消除这一信息缺失。

实验从带真实状态的合成视频开始。训练图像级或视频级编码器后，冻结编码器，分别读出位置、速度和身份；再比较单帧、双帧和长历史的性能。遮蔽物体区域、改变背景及打乱时间顺序用于检验依赖变量。预训练样本与探针测试应按完整轨迹和场景划分。

编程实现须检查三类边界：EMA 参数更新发生在规定时刻；掩码索引读取教师目标后保持原空间顺序；Gram、协方差及各层损失的归约在批次或 token 数变化时与公式一致。大模型报告中的训练数据、架构和目标是方法定义，小型合成实验只能验证对应机制在限定任务中的结果。

6.7 课后习题

习题 6.1 Gram 约束、表征对齐与退化点

学生特征为 $Z \in \mathbb{R}^{N \times d}$ ，教师特征为 T ，教师停止梯度。目标为 $L = N^{-2} \|ZZ^\top - TT^\top\|_F^2$ 。

- 从矩阵微分开始求 $\nabla_Z L$ ，明确两次出现的 Z 各贡献什么。若每行特征先单位化，继续把梯度传到单位化前的变量。
- 证明 Z 乘任意 $d \times d$ 正交矩阵不改变 Gram 矩阵。构造 Gram 损失为零而逐通道 MSE 非零的例子，并说明冻结线性探针是否需要同步变换。
- 判断 $Z = 0$ 是否为本损失的驻点。对 VICReg 的方差惩罚同样分析“惩罚值非零”和“梯度非零”的关系。解释仅检查损失值为何不能保证摆脱精确坍塌。
- 对中心化样本协方差 C 证明 $\text{rank}(C) \leq \min(d, N - 1)$ 。若要求所有通道方差为正且互不相关，给出批次大小的必要条件。
- 编程：实现 Gram 手动梯度和协方差检查。测试正交变换、常量特征、重复通道和错配位置。设计分类探针与坐标探针，说明它们分别检验哪些信息。

习题 6.2 掩码预测中的目标统计量与教师更新

给定可见上下文 $X = x$ ，被掩码位置的教师标量 Y 以概率 0.9 取 0，以概率 0.1 取 10。教师参数按 $\bar{\theta}_t = m\bar{\theta}_{t-1} + (1 - m)\theta_t$ 更新。

- (a) 分别推导 L2 与 L1 回归的最优预测和最小期望损失。对 L1 使用次梯度或左右导数，说明含原子分布时中位数的定义。
- (b) 增加可见条件 C 。证明 L2 最优误差不会增加，并给出等号条件。说明教师包含额外可见信息时，学生无法达到逐样本零误差的原因。
- (c) 展开 EMA 的历史权重，求稳态平均滞后。若每个优化器步包含 K 个微批次，分别在每微批次与每优化器步更新 EMA，求等效衰减系数。
- (d) 对一维位置 0, 1, 2, 3, 4，位置 2 被掩码。可见位置按 $w_i = 0.5/\sqrt{|i - 2|}$ 加权。计算权重，比较除以位置数与除以权重和的梯度尺度；多个样本的掩码不同后，该差别还能否视为统一常数？
- (e) 编程：实现加权 L1、教师 EMA 与掩码 gather。检查教师无梯度、索引不重复且可达，并比较单帧位置与双帧位置对匀速运动速度的预测。明确加入动作或加速度后恢复速度需要的附加条件。

第 7 章 策略梯度与近端策略优化

策略梯度通过采样轨迹估计期望回报的导数。本章依次推导回报估计、控制变量、优势估计和近端策略目标，并明确终止、自举及批次复用的实现条件。

7.1 马尔可夫决策过程与策略梯度

马尔可夫决策过程由状态空间 $\mathcal{S}$ 、动作空间 $\mathcal{A}$ 、转移核 $P(s' | s, a)$ 、奖励函数 $r(s, a, s')$ 、初始分布 ρ_0 和折扣因子 γ 定义。策略 $\pi_\theta(a | s)$ 是待优化的条件分布。标准设定中，环境转移不由策略参数 θ 直接参数化。

状态满足马尔可夫性质：给定当前状态与动作后，下一状态的条件分布不再依赖更早历史。单帧图像可能无法确定速度，此时观测过程具有部分可观测性。可使用帧堆叠、循环网络或潜在状态模型表示历史。有限时域任务的价值还依赖剩余时间，可将时间纳入状态。

对长度为 T 的轨迹 $\xi = (s_0, a_0, r_0, \dots, s_T)$ ，有

$$p_\theta(\xi) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi_\theta(a_t | s_t) P(s_{t+1} | s_t, a_t). \quad (7.1)$$

定义目标与回报

$$J(\theta) = \mathbb{E} \left[\sum_{t=0}^{T-1} \gamma^t r_t \right], \quad G_t = \sum_{k=t}^{T-1} \gamma^{k-t} r_k. \quad (7.2)$$

对轨迹分布使用式(1.13)，记 $R(\xi) = \sum_t \gamma^t r_t$ ，得到

$$\begin{aligned} \nabla_\theta J &= \mathbb{E}_\xi [R(\xi) \nabla_\theta \log p_\theta(\xi)] \\ &= \mathbb{E}_\xi \left[R(\xi) \sum_t \nabla_\theta \log \pi_\theta(a_t | s_t) \right]. \end{aligned} \quad (7.3)$$

环境通过采样轨迹影响期望，但该估计无须对环境转移求导。[15, 16]

因果性与基线 给定时刻 t 的历史，

$$\mathbb{E}_{a_t \sim \pi_\theta} [\nabla_\theta \log \pi_\theta(a_t | s_t)] = \sum_a \nabla_\theta \pi_\theta(a | s_t) = 0. \quad (7.4)$$

过去奖励在给定历史后为常量，因此其与当前 score 的乘积期望为零。去除这些项后，

$$\nabla_\theta J = \mathbb{E} \left[\sum_{t=0}^{T-1} \gamma^t G_t \nabla_\theta \log \pi_\theta(a_t | s_t) \right]. \quad (7.5)$$

外部权重 γ^t 对应式(7.2)的起点折扣目标。无限时域且 $\gamma < 1$ 时，定义归一化折扣状态访问分布

$$d_\gamma^\pi(s) = (1 - \gamma) \sum_{t \geq 0} \gamma^t \Pr_\pi(s_t = s), \quad (7.6)$$

则策略梯度可写为

$$\nabla J = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d_{\gamma}^{\pi}, a \sim \pi} [Q^{\pi}(s, a) \nabla \log \pi(a | s)]. \quad (7.7)$$

均匀采样轨迹位置并省略 γ^t 是常见代理目标约定；使用时应注明采样分布与折扣方式。

状态价值、动作价值与优势分别定义为

$$V^{\pi}(s) = \mathbb{E}[G_t | s_t = s], \quad Q^{\pi}(s, a) = \mathbb{E}[G_t | s_t = s, a_t = a], \quad A^{\pi}(s, a) = Q^{\pi}(s, a) - V^{\pi}(s). \quad (7.8)$$

由条件期望关系, $V^{\pi}(s) = \mathbb{E}_{a \sim \pi} Q^{\pi}(s, a)$, 故 $\mathbb{E}_{a \sim \pi} A^{\pi}(s, a) = 0$ 。

$$V^{\pi}(s) = \sum_a \pi(a | s) Q^{\pi}(s, a), \quad Q^{\pi}(s, a) = \mathbb{E}[r + \gamma V^{\pi}(s') | s, a]$$




图 7.1 状态价值对动作价值求策略加权平均；动作价值对后继转移求条件期望。图中省略其他动作。

任何仅依赖状态的基线 $b(s)$ 都满足

$$\mathbb{E}[b(s_t) \nabla \log \pi(a_t | s_t) | s_t] = 0. \quad (7.9)$$

因此可将 G_t 替换为 $G_t - b(s_t)$ 。令 $g = \nabla \log \pi(a | s)$, 最小化条件二阶矩 $\mathbb{E}[\|g\|^2 (G - b)^2 | s]$, 对 b 求导, 得到

$$b^*(s) = \frac{\mathbb{E}[\|g\|^2 G | s]}{\mathbb{E}[\|g\|^2 | s]}. \quad (7.10)$$

对标量 b 的驻点条件为

$$-2\mathbb{E}[\|g\|^2 G | s] + 2b\mathbb{E}[\|g\|^2 | s] = 0.$$

分母为正时得到式(7.10)。 $V^{\pi}(s) = \mathbb{E}[G | s]$ 在 score 范数与动作无关时达到这一最优值；一般情况下它仍是无偏基线，但未必方差最小。奖励归一化与优势标准化还会改变有限样本的尺度及相关性。

例题 7.1 伯努利策略的解析梯度

设 $a \in \{0, 1\}$, $p = \text{sigmoid}(\theta)$, 奖励 $r = a$ 。求策略梯度, 并求使单样本梯度方差为零的常数基线。

解 $J = p$, 故 $dJ/d\theta = p(1 - p)$ 。伯努利 score 为 $g = a - p$, 于是

$$\mathbb{E}[ag] = \mathbb{E}[a(a - p)] = p - p^2.$$

式(7.10)给出 $b^* = 1 - p$ 。当 $a = 1$ 时, $(a - b^*)(a - p) = p(1 - p)$; 当 $a = 0$ 时, 该值仍为 $p(1 - p)$ 。本例中的最小方差基线与 $V = p$ 一般不同。

7.2 Bellman 方程、时序差分与优势估计

由逐轨迹恒等式 $G_t = r_t + \gamma G_{t+1}$, 条件取期望可得

$$V^\pi(s) = \mathbb{E}_{a \sim \pi, s' \sim P}[r(s, a, s') + \gamma V^\pi(s')], \quad (7.11)$$

$$Q^\pi(s, a) = \mathbb{E}_{s' \sim P}[r + \gamma \mathbb{E}_{a' \sim \pi} Q^\pi(s', a')]. \quad (7.12)$$

对有界函数和 $0 \leq \gamma < 1$, Bellman 期望算子满足

$$\|\mathcal{T}^\pi V - \mathcal{T}^\pi U\|_\infty \leq \gamma \|V - U\|_\infty. \quad (7.13)$$

逐状态展开即可看到这一界:

$$|\mathcal{T}^\pi V(s) - \mathcal{T}^\pi U(s)| = \gamma |\mathbb{E}[V(s') - U(s') \mid s]| \quad (7.14)$$

$$\leq \gamma \mathbb{E}[|V(s') - U(s')| \mid s] \quad (7.15)$$

$$\leq \gamma \|V - U\|_\infty. \quad (7.16)$$

第一步中两个奖励项相消; 最后一步使用条件概率归一化。对所有 s 取上确界, 便得到式(7.13)。精确算子迭代由压缩映射定理收敛到唯一固定点; 神经网络逼近、投影和离策略采样需要另行分析。

Monte Carlo 与 TD Monte Carlo 使用完整实现回报 G_t 。在完整同策略轨迹下, 该样本目标对 V^π 条件无偏, 但包括后续所有随机性。TD(0) 使用 $r_t + \gamma V_\psi(s_{t+1})$, 引入自举估计, 其 TD 残差为

$$\delta_t = r_t + \gamma V_\psi(s_{t+1}) - V_\psi(s_t). \quad (7.17)$$

当 $V_\psi = V^\pi$ 时, $\mathbb{E}[\delta_t \mid s_t, a_t] = A^\pi(s_t, a_t)$ 。对近似价值函数, 偏差取决于价值误差; 方差取决于环境随机性、时域和目标构造。比较 MC 与 TD 时需要指定估计目标及采样条件。[6]

n 步目标与优势估计为

$$\widehat{G}_t^{(n)} = \sum_{l=0}^{n-1} \gamma^l r_{t+l} + \gamma^n V(s_{t+n}), \quad \widehat{A}_t^{(n)} = \widehat{G}_t^{(n)} - V(s_t). \quad (7.18)$$

先展开前两项以确定抵消方式:

$$\begin{aligned} \delta_t + \gamma \delta_{t+1} &= r_t + \gamma V(s_{t+1}) - V(s_t) \\ &\quad + \gamma r_{t+1} + \gamma^2 V(s_{t+2}) - \gamma V(s_{t+1}) \\ &= r_t + \gamma r_{t+1} + \gamma^2 V(s_{t+2}) - V(s_t). \end{aligned}$$

继续加入第 l 项时, $-\gamma^l V(s_{t+l})$ 抵消上一项的自举值, 仅留下最后一个边界价值。因此

$$\widehat{A}_t^{(n)} = \sum_{l=0}^{n-1} \gamma^l \delta_{t+l}. \quad (7.19)$$

对不同 n 使用几何权重, 在无限展开或相容的尾项处理下, 广义优势估计 GAE 为

$$\begin{aligned} \widehat{A}_t^{\text{GAE}} &= (1 - \lambda) \sum_{n \geq 1} \lambda^{n-1} \widehat{A}_t^{(n)} \\ &= (1 - \lambda) \sum_{l \geq 0} \gamma^l \delta_{t+l} \sum_{n \geq l+1} \lambda^{n-1} \\ &= \sum_{l \geq 0} (\gamma \lambda)^l \delta_{t+l}. \end{aligned} \quad (7.20)$$

上述求和交换要求绝对可积, 几何权重的展开取 $0 \leq \lambda < 1$ 。有限轨迹将剩余权重赋给最长可用回报, $\lambda = 1$ 由相容的有限时域尾项给出。于是可从后向前递推 $\widehat{A}_t = \delta_t + \gamma \lambda \widehat{A}_{t+1}$ 。 $\lambda = 0$ 给出一步残差; 增大 λ 增加较远残差的权重。 λ 控制优势估计的多步混合, γ 定义回报折扣。[17]

有限轨迹的混合权重 若从时刻 t 起仅有 m 个可用转移, 则不能直接删去无限几何和的尾部, 否则总权重小于一。将剩余权重赋给最长的 m 步目标, 定义

$$\widehat{A}_t^{(\lambda, m)} = (1 - \lambda) \sum_{n=1}^{m-1} \lambda^{n-1} \widehat{A}_t^{(n)} + \lambda^{m-1} \widehat{A}_t^{(m)}. \quad (7.21)$$

第 l 个残差 $\gamma^l \delta_{t+l}$ 出现在所有 $n \geq l+1$ 的目标中。它的混合系数为

$$(1 - \lambda) \sum_{n=l+1}^{m-1} \lambda^{n-1} + \lambda^{m-1} = \lambda^l - \lambda^{m-1} + \lambda^{m-1} \quad (7.22)$$

$$= \lambda^l. \quad (7.23)$$

因此有限目标恰等于 $\sum_{l=0}^{m-1} (\gamma \lambda)^l \delta_{t+l}$ 。当 $\lambda = 1$, 全部权重集中于最长回报; 当 $m = 1$, 唯一目标的权重为一。这两个边界均可直接代入有限表达式检验。

终止、截断与缓冲区边界 令 d_t^{term} 表示任务终止, d_t^{trunc} 表示外部截断, 定义

$$b_t = 1 - d_t^{\text{term}}, \quad c_t = 1 - (d_t^{\text{term}} \vee d_t^{\text{trunc}}), \quad (7.24)$$


$$\delta_t = r_t + \gamma b_t V(s_{t+1}^{\text{final}}) - V(s_t), \quad (7.25)$$

$$\widehat{A}_t = \delta_t + \gamma \lambda c_t \widehat{A}_{t+1}. \quad (7.26)$$

b_t 控制自举, c_t 控制残差递推能否跨到缓冲区下一条转移。外部截断保留任务内后续价值, 但环境重置后的转移属于新轨迹。自动重置环境中必须读取截断前真实后继观测, 避免使用重置后的初始观测。[41]

固定长度采样缓冲区的末端, 若任务尚未结束, 则用真实末状态价值自举, 并将缓冲区之外的优势递推尾项设为零。任务定义本身包含的有限时限可以构成真正终止; 剩余时间需纳入状态以维持马尔可夫性质。

$$\delta_t = r_t + \gamma b_t V(s_{t+1}) - V(s_t), \quad \hat{A}_t = \delta_t + \gamma \lambda c_t \hat{A}_{t+1}$$



边界 正常转移: $(b, c) = (1, 1)$; 真正终止: $(0, 0)$; 外部截断: $(1, 0)$ 。

运算 截断保留实际后继观测的价值, 但不将重置后新轨迹的优势纳入递归。

图 7.2 GAE 中的自举掩码与轨迹递归掩码。两项掩码控制不同的计算依赖。

例题 7.2 三步 GAE 与截断处理

取 $\gamma = 0.9, \lambda = 0.8$, 奖励 $(1, 2, 3)$, 当前价值 $(0.5, 0.4, 0.2)$, 第三步后真正终止。计算优势和价值目标。

解 TD 残差为 $(0.86, 1.78, 2.8)$, $\gamma\lambda = 0.72$ 。从后向前有

$$\hat{A}_2 = 2.8,$$

$$\hat{A}_1 = 1.78 + 0.72 \cdot 2.8 = 3.796,$$

$$\hat{A}_0 = 0.86 + 0.72 \cdot 3.796 = 3.59312.$$

价值回归目标 $\hat{R} = \hat{A} + V = (4.09312, 4.196, 3)$ 。若 $\lambda = 1$, 首步目标为完整回报 $1 + 0.9 \cdot 2 + 0.9^2 \cdot 3 = 5.23$ 。

若末步改为外部截断, 且截断观测的价值估计为 5, 则 $\delta_2 = 7.3$, $\hat{A}_1 = 7.036$, $\hat{A}_0 = 5.92592$ 。递推仍在该截断处停止, 不连接重置后的残差。

例题 7.3 错误后继观测的自举误差

时间截断后最后观测价值为 5, 自动重置的新观测价值为 1, 奖励为 0、当前价值为 2、 $\gamma = 0.9$ 。比较正确与错误 TD 残差。

解 正确值为 $0 + 0.9 \times 5 - 2 = 2.5$; 使用重置观测得到 -1.1 。差值为 -3.6 , 会按 GAE 递归影响此前时间步。两个输入具有相同形状, 形状检查无法发现这一错误。

GAE 通常由采样时缓存的价值在停止梯度下计算。策略损失将优势视为常量; 价值损失将回报目标视为常量。训练 critic 时仍需重新计算可导的 $V_\psi(s)$ 。共享特征参数的总梯度可包含策略损失与价值损失的梯度, 但优势目标的构造应保持固定。

7.3 重要性采样与 PPO 目标

轨迹由行为策略 π_{old} 采集。固定状态下，若当前策略的支持集被行为策略覆盖，重要性采样恒等式为

$$\mathbb{E}_{a \sim \pi_{\text{old}}} [\rho(a)f(a)] = \mathbb{E}_{a \sim \pi_{\theta}} [f(a)], \quad \rho_t(\theta) = \exp [\log \pi_{\theta}(a_t | s_t) - \log \pi_{\text{old}}(a_t | s_t)]. \quad (7.27)$$

单步动作比率不校正整条状态访问分布。PPO 在旧策略采集的状态上优化局部代理目标，并限制每批数据的复用程度。[18, 7]

从真实回报差到局部代理目标 令 π 为旧策略、 π' 为待比较策略，考虑有界回报和 $0 \leq \gamma < 1$ 。由优势定义，对 π' 轨迹求期望有

$$\mathbb{E}_{\pi'} \sum_{t=0}^{T-1} \gamma^t A^{\pi}(s_t, a_t) = \mathbb{E}_{\pi'} \sum_{t=0}^{T-1} \gamma^t [r_t + \gamma V^{\pi}(s_{t+1}) - V^{\pi}(s_t)] \quad (7.28)$$

$$= \mathbb{E}_{\pi'} \sum_{t=0}^{T-1} \gamma^t r_t - \mathbb{E}_{\rho_0} V^{\pi}(s_0) + \gamma^T \mathbb{E}_{\pi'} V^{\pi}(s_T). \quad (7.29)$$

中间价值项沿时间抵消。令 $T \rightarrow \infty$ ，最后一项在有界条件下趋于零，而 $\mathbb{E}_{\rho_0} V^{\pi} = J(\pi)$ 。于是

$$J(\pi') - J(\pi) = \frac{1}{1-\gamma} \mathbb{E}_{s \sim d_{\pi'}^{\pi}, a \sim \pi'} A^{\pi}(s, a). \quad (7.30)$$

真实差值使用新策略的状态分布。用旧分布 d_{π}^{π} 近似它，再仅对动作分布使用重要性比率，得到局部代理目标。其在 $\pi' = \pi$ 处具有正确的一阶导数：状态分布的导数所乘的 $\mathbb{E}_{a \sim \pi} A^{\pi}(s, a)$ 在每个状态都为零。因此小步更新有一阶依据，但有限步更新仍存在状态分布变化和优势估计误差。

普通代理目标为 $L_{\text{PG}} = \mathbb{E}[\rho_t \hat{A}_t]$ 。PPO 的裁剪代理目标为

$$L_{\text{clip}} = \mathbb{E} \left[\min \left(\rho_t \hat{A}_t, \text{clip}(\rho_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]. \quad (7.31)$$

对固定优势 A ，单样本函数写为

$$\ell(\rho, A) = \begin{cases} A \min(\rho, 1 + \epsilon), & A \geq 0, \\ A \max(\rho, 1 - \epsilon), & A < 0. \end{cases} \quad (7.32)$$

正优势样本在 $\rho > 1 + \epsilon$ 后对该代理项不再提供继续增大的梯度；负优势样本在 $\rho < 1 - \epsilon$ 后同样达到平坦区。沿相反方向改变概率仍受到线性项约束。




图 7.3 PPO 单样本代理函数的解析曲线。正优势与负优势的平坦区位于比率区间的不同侧。

例题 7.4 正负优势下的裁剪

令 $\epsilon = 0.2$ 。计算 $(A, \rho) = (2, 1.5), (-2, 1.5), (-2, 0.5)$ 的单样本代理值。

解 三种情况依次为

$$\min(3, 2.4) = 2.4, \quad \min(-3, -2.4) = -3, \quad \min(-1, -1.6) = -1.6.$$

第二种情况保留斜率 $A = -2$ ，因此策略最小化负代理目标时会抑制该动作概率继续增加。比率超出裁剪区间并不充分决定梯度是否为零。

PPO 通常最小化

$$\mathcal{L} = -L_{\text{clip}} + c_v \mathbb{E}[(V_\psi(s) - \text{sg}(\widehat{R}))^2] - c_H \mathbb{E}[\mathcal{H}(\pi_\theta(\cdot | s))]. \quad (7.33)$$

价值裁剪是可选实现。优势标准化 $\widetilde{A} = (A - \bar{A}) / (\text{std}(A) + \epsilon)$ 改变有限批次目标尺度，统计量仅应由有效样本计算。

裁剪损失对每个样本满足 $\ell_{\text{clip}} \leq \rho A$ ，但该关系不能直接推出真实回报的单调改进。共享参数、价值损失和熵损失均可能改变已进入平坦区的动作概率。因此裁剪不构成对实际 KL 的硬约束，需要独立监控 KL，并可设置提前停止更新的阈值。

7.4 训练循环、统计量与实现检查

一轮 PPO 训练按以下顺序执行：固定行为策略；采集状态、动作、奖励、旧对数概率、旧价值和边界标记；构造优势与回报目标；沿 $T \times B$ 展平采样轴；按随机小批量进行有限轮更新；使用更新后的策略重新采样。旧对数概率在一轮中的所有优化步骤保持不变。若只需要已采动作的概率比，缓存旧对数概率即可；计算完整分布 KL 或重新采样时需要策略快照或等价数据。

令 $l_t = \log \pi_\theta - \log \pi_{\text{old}}$ 。在旧策略采样且支持条件成立时，

$$\mathbb{E}[-l_t] = \text{KL}(\pi_{\text{old}} \| \pi_\theta), \quad \mathbb{E}[e^{l_t} - 1 - l_t] = \text{KL}(\pi_{\text{old}} \| \pi_\theta). \quad (7.34)$$

量	用途	梯度处理
当前对数概率	策略代理损失	更新 actor。
旧对数概率	重要性比率分母	固定。
优势与回报目标	策略权重、价值监督	固定。
当前价值	价值回归	更新 critic。
当前策略熵	熵正则化	更新 actor。

令 $l = \log \pi_\theta - \log \pi_{\text{old}}$ ，则 $\mathbb{E}_{\text{old}} e^l = \sum_a \pi_\theta(a) = 1$ 。所以第二式的期望为 $1 - 1 - \mathbb{E}_{\text{old}} l = -\mathbb{E}_{\text{old}} l$ ，与第一式相等。由 $e^l \geq 1 + l$ ，第二个估计量逐样本非负。可同时记录回报、动作熵、价值损失、梯度范数、比率分布、裁剪比例和解释方差

$$\text{EV} = 1 - \frac{\text{Var}(\widehat{R} - V)}{\text{Var}(\widehat{R})}. \quad (7.35)$$

当回报目标方差为零时，该比值需要单独处理。

更新前的零步检查应满足 $\rho \approx 1$ 、经验 KL 接近零。训练异常时，先在固定小批量上验证损失与梯度，再检查奖励对齐、GAE、实际执行动作及终止观测，最后扩展并行环境和重复更新。观察到回报未改善而尚未完成定位时，记录“原因未查明”，并单独列出待执行的检查。

更新统计量的联合解释 固定旧策略采样后，记录近似 KL、裁剪比例、熵和回报。高裁剪比例说明许多代理项处于裁剪区间，无法单独判断回报变化原因。高价值误差可以来自未拟合目标、错误自举、奖励尺度或数据噪声，需要逐项测试。完整训练需要连接采样、优势估计和策略更新。应先检验各函数的局部恒等式，再使用固定环境种子测试完整迭代。[2]

7.5 课后习题

习题 7.1 有限轨迹的 GAE 与边界语义

一条三步轨迹的奖励为 $(1, 2, 3)$ ，当前价值为 $(0.5, 0.4, 0.2)$ ， $\gamma = 0.9, \lambda = 0.8$ 。最后一步可能真正终止，也可能因外部时间上限被截断。

- 先对无中间终止的长度 m 轨迹展开 $G_t^{(n)} - V_t$ ，证明其等于前 n 个折扣 TD 残差之和。为有限 λ 回报写出所有权重，尤其是最长回报的尾项。
- 最后一步真正终止时，计算全部 TD 残差、GAE 和价值回归目标。分别取 $\lambda = 0$ 与 $\lambda = 1$ ，验证 TD 和 Monte Carlo 两个边界。
- 若最后一步仅为外部截断，实际末观测价值为 5，重新计算。若向量环境自动重置后返回的新初态价值为 0，使用它代替末观测会造成什么偏差？
- 在轨迹中间插入一次重置。分别定义 TD 自举掩码与 GAE 递归掩码，说明重置后的优势能否传播到重置前。推广到固定长度 rollout 切段但环境未终止的情况。
- 编程：实现反向递归与显式有限求和两个独立版本，逐元素比较。覆盖单步、向量环境、外部截断、真正终止和自动重置；检查优势与回归目标不向旧价值网络传播梯度。

习题 7.2 Bernoulli 策略、基线与 PPO 裁剪

单步策略选择 $a \in \{0, 1\}$ ， $p = \text{sigmoid}(\theta)$ ，奖励为 $r = a$ 。所有状态相同，环境不含其他随机性。

- 推导真实回报梯度与两动作的 score。求使 REINFORCE 梯度方差最小的常量基线，并证明本例可达到零方差。
- 令旧策略 $p_0 = 1/2$ ，使用真实旧优势 $A(a) = a - 1/2$ ，裁剪宽度为 $\epsilon = 0.2$ 。在旧动作分布下完整求和，写出 PPO 代理目标关于新概率 p 的分段表达式。
- 求代理目标的全部最大化概率。计算旧策略到新策略的 KL，并分析 $p \uparrow 1$ 。根据结果判断，代理目标裁剪能否单独给出全分布 KL 的硬上界。
- 把动作基线错误地设成 $b(a) = a$ 。计算期望梯度，解释有偏性的来源。随后证明状态基线的期望贡献为零。
- 编程：枚举两动作得到精确目标与梯度，再实现采样估计。检验正负优势的裁剪分支、旧概率固定以及多轮优化后的 KL。将优化器行为与代理目标本身的性质分开报告。

第 8 章 值函数方法与离线强化学习

值函数学习以 Bellman 关系构造训练目标。本章从离散动作 Q 学习扩展到最大熵控制，讨论离线数据中的分布偏移、保守估计、隐式策略提取和模仿学习。

8.1 Q-learning、目标网络与 Double DQN

最优动作价值函数满足 Bellman 最优方程

$$Q^*(s, a) = \mathbb{E} \left[r + \gamma \max_{a'} Q^*(s', a') \mid s, a \right]. \quad (8.1)$$

Q-learning 以采样转移构造该方程的随机更新。深度 Q 网络 (DQN) 使用神经网络近似 Q ，并引入经验回放与目标网络。回放缓冲区存储 (s, a, r, s', d) ，小批量采样降低连续转移间的相关性；目标网络以较低频率复制在线参数，或采用缓慢的参数平均，以减小回归目标随当前更新立即变化的程度。[19, 20]

对从缓冲区采样的转移，定义

$$y = r + \gamma(1 - d) \max_{a'} Q_{\bar{\theta}}(s', a'), \quad \mathcal{L}_Q = \frac{1}{2} \mathbb{E}[(Q_{\theta}(s, a) - \text{sg}(y))^2]. \quad (8.2)$$

这里 d 表示真正终止。外部时间截断通常保留后继状态的自举值，具体处理依赖任务的时间定义。Huber 损失可以替代平方损失，以降低大残差的梯度幅度。目标值整体停止梯度，包括目标网络的输出。

离散动作实现中，网络输出 $Q_{\theta}(S) \in \mathbb{R}^{B \times A}$ ，动作索引 $I \in \{0, \dots, A - 1\}^{B \times 1}$ 。选择量满足 $q_b = Q_{\theta}(S)[b, I_{b,0}]$ 。索引轴属于动作编号，不能用沿批次轴的最大值替代动作选择。

最大化偏差 若 $\widehat{Q}_a = Q_a + \epsilon_a$ 且 $\mathbb{E}[\epsilon_a] = 0$ ，最大值的凸性给出


$$\mathbb{E}[\max_a \widehat{Q}_a] \geq \max_a \mathbb{E}[\widehat{Q}_a] = \max_a Q_a. \quad (8.3)$$

同一组估计同时完成动作选择和价值评估时，正估计误差更容易被选中。Double DQN 将两项操作分别交给在线网络与目标网络：

$$a^* = \arg \max_{a'} Q_{\theta}(s', a'), \quad y_{\text{DDQN}} = r + \gamma(1 - d) Q_{\bar{\theta}}(s', a^*). \quad (8.4)$$

该方法降低选择与评估误差的耦合。两个网络仍然相关，因此偏差不会在一般情形下严格消失。[20]

$$a^* = \arg \max_a Q_\theta(s', a), \quad q' = Q_{\bar{\theta}}(s', a^*)$$



对象 价值为实数； a^* 为从零开始的整数动作索引。

运算 在线价值仅确定索引，目标价值在该索引处被读取；随后构造停止梯度的 TD 目标。

图 8.1 Double DQN 的选择与读取过程。连续价值、离散索引与最终选取值分别表示。

例题 8.1 在线选择与目标评估

设下一状态的在线价值为 $(3, 5, 4)$ ，目标价值为 $(6, 2, 3)$ ，即时奖励 $r = 1$ ， $\gamma = 0.9$ ，转移未终止。求 DQN 与 Double DQN 目标。

解 DQN 对目标价值取最大值，得到 $1 + 0.9 \times 6 = 6.4$ 。Double DQN 的在线网络选择第二个动作，再读取其目标价值 2，得到 $1 + 0.9 \times 2 = 2.8$ 。动作索引来自在线网络，数值评估来自目标网络；若两次均使用目标网络，计算退化为式(8.2)。

两个动作的高斯估计误差 当两个真实动作价值均为零，且误差 ϵ_1, ϵ_2 独立服从 $\mathcal{N}(0, \sigma^2)$ ，最大化偏差可精确求出。使用恒等式

$$\max(\epsilon_1, \epsilon_2) = \frac{\epsilon_1 + \epsilon_2 + |\epsilon_1 - \epsilon_2|}{2},$$

而 $\epsilon_1 - \epsilon_2 \sim \mathcal{N}(0, 2\sigma^2)$ 。对标准正态 Z ，

$$\mathbb{E}|Z| = 2 \int_0^\infty z \frac{e^{-z^2/2}}{\sqrt{2\pi}} dz = \sqrt{\frac{2}{\pi}}.$$

因此 $\mathbb{E} \max(\epsilon_1, \epsilon_2) = \sigma/\sqrt{\pi}$ 。若用于评估的误差与动作选择完全独立且均值为零，则所选动作的评估均值为零。这说明 Double DQN 所需的是误差相关性的控制；仅建立第二个同值网络不会自动获得这一性质。

回报分布预测 还可以学习随机回报 $Z^\pi(s, a)$ 的完整分布。其分布 Bellman 关系为

$$Z^\pi(s, a) \stackrel{D}{=} R + \gamma(1 - D)Z^\pi(S', A'), \quad (8.5)$$

其中 (R, D, S') 按环境转移联合采样， $A' \sim \pi(\cdot | S')$ ，后继回报按其条件分布采样。等号表示分布相同。对两侧取期望即可恢复普通 Bellman 方程。[101]

设网络在有序支撑点 $z_1 < \dots < z_K$ 上输出概率。转移目标 $y = r + \gamma(1-d)z_j$ 通常落在支撑点之间。若 $z_l \leq y \leq z_{l+1}$ ，将其概率质量分配为

$$w_l = \frac{z_{l+1} - y}{z_{l+1} - z_l}, \quad w_{l+1} = \frac{y - z_l}{z_{l+1} - z_l}. \quad (8.6)$$

两项和为一，且 $w_l z_l + w_{l+1} z_{l+1} = y$ ，因此该线性投影在范围内保持均值。超出支撑范围的目标通常被截到端点，此时均值一般改变。分布宽度还包含环境本身的随机性，不能直接作为模型知识不足的测量。第10章的 two-hot 价值目标使用了相近的插值思想。

8.2 最大熵强化学习与 SAC

最大熵目标在期望回报之外加入策略熵：

$$J_{\text{soft}}(\pi) = \mathbb{E}_{\pi} \sum_{t \geq 0} \gamma^t [r_t + \alpha \mathcal{H}(\pi(\cdot | s_t))], \quad \alpha > 0. \quad (8.7)$$

连续动作下使用微分熵。微分熵可以为负，且会随动作坐标的缩放而变化。以下约定 $Q(s, a)$ 不包含当前动作的熵项，并定义

$$V(s) = \mathbb{E}_{a \sim \pi} [Q(s, a) - \alpha \log \pi(a | s)], \quad Q(s, a) = \mathbb{E}[r + \gamma(1-d)V(s')]. \quad (8.8)$$

固定状态与价值函数，在概率归一化约束下最大化 $\int \pi(a) Q(a) da + \alpha \mathcal{H}(\pi)$ 。对带拉格朗日乘子的目标作变分，得到

$$Q(a) - \alpha(\log \pi(a) + 1) + \lambda = 0.$$

先将 $\log \pi(a)$ 单独列出，再对两边取指数：

$$\begin{aligned} \log \pi(a) &= Q(a)/\alpha + \lambda/\alpha - 1, \\ \pi(a) &= C \exp(Q(a)/\alpha), \quad C = \exp(\lambda/\alpha - 1). \end{aligned}$$

概率归一化要求 $C \int \exp(Q(a)/\alpha) da = 1$ 。定义配分函数

$$Z(s) = \int \exp(Q(s, a)/\alpha) da.$$

若该积分有限，则 $C = 1/Z(s)$ ，从而得到最优策略

$$\pi^*(a | s) = \frac{\exp(Q(s, a)/\alpha)}{Z(s)}. \quad (8.9)$$

将 $\log \pi^* = Q/\alpha - \log Z$ 代入 KL 定义，逐项展开：

$$\alpha \mathbb{E}_{\pi_{\phi}} [\log \pi_{\phi} - \log \pi^*] = \alpha \mathbb{E}_{\pi_{\phi}} \log \pi_{\phi} - \mathbb{E}_{\pi_{\phi}} Q + \alpha \log Z.$$

因此

$$\alpha \text{KL}(\pi_{\phi} \| \pi^*) = \mathbb{E}_{a \sim \pi_{\phi}} [\alpha \log \pi_{\phi}(a | s) - Q(s, a)] + \alpha \log Z(s). \quad (8.10)$$

当策略由参数化分布表示时, SAC 的 actor 更新可以理解为最小化上述 KL 中依赖 ϕ 的部分。[21]

SAC 使用两个 critic。以当前策略在后继状态采样 $a' \sim \pi_\phi(\cdot | s')$, 构造

$$y = r + \gamma(1 - d) \left[\min_{j=1,2} Q_{\bar{\theta}_j}(s', a') - \alpha \log \pi_\phi(a' | s') \right], \quad (8.11)$$

$$\mathcal{L}_{Q_j} = \frac{1}{2} \mathbb{E}_{(s,a) \sim \mathcal{D}} [(Q_{\theta_j}(s, a) - \text{sg}(y))^2]. \quad (8.12)$$

双 critic 的最小值用于抑制过估计, 也可能产生低估。该处理与 Double DQN 的动作选择、评估分离具有不同的计算结构。

actor 从回放状态出发, 重新采样当前策略动作:

$$\mathcal{L}_\pi = \mathbb{E}_{s \sim \mathcal{D}, \epsilon} \left[\alpha \log \pi_\phi(a_\phi(s, \epsilon) | s) - \min_j Q_{\theta_j}(s, a_\phi(s, \epsilon)) \right]. \quad (8.13)$$

critic 参数在此更新中固定, 但 Q 对动作的导数必须保留。回放记录中的旧动作适用于 critic 回归, actor 更新使用可重参数化的当前策略动作。若将 critic 前向放在 `no_grad` 中, 将同时删除策略所需的 $\partial Q / \partial a$ 。

$$\mathcal{L}_\pi = \mathbb{E}[\alpha \log \pi_\phi(a | s) - Q_\theta(s, a)], \quad a = a_\phi(s, \epsilon)$$




图 8.2 SAC actor 更新中的梯度依赖。图中用单个 Q 表示实际双 critic 最小值所在的分支。

目标参数以 Polyak 平均更新:

$$\bar{\theta} \leftarrow (1 - \rho)\bar{\theta} + \rho\theta, \quad 0 < \rho \ll 1. \quad (8.14)$$

实现中要区分采用更新率 ρ 与采用保留率 $1 - \rho$ 的配置约定。参数名称和公式应共同确定其含义。

有界动作的概率密度 令 $u = \mu_\phi(s) + \sigma_\phi(s) \odot \epsilon$, $\epsilon \sim \mathcal{N}(0, I)$, 并取 $a = \tanh u$ 。逐坐标变换的 Jacobian 为 $\partial a_i / \partial u_j = \mathbf{1}[i = j](1 - \tanh^2 u_i)$ 。概率质量守恒要求 $\pi(a) da = p_U(u) du$, 所以

$$\pi(a) = p_U(u) \left| \det \frac{\partial a}{\partial u} \right|^{-1}, \quad \left| \det \frac{\partial a}{\partial u} \right| = \prod_i (1 - \tanh^2 u_i).$$

两边取对数, 得到

$$\log \pi_\phi(a | s) = \log \mathcal{N}(u; \mu_\phi, \text{diag}(\sigma_\phi^2)) - \sum_i \log(1 - \tanh^2 u_i). \quad (8.15)$$

直接计算 $1 - \tanh^2 u$ 在饱和区域可能因舍入变成零。先用 $1 - \tanh^2 u = 1/\cosh^2 u$ ，再写 $\cosh u = e^u(1 + e^{-2u})/2$ 。对数化简后得到稳定形式

$$\log(1 - \tanh^2 u) = 2[\log 2 - u - \text{softplus}(-2u)]. \quad (8.16)$$

若环境动作还经过 $a_{\text{env}} = c + Da$ ，其中 D 为对角缩放矩阵，则对数密度还需减去 $\sum_i \log |D_{ii}|$ 。固定缩放常数不改变部分 actor 梯度，却会改变熵的数值和温度更新所依赖的目标。

例题 8.2 冻结 critic 后的策略梯度

取单维动作 $a = \tanh \phi$ ，固定 critic 为 $Q(a) = a$ ，暂令 $\alpha = 0$ 。求 actor 损失及其梯度。

解 $\mathcal{L}_\pi = -\tanh \phi$ ，故 $\partial \mathcal{L}_\pi / \partial \phi = -(1 - \tanh^2 \phi)$ 。在 $\phi = 0$ 时梯度为 -1 。critic 参数固定不影响这个链式导数；将 $Q(a)$ 的输出停止梯度会使该导数变为零。

温度优化 温度方向可从约束优化推导。设策略需满足 $\mathbb{E}\mathcal{H}(\pi) \geq \mathcal{H}_*$ ，对最大化回报的问题构造

$$\mathcal{F}(\pi, \alpha) = J(\pi) + \alpha[\mathbb{E}\mathcal{H}(\pi) - \mathcal{H}_*], \quad \alpha \geq 0.$$

策略侧最大化该函数，乘子侧最小化其对偶目标。固定当前策略时，对乘子的导数为 $\mathbb{E}\mathcal{H} - \mathcal{H}_*$ 。以 $\eta = \log \alpha$ 保证温度为正，并停止策略统计量的梯度，得到常用目标

$$\mathcal{L}_\alpha = \mathbb{E}[-e^\eta \text{sg}(\log \pi_\phi(a | s) + \mathcal{H}_*)]. \quad (8.17)$$

记采样熵 $\widehat{\mathcal{H}} = -\mathbb{E}[\log \pi]$ ，则

$$\frac{\partial \mathcal{L}_\alpha}{\partial \eta} = \alpha(\widehat{\mathcal{H}} - \mathcal{H}_*).$$

实际熵低于目标时，该梯度为负，梯度下降增加温度。另一个常用实现最小化 $-\eta \text{sg}(\log \pi + \mathcal{H}_*)$ ；其驻点相同，但梯度少了 α 因子，优化轨迹与步长尺度随之改变。

例题 8.3 温度梯度的方向

设 $\alpha = 0.2$ ， $\widehat{\mathcal{H}} = -3$ ， $\mathcal{H}_* = -2$ 。求对 η 的梯度。

解 梯度为 $0.2(-3 + 2) = -0.2$ 。更新 $\eta \leftarrow \eta - \zeta \partial \mathcal{L} / \partial \eta$ 将增大 η ，进而增大 α 。这里两项熵均为负，比较仍按通常的实数顺序进行。

8.3 模仿学习、分布偏移与数据聚合

模仿学习直接使用专家数据 $\mathcal{D} = \{(s_i, a_i)\}$ 学习策略。对离散动作，行为克隆的目标为

$$\mathcal{L}_{\text{BC}}(\theta) = -\mathbb{E}_{(s,a) \sim \mathcal{D}} \log \pi_\theta(a | s). \quad (8.18)$$

该目标在专家状态分布 d_{π_E} 上训练，而执行时状态来自学习策略自己的分布 d_{π_θ} 。设单步分类错误率至多为 ϵ 。在长度为 T 的轨迹上，只要早期动作使系统进入专家数据中较少出现的状态，后续错误概率就可能继续增加。经典误差传播分析表明，纯行为克隆的累计代价差在最坏情况下可达到 $O(T^2\epsilon)$ 。

行为克隆误差的有限时域界 设每步代价在 $[0, 1]$ ，示范状态分布上策略的动作错误概率至多为 ϵ 。在发生第一次错误之前，学习策略与专家路径相同。联合界给出前 t 步至少一次错误的概率不超过 $t\epsilon$ ；第一次错误后允许任意后续状态偏移。因此累积额外代价可被界定为

$$J(\pi) - J(\pi_E) \leq \sum_{t=1}^T \min(1, t\epsilon) \leq \frac{T(T+1)}{2} \epsilon. \quad (8.19)$$

这是最坏情形上界，依赖错误前路径可耦合的假设。DAgger 迭代收集学习策略访问状态的专家动作，通过数据聚合改变监督分布。其改进保证还依赖在线学习遗憾和专家标注等条件，不能仅通过把旧示范重复训练获得。[69]

DAgger 使用数据聚合修正这一分布偏移。第 k 轮用当前策略访问状态 $s \sim d_{\pi_k}$ ，再向专家查询 $a_E(s)$ ，得到

$$\mathcal{D}_{k+1} = \mathcal{D}_k \cup \{(s, a_E(s)) : s \sim d_{\pi_k}\}. \quad (8.20)$$

训练分布由专家轨迹逐渐扩展到学习策略实际访问的状态。对于机器人控制，行为克隆还需确定动作的表示方式。动作分块决定一次预测的执行长度，多峰策略分布影响不同有效动作的表达能力。数据采集协议则决定哪些状态和动作进入训练集。[5]

例题 8.4 两步系统中的行为克隆分布偏移

专家从 s_0 总选择动作 a 并到达 s_1 ；在 s_1 再选择 a 完成任务。学习策略在 s_0 以 0.9 概率选择 a ，错误动作 b 会进入未出现在专家数据中的 s'_1 ；在 s_1 上策略选择 a 的概率仍为 0.9，在 s'_1 上成功概率为 0.2。求总成功率。

解 按首步状态分支，

$$P(\text{success}) = 0.9 \times 0.9 + 0.1 \times 0.2 = 0.83.$$

如果只在专家分布上报告第二步准确率，会得到 0.9；闭环成功率还取决于首步错误诱导的状态分布。评估模仿策略时应同时报告离线动作误差与闭环任务指标。

8.4 离线数据、IQL 与保守价值估计

离策略学习允许行为策略与当前策略不同，训练过程仍可持续获得环境数据。离线强化学习则使用固定数据集 $\mathcal{D}$ ，不能依靠在线交互自动修正未覆盖动作的价值估计。

例如, 某状态的数据只包含动作 a_0 , 其回报为 1。若函数逼近给未出现的动作 a_1 赋值 10, Bellman 最大化与贪心策略会使用这个未经数据约束的值。回归损失在已观察样本上较小, 也允许这一现象发生。离线方法需要控制分布外动作对目标与策略的影响。[22, 23]

IQL 的 expectile 回归 隐式 Q 学习 (IQL) 通过状态价值回归构造无需在 TD 目标中显式最大化动作的更新。定义非对称平方损失

$$\ell_\tau(u) = |\tau - \mathbf{1}[u < 0]|u^2, \quad 0 < \tau < 1. \quad (8.21)$$

当 $\tau > 1/2$ 时, 正残差得到更大的权重。expectile 由非对称平方损失定义; 分位数由非对称绝对值损失定义, 两者对应不同的统计量。

IQL 的基本更新可写为

$$\mathcal{L}_V = \mathbb{E}_{(s,a) \sim \mathcal{D}} [\ell_\tau(\text{sg}(Q(s,a)) - V_\psi(s))], \quad (8.22)$$

$$\mathcal{L}_Q = \frac{1}{2} \mathbb{E}_{\mathcal{D}} \left[(Q_\theta(s,a) - \text{sg}(r + \gamma(1-d)V_\psi(s')))^2 \right], \quad (8.23)$$

$$\mathcal{L}_\pi = -\mathbb{E}_{\mathcal{D}} [\text{sg}(e^{\beta(Q(s,a)-V_\psi(s))}) \log \pi_\phi(a | s)]. \quad (8.24)$$

实践中可使用目标 Q 网络和双 critic, 并对指数权重设置上限。权重截断改变了原目标, 应记录具体阈值。策略提取相当于优势加权行为克隆; 参数化策略在未见状态或连续动作间仍可能外推, 数据支持不会由该损失自动构成硬约束。




图 8.3 非对称平方损失。 $\tau = 0.8$ 时正残差具有更高权重, 使最优价值偏向条件价值分布的较高 expectile。

expectile 的分段二次最优解 令随机变量 Q 以概率 p 取 q_h 、以概率 $1-p$ 取 $q_l < q_h$, expectile 为 $v \in [q_l, q_h]$ 。目标为

$$L(v) = p\tau(q_h - v)^2 + (1-p)(1-\tau)(q_l - v)^2.$$

求导并令零, 得到

$$v_\tau = \frac{p\tau q_h + (1-p)(1-\tau)q_l}{p\tau + (1-p)(1-\tau)}. \quad (8.25)$$

$\tau = 1/2$ 时为均值; $\tau \rightarrow 1$ 且 $p > 0$ 时趋于 q_h 。该分布来自数据动作上的估值, IQL 无需通过最大化未观测动作建立价值回归目标; actor 的优势加权仍受到数据覆盖限制。[22]

例题 8.5 两点分布的 expectile

随机变量 X 以相同概率取 0 与 2。求 $v = \arg \min_v \mathbb{E}[\ell_\tau(X - v)]$ ，其中 $0 < \tau < 1$ 。

解 最优解位于 $[0, 2]$ 。该区间内目标为

$$\frac{1}{2}(1 - \tau)v^2 + \frac{1}{2}\tau(2 - v)^2.$$

导数为 $(1 - \tau)v - \tau(2 - v) = v - 2\tau$ ，故 $v = 2\tau$ 。当 $\tau = 0.8$ 时得到 1.6；按通常的左连续逆分布定义，0.8 分位数为 2。在 $v = 1.6$ 处，正残差加权为 $0.5 \times 0.8 \times 0.4 = 0.16$ ，负残差加权为 $0.5 \times 0.2 \times (-1.6) = -0.16$ ，两者相消，验证驻点条件。

优势加权与行为参考分布 令 $\mu(a | s)$ 为数据行为分布。在固定状态下，以行为分布为参考最大化

$$\mathbb{E}_{a \sim \pi} Q(s, a) - \beta^{-1} \text{KL}(\pi \| \mu).$$

与式(8.9)相同的变分计算给出

$$\pi^*(a | s) = \frac{\mu(a | s)e^{\beta Q(s, a)}}{Z_\mu(s)}, \quad Z_\mu(s) = \mathbb{E}_{a \sim \mu} e^{\beta Q(s, a)}. \quad (8.26)$$

将 Q 改写为 $Q - V(s)$ ，归一化后的动作分布保持不变，因为 $e^{-\beta V(s)}$ 对同一状态的所有动作相同。通过最小化 $\text{KL}(\pi^* \| \pi_\phi)$ 提取参数化策略，依赖 ϕ 的部分为

$$-\mathbb{E}_{a \sim \mu} \left[\frac{e^{\beta Q(s, a)}}{Z_\mu(s)} \log \pi_\phi(a | s) \right].$$

IQL 的未逐状态归一化加权回归使用 $e^{\beta(Q-V)}$ 。在每个状态可独立拟合时，两者具有相同最优动作分布；共享参数、有限容量及不同状态权重下，优化结果可以不同。优势基线不仅影响数值范围，也可能改变状态之间的有效权重。

CQL 的保守正则化 保守 Q 学习 (CQL) 通过 log-sum-exp 项惩罚高预测值，并以数据动作价值项校正该惩罚，从而约束数据支持之外的价值估计。离散动作下的一种形式为

$$\mathcal{L}_{\text{CQL}} = \mathcal{L}_{\text{TD}} + \lambda \mathbb{E}_{s \sim \mathcal{D}} \left[\log \sum_a e^{Q(s, a)} - \mathbb{E}_{a \sim \mathcal{D}(\cdot | s)} Q(s, a) \right]. \quad (8.27)$$

对固定状态，正则项关于 $Q(s, a)$ 的导数为

$$\lambda [\text{softmax}(Q(s, \cdot))_a - \hat{\pi}_{\mathcal{D}}(a | s)]. \quad (8.28)$$

若一个动作获得高预测价值却很少出现在数据中，该项倾向于降低其估计。连续动作需要近似积分；使用提议分布采样时，积分估计中的重要性权重不可省略。保守下界性质依赖特定目标、采样与函数逼近假设，不能由任意正则化实现直接推出。正则过强也可能降低可达回报。

8.5 数据复用与评估协议

PPO 在每次更新前使用当前行为策略采样，并以固定旧概率构造有限次批次复用。SAC 利用 Bellman 关系从长期回放数据中更新 critic，再在回放状态上优化当前 actor。二者对数据、概率比和目标构造的要求不同。增大更新与交互的比率只增加优化次数，不增加独立环境信息。

SAC 实现首先应保证奖励、终止标记、价值与对数概率具有统一的 $[B]$ 或 $[B, 1]$ 形状。将 $[B]$ 与 $[B, 1]$ 相加会广播为 $[B, B]$ ，并可能产生可反向传播但语义错误的损失。分别验证 critic、actor、温度更新的梯度参数集合，再接入完整训练循环。

离线评估不能仅依据训练 TD 损失排序策略。重要性采样需要可用的行为概率与支持覆盖，长轨迹的乘积权重常有较高方差；拟合 Q 评估也受到函数逼近与数据覆盖的限制。在可使用独立模拟器的实验中，应固定训练数据，仅将模拟器用于预先定义的评估，不把测试转移加入离线训练集。

一种受控设置是构造规模相同、动作覆盖不同的两个数据集，比较行为克隆、朴素 Q-learning 与 IQL。报告实际任务回报、数据动作误差、候选动作价值分布以及动作覆盖。关于覆盖不足的解释，应由相应干预支持；未完成验证的结果保留为待检验假设。

离线策略评价与分布外动作 评价数据中没有覆盖的动作，其真实后果一般不能仅由经验 Bellman 误差确定。应记录策略与数据行为的偏离、数据动作的范围、任务覆盖和独立环境评价。SAC 中的 twin critic 最小值与 CQL 的显式保守惩罚具有不同目标；二者均不能在任意无覆盖数据上保证正确控制。

对连续动作的 $Z = \int e^{Q(s,a)} da$ ，若从覆盖积分区域的 $q(a | s) > 0$ 采样，则

$$\hat{Z} = \frac{1}{K} \sum_{k=1}^K \exp[Q(s, a_k) - \log q(a_k | s)]$$

是 Z 的无偏估计，适用条件还包括有限的一阶矩。然而 $\log \hat{Z}$ 一般有偏，由 Jensen 不等式有 $\mathbb{E} \log \hat{Z} \leq \log Z$ 。实际训练使用 log-sum-exp 实现数值稳定，但数值稳定性不会消除采样偏差。IQL 的指数优势权重需限制极端值或采用数值稳定实现，并报告实际限制规则及触发比例。[23, 22]

8.6 课后习题

习题 8.1 最大值偏差与 Double Q 估计的相关性

某后继状态有两个动作，真实 Q 值均为零。在线估计为 $Q_i = \varepsilon_i$ ，其中 ε_i 独立服从 $\mathcal{N}(0, \sigma^2)$ 。

- 利用 $\max(x, y) = (x + y + |x - y|)/2$ ，求 $\mathbb{E} \max_i Q_i$ 的精确值。与只使用 Jensen 不等式得到的结论比较。
- 令目标估计为 $\tilde{Q}_i = \rho \varepsilon_i + \sqrt{1 - \rho^2} \zeta_i$ ，其中 ζ_i 与全部在线噪声独立，分布相同， $|\rho| \leq 1$ 。选取 $I = \arg \max_i Q_i$ 后用 $\tilde{Q}_I$ 评价，推导其期望。
- 在线 Q 变为 (3, 5, 4)，目标 Q 为 (6, 2, 3)，奖励为 1， $\gamma = .9$ 。分别计算 DQN 与 DDQN 目标。将转移改为真正终止后重新计算；外部时间截断是否产生相同结果？
- 编程：实现两个目标及相关噪声实验。对并列最大值固定索引规则，对目标值停止梯度。比较 $\rho = 0, .5, 1$ 的样本均值与解析预测，报告采样标准误差。
- 若两个真实 Q 值不相等，即使目标噪声独立，DDQN 是否等于真实最大值的无偏估计？用错误选择事件分解期望，说明两种偏差需要怎样区分。

习题 8.2 SAC 动作密度与路径梯度

标量动作由 $u = \mu + e^\eta \varepsilon$ 、 $a = c + d \tanh u$ 产生， $d > 0$ ， $\varepsilon \sim \mathcal{N}(0, 1)$ 。固定 critic 为 $Q(a) = -(a - a^*)^2$ ，温度为 $\alpha > 0$ 。

- 先在有限动作集合上，使用 Lagrange 乘子推导最大熵最优策略和 soft value。再把任意策略的目标写成最优值减去 KL 项，说明连续动作推广所需的归一化条件。
- 从变量变换推导 $\log \pi(a)$ 。把 $\log(1 - \tanh^2 u)$ 改写为稳定表达式，明确动作尺度 d 的影响。
- 对单个固定基础噪声样本的 actor 损失 $\alpha \log \pi(a) + (a - a^*)^2$ 求 μ, η 的全路径导数。逐项区分高斯密度、Jacobian 修正和 critic 的贡献。
- 冻结 critic 参数与对整个 $Q(a)$ 停止梯度分别会怎样改变 actor 更新？若动作单位整体缩放 $a' = ka$ ，推导微分熵的变化，说明目标熵的数值为何依赖坐标单位。
- 编程：实现稳定的 squashed-Gaussian log-density 与 actor 更新，固定噪声比较解析、自动微分和有限差分。测试大 $|u|$ 、不同 d 、critic 参数冻结以及温度更新的梯度集合。

习题 8.3 离线数据中的 expectile 与不可辨识动作

单步环境有动作 a_0, a_1, a_2 。数据只包含 a_0, a_1 ，频率相等，奖励分别为 0 和 2。未观测动作 a_2 的奖励未知。采用 IQL 的 expectile 参数 $\tau = 0.8$ 。

- (a) 写出 V 的分段加权平方目标，从一阶条件求全局最优值。不要预先假设答案位于 $[0, 2]$ ；先说明该区间为何包含最优解。
- (b) 在经验动作分布上最小化指数优势加权交叉熵，温度尺度为 $T > 0$ 。求无容量限制时的最优动作概率，并解释减去状态基线 V 为什么会在本例归一化时消去。
- (c) 构造两个与全部离线数据一致的环境，使 a_2 分别成为最优和最差动作。证明仅由该数据不能判断这两个环境，讨论“Bellman 误差为零”能支持什么结论。
- (d) 对 $Q = (0, 2, q_2)$ 写出离散 CQL 正则项及梯度。固定前两个 Q ，分析正则项对 q_2 的作用与极限，说明保守估计是否等同于恢复真实未观测奖励。
- (e) 编程：实现 expectile、归一化优势权重和 CQL。用上述两个环境共享同一离线数据和训练配置，分别测量最终真实回报。把数据内拟合、未观测动作选择比例和环境回报分别报告。

第 9 章 语言模型后训练

语言模型后训练涉及 token 概率、序列奖励、偏好数据与策略约束。本章推导奖励建模、PPO、GRPO 和 DPO 的关系，并分析长度归约、采样分布及截断处理。

9.1 序列概率、动作定义与奖励

给定提示 x 与已生成前缀 $y_{<t}$ ，语言生成可表示为序列决策过程：状态为 $s_t = (x, y_{<t})$ ，动作为 token y_t ，策略为 $\pi_\theta(y_t | x, y_{<t})$ 。普通生成的状态转移由追加 token 确定；涉及工具或外部环境时，观测转移也可能具有随机性。

对回答 $y_{1:L}$ ，序列对数概率为

$$\log \pi_\theta(y | x) = \sum_{t=1}^L \log \pi_\theta(y_t | x, y_{<t}). \quad (9.1)$$

若只在回答结束时给予奖励 $R(x, y)$ ，且 $\gamma = 1$ ，则各回答 token 对应相同的终端回报。REINFORCE 的基本序列梯度为 $\mathbb{E}[(R - b)\nabla_\theta \log \pi_\theta(y | x)]$ 。

EOS、环境定义的终止和触及生成长度上限需要独立记录。长度截断后的奖励与回报处理应由任务协议确定。没有价值估计器的 GRPO 不具备可直接套用的价值自举项；语言训练中的长度上限也不能自动等同于环境中的外部时间截断。

token 选择与有效位置 令 logits 为 $Z \in \mathbb{R}^{B \times L \times V}$ ，整数 token ID 为 $Y \in \{0, \dots, V-1\}^{B \times L}$ 。下一 token 对齐先使用 $Z[:, 0:L-1, :]$ ，再沿词表轴读取 $Y[:, 1:L]$ 的对数概率：

$$\ell_{b,t} = \log \text{softmax}(Z_{b,t,:})_{Y_{b,t+1}}, \quad 0 \leq t < L-1. \quad (9.2)$$


回答掩码也需对齐到被预测的 $Y_{b,t+1}$ 。用于交叉熵忽略标签的 -100 不属于有效词表索引，不能未经处理直接传入 gather。通常保留合法 token ID，并单独用布尔掩码控制归约。

例题 9.1 回答对数概率的归约

两个回答的有效 token 概率分别为 $(0.5, 0.25)$ 和 $(0.5, 0.5, 0.5, 0.5)$ 。求序列对数概率与平均 token 对数概率。

解 两者序列概率分别为 $1/8$ 和 $1/16$ ，序列对数概率为 $-3 \log 2$ 与 $-4 \log 2$ 。平均 token 对数概率分别为 $-1.5 \log 2$ 和 $-\log 2$ 。求和与平均产生不同的排序，因此需要按目标函数规定选择归约方式。

$$\ell_t = \log \text{softmax}(Z_{t,:})_{Y_{t+1}}, \quad \log \pi(y | x) = \sum_t m_t \ell_t$$



对象 对数概率矩阵与整数 token ID 为 gather 的独立输入；掩码表示有效回答位置。

运算 每一行按下一 token 的 ID 读取一个值，再沿有效回答位置求和。

图 9.1 序列对数概率中的移位、词表索引与有效位置归约。图示省略批次轴， $Y_{1:L}$ 使用左闭右开的切片约定。

行为策略、当前策略与参考策略具有不同用途。行为策略 π_{old} 生成当前批次，并提供重要性比率分母；当前策略 π_{θ} 接收优化；参考策略 π_{ref} 提供长期固定的分布约束或偏好比较基准。一个批次的多次更新中，旧对数概率必须保持不变。

温度采样或 top- p 截断会改变实际行为分布。若使用原始模型概率构造重要性比率，却用另一种分布采样，式(7.27)的前提可能不成立。初始实现宜使用定义明确的分类分布，并将采样变换与对数概率计算保持一致。

9.2 GRPO、组内优势与 KL 正则化

对同一个提示采样 G 个回答，奖励为 $r_1, \dots, r_G$ 。一种常见的组相对优势定义为

$$\bar{r} = \frac{1}{G} \sum_i r_i, \quad \sigma_r = \sqrt{\frac{1}{G} \sum_i (r_i - \bar{r})^2}, \quad \hat{A}_i = \frac{r_i - \bar{r}}{\sigma_r + \varepsilon}. \quad (9.3)$$

此处方差分母为 G 。组内奖励相同或 $G = 1$ 时，中心化后的优势为零，应记录相应组数及零方差比例。GRPO 以组内比较替代显式价值网络，但组标准化的统计性质仍影响优化。[35]

设同一提示下回答独立采样， $g_i = \nabla \log \pi(y_i | x)$ ，且暂不除以随机标准差。先展开基线与 score 的乘积：

$$\mathbb{E}[g_i \bar{r}] = \frac{1}{G} \mathbb{E}[g_i r_i] + \frac{1}{G} \sum_{j \neq i} \mathbb{E}[g_i r_j] \quad (9.4)$$

$$= \frac{1}{G} \mathbb{E}[g_i r_i] + \frac{1}{G} \sum_{j \neq i} \mathbb{E}[g_i] \mathbb{E}[r_j] \quad (9.5)$$

$$= \frac{1}{G} \mathbb{E}[g_i r_i]. \quad (9.6)$$

第二步要求同一提示下各回答独立采样；第三步使用 $\mathbb{E}[g_i] = 0$ 。于是

$$\mathbb{E}[g_i(r_i - \bar{r})] = \left(1 - \frac{1}{G}\right) \mathbb{E}[g_i r_i]. \quad (9.7)$$

包含自身奖励的样本均值产生有限组大小的缩放。改用其余 $G - 1$ 个回答的均值作为基线可消除此中心化缩放；再除以随机标准差后，需要重新分析其相关性与权重，不能直接沿用该结论。

例题 9.2 组内奖励标准化

组内奖励为 $(0, 1, 1, 0)$ 。计算式(9.3)，并说明忽略 ε 时的结果。

解 均值为 $1/2$ ，总体标准差为 $1/2$ ，优势为 $(-1, 1, 1, -1)$ 。若把标准差分母改为 $G - 1$ ，数值尺度会变化。实现与理论约定应使用相同的标准差定义。

对回答 i 的第 t 个 token，定义

$$\rho_{i,t} = \exp(\ell_{\theta,i,t} - \ell_{\text{old},i,t}), \quad S_{i,t} = \min(\rho_{i,t} \hat{A}_i, \text{clip}(\rho_{i,t}, 1 - \epsilon, 1 + \epsilon) \hat{A}_i). \quad (9.8)$$

令 $m_{i,t}$ 为有效回答掩码， $L_i = \sum_t m_{i,t} > 0$ 。采用每回答平均后再对组平均的一种目标为

$$\mathcal{L}_{\text{GRPO}} = -\frac{1}{G} \sum_{i=1}^G \frac{1}{L_i} \sum_t m_{i,t} S_{i,t} + \frac{\beta}{G} \sum_{i=1}^G \frac{1}{L_i} \sum_t m_{i,t} K_{i,t}. \quad (9.9)$$

优势与旧对数概率固定； $K_{i,t}$ 是指定的 KL 项或估计量。空回答需拒绝、重采样或按预先声明的规则处理，不能让零长度分母隐式决定结果。

原始终端奖励 REINFORCE 对回答 token 的对数概率求和，没有 $1/L_i$ 因子。每回答平均、全 token 平均及固定常数归一化对应不同权重。回答长度、截断比例和奖励之间的关系应与具体归约公式共同报告。

序列级重要性代理与 GSPO 当回答作为完整动作时，精确序列重要性比率为

$$R_i = \frac{\pi_{\theta}(y_i | x_i)}{\pi_{\text{old}}(y_i | x_i)} = \exp \left[\sum_t m_{it} (\ell_{\theta,it} - \ell_{\text{old},it}) \right].$$

GSPO 使用长度归一化的几何平均比率

$$s_i = \exp \left[\frac{1}{L_i} \sum_t m_{it} (\ell_{\theta,it} - \ell_{\text{old},it}) \right] = R_i^{1/L_i}, \quad (9.10)$$

再对 $s_i \hat{A}_i$ 作序列级裁剪。该选项也出现在 CS336 2026 对齐作业的策略梯度接口中。[102, 87]

对固定回答求导， $\nabla s_i = (s_i/L_i) \sum_t m_{it} \nabla \ell_{\theta,it}$ 。因此一条回答内的 token 共享序列级裁剪判定。几何平均可以减轻序列长度引起的比率数值增长，但通常 $\mathbb{E}_{\text{old}}[s_i] \neq 1$ ，不能用它直接替代无偏重要性采样恒等式中的 R_i 。相反方向的 token 对数比率也可能在序列平均中相消。比较 GRPO 与 GSPO 时，应固定奖励、长度归约、行为分布及生成预算，分别观察序列与 token 的比率分布。

KL 的方向与估计 在固定前缀下，当前策略相对参考策略的精确 KL 为

$$K(s) = \sum_a \pi_\theta(a | s) [\log \pi_\theta(a | s) - \log \pi_{\text{ref}}(a | s)]. \quad (9.11)$$

若 $a \sim \pi_\theta(\cdot | s)$ ，定义 $z = \log \pi_{\text{ref}}(a | s) - \log \pi_\theta(a | s)$ ，则在相同支持等条件下

$$k_3 = e^z - z - 1 \geq 0, \quad \mathbb{E}_{a \sim \pi_\theta}[k_3] = \text{KL}(\pi_\theta \| \pi_{\text{ref}}). \quad (9.12)$$

证明利用 $\mathbb{E}_{\pi_\theta}[e^z] = 1$ 与 $e^z \geq 1 + z$ 。注意式(7.34)使用旧策略采样并估计另一方向的 KL，不能只凭表达式外形确定方向。

如果将已采 token 视为固定离散样本，仅对 k_3 的显式参数依赖反向传播，将缺少采样分布的 score-function 梯度。旧策略采样后的重复更新还会改变估计量所对应的期望分布。精确词表 KL 可避免固定前缀下的动作采样近似，但对一组固定前缀取平均仍不自动包含完整序列状态分布随策略变化的梯度。应区分正则项的实际代理目标、统计估计与完整序列 KL。

估计值与估计梯度 一个随机量对 KL 的期望正确，仍不足以说明固定采样后自动微分的结果正确。令 $p_\theta(a)$ 为当前策略、 $q(a)$ 为固定参考，且所有概率均为正。对于 $k_3 = q(a)/p_\theta(a) - \log[q(a)/p_\theta(a)] - 1$ ，固定动作时

$$\partial_\theta k_3 = \left(1 - \frac{q(a)}{p_\theta(a)}\right) \partial_\theta \log p_\theta(a), \quad (9.13)$$

$$\partial_\theta \mathbb{E}_{p_\theta} k_3 = \mathbb{E}_{p_\theta}[\partial_\theta k_3] + \mathbb{E}_{p_\theta}[k_3 \partial_\theta \log p_\theta(a)]. \quad (9.14)$$

第二项来自采样分布变化。另一方面，直接对精确 KL 求导，有

$$\partial_\theta \sum_a p_\theta(a) \log \frac{p_\theta(a)}{q(a)} = \sum_a \partial_\theta p_\theta(a) \left[\log \frac{p_\theta(a)}{q(a)} + 1 \right] \quad (9.15)$$

$$= \mathbb{E}_{p_\theta} \left[\log \frac{p_\theta(a)}{q(a)} \partial_\theta \log p_\theta(a) \right]. \quad (9.16)$$

最后一行使用 $\sum_a \partial_\theta p_\theta(a) = 0$ 。在小词表上枚举所有动作，可分别验证 KL 值、显式导数与完整导数，避免把一次采样的自动微分结果作为证明。

长度归约、零方差组与动态采样 原始 GRPO 的每回答归一化、DAPO 的全有效 token 归一化及 Dr. GRPO 的固定长度常数归一化具有不同权重。[70, 71] 暂不含 KL，对任意 token 代理项 S_{it} ，三种目标分别为

$$J_{\text{seq}} = \frac{1}{G} \sum_i \frac{1}{L_i} \sum_t m_{it} S_{it}, \quad (9.17)$$

$$J_{\text{token}} = \frac{\sum_{i,t} m_{it} S_{it}}{\sum_i L_i}, \quad (9.18)$$

$$J_{\text{fixed}} = \frac{1}{GL_{\max}} \sum_{i,t} m_{it} S_{it}. \quad (9.19)$$

J_{token} 与 J_{fixed} 在同一固定批次上相差常数，但该常数随批次长度改变； J_{seq} 还改变回答之间的相对权重。Dr. GRPO 同时分析了奖励标准差归一化导致的难度相关权重；修改标准化后应重新写出完整目标。

DAPO 使用非对称裁剪阈值，将区间改为 $[1 - \epsilon_{\text{low}}, 1 + \epsilon_{\text{high}}]$ ，并通过动态采样补充非零奖励方差的组。[70] 仅保留这类组会改变提示被用于更新的频率。若接受事件为 $A(x, Y)$ ，保留后提示分布正比于 $p(x) \Pr(A | x)$ 。因此要同时记录原始提示数、采样回答数、接受组数和每个难度层的保留率；相同优化步数不代表相同生成计算预算。

例题 9.3 相同 token 项的两种归约

两个回答长度为 2 和 4，每个有效位置的代理项分别恒为 1 和 -1 。求 J_{seq} 与 J_{token} 。

解 每回答平均后得到 $(1 - 1)/2 = 0$ ；全 token 平均为 $(2 - 4)/6 = -1/3$ 。两者差异来自样本权重，不能由 padding mask 正确这一条件消除。

采样策略与训练策略的一致性 对温度 T ，采样分布为 $\mu(a | s) = \text{softmax}(z/T)_a$ 。若采用 top- p 再归一化，支持也随前缀变化。更新比率的分母必须对应实际行为分布，或明确说明使用的代理近似及误差控制。生成服务和训练引擎还应使用同一 tokenizer、特殊 token、模板、模型权重版本和精度协议。CS336 2026 对齐作业将 log-prob、奖励标准化和 GRPO 测试接口与完整训练分离，便于逐项验证。[74]

9.3 偏好模型与直接偏好优化

偏好数据包含相同提示下的优选回答 y_w 与非优选回答 y_l 。Bradley-Terry 模型用奖励差表示偏好概率：

$$\Pr(y_w \succ y_l | x) = \text{sigmoid}(r_\phi(x, y_w) - r_\phi(x, y_l)). \quad (9.20)$$

对应负对数似然为 $-\log \text{sigmoid}(r_w - r_l)$ 。给奖励同时加上依赖提示的常数不会改变偏好概率；奖励尺度则与偏好噪声模型有关。长度、形式、风格和正确性可能共同影响偏好标签，需要明确评价协议。

直接偏好优化（DPO）从带参考策略 KL 约束的奖励优化出发。对固定提示，考虑

$$\max_{\pi} \left\{ \mathbb{E}_{y \sim \pi} [r(x, y)] - \beta \text{KL}(\pi(\cdot | x) \| \pi_{\text{ref}}(\cdot | x)) \right\}, \quad \beta > 0. \quad (9.21)$$

在参考策略支持上引入归一化乘子 λ 。目标关于单个概率 $\pi(y)$ 的导数为

$$r(x, y) - \beta \left[\log \frac{\pi(y | x)}{\pi_{\text{ref}}(y | x)} + 1 \right] + \lambda = 0.$$

整理并取指数, 得 $\pi(y | x) = \pi_{\text{ref}}(y | x)e^{r(x,y)/\beta}e^{\lambda/\beta-1}$ 。最后一个因子与回答无关, 利用概率和为一确定它。若配分函数有限, 则

$$\pi^*(y | x) = \frac{\pi_{\text{ref}}(y | x)e^{r(x,y)/\beta}}{Z(x)}, \quad Z(x) = \sum_y \pi_{\text{ref}}(y | x)e^{r(x,y)/\beta}. \quad (9.22)$$

还可以通过代回检验最优性。将 $\log \pi^* = \log \pi_{\text{ref}} + r/\beta - \log Z$ 代入, 得到

$$\beta \text{KL}(\pi \| \pi^*) = \beta \text{KL}(\pi \| \pi_{\text{ref}}) - \mathbb{E}_{\pi} r + \beta \log Z.$$

移项后, 原目标等于 $\beta \log Z(x) - \beta \text{KL}(\pi \| \pi^*)$ 。因而最优策略的归一化条件与 KL 的非负性共同确定该解。[36, 85]

将式(9.22)反解为奖励, 得到

$$r(x, y) = \beta \log \frac{\pi^*(y | x)}{\pi_{\text{ref}}(y | x)} + \beta \log Z(x). \quad (9.23)$$

同一提示下的奖励差消去 $\log Z(x)$ 。以 π_{θ} 参数化该隐式奖励并代入偏好似然, 得到

$$\Delta_{\theta} = [\log \pi_{\theta}(y_w | x) - \log \pi_{\theta}(y_l | x)] - [\log \pi_{\text{ref}}(y_w | x) - \log \pi_{\text{ref}}(y_l | x)], \quad (9.24)$$

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E}_{(x, y_w, y_l)} \log \text{sigmoid}(\beta \Delta_{\theta}). \quad (9.25)$$

这里所有序列对数概率采用式(9.1)的求和。参考策略固定, 优选与非优选回答必须属于同一个提示。长度平均会改变式(9.23)的参数化。

$$\Delta = (s_{\theta, w} - s_{\theta, l}) - (s_{\text{ref}, w} - s_{\text{ref}, l}), \quad \mathcal{L} = -\log \sigma(\beta \Delta)$$




图 9.2 DPO 的偏好间隔。序列求和、当前策略与参考策略的区别由独立计算量表示。

例题 9.4 DPO 的初始损失与梯度

设当前策略等于参考策略。求一对偏好样本的损失，以及损失关于 Δ_θ 的导数。

解 此时 $\Delta_\theta = 0$ ，所以 $\mathcal{L} = \log 2$ 。一般情况下

$$\frac{\partial \mathcal{L}}{\partial \Delta_\theta} = -\beta \text{sigmoid}(-\beta \Delta_\theta),$$

初始值为 $-\beta/2$ 。损失为 $\log 2$ 只说明相对参考的偏好间隔为零，不决定模型原有 token 分布或回答质量。

式(9.21)中的 β 控制固定奖励问题的 KL 正则强度；式(9.25)中的有限样本梯度也直接依赖 β 。改变模型容量、数据、训练步数或参数化后，不能仅凭最优分布公式推断训练结果对 β 的单调关系。

若偏好数据在模型参数化下完全可分， $-\log \text{sigmoid}(\beta \Delta)$ 可随着间隔增大而趋于零，有限参数最优未必存在。参考分布出现在间隔定义中，仍不能自动给有限数据拟合提供参数范数界。训练停止、附加正则化和独立验证各自承担不同作用。

回答截断可能删除决定偏好标签的部分，应检查截断后数据是否仍支持原标签。DPO 本身可在固定偏好集上训练；迭代方法还可以重新采样并标注偏好，数据生成方式需要另行说明。

9.4 奖励有效性与后训练评估

可验证奖励应给出明确的接受条件，例如格式匹配、数值容差、符号等价或边界框规则。实现需覆盖重复答案、空回答、数值表示差异、非法输出、padding 与触及长度上限等情况。奖励被优化但评测指标未改善时，应分别报告两项量，并检查评价器定义与训练分布，原因未查明时保持这一标记。

多模态奖励还需检验视觉依赖。可以固定问题并打乱图像、遮蔽相关区域或置换关键物体，观察奖励与回答是否按任务定义变化。纯文本规律可能解释部分正确结果；是否存在这种影响需要由实际对照实验确定。

方法	数据	优化信号	主要检查
PPO	行为策略轨迹	优势估计、价值回归	终止与自举、概率比率、KL。
GRPO	同提示下的回答组	组相对奖励	组方差、长度归约、旧策略与参考策略。
DPO	同提示偏好对	相对参考的偏好间隔	标签有效性、序列求和、截断。

实现顺序可从人工构造的 token 概率与奖励开始,再接入模型输出。固定 logits 检查 log-softmax、移位、词表索引、回答掩码和归约;随后验证组优势与裁剪;最后加入参考策略及完整生成。完整训练还需记录行为采样配置、模型版本、实际长度、有效回答数及独立评估结果。[9]

9.5 课后习题

习题 9.1 组优势、序列比率与 KL 梯度

对一个提示独立采样 G 个回答,终端奖励为 R_i , score 为 $g_i = \nabla_{\theta} \log \pi_{\theta}(y_i | x)$ 。假设采样来自当前策略,奖励函数不显式依赖参数。

- 计算使用组内均值基线的梯度估计 $G^{-1} \sum_i (R_i - \bar{R}) g_i$ 的期望。构造 leave-one-out 基线,并证明其在相同独立假设下不产生该缩放偏差。
- 令 $G = 2$, 回答为 Bernoulli 动作,奖励为 $R = ca$, $c > 0$ 。使用总体标准差且忽略数值稳定项,组奖励相同时定义优势为零。求标准化组优势梯度的期望,解释改变 c 后的结果。
- 长度为 L 的回答逐 token 概率比为 r_t 。分别写出完整序列重要性比与 GSPO 的长度归一化比,并求后者对当前参数的梯度。构造不同长度、相同逐 token 比率的例子,说明二者所表达的变化量。
- 考虑 $\pi_{\theta} = (p, 1-p)$ 、参考分布 $(1/2, 1/2)$, $p = \text{sigmoid}(\theta)$ 。对采样量 $K_3 = \pi_{\text{ref}}(a)/\pi_{\theta}(a) - 1 + \log[\pi_{\theta}(a)/\pi_{\text{ref}}(a)]$, 分别求其期望、固定样本反向后的期望梯度,以及精确 KL 的导数。取 $p = .8$ 比较。
- 编程:实现组均值、leave-one-out、标准差归一化、GRPO 与 GSPO 核心项。用可枚举分布验证前四问;测试同奖励组、不同回答长度、padding 和旧策略固定。逐个写明估计值相等与梯度相等是否成立。

习题 9.2 偏好概率、DPO 温度与序列目标

固定提示下先考虑两个回答 y_1, y_2 ，参考策略各赋概率 $1/2$ 。数据中 y_1 被偏好的比例为 $q \in (0, 1)$ 。当前策略给 y_1 的概率为 p ，DPO 参数为 $\beta > 0$ 。

- (a) 从奖励减 KL 的目标出发，用 Lagrange 乘子求最优策略，并把奖励写成策略对数比加提示相关常数。代入 Bradley–Terry 偏好模型，推导本题 DPO 间隔。
- (b) 写出包含两种偏好方向的平均 DPO 损失，求关于间隔的一阶、二阶导数。求最优 p ；取 $q = .8$ ，分别计算 $\beta = .5, 1, 2$ 的结果。
- (c) 令全部偏好均支持 y_1 。讨论有限最优间隔是否存在；若训练偏好准确率达到 100%，还能否据此判断参数已收敛或独立任务正确率已提高？
- (d) 另考虑允许其他回答的生成模型。两个候选的策略概率为 $(.4, .2)$ 、参考概率为 $(.2, .05)$ ，长度为 $(1, 4)$ 。比较序列对数比之差与每 token 平均对数比之差，说明长度平均如何改变偏好目标。
- (e) 编程：实现序列求和 DPO。验证参考策略梯度为零、交换偏好标签的对称性、两方向偏好样本的最优概率，以及回答截断改变目标的情况。用独立任务评价区分偏好拟合与答案正确性。

第 10 章 世界模型与模型预测控制

世界模型学习动作条件下的状态转移，并用于策略学习或测试时规划。本章从模型误差传播出发，推导潜变量序列目标、想象轨迹和滚动优化，讨论目标条件控制。

10.1 动作条件动力学与多步误差

世界模型学习环境状态、观测或表征的条件演化规律。用于控制时，模型需表示动作改变后的后果，例如 $p(s_{t+1} | s_t, a_t)$ 。仅从未标注动作的视频学习 $p(o_{t+1} | o_{\leq t})$ ，通常得到对数据行为分布边缘化后的预测。将这种预测用于动作干预，需要额外的动作记录、状态信息和可识别性假设。

在完全可观测的低维环境中，可以首先训练残差动力学

$$\hat{s}_{t+1} = \hat{f}_\theta(s_t, a_t) = s_t + g_\theta(s_t, a_t), \quad \mathcal{L}_{\text{dyn}} = \mathbb{E}_{\mathcal{D}} \|W(\hat{f}_\theta(s_t, a_t) - s_{t+1})\|^2. \quad (10.1)$$

W 控制不同状态分量的尺度。例如小球状态 $s = (x, y, v_x, v_y)$ 中，位置与速度可分别标准化；统计量只由训练集估计。状态、动作与后继状态应对应同一次环境转移。碰撞、自由运动与罕见动作可分别报告误差。

当后继状态具有多模态随机性时，平方误差模型估计条件均值。若控制依赖罕见碰撞或多种可能结果，应考虑概率模型、模型集成或其他不确定性表示，并用独立实验检查其校准程度。

一步预测与递归预测 一步评估每次输入真实状态。多步评估从真实初始状态出发，之后输入模型预测状态：

$$\hat{s}_0 = s_0, \quad \hat{s}_{t+1} = \hat{f}_\theta(\hat{s}_t, a_t).$$

它们访问的状态分布不同。设真实动力学 f 对状态为 L -Lipschitz，模型在相关状态动作范围内满足 $\|\hat{f}(s, a) - f(s, a)\| \leq \varepsilon$ ，则对相同动作序列，先加入并减去 $f(\hat{s}_t, a_t)$ ：

$$e_{t+1} = \|\hat{f}(\hat{s}_t, a_t) - f(s_t, a_t)\| \quad (10.2)$$

$$\leq \|\hat{f}(\hat{s}_t, a_t) - f(\hat{s}_t, a_t)\| + \|f(\hat{s}_t, a_t) - f(s_t, a_t)\| \quad (10.3)$$

$$\leq \varepsilon + L e_t. \quad (10.4)$$

从 $e_0 = 0$ 开始，依次得到 $e_1 \leq \varepsilon$ 、 $e_2 \leq \varepsilon(1 + L)$ 、 $e_3 \leq \varepsilon(1 + L + L^2)$ 。一般形式为

$$e_{t+1} \leq \varepsilon + L e_t, \quad e_0 = 0 \implies e_H \leq \varepsilon \sum_{j=0}^{H-1} L^j. \quad (10.5)$$

当 $L \neq 1$ 时上界为 $\varepsilon(L^H - 1)/(L - 1)$ ；当 $L = 1$ 时为 $H\varepsilon$ 。该论证使用相关范围内的一致误差界，不能把训练集平均 MSE 直接代入 ε 。




图 10.1 一致局部误差 $\varepsilon = 0.01$ 下的解析多步上界。实际误差需要从独立轨迹估计。

例题 10.1 局部误差的多步上界

取 $\varepsilon = 0.01$ ，预测 10 步。分别计算 $L = 1$ 与 $L = 1.1$ 的误差上界。

解 当 $L = 1$ 时为 0.1；当 $L = 1.1$ 时为

$$0.01 \frac{1.1^{10} - 1}{0.1} \approx 0.15937.$$

这些数值来自给定假设下的最坏情况界，不等于某个训练模型的实际预测误差。实验仍需测量各预测长度上的误差分布。

规划通常最大化预测回报，因此候选动作中的正预测误差更容易被选择。增加搜索候选数可能同时提高模型内目标与实际控制误差。需要限制数据覆盖之外的搜索、比较较短预测长度，或用集成分歧等统计量检查候选动作；低分歧本身也不能证明预测正确。

基于模型的策略优化 (MBPO) 从真实回放状态启动较短的模型 rollout，再将生成转移与真实转移结合，训练离策略算法。短 rollout 减少连续模型误差的累积，但起始状态、合成比例、更新频率与数据保留策略仍决定训练分布。[37, 82]

10.2 模型预测控制与交叉熵方法

模型预测控制 (MPC) 在每个真实环境时刻优化有限动作序列，并只执行首个动作。设预测长度为 H ，目标为

$$\max_{a_{0:H-1}} \left[\sum_{t=0}^{H-1} \gamma^t r(\hat{s}_t, a_t, \hat{s}_{t+1}) + \gamma^H V_T(\hat{s}_H) \right], \quad \hat{s}_{t+1} = \hat{f}_\theta(\hat{s}_t, a_t). \quad (10.6)$$

执行 a_0 后读取新的真实状态，再重新求解。终端价值 V_T 近似预测长度之外的回报；令其为零可简化实现，但会改变短时域目标。

随机采样 MPC 生成 N 条候选序列 $A \in \mathbb{R}^{N \times H \times d_a}$ ，并行递归预测、累加回报，再选择最大值对应的首个动作。动力学评估量约为 NH 个样本步。候选采样应满足动作边界，终止与奖励时序应与环境一致。

$$A^* = \arg \max_{A \in \mathcal{C}} \hat{J}(A; s), \quad \text{执行 } A_0^*$$




图 10.2 MPC 的滚动规划。每次规划从新的真实状态开始，候选动作序列在模型中评估。

例题 10.2 有限候选集中的 MPC

一维动力学为 $s_{t+1} = s_t + a_t$ ，初始状态为 0，目标位置为 1。两步总代价为

$$C = \sum_{t=0}^1 [(s_{t+1} - 1)^2 + 0.1a_t^2].$$

在候选 $(0, 1)$ 、 $(1, 0)$ 、 $(0.5, 0.5)$ 中选择总代价最小者。

解 三条序列的状态分别为 $(0, 1)$ 、 $(1, 1)$ 、 $(0.5, 1)$ ，总代价依次为 1.1、0.1、0.3。选择 $(1, 0)$ 并执行首个动作 1。新的真实状态到达后重新规划；有限候选集中的最优结果不保证等于连续动作空间的全局最优解。

交叉熵方法 交叉熵方法（CEM）迭代拟合高回报候选的采样分布。若每个时间动作分量采用独立高斯分布，在一轮采样后选出 K 条精英序列 $\mathcal{E}$ ，更新

$$\mu_{t,j} = \frac{1}{K} \sum_{n \in \mathcal{E}} A_{n,t,j}, \quad \sigma_{t,j}^2 = \frac{1}{K} \sum_{n \in \mathcal{E}} (A_{n,t,j} - \mu_{t,j})^2. \quad (10.7)$$

为验证这一更新，固定时间与动作分量，把精英值记为 $x_1, \dots, x_K$ 。独立高斯负对数似然在常数项之外为

$$L(\mu, v) = \frac{K}{2} \log v + \frac{1}{2v} \sum_{n=1}^K (x_n - \mu)^2.$$

对均值求导得到 $\partial_\mu L = (K\mu - \sum_n x_n)/v = 0$ ；代入样本均值后，再对 v 求导， $K/(2v) - \sum_n (x_n - \mu)^2/(2v^2) = 0$ ，即式(10.7)。这是未裁剪高斯族中的最大似然更新。裁剪样本后的分布带有边界质量，直接套用该更新属于另一种近似，需要声明。可添加参数平滑、方差下限与上次计划的平移初始化，以减小有限样本波动或退化。动作裁剪改变实际提议分布，应在方法与实现中注明。

例题 10.3 CEM 的一次参数更新

两条精英动作序列为 $(1, 0)$ 与 $(0.5, 0.5)$ 。计算式(10.7)的均值与方差。

解 均值为 $(0.75, 0.25)$ ，两个分量的最大似然方差均为 0.0625。这里分母为 $K = 2$ 。若改用无偏样本方差，分母为 $K - 1$ ，数值会变为 0.125，与该最大似然更新不同。

控制评估至少比较随机策略、学习动力学 MPC 和真实动力学 MPC。后两者应使用相同奖励、预测长度、候选预算与随机候选，便于区分模型误差与有限搜索误差。真实动力学 MPC 仍受到有限时域和搜索预算影响。任务成功条件应明确位置、速度、保持时间及容许误差。

状态误差到回报误差 设转移奖励满足 $|r(s, a, s') - r(\tilde{s}, a, \tilde{s}')| \leq L_r(\|s - \tilde{s}\| + \|s' - \tilde{s}'\|)$ ，模型奖励头在相同输入上的误差至多为 ϵ_r 。逐步加入并减去真实奖励在预测状态上的值，得到单步误差至多为 $L_r(e_t + e_{t+1}) + \epsilon_r$ 。对折扣回报使用三角不等式，有

$$|J - \hat{J}| \leq \sum_{t=0}^{H-1} \gamma^t (L_r(e_t + e_{t+1}) + \epsilon_r) + \gamma^H L_V e_H, \quad (10.8)$$

其中终端价值为 L_V -Lipschitz。把式(10.5)代入可得随时域增长的界。若对所有候选动作序列均有 $|J(A) - \hat{J}(A)| \leq \delta$ ，真实最优候选为 A^* 、模型所选为 $\hat{A}$ ，则

$$\begin{aligned} J(A^*) - J(\hat{A}) &= [J(A^*) - \hat{J}(A^*)] + [\hat{J}(A^*) - \hat{J}(\hat{A})] \\ &\quad + [\hat{J}(\hat{A}) - J(\hat{A})] \leq \delta + 0 + \delta = 2\delta. \end{aligned}$$

中间使用 $\hat{J}(\hat{A}) \geq \hat{J}(A^*)$ 。对训练分布的平均预测误差很小，不能推出该候选集上的一致误差条件成立。

例题 10.4 模型排序导致的候选损失界

两条候选真实回报为 1 和 0.9，每条预测回报误差至多为 0.08。模型是否可能选择较差候选？

解 可以，例如预测分别为 0.92 和 0.98。实际损失为 0.1，低于 $2\delta = 0.16$ 。将候选数增加不会自动缩小每条候选的预测误差界。

10.3 RSSM 与潜空间策略学习

部分可观测环境中，当前图像通常不足以确定速度、隐藏对象或其他状态。理想的信息状态是信念分布 $b_t(s) = p(s_t = s \mid o_{\leq t}, a_{< t})$ 。信念更新先预测，再利用观测条件化。设观测似然为 $p(o_t \mid s_t)$ ，则

$$\tilde{b}_t(s) = \int P(s \mid s', a_{t-1}) b_{t-1}(s') ds', \quad (10.9)$$

$$b_t(s) = \frac{p(o_t \mid s) \tilde{b}_t(s)}{\int p(o_t \mid u) \tilde{b}_t(u) du}. \quad (10.10)$$

第一行对上一步未知状态边缘化；第二行的分母是新观测的预测概率。若分母为零，该观测在当前模型下不可能，需要单独处理模型失配。循环状态空间模型（RSSM）以确定性递归状态与随机潜变量近似压缩历史：

$$\begin{aligned} h_t &= f_\theta(h_{t-1}, z_{t-1}, a_{t-1}), \\ z_t &\sim q_\theta(z_t | h_t, o_t), \quad \hat{z}_t \sim p_\theta(z_t | h_t). \end{aligned} \quad (10.11)$$

后验编码器 q 使用当前观测；先验 p 用于缺少未来观测的模型预测。模型状态记为 $s_t^{\text{lat}} = (h_t, z_t)$ ，观测、奖励与继续标记由该状态预测。DreamerV3 采用这类结构学习世界模型，并以潜空间 rollout 训练 actor 与 critic。[38]




图 10.3 RSSM 的后验与先验路径。动作通过确定性递归状态影响后续分布。

RSSM 的序列证据下界 给定动作序列，联合模型的简化分解为

$$p(o_{1:T}, z_{1:T} | a_{<T}) = \prod_t p(z_t | h_t) p(o_t | h_t, z_t),$$

其中 h_t 按式(10.11)确定性递推。近似后验为 $q(z_{1:T} | o, a) = \prod_t q(z_t | h_t, o_t)$ 。应用 Jensen 不等式并按时间分解对数项，得到

$$\log p(o_{1:T} | a) = \log \mathbb{E}_q \left[\frac{p(o_{1:T}, z_{1:T} | a)}{q(z_{1:T} | o, a)} \right] \quad (10.12)$$

$$\geq \mathbb{E}_q \log \frac{p(o_{1:T}, z_{1:T} | a)}{q(z_{1:T} | o, a)} \quad (10.13)$$

$$= \mathbb{E}_q \sum_t \left[\log p(o_t | h_t, z_t) + \log \frac{p(z_t | h_t)}{q(z_t | h_t, o_t)} \right] \quad (10.14)$$

$$= \mathbb{E}_q \sum_t \log p(o_t | h_t, z_t) \quad (10.15)$$

$$- \sum_t \mathbb{E}_{q(z_{<t})} \text{KL}(q(z_t | h_t, o_t) \| p(z_t | h_t)). \quad (10.16)$$

奖励和继续概率预测可作为额外观测头加入对数似然。Dreamer 的实际损失还使用 KL 梯度平衡、free bits 和数值变换；它们调整训练信号，需与上述原始变分分解分别说明。[38]

以过滤后验 $q(z_{1:T} | o_{1:T}, a_{<T}) = \prod_t q(z_t | h_t, o_t)$ 近似序列后验，负 ELBO 包含

$$\mathcal{L}_{\text{WM}} = \mathbb{E}_q \sum_t [-\log p(o_t | h_t, z_t) - \log p(r_t | h_t, z_t) - \log p(c_t | h_t, z_t) + \text{KL}(q(z_t | h_t, o_t) \| p(z_t | h_t))]. \quad (10.17)$$

该式中的 r_t, c_t 采用到达状态 t 的记录约定；与环境采用转移出发时刻编号时，需要一致地平移数据索引。图像重建、奖励和继续概率具有不同似然形式与尺度，应分别定义。

DreamerV3 对 KL 的两个梯度方向使用不同损失：

$$\mathcal{L}_{\text{dyn}} = \max(\kappa, \text{KL}(\text{sg}(q) \| p)), \quad \mathcal{L}_{\text{rep}} = \max(\kappa, \text{KL}(q \| \text{sg}(p))). \quad (10.18)$$

两项在停止梯度前对应同一个 KL 数值，却更新不同参数路径。按不同系数加权后，先验预测与后验表征受到不同强度的约束。free bits 下限 κ 使 KL 较小时该正则项不再提供梯度。报告版本还将分类分布与少量均匀分布混合，以避免概率退化造成过大的 KL。

对离散潜变量，一种直通估计写为

$$z_{\text{ST}} = z_{\text{hard}} + q - \text{sg}(q). \quad (10.19)$$

其前向值为离散样本，反向梯度使用概率向量的导数。这种估计一般有偏，与 REINFORCE 的 score-function 估计不同。实现审查需分别标明采样分布、前向值和反向使用的函数。

数值变换与分布价值 Dreamer 使用对称对数变换与其逆变换处理跨度较大的量：

$$\text{symlog}(x) = \text{sign}(x) \log(1 + |x|), \quad \text{symexp}(u) = \text{sign}(u)(e^{|u|} - 1). \quad (10.20)$$

对于分类表示的连续目标，可将 y 分配给相邻分箱中心 $b_k \leq y \leq b_{k+1}$ ，采用 two-hot 权重

$$w_k = \frac{b_{k+1} - y}{b_{k+1} - b_k}, \quad w_{k+1} = \frac{y - b_k}{b_{k+1} - b_k}, \quad (10.21)$$

其余为零，并对软标签使用交叉熵。给定概率 p_j ，原始尺度上的均值为 $\sum_j p_j b_j$ 。若分箱在变换后的坐标上定义，则编码、读出和边界规则需相应说明；一般有 $\text{symexp}(\mathbb{E}[u]) \neq \mathbb{E}[\text{symexp}(u)]$ 。DreamerV3 (arXiv:2301.04104v2) 使用指数间距分箱的概率加权读出。

例题 10.5 two-hot 编码与非线性读出

分箱中心为 0 和 2, 目标 $y = 0.5$ 。求 two-hot 权重。再设变换坐标以相同概率取 0 和 $\log 3$, 比较先求平均再逆变换与先逆变换再求平均。

解 权重为 (0.75, 0.25), 加权中心为 0.5。后一问题中, 先平均再逆变换得到 $e^{\log 3/2} - 1 = \sqrt{3} - 1 \approx 0.732$; 先逆变换再平均得到 $(0 + 2)/2 = 1$ 。两种读出对应不同的统计量。

想象轨迹与 actor-critic 从真实数据推断的后验状态开始, 模型使用 actor 采样动作, 再仅依赖递归状态与先验生成未来潜变量。未来真实观测不参与此 rollout。将预测奖励重新编号为从状态 t 出发的转移奖励 $\hat{r}_t$, 预测继续概率为 $\hat{c}_t$, 定义 $d_t = \gamma \hat{c}_t$, 则

$$R_t^\lambda = \hat{r}_t + d_t [(1 - \lambda)v(s_{t+1}^{\text{lat}}) + \lambda R_{t+1}^\lambda], \quad R_H^\lambda = v(s_H^{\text{lat}}). \quad (10.22)$$

价值网络以停止梯度的回报目标训练, 可使用分布预测损失。需要保证奖励、继续概率和下一状态价值的时间索引一致。

DreamerV3 (arXiv:2301.04104v2) 对离散与连续动作均使用 REINFORCE actor 估计。将回报尺度记为 S , 单状态代理损失为

$$\mathcal{L}_{\pi,t} = -\text{sg} \left(\frac{R_t^\lambda - v(s_t^{\text{lat}})}{\max(1, S)} \right) \log \pi_\phi(a_t | s_t^{\text{lat}}) - \eta \mathcal{H}(\pi_\phi(\cdot | s_t^{\text{lat}})). \quad (10.23)$$

报告用回报批次的第 95 与第 5 百分位之差作指数移动平均估计 S 。轨迹损失的有效权重还应与累计继续概率和折扣约定一致; 将世界模型预测的状态视为训练样本时, actor 更新不应顺带优化世界模型参数。具体版本的梯度估计器与目标权重应按报告或代码确认。

Dreamer 在真实交互时直接从 actor 选动作。MPC 在每次交互时显式搜索动作序列。两者均使用世界模型, 但模型参与策略改进与执行的阶段不同。

10.4 目标条件强化学习与 Hindsight Relabeling

许多控制问题的策略需要显式接收目标 g 。将状态扩展为 (s, g) 后, 目标条件动作价值函数满足

$$Q^\pi(s, a, g) = \mathbb{E}_{s' \sim P} [r(s, a, s', g) + \gamma(1 - d_g(s, a, s')) \mathbb{E}_{a' \sim \pi(\cdot | s', g)} Q^\pi(s', a', g)]. \quad (10.24)$$

同一动力学转移 (s, a, s') 可以对应多个目标, 因此离线轨迹可以通过目标重标记增加监督信号。Hindsight Experience Replay 将轨迹中未来实际达到的状态映射为替代目标 g' 。若原始样本为 $(s_t, a_t, r_t, s_{t+1}, g)$, 重标记后重新计算

$$\begin{aligned} \tilde{r}_t &= r(s_t, a_t, s_{t+1}, g'), & \tilde{d}_t &= d_{g'}(s_t, a_t, s_{t+1}), \\ \tilde{\xi}_t &= (s_t, a_t, \tilde{r}_t, s_{t+1}, \tilde{d}_t, g'). \end{aligned} \quad (10.25)$$

重标记需同步改变目标、目标相关奖励以及目标相关终止标记，保留真实发生的状态转移。外部采样截断标记应另外记录。使用离策略算法时，经验回放允许将原目标样本和重标记样本同时用于更新。

目标条件控制与第10章前面的潜空间规划具有直接接口：计划器可以把目标编码 $e(g)$ 作为终端代价的参数，策略学习则把 g 作为条件输入。V-JEPA 2-AC 使用动作条件预测进行目标驱动规划时，目标表征与当前表征之间的距离承担类似角色；其有效性仍需通过动作敏感性与闭环任务成功率验证。[39]

例题 10.6 稀疏奖励轨迹的 hindsight 重标记

一条轨迹依次访问位置 $0 \rightarrow 1 \rightarrow 2 \rightarrow 3$ ，原目标为 $g = 5$ ，奖励定义为到达目标时 1，其余为 0。采用 future 策略，在 $t = 1$ 的样本中选择未来达到的 $g' = 3$ 。写出该样本及后续样本的奖励变化。

解 原目标下所有已观察转移奖励均为 0。将目标改为 3 后， $1 \rightarrow 2$ 仍未到达目标，因此奖励为 0； $2 \rightarrow 3$ 到达目标，因此奖励为 1。动力学数据未改变，改变的是目标条件及目标相关奖励。

目标重标记的条件偏差 HER 将后续实际达到的状态重标记为目标，需重新计算奖励及任务终止。若动力学随机，按未来成功状态选择目标会使条件转移分布发生选择偏差。例如固定动作后 s' 等概率为 0 或 1，并取重标记目标 $g = s'$ ；重标记数据中 $\Pr(s' = g | g) = 1$ ，而对独立指定目标的真实环境该概率为 $1/2$ 。因此不能在任意随机环境中将重标记样本视为无偏目标条件转移。[72]

控制实验应分别验证状态充分性、动作依赖、开放环预测和闭环任务。CEM 或随机搜索中所有候选共用同一模型误差来源；重复采样候选不能当作独立的模型准确性评估。

10.5 课后习题

习题 10.1 动力学辨识与有限时域规划

真实系统满足 $s_{t+1} = as_t + bu_t$ 。训练数据由策略 $u_t = s_t$ 采集。随后需要控制系统到达目标 $g = 1$ 。

- 将动力学拟合写成线性回归。说明该数据能辨识哪些参数组合，构造两组不同的 (a, b) 产生完全相同的训练转移。加入 $\lambda \|\theta\|^2$ 后推导闭式解，并说明正则化是否增加了数据中的信息。
- 对于已知系统 $s' = s + u$ 、初态 $s_0 = 0$ ，最小化两步代价 $(s_1 - 1)^2 + \rho u_0^2 + (s_2 - 1)^2 + \rho u_1^2$ 。从一阶条件求最优动作序列，取 $\rho = .1$ 给出数值；说明 MPC 实际执行哪个动作。
- 设在规划使用的状态动作范围内模型一步误差不超过 ϵ ，真实动力学对状态为 L -Lipschitz。推导 H 步状态误差界，并区分 $L < 1, L = 1, L > 1$ 。
- 若每步奖励依赖 (s_t, u_t, s_{t+1}) ，以状态变量的 Lipschitz 条件把上问误差传到回报。证明候选集上一致回报估计误差不超过 δ 时，模型所选动作序列相对真实最优候选的损失不超过 2δ 。
- 编程：实现带正则的辨识、解析两步规划和采样 MPC。先用具有充分输入变化的数据验证参数恢复，再与 $u = s$ 数据比较。报告训练误差、不同动作下的预测误差和闭环任务结果，不能只用训练误差判断可控制性。

习题 10.2 条件分布、状态估计与目标重标记

系统状态为 (x_t, v_t) ，观测只包含位置，动力学为 $x_{t+1} = x_t + v_t \Delta$ 、 $v_{t+1} = v_t + u_t \Delta$ 。希望同时学习状态估计与目标条件控制。

- 构造两个当前观测相同但未来位置不同的状态。给定相邻两帧位置和上一动作，求当前速度，列出该恢复式依赖的采样及动力学假设。
- 考虑单步概率更新：先验 $v \sim \mathcal{N}(m_-, P_-)$ ，测量 $d = v + \eta$ ， $\eta \sim \mathcal{N}(0, R)$ 独立， $P_-, R > 0$ 。对两个密度相乘配方，求后验均值与方差，并分析 $R \rightarrow 0$ 与 $R \rightarrow \infty$ 。
- 从 $\log p(d)$ 插入任意高斯 $q(v | d)$ 推导 ELBO，写出其解码项与先验 KL。说明 RSSM 训练后验和无观测想象先验各对应什么条件，为什么不能在想象阶段读取真实未来观测。
- 另有随机转移 $s' \in \{0, 1\}$ 等概率。目标奖励为 $1[s' = g]$ 。分别计算独立指定 $g = 1$ 的成功概率，以及按本次后继状态重标记 $g = s'$ 后的条件成功概率。用条件分布解释差异。
- 编程：实现高斯更新与 KL，检查后验不确定性的极限。为确定性轨迹实现 HER，重新计算奖励与成功终止，同时保留外部截断；禁止跨轨迹选择目标。对随机反例保留选择偏差测试。

第 11 章 生成式策略与视觉语言动作模型

视觉语言动作模型将多模态条件编码与动作分布建模结合。动作的物理单位、时间约定、表示方式和执行时序直接影响训练目标。本章从条件密度出发推导连续动作生成、离散动作编码和闭环执行。

11.1 动作条件分布与多模态模仿学习

令观测历史为 $o_{t-T:t}$ ，语言指令为 c ，机器人本体状态为 q_t 。策略预测长度为 H 的动作块

$$A_t = (a_t, \dots, a_{t+H-1}) \in \mathbb{R}^{H \times d_a}, \quad \pi_\theta(A_t \mid o_{t-T:t}, q_t, c). \quad (11.1)$$

各动作分量可以是关节位置、关节速度或末端位姿增量。动作坐标系、单位、控制频率及控制器类型属于数据定义。来自不同机器人或控制模式的数据，必须在条件变量或预处理变换中保留这些差异。

确定性回归的条件均值 对固定上下文 h ，平方误差目标为 $\mathbb{E}[\|f(h) - A\|^2 \mid h]$ 。展开并对 f 求导：

$$\mathbb{E}\|f - A\|^2 = \|f\|^2 - 2f^\top \mathbb{E}[A] + \mathbb{E}\|A\|^2, \quad (11.2)$$

$$\nabla_f \mathbb{E}\|f - A\|^2 = 2(f - \mathbb{E}[A]), \quad f^*(h) = \mathbb{E}[A \mid h]. \quad (11.3)$$

当存在多个有效动作模式时，条件均值可能落在低概率区域。概率策略需要表示各模式及其权重，不能仅增加确定性网络容量解决这一问题。

例题 11.1 双峰动作与均值预测

给定同一图像，两条等概率示范的标量动作分别为 -1 与 1 。环境只在 $|a| \geq 0.8$ 时成功。比较平方损失最优策略与匹配示范分布的随机策略。

解 确定性最优动作为 0 ，期望平方误差为 1 ，任务失败。随机策略以相同概率选择 -1 和 1 ，每次都满足成功条件。训练误差与任务成功率由不同目标定义，应分别测量。

闭环分布与历史依赖 行为克隆拟合示范访问状态上的动作分布；执行时动作误差会改变后续观测。第8章的 DAgger 讨论了重新采集策略访问状态及专家标注。动作块只在预测后执行前 $K \leq H$ 步，然后读取新观测，其观测频率由 K 与控制周期共同决定。增大动作块可以减少模型调用，但增大开环执行长度会延后环境反馈。

部分可观测任务还需记忆。可以将历史图像编码为固定 token 序列，或维护包含过去子任务与观测摘要的记忆变量 m_t 。此时策略为 $\pi(A_t \mid o_t, m_t, q_t, c)$ ，记忆更新为 $m_{t+1} = F(m_t, o_{t+1}, a_t)$ 。记忆是否充分需要通过具有相同当前图像、不同历史且要求不同动作的测试区分。

11.2 动作扩散与条件流匹配

扩散策略对动作块添加噪声，并以观测特征作为条件。对归一化动作 A ，离散前向加噪为

$$A_k = \sqrt{\alpha_k}A + \sqrt{1 - \alpha_k}\epsilon, \quad \mathcal{L}_\epsilon = \mathbb{E}\|\epsilon_\theta(A_k, k, h) - \epsilon\|^2. \quad (11.4)$$

网络可采用一维时间卷积或 Transformer。输入时间轴为动作块内部时间，扩散索引 k 表示噪声水平，两者必须使用不同的嵌入或命名。Diffusion Policy 将这一分布建模与滚动执行结合。[58]


对流匹配，固定噪声端点 $A_0 \sim \mathcal{N}(0, I)$ 和示范端点 A_1 ，定义

$$A_\tau = (1 - \tau)A_0 + \tau A_1, \quad U = A_1 - A_0, \quad (11.5)$$

$$\mathcal{L}_{\text{action}} = \mathbb{E} \left[\frac{1}{H d_a} \|v_\theta(A_\tau, \tau, h) - U\|_F^2 \right]. \quad (11.6)$$

在动作块末端缺失的样本中，使用有效位置掩码并按有效维度数归约。将缺失动作填零而不屏蔽损失，会改变条件动作分布。采样从 A_0 开始，积分至 $\tau = 1$ ；再撤销归一化，执行定义好的前 K 步。

$$A_\tau = (1 - \tau)\epsilon + \tau A, \quad u = A - \epsilon$$



维度 行轴 H 为预测动作时间，列轴 d_a 为动作维度；省略批次轴。

对象 A 为归一化数据动作， ϵ 为同形高斯噪声； τ 是生成时间。

运算 速度网络预测同形的 u ，并以观测、任务和已提交动作前缀为条件。

图 11.1 动作块的条件流匹配。物理动作时间轴和连续生成时间为不同变量。

单位变换与目标权重 设 $A = \mu + D\tilde{A}$ ， D 为正对角尺度矩阵，沿动作块时间轴广播。速度满足 $v_A = Dv_{\tilde{A}}$ ，因为 $d\mu/d\tau = 0$ 。因此

$$\|v_{\tilde{A}} - U_{\tilde{A}}\|^2 = (v_A - U_A)^\top D^{-2}(v_A - U_A). \quad (11.7)$$

归一化空间中的等权 MSE 等价于物理空间中的加权 MSE。改变角度单位从弧度到度，同时不调整归一化，可能使角度分量主导目标。

若需要动作密度，则由变量变换有

$$\log p_A(A | h) = \log p_{\tilde{A}}(D^{-1}(A - \mu) | h) - H \log |\det D|. \quad (11.8)$$

流匹配训练本身不要求计算该密度；使用 PPO 或离线策略比率时，必须另行定义可计算的策略概率。不能将速度回归损失直接替代对数概率。

例题 11.2 动作标准化对应的误差度量

动作包含米制位移与弧度角度，训练集标准差分别为 0.02 和 0.2。物理误差为 (0.01, 0.1)。求归一化平方误差。

解 归一化误差为 (0.5, 0.5)，平方和为 0.5。物理空间权重为 $D^{-2} = \text{diag}(2500, 25)$ ，因此 $2500(0.01)^2 + 25(0.1)^2 = 0.5$ 。直接比较两个物理分量的原始数值会忽略单位差异。

11.3 离散动作编码与联合监督

标量量化将区间 $[a_{\min}, a_{\max}]$ 分成 K 个 bin，以整数索引作为动作 token。在最近中心量化下，未截断样本的单维误差至多为半个 bin 宽。多自由度动作逐维自回归可表示相关性，但序列长度随 Hd_a 增长。

FAST 利用动作时间序列的离散余弦变换 (DCT)、量化和序列压缩，减少冗余的高频动作 token。[59] 对某一动作维度 a_t ， $0 \leq t < H$ ，正交 DCT-II 可写为

$$c_k = \alpha_k \sum_{t=0}^{H-1} a_t \cos \left[\frac{\pi}{H} \left(t + \frac{1}{2} \right) k \right], \quad \alpha_0 = H^{-1/2}, \quad \alpha_{k>0} = \sqrt{2/H}. \quad (11.9)$$

令正交矩阵为 C ，则 $c = Ca$ 、 $a = C^\top c$ 。正交性可由三角乘积和式验证： $2 \cos u \cos v = \cos(u - v) + \cos(u + v)$ 。在半格点 $t + 1/2$ 上求和后，不同频率的交叉项为零；零频行的平方和为 H ，其余为 $H/2$ 。乘上式(11.9)的归一化系数，得到 $CC^\top = C^\top C = I$ 。因此

$$\|a - \hat{a}\|^2 = \|C^\top(c - \hat{c})\|^2 = (c - \hat{c})^\top CC^\top(c - \hat{c}) = \|c - \hat{c}\|^2.$$

这就是此处的 Parseval 恒等式。如果只保留低频系数 $0, \dots, K-1$ ，重建误差等于被移除系数的能量和。该结论针对正交变换；后续量化和 token 压缩还需分别分析。

若保留的 K 个系数分别用步长 Δ 作最近中心量化，且没有范围截断，则每个误差的绝对值至多为 $\Delta/2$ 。由正交性，整段动作的平方误差满足

$$\|a - \hat{a}\|^2 \leq \sum_{k=K}^{H-1} c_k^2 + \frac{K\Delta^2}{4}. \quad (11.10)$$

第一项来自频率截断，第二项来自量化。后续若仅对整数系数作无损序列压缩，不再增加数值误差；若还裁剪系数范围，应另外加入相应误差。

例题 11.3 恒定动作的 DCT

取 $H = 4$ ，动作序列为 $(1, 1, 1, 1)$ 。求 DCT 系数，并分析仅保留首系数的重建。

解 $c_0 = (1/2) \times 4 = 2$ ，其他系数为零。逆变换得到每个时刻 $a_t = (1/2)c_0 = 1$ ，可精确重建。突变动作通常含更多非零高频系数，不能沿用这一压缩结论。

视觉语言动作模型中的两类监督 VLA 可将视觉与语言编码结果提供给较小的动作专家。离散动作 token 的交叉熵有利于复用语言建模接口；连续动作专家用扩散或流匹配生成动作块。若两个目标共用编码器，其梯度一般相加：

$$\mathcal{L} = \mathcal{L}_{\text{token}} + \lambda \mathcal{L}_{\text{action}}, \quad \nabla_{\theta_e} \mathcal{L} = \nabla_{\theta_e} \mathcal{L}_{\text{token}} + \lambda \nabla_{\theta_e} \mathcal{L}_{\text{action}}. \quad (11.11)$$

也可有意在动作专家的上下文入口停止梯度，采用

$$\mathcal{L} = \mathcal{L}_{\text{token}}(E_{\theta_e}(o, c)) + \lambda \mathcal{L}_{\text{action}}(v_{\theta_a}(A_\tau, \tau, \text{sg}(E_{\theta_e}(o, c)))). \quad (11.12)$$

此时动作损失仅更新 θ_a ，编码器由离散目标训练。 $\pi_{0.7}$ 报告采用这类 knowledge insulation 训练设置，视觉语言基座为 Gemma3 4B，动作专家约为 860M 参数。[60]

多种条件与混合质量轨迹 $\pi_{0.7}$ 还使用子任务指令、目标图像、轨迹质量与执行方式等条件，并在训练中对部分条件随机丢弃。[60] 数学上，可将轨迹质量变量记为 m ，拟合 $p(A | h, m)$ 。在混合数据上，边缘策略为 $p(A | h) = \sum_m p(A | h, m)p(m | h)$ ；给定某个质量标签则选择对应条件分布。条件标签只有与行为差异相联系时才有训练信号，未观测的标签组合无法由这一分解保证可用。

目标图像在训练时可来自轨迹后续观测，部署时可能由生成模型提供。必须防止目标图像直接包含无法在执行前获取的测试答案，并分别评估真实目标、生成目标和无目标条件。条件丢弃对未见条件组合的作用需要在固定测试集上验证。

11.4 优势条件策略与经验数据

生成式动作模型通常能够采样，但动作密度的精确计算可能昂贵。优势条件策略用一个额外条件区分数据中的行为质量，从而可以继续使用监督式动作生成目标。RECAP 将示范、自主执行与人工干预数据合并，先训练回报分布，再用优势估计构造二元条件。条件策略继续拟合数据中的动作，其优化方向取决于价值估计与质量标签的定义。[103, 84, 83]

价值估计与改进标签 设数据记录完整回报 G_t ，价值模型先拟合其条件分布，并通过分箱中心的概率加权和计算 $V(s_t)$ 。一个 N 步优势估计为

$$\hat{A}_t = \sum_{j=0}^{N-1} \gamma^j r_{t+j} + \gamma^N b_{t:t+N} V(s_{t+N}) - V(s_t), \quad (11.13)$$

其中 $b_{t:t+N}$ 表示这一段内未真正终止；若中途终止，奖励求和也在终止处停止。根据任务阈值 τ_g 定义标签 $I_t = \mathbf{1}[\hat{A}_t > \tau_g]$ 。实际 RECAP 报告的后训练优势使用 50 步前视，并以 30% 的概率省略优势条件，以支持有条件与无条件推理。[103] 这些是具体配置，迁移到不同控制频率时需要重新确定对应的物理时长。

条件化如何改变动作分布 令 $\mu(a | s)$ 为数据中的动作分布， $w(s, a) = \Pr(I = 1 | s, a)$ 为获得正标签的条件概率。联合概率有两种分解：

$$p(a, I = 1 | s) = \mu(a | s)w(s, a), \quad (11.14)$$

$$p(a, I = 1 | s) = p(a | s, I = 1) \Pr(I = 1 | s). \quad (11.15)$$

因此，只要接受概率为正，

$$p(a | s, I = 1) = \frac{\mu(a | s)w(s, a)}{\int \mu(u | s)w(s, u) du}. \quad (11.16)$$

分母保证条件分布归一化。若标签精确地表示 $A^\mu(s, a) \geq 0$ ，且正标签动作有非零数据概率，则条件分布下的平均优势非负。结合式(7.30)，在所有相关状态均满足该条件并且策略精确拟合时，可得到策略改进结论。

实际标签依赖有限轨迹、近似价值和任务阈值。按一个随机回报是否超过阈值筛选，会更偏好超过阈值概率较高的动作；这个概率与期望回报的排序可以不同。因此应同时评价标签质量、条件动作分布和实际任务回报。对于没有正标签的状态，也应预先规定退回无条件策略或其他处理方式。

例题 11.4 正标签概率与期望回报

某状态下，动作 a 的回报恒为 1；动作 b 以概率 0.2 得到 6，否则为 0。若数据对两动作等权，且正标签定义为单次回报大于 2，求正标签条件策略及其期望回报。

解 $w(a) = 0, w(b) = 0.2$ ，故条件策略总选择 b ，期望回报为 1.2。将 b 的高回报改为 4，标签概率保持不变，但其期望降为 0.8，低于动作 a 。条件化效果由完整回报分布决定，单次阈值标签不等同于真实优势的符号。

联合监督的信息边界 知识隔离训练中，连续动作专家可以读取视觉语言隐藏状态，但不应读取训练答案中的 FAST 动作 token。否则连续任务可能退化为读取同一动作的另一种编码。RECAP 报告明确将两类动作预测的输入分开。[103] 实现测试应改变离散动作标签而固定观测，检查连续专家前向输出是否保持不变；共享编码器的梯度则按式(11.12)单独验证。

11.5 视频、动作与联合生成模型

视频生成模型通常描述未来观测的条件分布；动作条件动力学描述给定动作的后果；联合视频-动作模型还直接建模将要执行的动作。DreamZero 的报告版本采用世界动作模型，结合历史视觉观测、语言与机器人本体状态，自回归生成未来视频与动作，并使用基于流匹配的训练构造。[40]

用抽象随机变量表示其目标，可写为

$$p_{\theta}(V_{\text{future}}, A_{\text{future}} \mid V_{\text{history}}, q, c). \quad (11.17)$$

联合分布可以按概率链式法则分解为先动作后视频或先视频后动作，但这种代数分解不能直接说明实际网络的采样顺序。阅读实现时需检查哪些变量联合去噪、哪些块自回归、动作块如何执行以及真实反馈何时更新历史与缓存。

模型类别	学习对象	控制过程
视频生成模型	条件未来视频分布	需要另行定义动作生成或规划机制。
Dreamer	潜状态、奖励、继续概率	想象轨迹训练 actor，执行时使用 actor。
V-JEPA 2-AC	动作条件表征预测	目标表征距离与采样规划。
DreamZero	未来视频与动作的联合条件分布	生成动作块，并由真实观测更新后续条件。

生成视频的连续性与控制任务成功依赖不同评价量。控制实验应包含动作敏感性、开放环多步预测、闭环任务结果和真实反馈更新。动作打乱、动作置零、规划长度变化及相同搜索预算的真实动力学对照，可用于定位模型对动作的依赖及误差的实际影响。

动作块的折扣与决策间隔 若上层每次选择一个持续 K 步的动作块，将物理步回报展开为

$$G_t = \sum_{j=0}^{K-1} \gamma^j r_{t+j} + \gamma^K G_{t+K}, \quad (11.18)$$

$$Q(s, A) = \mathbb{E} \left[\sum_{j=0}^{K-1} \gamma^j r_{t+j} + \gamma^K V(s_{t+K}) \mid s, A \right]. \quad (11.19)$$

持续时间可变时， K 留在期望内部。这是半马尔可夫决策的回报结构。将每个动作块都只乘一次物理步折扣 γ ，会改变不同持续时间的相对价值。训练、部署与延迟测试应共享相同的控制周期定义。

11.6 执行延迟、动作块衔接与闭环评估

动作生成耗时 δ ，低层控制周期为 Δt 。在新动作块可用之前，控制器需继续执行已提交动作。若将当前观测时刻作为新块起点，已确定的前缀至少为


$$d = \left\lceil \frac{\delta}{\Delta t} \right\rceil \quad (11.20)$$

步。若 $d \geq H$ ，新块在完成推理时已全部过期，必须改变推理时间、预测长度或时间对齐方式。

一种已知前缀条件生成方式将旧计划前 d 步作为约束。在流匹配时间 τ ，令有效已知前缀掩码为 M ，相容路径为 $A_\tau^{\text{known}} = (1 - \tau)\epsilon + \tau A^{\text{committed}}$ ，每一步数值积分后施加

$$A_\tau \leftarrow M \odot A_\tau^{\text{known}} + (1 - M) \odot A_\tau. \quad (11.21)$$

终点已知前缀精确等于提交动作。该投影构造需与训练中的条件方式相容；其本身不保证未知后缀符合原模型的精确条件分布。实时动作块方法进一步处理异步推理和前缀衔接，具体约束应按实现核对。[61]



参数 $f_c = 50 \text{ Hz}$ ，延迟 $\Delta = 70 \text{ ms}$ ，动作块长 $H = 12$ 。

边界 已提交位置采用条件前缀，后缀根据最新可用观测生成。

执行 每个动作关联观测时间戳和执行时间；迟到动作不能覆盖已执行动作。

图 11.2 带推理延迟的动作块。相同时间步采用相同宽度，前缀与后缀完整划分预测范围。

例题 11.5 推理延迟与有效动作长度

控制频率为 50 Hz ，动作生成耗时 70 ms ，动作块长度为 12 。求已提交前缀最小长度与尚可调整的步数。

解 $\Delta t = 20 \text{ ms}$ ， $d = \lceil 70/20 \rceil = 4$ ，至少 4 步不可再由新推理修改，剩余 8 步。若实际延迟波动，应测量高分位数延迟并规定超时处理，平均延迟不能确定最坏执行间隔。

动作块衔接的误差来源 对两个重叠动作块直接加权平均，可减小数值跳变，但可能混合两个不同动作模式。若动作涉及接触、夹爪开合或离散控制模式，平均操作还可能产生无效动作。应分别测量位置连续性、速度或加速度限制、任务成功与失败类型。

实现与实验要求 最低限度的闭环实验可使用低维双积分器或小球环境。先训练动作条件生成器拟合两个可区分模式，再加入图像条件，最后比较单步执行、动作块执行及含延迟的执行。图像条件可以使用本章前述架构，动作维度应通过固定变换恢复到环境单位。

评估按场景、对象与指令组合划分。每个方法采用相同初始状态、任务成功定义和随机种子；记录模型推理耗时、环境步数、动作限幅、超时与执行失败。对未成功试验保留完整轨迹。离线动作误差、动作分布覆盖、生成视频质量与闭环成功率分别报告。动作代码的单元测试可验证形状、单位变换、掩码和执行时序；硬件实时性能与真实机器人安全需要在相应系统上另外验证。

11.7 课后习题

习题 11.1 动作块的坐标、压缩与执行前缀

一个动作块含 H 个标量动作。训练分布以相同概率取 $A = \mathbf{1}_H$ 与 $A = -\mathbf{1}_H$ 。执行环境只有当每步动作均满足 $|a_t| \geq 1/2$ 时才允许通过。

- (a) 求确定性平方回归的最优动作块和最小误差，判断其可执行性。比较离线平均误差和环境成功条件所衡量的对象。
- (b) 采用逐维归一化 $A = \mu + D\tilde{A}$ ， D 为正对角矩阵。推导物理空间速度、平方误差度量和动作密度的 Jacobian 修正，说明不同单位的动作维度为何需要记录尺度。
- (c) 对时间轴作正交 DCT，求本题两种动作块的系数。证明保留前 K 项并以步长 δ 量化时，总重建误差可分解为截断误差与量化误差；给出后者的上界。
- (d) 控制频率为 50 Hz，推理延迟为 70 ms，块长为 12。求不能再改变的最小前缀长度。在线性流路径中写出对已提交前缀的相容投影；再分析延迟变为 260 ms 的情况。
- (e) 编程：实现动作归一化、DCT 往返、有效长度掩码和已知前缀投影。比较确定性回归与条件流的动作分布。评价时同时检查模式覆盖、执行前缀一致性和环境成功率，不只比较训练 MSE。

习题 11.2 质量条件策略的选择效应与梯度隔离

同一观测下，数据动作 a, b 的频率相同。动作 a 的奖励恒为 1，动作 b 以概率.2 得到 6、否则得到 0。先用可观测标签 $I = \mathbf{1}[R > 0]$ 训练条件动作模型，再考虑真实优势标签。

- (a) 计算两动作的期望奖励、数据策略价值和 $p_D(a | I = 1), p_D(b | I = 1)$ 。若部署时固定 $I = 1$ ，求新策略价值，判断正质量条件是否必然提高平均回报。
- (b) 把动作 b 的非零奖励从 6 改为 4，重复比较。说明只检查正标签频率会遗漏什么信息。再使用真实优势 $A^{\pi_D}(a)$ 的正负作为标签，分析其改进条件。
- (c) 从 Bayes 公式推导一般的 $p_D(A | h, I = 1)$ ，写出归一化常数。若采用有限步采样回报减价值基线生成优势标签，列出与真实期望优势符号不同的来源。
- (d) 共享视觉语言编码器产生 h ，离散头使用 token 交叉熵，连续专家使用 $\mathcal{L}_{\text{FM}}(\text{sg}(h))$ 。推导编码器与两个头的梯度集合。若连续专家能读取同一动作的目标 FAST token，训练损失下降能否说明部署时可用？
- (e) 编程：枚举本题条件分布并实现质量条件策略。建立共享线性编码器和两个头，验证梯度隔离；加入条件丢弃和目标 token 可见性测试。分别记录经验标签拟合、真实环境价值以及训练和部署的信息差异。

第 12 章 高效训练、长上下文与推理系统

模型实现需要同时满足数学等价性、内存约束与可重复测量。本章推导稳定归一化、分块注意力、梯度累积和并行计算中的核心恒等式，并将这些结果用于多模态训练和生成推理。

12.1 Transformer 模块与数值尺度

采用预归一化结构，一个 Transformer 层可写为

$$U = X + \text{Attention}(\text{Norm}(X)), \quad (12.1)$$

$$Y = U + \text{FFN}(\text{Norm}(U)). \quad (12.2)$$

残差、归一化、投影、激活函数与 dropout 的实际次序属于模型定义。替换其中一个模块后，即使形状保持不变，也需要重新验证 checkpoint 的兼容性。

RMSNorm 的 Jacobian 对 $x \in \mathbb{R}^d$ ，设 $r = \sqrt{d^{-1} \sum_j x_j^2 + \varepsilon}$ ， $y_j = g_j x_j / r$ 。令上游梯度为 u ，用 $\partial r / \partial x_k = x_k / (dr)$ ，得到

$$\frac{\partial y_j}{\partial x_k} = g_j \left(\frac{\delta_{jk}}{r} - \frac{x_j x_k}{dr^3} \right), \quad (12.3)$$

$$\frac{\partial \mathcal{L}}{\partial x} = \frac{g \odot u}{r} - \frac{x}{dr^3} \sum_j g_j u_j x_j. \quad (12.4)$$

RMSNorm 不减去均值，LayerNorm 则包含均值中心化。实现使用较低精度输入时，可在更高精度中累计平方和，再转换输出数据类型。[62]

SwiGLU 的通道数 SwiGLU 可写为

$$\text{FFN}(X) = [\text{SiLU}(XW_g) \odot (XW_u)]W_d, \quad (12.5)$$

其中 $W_g, W_u \in \mathbb{R}^{d \times d_f}$ ， $W_d \in \mathbb{R}^{d_f \times d}$ 。忽略偏置时参数量为 $3dd_f$ 。与中间宽度 $4d$ 的两层 FFN 的 $8d^2$ 参数匹配，需取 $d_f = 8d/3$ ，实际模型再按硬件对齐要求取整。[63]

例题 12.1 归一化与参数量

取 $x = (3, 4)$ 、 $g = (1, 1)$ 、 $\varepsilon = 0$ 。求 RMSNorm 输出。另取 $d = 768$ ，求参数匹配的 SwiGLU 中间维数。

解 $r = \sqrt{25/2} = 5/\sqrt{2}$ ，输出为 $(3\sqrt{2}/5, 4\sqrt{2}/5)$ ，其平方平均为 1。中间维数为 2048，参数量 $3 \times 768 \times 2048 = 4718592$ ，与 8×768^2 一致。

12.2 分块 softmax 与精确注意力

普通注意力为 $O = \text{softmax}(S)V$ 、 $S = QK^\top/\sqrt{d_k} + M$ 。显式存储 S 需要 $O(L^2)$ 元素，但最终输出每行只有 d_v 个值。FlashAttention 通过分块计算和在线归一化避免写出完整注意力矩阵；具体 GPU 内核还涉及线程分工和片上内存访问。[64, 65]

可合并的归一化统计量 考虑一行分数 s_j 与对应值向量 v_j 。在索引子集 A 上定义

$$m_A = \max_{j \in A} s_j, \quad l_A = \sum_{j \in A} e^{s_j - m_A}, \quad u_A = \sum_{j \in A} e^{s_j - m_A} v_j. \quad (12.6)$$


最终输出为 u_A/l_A 。对不相交子集 A, B ，令 $m = \max(m_A, m_B)$ 。将旧指数重新以 m 为基准：

$$l_{A \cup B} = e^{m_A - m} l_A + e^{m_B - m} l_B, \quad (12.7)$$

$$u_{A \cup B} = e^{m_A - m} u_A + e^{m_B - m} u_B.$$

该等式来自 $e^{s_j - m} = e^{s_j - m_A} e^{m_A - m}$ 。因此逐块只保留一个最大值、一个分母和一个值向量即可得到完整 softmax 加权和。

$$m = \max(m_A, m_B), \quad O = \frac{e^{m_A - m} u_A + e^{m_B - m} u_B}{e^{m_A - m} l_A + e^{m_B - m} l_B}$$



维度 每个查询行保留两个标量 m, l 和一个 d_v 维向量 u 。

对象 m 为最大分数， l 为指数分母， u 为未归一化值向量。

运算 合并沿键位置划分的块；各分块的向量维度始终相同。

图 12.1 在线 softmax 的统计量合并。归一化基准变化时，分母与未归一化输出使用相同缩放。

若当前块全部被掩码，应跳过该块；若整行没有任何合法键，需要按接口拒绝输入或返回预定结果。直接计算 $-\infty - (-\infty)$ 会产生 NaN。因果掩码与打包样本边界必须在每个分块内依据全局位置构造。

例题 12.2 分块结果的精确合并

两项分数为 $(0, \log 3)$ ，值为 $(2, 6)$ 。每项分别作为一个块。求合并统计量和输出。

解 两块各有 $l = 1$ ， u 分别为 $2, 6$ ， $m_1 = 0, m_2 = \log 3$ 。合并后 $l = 1/3 + 1 = 4/3$ ， $u = 2/3 + 6 = 20/3$ ，输出为 5。直接 softmax 得到权重 $(1/4, 3/4)$ ，结果相同。

反向传播的重计算 令 G_O 为输出梯度，则 $G_V = P^\top G_O$ 、 $G_P = G_O V^\top$ 。每个查询行的 softmax 梯度使用

$$G_{S,ij} = P_{ij} [(G_{O,i} \cdot V_j) - (G_{O,i} \cdot O_i)] . \quad (12.8)$$

第二项由 $\sum_j P_{ij}(G_{O,i} \cdot V_j) = G_{O,i} \cdot O_i$ 得到。保存每行 log-sum-exp 与输出后，可重计算所需 P_{ij} ，避免保存完整 P 。运算重排会产生浮点舍入差异，验收应使用规定的数据类型与容差，而非逐位相等。

12.3 GQA、KV cache 与长上下文

自回归推理中，历史键值可缓存。设层数为 n_ℓ 、批次为 B 、历史长度为 L 、KV 头数为 h_{kv} 、每头宽度为 d_h 、每元素字节数为 b ，标准完整 KV cache 大小为

$$M_{KV} = 2n_\ell B L h_{kv} d_h b. \quad (12.9)$$

系数 2 来自键和值。该估计不含块表、对齐、额外缓存以及模型权重。视觉 token 与文本 token 一起进入全注意力层时，都会贡献 L 。

GQA 使用 h_q 个查询头和较少的 h_{kv} 个键值头。若 $h_q = g h_{kv}$ ，查询头 j 使用键值头 $\lfloor j/g \rfloor$ 。[66] 将头轴展开为 $B \times h_{kv} \times g \times L_q \times d_h$ 可显式表达共享关系，避免将重复键值张量永久存储为 h_q 份。

例题 12.3 多模态前缀的缓存成本

取 $n_\ell = 32$ 、 $B = 1$ 、 $L = 8192$ 、 $h_{kv} = 8$ 、 $d_h = 128$ ，缓存为 BF16，每元素 2 字节。求缓存大小；再求额外 1024 个视觉 token 的增量。

解 总大小为 1 073 741 824 字节，即 1 GiB。每个 token 的全层缓存为 131 072 字节，1024 个视觉 token 增加 128 MiB。若所有层具有相同配置，该增量与视觉内容无关。

混合层的内存估计 第3章的 Gated DeltaNet 维护固定形状循环状态；全注意力层维护随上下文增长的键值。对混合网络可分别计数：

$$M \approx 2n_{\text{attn}}BLh_{kv}d_hb + n_{\text{rec}}Bh_sd_kd_vb_s + M_{\text{auxiliary}}. \quad (12.10)$$

这里循环头数、状态精度和辅助卷积状态取决于实现。Qwen3.5 的混合层配置提供了这种计数的实例，不能将所有层都按标准 KV cache 或都按固定状态估算。[49]

prefill 与 decode prefill 一次处理提示的多个 token；decode 每步增加一个或少量 token。对稠密注意力，prefill 的注意力算术量随 L^2 增长，单个 decode 步访问长度 L 的键值。基座、图像编码和首 token 等待时间应分开测量。生成整段回答的平均 token 吞吐量不能描述首 token 延迟。

位置插值与缓存一致性 第3章的 RoPE 对通道频率 ω_j 使用相位 $p\omega_j$ 。若训练长度为 L ，希望覆盖约 sL 的位置，可把位置替换为 p/s ，使最大相位保持在接近训练范围内。相对位置公式随之变为

$$(R(p\omega_j/s)q_j)^\top (R(t\omega_j/s)k_j) = q_j^\top R((t-p)\omega_j/s)k_j. \quad (12.11)$$

这也把相邻位置的相位差从 ω_j 降到 ω_j/s ，因此长距离范围与局部位置分辨率会同时改变。按频段调整缩放的方法需要另外说明频率规则和训练配置。位置插值和 YaRN 等方法采用不同的频段处理规则，比较时应固定训练长度与评测任务。[90, 104]

若推理过程中更改缩放系数，已缓存的键仍带有旧旋转。新查询与旧键的相位差将不再等于式(12.11)。因此缓存的有效性不仅取决于 token ID，还取决于位置规则、模型参数和此前计算。共享前缀缓存或切换适配器时，应核对完整条件。

12.4 推测解码与目标分布保持

推测解码先由较便宜的草稿模型提出候选 token，再由目标模型验证。它的目标是在特定采样假设下保持目标分布，同时减少昂贵的串行调用。李宏毅 2026 的推理课件将其与 KV cache 和注意力优化并列讨论。[91, 105]

单步接受与残差采样 固定前缀，令目标分布为 p ，草稿分布为 q 。先采样 $a \sim q$ ，以概率 $\alpha(a) = \min\{1, p(a)/q(a)\}$ 接受。这里仅需对被草稿实际采到、因而 $q(a) > 0$ 的动作计算比率。动作 a 通过接受路径获得的概率质量为

$$q(a)\alpha(a) = \min\{q(a), p(a)\}.$$

定义总拒绝概率

$$Z = 1 - \sum_a \min\{q(a), p(a)\} \quad (12.12)$$

$$= \sum_a [p(a) - q(a)]_+. \quad (12.13)$$

若发生拒绝，从 $r(a) = [p(a) - q(a)]_+ / Z$ 采样。于是最终输出概率为

$$\Pr(\text{输出} a) = \min\{q(a), p(a)\} + Zr(a) = p(a). \quad (12.14)$$

当 $Z = 0$ 时两分布相同，所有提议均被接受，不应计算无定义的残差归一化。接受率等于 $1 - \frac{1}{2} \sum_a |p(a) - q(a)|$ ，因此草稿与目标的接近程度直接影响验证效率。

例题 12.4 一次草稿验证的概率质量

设 $p = (0.6, 0.3, 0.1)$ ， $q = (0.2, 0.5, 0.3)$ 。求每个类别的接受概率、总接受率与残差分布。

解 接受概率为 $(1, 0.6, 1/3)$ ，通过接受路径的质量为 $(0.2, 0.3, 0.1)$ ，总接受率为 0.6。剩余目标质量为 $(0.4, 0, 0)$ ，故拒绝后总输出第一类。最终质量恢复为 $(0.6, 0.3, 0.1)$ 。

$$p = \min(p, q) + Zr, \quad Z = 1 - \sum_a \min\{p(a), q(a)\}$$

0.2	0.3	0.1	+	0.4	0	0	=	0.6	0.3	0.1
$\min(p, q)$				Zr				p		
1×3				1×3				1×3		

条件 目标分布 $p = (0.6, 0.3, 0.1)$ ，草稿分布 $q = (0.2, 0.5, 0.3)$ 。

对象 接受的总概率为 0.6；拒绝概率 $Z = 0.4$ ；残差分布 $r = (1, 0, 0)$ 。

结果 接受事件与残差重采样的概率相加后，输出分布逐项等于 p 。

图 12.2 推测解码的概率分解。各向量共用相同的词表轴，零概率分量保持空白。

多步验证与实现条件 草稿连续提出多个 token 后，目标模型可在一个因果前向中评价各候选前缀。按顺序接受，第一次拒绝处使用该前缀的残差分布，并丢弃其后的草稿 token。后续概率必须条件于实际已接受的前缀；缓存也要回退到同一位置。对上述单步恒等式逐前缀归纳，可证明输出序列服从目标自回归分布。

温度或 top- p 变换应先作用于目标与草稿各自的实际采样分布，再使用接受公式。吞吐量还取决于草稿成本、接受长度、验证批次及缓存管理。单步概率相等是正确性测试，实际加速需要单独的设

12.5 低秩适配、混合精度与激活重计算

采用列向量，LoRA 定义

$$W' = W + sB_r A_r, \quad A_r \in \mathbb{R}^{r \times d_{\text{in}}}, \quad B_r \in \mathbb{R}^{d_{\text{out}} \times r}, \quad (12.15)$$

其中 s 为固定缩放, W 冻结。设 $y = W'x$ 、 $g = \partial\mathcal{L}/\partial y$, 则

$$\frac{\partial\mathcal{L}}{\partial B_r} = sg(A_r x)^\top, \quad (12.16)$$

$$\frac{\partial\mathcal{L}}{\partial A_r} = sB_r^\top g x^\top, \quad \frac{\partial\mathcal{L}}{\partial x} = W'^\top g. \quad (12.17)$$

这些梯度可由 $dy = (W + sB_r A_r)dx + s(dB_r)A_r x + sB_r(dA_r)x$ 逐项读取。例如 $g^\top s(dB_r)A_r x = s \operatorname{tr}[(g(A_r x)^\top)^\top dB_r]$, 确定第一式; 另两项同理。因而冻结 W 只删除对 W 的参数更新, 输入仍经过完整 W' 反向传播。

若 B_r 初始化为零、 A_r 随机初始化, 首次更新的 A_r 梯度为零, B_r 梯度一般非零。两者同时初始化为零会使两条梯度均为零。[14]

例题 12.5 低秩参数量

令 $d_{\text{in}} = d_{\text{out}} = 4096$, $r = 8$ 。求可训练参数量与完整矩阵参数量之比。

解 低秩参数量为 $8(4096 + 4096) = 65\,536$, 完整矩阵为 $16\,777\,216$, 比值为 $1/256$ 。前向激活宽度仍为 4096 ; 总内存还包括基座权重、激活和临时缓冲区。

混合精度的更新次序 矩阵乘法可使用 BF16 或 FP16, 损失归约、归一化统计量和某些优化器状态通常需要较高精度。FP16 的损失缩放先计算 $s\mathcal{L}$ 的梯度, 再在裁剪和更新前除以 s 。若在反缩放前执行梯度裁剪, 实际阈值变为原阈值除以 s 。混合精度中的累积、反缩放与非有限梯度检测应遵循实现的优化器接口。[75]

AdamW 对每个参数维护一阶与二阶矩估计:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1)g_t, \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2)g_t^2, \quad (12.18)$$

$$\theta_{t+1} = (1 - \eta_t \lambda)\theta_t - \eta_t \frac{m_t / (1 - \beta_1^t)}{\sqrt{v_t / (1 - \beta_2^t)} + \varepsilon}. \quad (12.19)$$

从零初始化展开一阶矩, $m_t = (1 - \beta_1) \sum_{j=1}^t \beta_1^{t-j} g_j$ 。若各步梯度的期望均为 μ_g , 则

$$\mathbb{E}[m_t] = (1 - \beta_1)\mu_g \sum_{j=0}^{t-1} \beta_1^j = (1 - \beta_1^t)\mu_g.$$

这说明除以 $1 - \beta_1^t$ 校正了零初始化对一阶矩的影响; 二阶矩在相同平稳假设下同理。真实训练中的梯度分布会变化, 该计算没有保证归一化更新本身无偏。

权重衰减与自适应梯度项解耦。比较冻结和解冻配置时, 需明确哪些参数进入优化器、哪些应用衰减。[67]

激活 checkpointing 在反向传播时重算部分前向结果, 以额外计算减少保存激活。重计算必须保持随机操作和状态更新的语义。目标教师 EMA、计数器或缓存写入等带副作用操作, 不宜未经处理地放入会重复执行的函数。

12.6 梯度累积与分布式归约

设全批次监督损失分子为 $S = \sum_i \sum_t m_{it} \ell_{it}$ ，有效 token 数为 $N = \sum_i \sum_t m_{it}$ ，目标为 S/N 。微批次 k 的分子与计数为 S_k, N_k ，正确梯度为

$$\nabla \mathcal{L} = \frac{1}{\sum_k N_k} \sum_k \nabla S_k. \quad (12.20)$$

简单平均各微批次均值会得到 $K^{-1} \sum_k \nabla S_k / N_k$ ，只有各 N_k 相等或特殊数据情况才相同。对平方根长度权重，可把 N_k 替换为该微批次的权重总和，保留相同推导。

例题 12.6 变长微批次的归约偏差

两个微批次分别有 1 和 3 个有效 token，每个 token 对某个参数的损失导数分别为第一批 2、第二批均为 6。求全 token 平均梯度与微批次均值平均。

解 正确梯度为 $(2 + 18)/4 = 5$ 。平均两个微批次均值给出 $(2 + 6)/2 = 4$ 。调整学习率不能对所有变长批次统一消除这种权重变化。

若使用 R 个数据并行进程，默认梯度通信结果为各进程梯度平均。第 r 个进程的分子为 S_r ，全局有效计数为 N_{global} 。各进程应反传 RS_r/N_{global} ，使通信后得到

$$\frac{1}{R} \sum_r \nabla \left(\frac{RS_r}{N_{\text{global}}} \right) = \frac{\sum_r \nabla S_r}{N_{\text{global}}}. \quad (12.21)$$

即使某个进程没有有效 token，也需要参加同一通信顺序。可令该进程的局部分子为与计算图相连的零，并使用正的全局分母；不能计算局部 0/0。若全局计数也为零，则整次更新应按预定规则跳过。

计数没有模型梯度，但必须跨进程同步。若框架使用求和通信或额外累积因子，应据其合同调整系数，不能重复除以进程数。

参数分片与张量并行 数据并行复制参数并同步梯度。优化器状态、梯度和参数可进一步分片，从而减少单设备持有的完整状态。完全分片训练还涉及前向与反向时的参数集合及释放；这些通信时间需纳入测量。

对行向量矩阵乘法 $Y = XW$ ，若按输出维划分 $W = [W^{(1)} | \dots | W^{(R)}]$ ，则

$$Y = [XW^{(1)} | \dots | XW^{(R)}]. \quad (12.22)$$

若按收缩维划分 $X = [X^{(1)} | \dots | X^{(R)}]$ 、 $W = [W^{(1)\top} | \dots | W^{(R)\top}]^\top$ ，则

$$Y = \sum_{r=1}^R X^{(r)} W^{(r)}. \quad (12.23)$$

第一种产生输出分片，第二种产生需归约的部分和。MoE 的专家并行还需根据第3章的整数路由索引发送 token，记录每个专家的接收数量、溢出处理和逆置换。




图 12.3 变长多模态批次的全局归约。局部分子和全局分母需要保持同一统计口径。

12.7 计算预算、规模定律与性能测量

对固定模型族，可用经验形式 $L(N, D) = L_\infty + aN^{-\alpha} + bD^{-\beta}$ 拟合损失随参数量 N 与训练 token 数 D 的变化。若近似计算预算为 $C = \kappa ND$ ，代入 $D = C/(\kappa N)$ ，对 N 求导并令零：

$$-\alpha a N^{-\alpha-1} + \beta b (\kappa/C)^\beta N^{\beta-1} = 0, \quad (12.24)$$

$$\beta b (\kappa/C)^\beta N^{\alpha+\beta} = \alpha a, \quad (12.25)$$

$$N^{\alpha+\beta} = \frac{\alpha a}{\beta b} (C/\kappa)^\beta, \quad (12.26)$$

$$N^* = \left(\frac{\alpha a}{\beta b} \right)^{1/(\alpha+\beta)} (C/\kappa)^{\beta/(\alpha+\beta)}. \quad (12.27)$$

该解依赖拟合模型及约束的适用范围。多模态编码成本、上下文长度、稀疏专家和数据重复都会改变 C 的近似，不能从小规模拟合直接外推任意大规模训练。CS336 的规模定律作业将测量与预算分配作为独立实验问题。[1, 68]

性能测量应先固定正确性，再改变实现。对每种输入形状执行预热；测 GPU 时间时同步相应设备或使用设备事件；区分编译、数据读取、图像编码、前向、反向和优化器更新。报告中位数、分位数、有效 token 吞吐量和峰值分配内存；注明 GPU、软件版本、精度及是否启用重计算。CS336 2026 系统作业要求实现、剖析并测试优化后的 Transformer 与分布式训练模块。[73]

对小型 CPU 实现，目标是验证分块算法、梯度和归约恒等式。GPU kernel、通信重叠与长上下文吞吐量必须在相应硬件上测量。理论复杂度不应替代性能数据，尚未执行的硬件测量不得标记为已完成。

12.8 课后习题

习题 12.1 分块计算与全量目标的等价性

单个查询的注意力为 $o = \sum_j e^{s_j} v_j / \sum_j e^{s_j}$ 。训练批次还被拆为具有不同有效 token 数的微批次和数据并行进程。要求分块实现保留同一个数学目标。

- 对每个注意力块保存最大值 m 、缩放分母 $\ell = \sum e^{s-m}$ 和缩放分子 $z = \sum e^{s-m} v$ 。推导两个块的合并公式，并证明合并结果与完整 softmax 一致。
- 取分数 $(0, \log 3)$ 、值 $(2, 6)$ ，分别计算完整与分块输出。分析空块、全掩码块和全掩码查询行，说明为什么不能直接对 $-\infty - (-\infty)$ 求指数。
- 设输出梯度为 g 。从 $o = \sum_j p_j v_j$ 推导 $\partial L / \partial s_j = p_j g^\top (v_j - o)$ ，说明反向重计算需要恢复哪些概率或行统计量。
- 第 r 个进程的有效损失和为 S_r ，计数为 N_r ，通信操作对进程梯度取平均。推导局部反向目标的缩放，使最终梯度等于 $\nabla[\sum_r S_r / \sum_r N_r]$ 。说明局部 $N_r = 0$ 与全局计数为零的处理。
- 编程：实现 CPU 分块注意力和多微批次梯度累积。比较完整参考的前向与反向；模拟有效 token 数极不均衡的多进程归约。正确性测量和 GPU 时间、峰值内存测量应使用独立入口。

习题 12.2 推测解码的概率守恒与计算收益

目标下一 token 分布为 $p = (.6, .3, .1)$ ，草稿分布为 $q = (.2, .5, .3)$ 。先从 q 采样，再通过接受或残差重采样得到最终 token。

- 推导接受概率 $\alpha(x) = \min(1, p(x)/q(x))$ 、总体接受概率和拒绝后的残差分布。用本题数值逐项验证最终输出分布等于 p 。
- 证明总体接受概率等于 $1 - \text{TV}(p, q)$ 。分析 $p = q$ 、某个 $q(x) = 0$ 以及支持完全不重叠的情形；指出哪些除法只需在实际采样到的事件上定义。
- 推广到长度为 K 的草稿。使用条件分布逐步说明，为什么每一位置必须按已经接受的真实前缀验证；拒绝后哪些草稿 token 和缓存内容必须丢弃？说明 EOS 如何改变后续流程。
- 在简化成本模型中，每个位置独立以概率 a 接受，全部 K 个草稿接受后再生成一个目标 token。求每轮期望输出数。若一次目标验证成本为 C_T 、每个草稿成本为 C_D ，写出相对逐 token 目标采样的理想加速比；讨论该式的假设。
- 编程：实现有限词表单步采样并作精确概率核对。扩展为两步前缀相关分布，测试拒绝回退、EOS、温度和 top- p 后的实际分布。性能实验需单独测量验证成本随草稿长度和上下文长度的变化。

第 13 章 实验设计与实现规范

实验结论依赖数据划分、目标实现、测量方法与统计不确定性。本章为各类模型定义分层测试、对照实验、复现记录和交互式评测流程。

13.1 数据划分、统计单位与不确定性

实验从可检验的问题开始。例如，条件视频模型是否响应运动方向变化，学习动力学是否依赖动作，或 PPO 更新中的截断处理是否改变价值估计。每个问题应对应明确的干预、观测量与评价协议。

数据划分 视频与动力学实验按完整轨迹划分数据；控制任务可进一步按初始状态和目标组合划分。VLM 数据应检查相同图像、相同语义样本及近重复样本是否跨集合出现。预处理和归一化统计量由训练集计算。验证集用于模型选择，测试集用于预先定义的最终评估。

运行记录 记录数据版本、划分标识、模型版本、随机种子、有效批次、优化器、学习率、训练更新数与环境交互数。保存 checkpoint 时包括模型、优化器、调度器、随机数状态和当前训练步；恢复实验应验证下一步数据与参数更新的一致性。对于使用 replay buffer 的方法，还需定义缓冲区是否被恢复以及采样状态如何处理。

`eval()` 修改 dropout、批归一化等模块的行为；它不自动关闭梯度。停止梯度的推理上下文、模型模式与随机采样规则应分别设置。可复现性应通过实际重复运行检查，不能仅由设置一个种子推断。[42]

统计单位 独立训练运行、独立环境轨迹和同一轨迹的相邻时间步属于不同层级。均值与区间估计应依据问题选择统计单位。相邻帧和相邻状态高度相关，不能直接当作独立重复实验扩大样本量。单次运行可以报告该运行的结果与轨迹分布，跨种子不确定性则需要独立训练运行。

例题 13.1 相关观测与样本均值方差

设同一轨迹上 n 个观测具有相同方差 σ^2 ，任意两者的相关系数均为 ρ 。求样本均值的方差。

解 由协方差求和，

$$\text{Var}(\bar{X}) = \frac{1}{n^2} [n\sigma^2 + n(n-1)\rho\sigma^2] = \frac{\sigma^2}{n} [1 + (n-1)\rho]. \quad (13.1)$$

取 $n = 100, \rho = 0.1$ ，得到 $0.109\sigma^2$ ，高于独立假设下的 $0.01\sigma^2$ 。该等相关模型只用于说明相关性如何影响方差，实际时间序列需要按其相关结构选择估计方法。

配对比较与统计不确定性 对同一个测试轨迹 i , 两个方法结果为 X_i, Y_i , 定义差值 $D_i = X_i - Y_i$ 。先在一个任务内展开平方, 再对独立任务求和:

$$\begin{aligned}\text{Var}(D_i) &= \mathbb{E}[(X_i - \mathbb{E}X_i - Y_i + \mathbb{E}Y_i)^2] \\ &= \text{Var}(X_i) + \text{Var}(Y_i) - 2\text{Cov}(X_i, Y_i), \\ \text{Var}(\bar{D}) &= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(D_i).\end{aligned}$$

若各任务同分布, 便得到

$$\text{Var}(\bar{D}) = \frac{\text{Var}(X) + \text{Var}(Y) - 2\text{Cov}(X, Y)}{n}. \quad (13.2)$$

使用相同环境初始状态或生成噪声可能增大协方差并减少差值方差。相同随机数只是配对设计的一部分, 仍需保留各方法的完整结果和失败记录。

例题 13.2 配对设计的方差

设两个方法的结果方差均为 1、同一任务上的相关系数为 0.8, 共有 $n = 100$ 个独立任务。求差值均值的标准误差。

解 方差为 $(1+1-1.6)/100 = 0.004$, 标准误差约为 0.06325。若忽略配对协方差, 得到 $\sqrt{2/100} \approx 0.14142$ 。实际计算应从任务差值直接估计。

可按独立轨迹进行 bootstrap: 重复有放回抽取轨迹 ID, 保留每条轨迹的所有相关帧, 再计算统计量。训练随机性与测试采样随机性属于不同层级; 多个 checkpoint 来自同一次训练时, 不构成多个独立训练种子。报告区间的构造方式、重采样单位和样本数。

成功率区间 有限样本下, 成功率 $\hat{p} = k/n$ 的正态近似在 $k = 0$ 或 n 时会给出不合理的零宽区间。Wilson 区间使用原假设参数 p 计算标准误差。将绝对 score 统计量限制在 z 内, 有

$$\begin{aligned}\left| \frac{\hat{p} - p}{\sqrt{p(1-p)/n}} \right| \leq z &\iff n(\hat{p} - p)^2 \leq z^2 p(1-p) \\ &\iff (n + z^2)p^2 - (2n\hat{p} + z^2)p + n\hat{p}^2 \leq 0.\end{aligned}$$

二次项系数为正, 可行参数位于两个实根之间。将求根公式的分子和分母同时除以 $2n$, 得到

$$\frac{\hat{p} + z^2/(2n) \pm z\sqrt{\hat{p}(1-\hat{p})/n + z^2/(4n^2)}}{1 + z^2/n}. \quad (13.3)$$

独立 Bernoulli 假设下, $z = 1.96$ 对应常用的近似 95% 区间。它不包括训练种子、分布迁移或环境系统性误差。零次成功仍有非零上界; 样本不足时应如实报告区间。

数据来源与去重 重复图像、视频片段及相同问题模板可能同时出现在训练和测试。精确哈希可以识别相同字节，感知哈希或嵌入近邻可以检索近重复候选，最终规则需按任务定义。阈值、过滤器和人工排查记录应在最终评价前固定。选择数据与性能评估使用同一测试集会引入选择偏差。CS336的数据作业将过滤、去重和语言模型训练效果相联系。[1]

MinHash 候选与实际去重规则 把文档表示为有限的 token n -gram 集合 A, B , Jaccard 相似度为 $s = |A \cap B| / |A \cup B|$ 。对全集施加均匀随机排列 π , 记 $h_\pi(A)$ 为排列中最先出现的集合元素。两集合的最小元素相同, 当且仅当并集中最先出现的元素属于交集。因此

$$\Pr[h_\pi(A) = h_\pi(B)] = \sum_{x \in A \cap B} \Pr[x = \arg \min_{u \in A \cup B} \pi(u)] = \frac{|A \cap B|}{|A \cup B|} = s. \quad (13.4)$$

实际实现通常以哈希族近似随机排列, 需要另外测量其碰撞和偏差。空文档没有最小元素, 应在调用前定义处理规则。

将独立的 br 个签名分成 b 组, 每组 r 个。只要任意一组的签名完全相同, 就将文档对加入候选。单组匹配概率为 s^r , 全部组不匹配的概率为 $(1 - s^r)^b$, 故

$$\Pr[\text{进入候选集}] = 1 - (1 - s^r)^b. \quad (13.5)$$

这个概率随相似度平滑变化。进入候选集后仍应计算实际相似度, 并按预定规则处理连通分量与保留样本。检测文本近重复和判断两个图像是否对应同一任务, 需要使用各自的数据表示。[88, 106]

13.2 实现接口、梯度检查与数值测试

每个核心函数应明确输入语义、形状、数据类型、有效范围、输出及梯度参数集合。以下接口覆盖主要训练目标:

模块	输入或输出	检查内容
GAE	$[T, B]$ 奖励、价值与边界	自举与递归掩码、实际后继观测。
PPO 更新	当前与旧对数概率、优势	比率、优势固定、正负裁剪。
SAC 更新	回放转移、当前策略	critic、actor、温度的梯度集合。
噪声与速度目标	数据、噪声、时间	系数、端点方向、逐样本广播。
序列概率	logits、token ID、回答掩码	移位、词表选择、有效位置归约。
视频分块	视频张量与块尺寸	轴置换、元素顺序、逆变换。
模型 rollout	初始状态与动作序列	时间对齐、递归预测、终止处理。

实现时先根据公式写出伪代码与形状断言, 再建立最小数值例题。自动微分可与有限差分对照; 涉及随机采样时固定基础噪声, 以比较同一个确定性重参数化函数。对 `detach` 的检查同时观察前向数值与反向梯度, 避免只比较损失值。

实现验收分为函数、训练更新与任务评测三个层级。函数测试使用可手算的输入和独立参考实现；更新测试检查梯度集合与参数变化；任务评测使用固定的数据划分和指标入口。错误报告保留可复现输入、预期结果及实际结果。通过某一层级后，再连接依赖该接口的下一层级。

例题 13.3 停止梯度的数值检查

令 $L(\theta) = (\theta - \text{sg}(2\theta + 1))^2$ 。在 $\theta = 1$ 处分别计算自动微分约定下的梯度，以及每次扰动都重新生成目标时的有限差分结果。

解 固定目标 $\text{sg}(3) = 3$ 时，梯度为 $2(1 - 3) = -4$ 。若有限差分每次重新计算 $2\theta + 1$ ，前向函数变为 $(\theta + 1)^2$ ，导数为 4。检验半梯度时，有限差分也需固定目标；否则两种计算检查的是不同的导数定义。

13.3 综合实验与交互任务

实验一：视觉语言数据与监督 实现包含视觉输入、提示、回答和 padding 的数据批次。输出视觉特征、投影 token、拼接序列、注意力掩码、监督标签和有效 token 数。验证下一 token 移位、视觉 token 数、冻结参数与连接模块梯度。进一步使用配对图像干预测量视觉依赖，分别报告接口正确性、监督拟合与独立任务表现。

可以使用固定视觉特征检查连接模块与监督路径。缓存特征时需固定对应的图像预处理与增强规则；端到端视觉编码器更新和动态增强需要重新计算特征。模型选型与规模应记录为实验设置，不能由模块测试直接推断完整 VLM 能力。

实验二：策略优化与价值学习 完成离散小环境的 PPO 训练过程，记录交互步数、回报、熵、KL、裁剪比例与价值拟合。SAC 实验先验证各项更新，再在连续动作环境评估。DDQN 与 expectile 可以独立使用人工数据测试，随后接入统一回放接口。实现基础设施可参考公开课程作业，但目标公式和接口需与实际版本一致。[8]

语言后训练实验先验证 token 概率、组优势、GRPO 与 DPO 核心损失，再决定完整模型运行配置。人工奖励测试与完整生成训练分别记录，避免将函数验证计为端到端训练结果。[9]

实验三：二维分布与小视频生成 先完成二维条件流匹配，检查训练目标、积分方向、CFG 与固定噪声对照。之后扩展到 8 帧、 16×16 的可控视频。保存图像及真实状态，明确首帧条件或运动条件，验证单批拟合、轨迹划分和视频块逆变换。比较正确、空缺、打乱与反向条件；在同一 NFE 下比较采样器。报告方向、速度、边界与可见性，保存固定测试集的完整样本。

实验四：动作条件预测与控制 复用可控环境，从低维真实状态训练动力学。先比较一步与开放环多步预测，再实现随机采样 MPC。对照随机策略、学习动力学 MPC 与真实动力学 MPC，固定候选预算及奖励。动作置零或打乱用于检验动作依赖，预测长度消融用于测量累积误差的影响。任务成功条件在观察结果之前确定。图像编码后的 latent 动力学可以作为后续扩展，并重新验证表征中是否保留控制变量。

交互任务与轨迹评测 涉及工具调用的模型产生多步轨迹 $\tau = (o_0, a_0, o_1, a_1, \dots)$ 。动作包含工具名称与参数，观测包含返回值、错误和环境状态。模型可读的内容、工具实际执行结果和最终任务成功应分别记录。上下文压缩、外部记忆和工具执行改变模型在下一步实际可见的信息，因此应作为系统配置的一部分固定。[92]

工具返回文本本身不应被直接解释为新的训练指令。评测需固定工具版本、权限、超时规则和外部状态；具有外部副作用的操作使用隔离或模拟环境。模型使用记忆时，测试任务之间的状态是否清空必须明确，避免前一任务结果泄漏到后一任务。

若完整历史为 h_t ，压缩上下文为 $c_t = C(h_t)$ ，策略实际使用 $\pi(a_t | c_t)$ 。压缩后保持控制能力的一项充分条件是：对任务奖励与后继观测， c_t 包含选择动作所需的历史信息。若存在 $C(h) = C(h')$ ，但两个历史中的同一动作具有不同的成功条件，则仅依赖 c_t 的策略无法同时区分它们。测试时可构造仅在早期工具返回值上不同的两条历史，检查压缩是否保留该差异。摘要长度、外部状态和检索结果需要一并记录。

成功指标与过程指标 最终任务成功率对应结果，工具调用次数、无效参数率、超时率和总延迟对应过程。奖励只依赖某个过程指标时，可能出现该指标改善而任务成功率未改善。应保留独立评价器与干预实验，不依据单一训练奖励解释系统能力。未查明原因的失败记录为“原因未查明”。

13.4 自我修正、候选选择与评价器误差

模型生成多个答案或根据反馈重新作答时，最终正确率取决于初始生成、修正操作和答案选择。将它们分别评估，可以判断变化发生在哪个环节。[93, 89]

一次修正的收益条件 记初始正确率为 p ，错误答案被修正为正确的条件概率为 q ，正确答案被改错的条件概率为 r 。根据初始答案是否正确分解，有


$$\begin{aligned} p' &= \Pr[\text{修正后正确, 初始正确}] + \Pr[\text{修正后正确, 初始错误}] \\ &= p(1-r) + (1-p)q, \\ p' - p &= (1-p)q - pr. \end{aligned} \tag{13.6}$$

因此，修正前后必须保留配对结果，分别统计纠错率 q 和改错率 r 。只报告发生修改的样本或只保留正确反馈，会改变评价总体。通过率相同的两个系统也可能具有不同的纠错与改错行为。

例题 13.4 相同正确率下的不同修正行为

初始正确率为 0.6。系统在错误样本上有 0.3 的概率纠错，在正确样本上有 0.2 的概率改错。求最终正确率，并判断单独观察最终正确率能否确定修正操作的影响。

解 $p' = 0.6 \times 0.8 + 0.4 \times 0.3 = 0.6$ 。总体正确率未变化，但 12% 的全部样本被纠正，另外 12% 被改错。需要保留这两类转移的计数，才能描述操作的影响。



维度 行、列分别表示修正前、后的正确性；索引 1 为正确，0 为错误。

结果 本例中总体正确率不变；错误修复与原有正确答案受损各发生 12 次。

评估 配对差值保留样本对应关系。仅报告两个平均正确率会遗漏具体转移。

图 13.1 自我修正的配对状态转移。计数与正确性差值分别表示，避免将不变的平均指标解释为没有变化。

多个候选与 pass@k 对同一问题，若每次独立采样的正确率均为 p ， k 次均失败的概率为 $(1-p)^k$ 。至少一次成功的概率为 $1 - (1-p)^k$ 。题目之间通常具有不同的 p ，应逐题计算后平均，不能先把各题正确率平均再代入非线性函数。

给定同一问题的 n 个样本，其中 c 个正确。在这 n 个样本中等概率选取 k 个，全部错误的子集共有 $\binom{n-c}{k}$ 个，全部子集共有 $\binom{n}{k}$ 个，因此估计量为

$$\widehat{\text{pass@}k} = 1 - \frac{\binom{n-c}{k}}{\binom{n}{k}}, \quad 1 \leq k \leq n. \quad (13.7)$$

当 $n-c < k$ 时，分子按零处理。它描述候选中存在正确答案的频率；实际系统还需要根据可用信息选择答案。选择器出错时，提交答案的成功率会低于该指标。测量时同时报告总生成预算、每个候选的长度限制、选择器成本和最终选择正确率。[107]

评价器校准 评价器的输出也可能包含错误。设真实正确标签为 Y ，评价器标签为 J ，敏感度为 $u = \Pr(J=1 | Y=1)$ ，特异度为 $v = \Pr(J=0 | Y=0)$ 。使用全概率公式，

$$\begin{aligned} q_J = \Pr(J=1) &= up + (1-v)(1-p) \\ &= (u+v-1)p + 1-v. \end{aligned}$$

若校准集与测试集上这两个条件概率相同，且 $u + v \neq 1$ ，可以反解

$$p = \frac{q_J + v - 1}{u + v - 1}. \quad (13.8)$$

当 $u + v$ 接近 1 时，分母很小，估计误差会被放大。有限校准样本还会给 u, v 带来不确定性。若答案长度、模型来源或任务分布改变了评价器误差率，直接使用原校准公式不再成立。应抽取人工审查子集，按预先定义的任务类别检查误差，而不能把评价器分数直接当作真实正确率。

13.5 实验交付与结果报告

结果报告应列出预先定义的指标、独立重复次数、汇总方法和不确定性估计。结论的适用范围由数值结果、数据分布与评价协议共同确定。原因未查明的现象按该状态记录，原因解释需要由控制变量的干预实验支持。

消融应改变明确变量，例如动作输入、条件掩码、预测长度、目标网络更新率或采样器。多项配置同时变化时，应将结论限制为整体方案差异。选择展示样本、确定测试划分或修改指标发生在观察结果之后时，应如实记录其顺序。

阅读新方法可按计算依赖完成分析：定义观测、动作、潜变量与生成顺序；列出训练数据中实际可用的字段；写出损失与停止梯度位置；比较训练与推理历史来源；说明动作执行后的反馈规则；核对评价协议和消融所支持的结论。Qwen3-VL、Wan、DreamerV3、V-JEPA 2 与 DreamZero 可据此放入统一的比较框架。[12, 33, 38, 39, 40]

统一交付内容 每章编程题使用独立函数接口和确定性测试，随后连接受控实验。提交材料包括源代码、配置、测试输出、训练或评测入口、指标定义和结果文件。实验报告区解析结果、单元测试、实际训练和未执行的硬件测量。测试代码应从清洁目录运行，checkpoint 恢复应验证下一步更新。

题目中的参数规模、样本数和数值容差用于定义任务；结果由实际运行填写。CPU 测试通过能够支持相应函数的局部正确性，端到端学习曲线、模型泛化与 GPU 性能需分别验收。

13.6 课后习题

习题 13.1 修正、选择与评价误差的可分辨性

对 100 个独立问题，初始答案中 60 个正确。修正后，有 12 个原错误答案变正确，也有 12 个原正确答案变错误。

- 写出修正前后正确性的 2×2 联合计数表，计算初始、最终正确率及两个条件转移率。推导一般的 $p' - p = (1 - p)q - pr$ ，解释总体均值不变时还应报告哪些信息。
- 令每题配对差值 $D_i \in \{-1, 0, 1\}$ 。求本题的经验二阶矩及均值差标准误差的 plug-in 估计。与把修正前后当作两组独立样本的处理比较，说明依赖结构的影响。
- 自动评价器的敏感度为.9、特异度为.8，观察到的判对率为.7。推导校准后的真实正确率。若两项误差率来自有限且不同分布的校准集，哪些条件尚需验证？
- 另对一个问题生成 5 个候选，其中 2 个正确。求 pass@2 的组合估计，并与随机选择一个候选的正确概率比较。是否可以用该 pass@2 作为部署时提交答案的成功率？
- 编程：实现配对统计、Wilson 区间和 pass@ k 。检查零次成功、全部成功、配对 ID 不匹配及 $k > n$ 。设计同一总计算预算下的一次修正与多候选选择比较，并固定独立评价入口。

习题 13.2 近重复数据、统计单位与可复现实验

一个视频语料包含场景 ID、轨迹 ID 和帧。关联文本用 token 集合表示。评估目标是泛化到独立场景，而非预测已见轨迹的相邻帧。

- 给定 $A = \{1, 2, 3\}$ 、 $B = \{2, 3, 4\}$ ，计算 Jaccard 相似度，并通过并集随机排列证明 MinHash 碰撞概率。使用 2 组、每组 2 个独立签名时，求候选概率。
- 取 $A = \{1, 2\}$ 、 $B = \{1, 2, 3\}$ 、 $C = \{2, 3\}$ ，阈值为.6。求相似关系，说明近重复关系为何不一定具有传递性。把连通分量放入同一数据集与每个分量只保留一条样本，有何不同影响？
- 同一轨迹有 n 帧，等方差为 σ^2 ，等相关系数为 ρ 。求均值方差。若各轨迹长度不同，平均所有帧与先算各轨迹均值再平均分别估计什么总体？
- 编程：按场景与近重复连通分量生成数据划分，并实现按独立场景的 bootstrap。保存一次含随机增强和梯度累积的训练状态，验证恢复后的下一次更新与原运行一致；列出需要保存的状态。
- 过滤后测试性能下降，原因尚未确认。设计能够区分样本量变化、任务分布变化与标签一致性变化的受控比较，并规定哪些数据用于选择过滤阈值，哪些数据只用于最终检验。

附录 A 习题解答与实验判据

解析解说明在题设假设下可以确定的结果。编程部分给出独立参考、边界条件与实验判据；涉及训练和硬件性能的结论需要由对应实验记录支持。

A.1 张量计算与概率优化

习题1.1

- (a) 记 $N = \sum_{bt} m_{bt} > 0$ 、 $P = \text{softmax}(U)$ 。单个位置有 $\ell = -\sum_c q_c U_c + \log \sum_c e^{U_c}$ ，所以 $\partial \ell / \partial U_c = P_c - q_c$ 。令 $G_{btc} = m_{bt}(P_{btc} - q_{btc})/N$ ，则

$$\frac{\partial L}{\partial W_{ic}} = \sum_{bt} X_{bti} G_{btc}, \quad \frac{\partial L}{\partial b_c} = \sum_{bt} G_{btc}, \quad \frac{\partial L}{\partial X_{bti}} = \sum_c G_{btc} W_{ic}.$$

无效位置的 q 可以不参与计算； $N = 0$ 应拒绝该损失调用，或由上层明确跳过更新。不能将分母替换为 1 后把空批次当作普通训练样本。

- (b) $\partial P_i / \partial U_j = P_i(\mathbf{1}[i=j] - P_j)$ ，故 $H = \text{diag}(P) - PP^\top$ 。对任意 v ，

$$v^\top H v = \sum_i P_i v_i^2 - \left(\sum_i P_i v_i \right)^2 = \text{Var}_{i \sim P}(v_i) \geq 0.$$

由于 $H\mathbf{1} = P - P = 0$ ，共同平移位于零曲率方向。有限 logits 下 $P_i > 0$ ，仅常量向量使该方差为零。

- (c) 交叉熵 $H(q, P) = H(q) + \text{KL}(q\|P)$ ，最小值在 $P = q$ 取得。因此 $U_c = \log q_c + k$ ， $k \in \mathbb{R}$ 。one-hot 目标要求正确类别概率为 1，有限 softmax 无法达到；令正确类别与其余类别的 logit 差趋于正无穷，可使损失趋于零。具有正支持的平滑标签给出有限的最优差值，但不消除共同平移的不唯一性。

- (d) 正确梯度为 $(2+6+6+6)/4 = 5$ ；微批次均值的简单平均为 $(2+6)/2 = 4$ 。若第 j 个微批次有 N_j 个有效位置，其平均损失应乘 $N_j / \sum_i N_i$ 后反向。把每次梯度累积再除以微批次数只适用于各微批次有效计数相同的情况。

- (e) 参考实现应直接从 X, W, b, q, m 建立自动微分图，手动实现则使用上述 G 。测试比较张量元素和形状，误差采用绝对与相对容差。平移测试同时比较概率、损失和梯度；使用减最大值的 log-sum-exp，避免先指数化大 logits。微批次测试只执行一次优化器步，并关闭会改变批次语义的随机层。

习题1.2

(a) $J = \mu^2 + 1, J' = 2\mu$ 。由 $\partial_\mu p = p \partial_\mu \log p$ 以及 $\partial_\mu \log p_\mu(z) = z - \mu$, 得到 $G_s = z^2(z - \mu) = (\mu + \varepsilon)^2 \varepsilon$ 。固定基础噪声求导给出 $G_p = 2(\mu + \varepsilon)$ 。高斯尾部可积地控制这些多项式及其参数邻域内的导数, 允许本题中的微分交换。

(b) 展开 $G_s = \mu^2 \varepsilon + 2\mu \varepsilon^2 + \varepsilon^3$ 。奇数阶矩为零, 故 $\mathbb{E}G_s = 2\mu$, 而

$$\mathbb{E}G_s^2 = \mu^4 + 18\mu^2 + 15, \quad \text{Var}(G_s) = \mu^4 + 14\mu^2 + 15.$$

$\mathbb{E}G_p = 2\mu$, $\text{Var}(G_p) = 4$ 。在 $\mu = 0$ 处两个方差为 15 和 4; 前者随 $|\mu|$ 增大而增长。该比较针对本题, 不能推广成所有随机目标的统一排序。

(c) $G_b = (z^2 - b)\varepsilon$, 且 $\mathbb{E}[b\varepsilon] = 0$ 。最小化二阶矩时,

$$0 = \frac{d}{db} \mathbb{E}[(z^2 - b)^2 \varepsilon^2] = -2\mathbb{E}[z^2 \varepsilon^2] + 2b\mathbb{E}[\varepsilon^2],$$

所以 $b^* = \mu^2 + 3$ 。此时方差为 $8\mu^2 + 6$; 取 $b = \mu^2 + 1$ 时为 $8\mu^2 + 10$ 。最优基线按 score 的平方加权, 而目标均值没有该权重。

(d) 每次实验复用同一噪声数组, 有限差分计算 $[(\mu + h + \varepsilon)^2 - (\mu - h + \varepsilon)^2]/(2h)$, 在实数运算下恰为 $2(\mu + \varepsilon)$ 。浮点误差随过小的 h 增大。均值的标准误差可由解析方差除以样本数后开方得到; 样本方差另有估计不确定性。

(e) score-function 估计将样本和优势视为固定数值。对应的策略代理损失可写为

$$L_{\text{policy}} = -\log p_\mu(\text{sg } z) \text{sg}(z^2 - b_\psi).$$

若基线与策略共享参数, 取消基线的停止梯度后, 会额外出现 $\log p_\mu(z) \partial_\mu b_\psi$ 。若保留重参数化样本的梯度, 还会加入经过样本值的导数。基线参数可使用独立回归损失更新; 策略代理损失只用于估计目标期望的梯度。

A.2 多模态对齐与条件生成

习题2.1

(a) 记 $Z = 2e^r + 1$ 。三个损失分别为 $\log Z - r$, $\log Z - r$, $\log Z - r - \log 2$, 即前两者为 $\log(2 + e^{-r})$, 第三个为 $\log(1 + e^{-r}/2)$ 。极限依次为 $\log 2, \log 2, 0$; 共同导数为 $-1/(2e^r + 1)$ 。在这个受约束的分数族上, 它们只相差常数。

(b) 前两种梯度分别是 $p - e_1$ 和 $p - q$ 。集合目标为 $-\log(p_1 + p_2)$, 其梯度是

$$\partial_{s_j} L = p_j - \mathbf{1}[j \in \{1, 2\}] \frac{p_j}{p_1 + p_2}.$$

单一正例目标奖励对第一个文本的集中；软标签目标要求正例概率按 1:1 分配；集合目标只约束总正例概率。语义等价只支持把它们视为正例，是否要求均衡还依赖任务对多个标注的概率解释。

- (c) $\partial_{\eta} L = -e^{\eta} c / (2e^{\eta} c + 1) < 0$ ，因此在固定 $c > 0$ 的例子中，增大逆温度持续降低损失，只有极限最优。单位化限制相似度，不限制额外的逆温度参数；实现可显式约束该参数，并分别检查梯度尺度与饱和行为。

- (d) 若行概率为 P^r 、列概率为 P^c ，则 $G_{ij} = (P_{ij}^r + P_{ij}^c - 2\mathbf{1}[i = j]) / (2B)$ 。对 $u_i = x_i / \|x_i\|$ ，

$$\frac{\partial L}{\partial x_i} = \frac{I - u_i u_i^{\top}}{\|x_i\|} \frac{1}{\tau} \sum_j G_{ij} v_j.$$

共同置换同时变换行列和正例关系。仅置换文本时，原对角标签应变成相应的置换矩阵；仍使用对角标签会改变监督问题。

- (e) $B = 1$ 的对称 CLIP 梯度为零。全部图文等价时，单对角监督仍存在不可区分的标签；多正例集合目标可达到零损失，但不因此获得区分非等价样本的能力。程序应比较解析梯度与自动微分，并记录正例掩码的构造规则。

习题2.2

- (a) 标签为 $(V, Q, \text{SEP}, A, B, \text{EOS})$ ，掩码为 $(0, 0, 0, 1, 1, 1)$ 。打包注意力为 $\text{diag}(\text{tril}(\mathbf{1}_{7 \times 7}), \text{tril}(\mathbf{1}_{4 \times 4}))$ 。第一段 EOS 预测第二段 BOS 的跨样本标签应排除；打包只改变存储方式，不建立跨样本条件关系。
- (b) $\partial L / \partial e_V = (h - y) / 2$ ， $\partial L / \partial \phi = (h - y)z / 2$ 。例如 $e_V = 2, e_Q = 0, y = 0, z = 1$ 时，两者均为 $1/2$ 。下游权重固定后，仍可对输入求导；把整个下游前向放入无梯度上下文会切断这条路径。
- (c) 对框的两个角分别施加仿射变换，逆变换为 $x = (x' - b_x) / s_x, y = (y' - b_y) / s_y$ ，要求 $s_x, s_y \neq 0$ 。若用图像宽高归一化，必须明确除以哪个坐标系的宽高。水平翻转把左右象限互换；改变方块颜色时，颜色答案应同步改变或禁止该增强。
- (d) 注意力支持、标签支持与 padding 支持应分别构造。用全词表 logits 的基础实现作为参考，不要直接用忽略标签 -100 进行 gather。对被忽略位置先替换成合法索引，再在归约前掩码；或者只 gather 有效位置。空监督接口应采用与本书第 1 章一致的规则。
- (e) 可对相同问题计算正确图像与打乱图像下的答案对数概率差、颜色正确率差及定位误差差。测试集按场景划分，配对样本共享问题和评分规则。显著差异说明在该干预和该数据分布下输出依赖视觉输入；它不能单独证明对象组合、背景变化或真实图像上的泛化。

A.3 现代视觉语言模型架构

习题3.1

- (a) 先得到 $(B, H/s, s, W/s, s, d)$, 再替换为 $(B, H/s, W/s, s, s, d)$, 最后变成 $(B, HW/s^2, s^2d)$ 。本题依次为 $(2, 2, 2, 3, 2, 3)$ 、 $(2, 2, 3, 2, 2, 3)$ 、 $(2, 6, 12)$ 。输出第 (i, j) 个 token 的通道顺序为 (a, b, c) , 对应 $U_{b_0, si+a, sj+b, c}$ 。拼接保留全部元素, 可逆; 投影矩阵不满列秩或输出维数较小时通常不能恢复原输入。
- (b) 设置换矩阵为 Π 。 $K' = \Pi K, V' = \Pi V$, 于是 $QK'^\top = QK^\top \Pi^\top$, 行 softmax 同样置换列。因此 $\text{softmax}(QK'^\top)V' = \text{softmax}(QK^\top)V$ 。例如左红右蓝与左蓝右红具有相同的无序内容集合, 固定查询不能识别其位置交换。
- (c) 只置换内容时 $\Pi U + P$ 通常不同于 $\Pi(U + P)$, 故可改变输出; 同时置换内容与坐标仍只改变集合顺序。令 $A = \text{softmax}(QK^\top/\sqrt{d})$ 、输出梯度为 G , 则 $G_V = A^\top G, G_A = GV^\top$ 。对每行, $G_S = A \odot (G_A - \langle A, G_A \rangle)$, 再有 $G_K = G_S^\top Q/\sqrt{d}$ 。若 $K = UW_K, V = UW_V$, 则 $G_U = G_K W_K^\top + G_V W_V^\top$ 。
- (d) 低分辨率基数为 $64n$, 每个高分辨率块额外需要 192 token。 $64n > M$ 时无可行解; 否则 $k_{\max} = \min\{n, \lfloor (M - 64n)/192 \rfloor\}$ 。取 $n = 8, M = 1280$ 得 $k_{\max} = 4$; $M = 500 < 512$, 连全部低分辨率表示也无法容纳。
- (e) 逆操作只针对投影之前的拼接。形状相同的错误置换可能通过尺寸检查, 因此必须比对元素地址。相对位置实验改变对象位置但保持对象集合; 计数实验改变重复对象数量。实验需分别记录压缩后 token 数、预测目标和任务指标, 避免用一个任务替代全部压缩能力。

习题3.2

- (a) 展开 $h_2 = [ca + cb + d]\phi x$ 。分别沿 h_0 、 bu 和 du 三条接口路径得到 $(h_2 - y)cax$ 、 $(h_2 - y)cbx$ 、 $(h_2 - y)dx$ 。总和等于 $(h_2 - y)(ca + cb + d)x$, 与直接求导相同。
- (b) $h_1 = 5, h_2 = 25, L = 625/2$ 。三个贡献依次为 200, 300, 125, 总梯度为 625。遗漏初始路径只得到 425; 前向损失并不暴露这个遗漏。
- (c) 停止 bu 的梯度后, 前向仍为 25; $\partial_\phi L = 200 + 125 = 325, \partial_b L = 0$ 。只冻结 a, c 的参数并不切断它们对输入的线性导数, $\partial_\phi L$ 保持 625。冻结参数和停止整个中间张量的梯度作用于不同的计算对象。
- (d) 若独立接口为 $H_0 = P_0(E_\phi(I))$ 和注入量 $J_\ell = P_\ell(E_\phi(I))$, 总梯度为

$$\nabla_\phi L = (D_\phi H_0)^\top \frac{\partial L}{\partial H_0} + \sum_\ell (D_\phi J_\ell)^\top \frac{\partial L}{\partial J_\ell}.$$

这里把各接口量作为独立变量求偏导；接口之后的共同计算由反向传播处理。若某一项已经包含另一接口对共享编码器的依赖，再加一次该接口贡献会重复计数。

- (e) 验证 $\text{sg}(bu)$ 的半梯度时，先在基准参数处缓存该数值，再对其他路径扰动参数。每次扰动后重新计算被停止梯度的量，会检验完整前向函数的导数。冻结的参数通常具有 `grad=None`；参与图但梯度为零的参数可具有零张量，两种状态应按实际接口区分。

A.4 扩散模型与流匹配

习题4.1

- (a) $x_2 = \sqrt{\alpha_2\alpha_1}x_0 + \sqrt{\alpha_2\beta_1}\varepsilon_1 + \sqrt{\beta_2}\varepsilon_2$ 。独立高斯的线性组合仍为高斯，方差相加为 $0.8 \times 0.1 + 0.2 = 0.28$ 。因此 $q(x_2 | x_0) = \mathcal{N}(\sqrt{0.72}x_0, 0.28)$ 。定义合并噪声为后两项除以 $\sqrt{0.28}$ ，即可验证其均值为零、方差为一。

- (b) 忽略与 x_1 无关的常数，负两倍对数密度为

$$\frac{(x_2 - \sqrt{0.8}x_1)^2}{0.2} + \frac{(x_1 - \sqrt{0.9}x_0)^2}{0.1} = 14x_1^2 - 2(5\sqrt{0.8}x_2 + 10\sqrt{0.9}x_0)x_1 + C.$$

因此方差为 $1/14$ ，均值为 $[5\sqrt{0.8}x_2 + 10\sqrt{0.9}x_0]/14$ 。代入给定值后，均值为 $5\sqrt{0.9}/7 \approx 0.677631$ ，方差约为 0.071429 。

- (c) 真实均值和预测均值分别将 ε 、 ε_θ 代入

$$\mu(x_2, \varepsilon) = \frac{1}{\sqrt{\alpha_2}} \left(x_2 - \frac{\beta_2}{\sqrt{1 - \bar{\alpha}_2}} \varepsilon \right).$$

均值差为 $\beta_2(\varepsilon_\theta - \varepsilon)/\sqrt{\alpha_2(1 - \bar{\alpha}_2)}$ 。等方差高斯 KL 为均值差平方除以 $2\tilde{\beta}_2^2$ ，故权重为 $0.2^2/[2(1/14) \cdot 0.8 \cdot 0.28] = 1.25$ 。

- (d) 由 Jensen 不等式， $\log p_\theta(x_0) \geq \mathbb{E}_q[\log p_\theta(x_0, x_1, x_2) - \log q(x_1, x_2 | x_0)]$ 。把联合概率分解后，再使用 $q(x_1, x_2 | x_0) = q(x_2 | x_0)q(x_1 | x_2, x_0)$ ，负下界化为

$$\text{KL}(q(x_2 | x_0) \| p(x_2)) + \mathbb{E}_{q(x_2 | x_0)} \text{KL}(q(x_1 | x_2, x_0) \| p_\theta(x_1 | x_2)) - \mathbb{E}_q \log p_\theta(x_0 | x_1).$$

给定 x_0 后的第一步“后验”是点质量，不能当作具有正方差的高斯使用同一 KL 表达式；它由解码似然项处理。

- (e) 重建测试应固定基础噪声，用 $\hat{x}_0 = (x_k - \sqrt{1 - \bar{\alpha}_k}\varepsilon)/\sqrt{\bar{\alpha}_k}$ 恢复 x_0 。矩测试有 Monte Carlo 误差，应根据样本量和解析方差设置统计判据。时间索引必须按每个样本 gather 系数，再补齐非批次轴；不得把批次轴误当空间轴广播。

习题4.2

(a) $\mu_t = tm$, $q_t = (1-t)^2 + t^2s^2$, $c_t = \text{Cov}(U, X_t) = ts^2 - (1-t)$ 。由于 (U, X_t) 联合高斯,

$$v^*(x, t) = m + \frac{c_t}{q_t}(x - tm), \quad \text{Var}(U | X_t) = 1 + s^2 - \frac{c_t^2}{q_t} = \frac{s^2}{q_t}.$$

最后一步使用 $(1 + s^2)q_t - c_t^2 = s^2$ 。所以零训练回归误差通常不可达到; 条件目标本身存在方差。

(b) $\dot{q}_t = 2c_t$ 。用乘积法则,

$$\dot{Y}_t = \frac{\dot{x}_t - m}{\sqrt{q_t}} - \frac{(x_t - tm)\dot{q}_t}{2q_t^{3/2}} = \frac{c_t(x_t - tm)}{q_t^{3/2}} - \frac{c_t(x_t - tm)}{q_t^{3/2}} = 0.$$

因此 $\Phi_{a,b}(x) = bm + \sqrt{q_b/q_a}(x - am)$ 。从 0 到 1 的映射为 $m + sx$, 其分布正好为目标高斯。

(c) 此时 $q_{1/2} = 1/2, c_{1/2} = 0$, 所以 $v^*(x, 1/2) = 0$ 。条件直线为 $1 - 2t$, 会经过零点并变为负值; ODE 轨迹为 $\sqrt{q_t} > 0$, 末端返回 1。独立端点训练定义了边缘分布与条件速度回归问题; 边缘速度的确定性轨迹采用另一种端点耦合。

(d) $f(x, t) = m + s(x - tm)/\sqrt{q_t}$ 。代入 $t = 1$ 得 $f(x, 1) = x$; 对 x, t 求导后, $-sm/\sqrt{q_t}$ 与速度中的常数项抵消, 其余 c_t 项抵消, 从而满足 PDE。仅要求沿轨迹一致时, 任意常数函数都满足约束; 端点条件排除该退化解。

(e) 确定性检查包括随机时刻的组合律、端点条件及 PDE 残差。采样器比较应使用同一初值、时间区间和 NFE。学习实验中, 回归误差应与 s^2/q_t 的不可约项比较; 终点误差还包含函数近似与数值积分误差, 二者需要分开测量。

习题4.3

(a) Q_1 的三行为 $(.8, 0, .2)$ 、 $(0, .8, .2)$ 、 $(0, 0, 1)$ 。第二步在尚未吸收的条件下存活概率为 $.4/.8 = .5$, 故 Q_2 的前两行为 $(.5, 0, .5)$ 、 $(0, .5, .5)$ 。乘积 $\bar{Q}_2$ 的前两行为 $(.4, 0, .6)$ 、 $(0, .4, .6)$; mask 行始终为 $(0, 0, 1)$ 。

(b) 给定 $X_0 = a$, 联合事件 $(X_1 = a, X_2 = \text{mask})$ 的概率为 $.8 \times .5 = .4$, 第二步已吸收的概率为 $.6$ 。所以后验为 $(2/3, 0, 1/3)$ 。mask 事件对初始类别的似然相同, 初始后验仍为 $(.4, .6)$, 混合后得到 $(4/15, 2/5, 1/3)$ 。

(c) $p_\theta(X_1 = i | X_2 = j) = \sum_c q(X_1 = i | X_2 = j, X_0 = c)p_\theta(X_0 = c | X_2 = j)$ 。例如给定 $X_0 = a$ 却观测 $X_2 = b$, 前向事件概率为零, 条件后验未定义。模型的混合必须尊重可达支持; 不应计算 $0/0$ 后仅用归一化掩盖错误。

(d) R 的前两行为 $(-\lambda, 0, \lambda)$ 、 $(0, -\lambda, \lambda)$, 最后一行为零。 $p_t(a) = .4e^{-\lambda t}, p_t(b) = .6e^{-\lambda t}, p_t(\text{mask}) = 1 - e^{-\lambda t}$ 。沿增加的反向时间, mask 到 a, b 的速率分别为 $\lambda p_t(a)/p_t(\text{mask})$ 与 $\lambda p_t(b)/p_t(\text{mask})$ 。当 $\lambda \Delta t > 1$ 时, Euler 矩阵的前两个对角项为负。

- (e) 用 $p(X_0 = c, X_1 = i, X_2 = j) = p_0(c)Q_1(c, i)Q_2(i, j)$ 独立建立参考。归一化只对概率非零的条件事件执行。连续时间比较使用 $\exp(\Delta t R)$ ；反向速率在 $t \downarrow 0$ 的边界可发散，应避免把不存在 mask 质量的端点直接代入比值。

A.5 视频生成与自回归建模

习题5.1

- (a) 潜时间长度为 $1 + (81 - 1)/4 = 21$ ，空间为 32×32 ，故潜变量为 $(B, 16, 21, 32, 32)$ 。每块宽度为 $1 \cdot 2 \cdot 2 \cdot 16 = 64$ ，token 数为 $21 \cdot 16 \cdot 16 = 5376$ 。全注意力元素数为 $5376^2 = 28\,901\,376$ ；令 $F = 21, S = 256$ ，分解注意力为 $FS^2 + SF^2 = 1\,489\,152$ 。空间与时间两次归一化形成不同的算子，不能仅由复杂度推断函数等价。
- (b) 把 (F, H, W) 分解为块索引与块内索引，按 $(f_b, h_b, w_b, c, f_i, h_i, w_i)$ 排列后展平。逆操作恢复这些轴并转回 (c, f, h, w) 。空间压缩率 16 时，潜空间 16×16 、块网格 8×8 ，token 数为 $21 \cdot 64 = 1344$ 。真实模型还需核对潜通道、时间边界、块尺寸和具体 VAE 版本；不能仅替换一个压缩数字。
- (c) 时间因果编码的位置 t 只能使用原始时间不晚于 t 的观测。联合去噪可以使用整个带噪视频，因为所有帧均为本次联合生成变量。自回归块可以访问已生成历史和当前块的带噪变量，但不能读取未来块的真实干净帧。测试应分别干预未来原始观测和未来带噪变量，不混淆两种条件。
- (d) 对第 n 个样本， $\sin(2\pi(f + k/\Delta)n\Delta) = \sin(2\pi fn\Delta + 2\pi kn) = \sin(2\pi fn\Delta)$ 。这是采样映射的不可辨识性。增加模型规模可以改变先验或利用额外观测，但不能从这组完全相同的样本唯一恢复两个候选频率。
- (e) 整数位置编码用于验证往返和轴顺序；扰动后续原始帧用于检验编码器因果性。速度按真实时间差计算。全黑帧应返回有效性标记为假；多物体或被截断物体的质心还需独立定义任务对象和可见性规则。

习题5.2

- (a) 一步损失为 $L_1 = (\theta - a)^2 \sigma_x^2$ ，梯度为 $2(\theta - a)\sigma_x^2$ 。末端预测为 $\theta^H x_0$ ，故 $L_H = (\theta^H - a^H)^2 \sigma_x^2$ ，梯度为 $2H\theta^{H-1}(\theta^H - a^H)\sigma_x^2$ 。当 $H > 1, \theta = 0$ 时，末端损失梯度为零，即使预测不正确；多步目标的优化性质与一步目标不同。
- (b) $\hat{x}_2 = \theta^2 x_0$ 。完整梯度为 $(\theta^2 - a^2)x_0 \cdot 2\theta x_0$ ；停止历史梯度后仅保留第二次使用 θ 的贡献，为 $(\theta^2 - a^2)x_0 \cdot \theta x_0$ 。代入得到输出 4、目标 1、损失 $9/2$ ，梯度分别为 12 和 6。
- (c) 若输入为 $z = x_t + \delta$ 且 δ 已知固定，则旧标签为 $a(z - \delta)$ ，真实动力学在新状态上的标签为 az ，相差 $a\delta$ 。若任务明确要求从带噪观测恢复原轨迹，可把前者解释为去噪；若 z 是执行过程中实

际达到的新状态，仍使用旧标签会错配动力学监督。随机偏移时最优回归为 $a\mathbb{E}[x_t | z]$ ，仍需明确观测模型。

- (d) 已知位置的中间状态为 $(1 - \tau)\varepsilon + \tau x^*$ ，速度为 $x^* - \varepsilon$ 。端点 $\tau = 1$ 精确等于 x^* ，而 $\tau < 1$ 通常不等于干净值。可以把干净首帧作为额外条件输入；若它属于联合生成状态，则投影必须与定义的路径相容。
- (e) 单元测试分别固定真实历史、递归历史和停止梯度的缓存值。视频实验的干预对象应明确为输入历史或条件，不同时改变评价轨迹。所有固定测试样本都应保留，避免只选择运动稳定的序列报告。

A.6 多模态自监督学习与预测表征

习题6.1

- (a) 令 $E = ZZ^\top - TT^\top$ ， $E = E^\top$ 。有 $dE = dZ Z^\top + Z dZ^\top$ ，因此

$$dL = \frac{2}{N^2} \text{tr}(E^\top dZ Z^\top) + \frac{2}{N^2} \text{tr}(E^\top Z dZ^\top) = \frac{4}{N^2} \text{tr}((EZ)^\top dZ).$$

故 $\nabla_Z L = 4EZ/N^2$ 。若 $Z_i = F_i/\|F_i\|$ ，再左乘 $[I - Z_i Z_i^\top]/\|F_i\|$ 。

- (b) $(ZO)(ZO)^\top = ZOO^\top Z^\top = ZZ^\top$ 。取 $T = I_2, Z = -I_2$ ，Gram 相同，逐通道平方差和为 8。若原预测为 Zw ，变换特征为 ZO 后需要 $w' = O^\top w$ 才保持预测；固定原探针不变通常会改变输出。
- (c) 在 $Z = 0$ 处 $EZ = 0$ ，梯度为零，但若教师 Gram 非零，损失为正。VICReg 中 $\sqrt{\text{Var}(Z_j) + \epsilon}$ 对样本的导数包含中心化特征；精确常量输入下该导数为零。因此正的方差惩罚能检测该状态，但不保证在精确对称点产生非零更新。实际优化还受初始化、数值扰动和其他目标影响。
- (d) 中心化矩阵 $H = I - \mathbf{1}\mathbf{1}^\top/N$ 的秩为 $N - 1$ ， $C = Z^\top HZ/(N - 1)$ ，故秩不超过 $\min(d, N - 1)$ 。正对角且无非对角项的 d 维协方差满秩，因此必须有 $N \geq d + 1$ 。该条件为必要条件，并不保证训练会得到所需协方差。
- (e) 错配位置测试应只置换学生或教师的一侧；同时一致置换两侧不应改变 Gram 损失。分类探针检验标签可读性，坐标探针检验空间变量可读性；某一探针成功不保证所有下游任务保留了所需状态。

习题6.2

(a) L2 风险为 $.9z^2 + .1(z-10)^2 = (z-1)^2 + 9$, 最优预测为 1, 最小值 9。L1 风险为 $.9|z| + .1|z-10|$; 在 $(0, 10)$ 上导数为 $.8 > 0$, 在 $z < 0$ 上导数为 -1 , 故最优为 0, 最小值 1。中位数满足左右两侧概率均不大于 $1/2$ 。

(b) 由全方差公式,

$$\mathbb{E} \text{Var}(Y | X) = \mathbb{E} \text{Var}(Y | X, C) + \mathbb{E} \text{Var}(\mathbb{E}[Y | X, C] | X).$$

第二项非负; 等号要求新增条件几乎处处不改变条件均值。即使最优均值可以准确预测, $\text{Var}(Y | X) > 0$ 时仍存在不可约逐样本误差。

(c) 忽略初始瞬态后, 滞后 k 的权重为 $(1-m)m^k$, 平均滞后为 $(1-m) \sum_{k \geq 0} km^k = m/(1-m)$ 。每微批次用系数 m_{micro} 时, 一个优化器步的旧教师权重为 m_{micro}^K 。要匹配每步系数 m_{step} , 取 $m_{\text{micro}} = m_{\text{step}}^{1/K}$; 但若微批次间学生参数发生变化, 还需比较中间目标的实际来源。

(d) 四个权重为 $(1/(2\sqrt{2}), 1/2, 1/2, 1/(2\sqrt{2}))$, 和为 $1 + 1/\sqrt{2}$ 。同一样本固定掩码时, 两种归约相差固定倍数; 不同样本的权重和不同, 按位置数归约会改变样本间相对权重, 不能以单一学习率缩放完全抵消。

(e) 匀速且时间差 Δt 已知时, 双帧位置给出 $v = (x_t - x_{t-1})/\Delta t$; 单帧无法区分相同位置的不同速度。若存在加速度, 位置差给出区间平均速度, 恢复瞬时速度还需动力学假设或更多观测。程序需验证教师目标只在前向提供数值, EMA 使用参数更新而不建立反向图。

A.7 策略梯度与近端策略优化

习题7.1

(a) 由 $\delta_{t+l} = r_{t+l} + \gamma V_{t+l+1} - V_{t+l}$, 求和后相邻价值项抵消, 得到 $\sum_{l=0}^{n-1} \gamma^l \delta_{t+l} = G_t^{(n)} - V_t$ 。有限混合权重为 $w_n = (1-\lambda)\lambda^{n-1}$, $1 \leq n < m$, 而 $w_m = \lambda^{m-1}$ 。第 l 个 TD 残差的系数为 $\gamma^l \sum_{n=l+1}^m w_n = (\gamma\lambda)^l$, 因此得到 GAE。

(b) 残差为 $(.86, 1.78, 2.8)$ 。从后向前计算, $A_2 = 2.8$ 、 $A_1 = 1.78 + .72 \cdot 2.8 = 3.796$ 、 $A_0 = .86 + .72 \cdot 3.796 = 3.59312$ 。回归目标为 $(4.09312, 4.196, 3)$ 。 $\lambda = 0$ 时优势等于残差; $\lambda = 1$ 时 $A_0 = 1 + .9 \cdot 2 + .9^2 \cdot 3 - .5 = 4.73$, 其余位置同理。

(c) 第三个残差改为 $3 + .9 \cdot 5 - .2 = 7.3$ 。优势为 $(5.92592, 7.036, 7.3)$, 回归目标为 $(6.42592, 7.436, 7.5)$ 。错误使用重置初态会把第三个残差减少 4.5, 并沿递归把误差传到前面的优势。

- (d) 设 $b_t = 1 - \text{terminated}_t$, $c_t = 1 - \mathbf{1}$ [此转移后轨迹已重置或递归已结束]。则 $\delta_t = r_t + \gamma b_t V(s_{t+1}^{\text{actual}}) - V_t$, $A_t = \delta_t + \gamma \lambda c_t A_{t+1}$ 。外部截断可有 $b_t = 1, c_t = 0$ ；真正终止时二者为零。rollout 切段时保留实际末观测的自举值，递归仅在本次采样片段内执行。
- (e) 显式版本要把所有中间 c 掩码的乘积纳入每个远期残差的系数，不能仅检查最后一步。目标函数可在无梯度上下文中计算，或在输出处统一停止梯度。优势标准化与原始回报目标使用不同张量，避免改变 critic 的监督尺度。

习题7.2

- (a) $J = p$, $\nabla_{\theta} J = p(1-p)$, score 为 $a-p$ 。方差最优基线满足

$$b^* = \frac{\mathbb{E}[r(a-p)^2]}{\mathbb{E}[(a-p)^2]} = \frac{p(1-p)^2}{p(1-p)} = 1-p.$$

$a = 1$ 时估计为 $p(1-p)$ ； $a = 0$ 时也为 $p(1-p)$ 。这里要求 $0 < p < 1$ ；两动作的梯度估计完全一致，所以方差为零。

- (b) 两个概率比为 $2p$ 与 $2(1-p)$ 。代理目标为

$$L(p) = \frac{1}{4} \min(2p, 1.2) - \frac{1}{4} \max(2(1-p), .8) = \begin{cases} p - .5, & p \leq .6, \\ .1, & p \geq .6. \end{cases}$$

下侧裁剪不会在正优势分支形成平坦区，上侧裁剪不会在负优势分支形成平坦区。

- (c) 所有 $p \in [.6, 1)$ 都最大化该代理目标。 $\text{KL}(\pi_0 \| \pi) = -\frac{1}{2} \log[4p(1-p)]$ ，当 $p \uparrow 1$ 时发散。例如 $p = .9$ 时约为 0.510826。因此裁剪目标本身不保证全分布 KL 上界；实际还可使用早停、学习率控制或其他约束。
- (d) 若 $b(a) = a$ ，每个样本的优势均为零，期望梯度为零，未得到真实的 $p(1-p)$ 。状态基线在给定状态下是常数，其贡献为 $b(s) \sum_a \pi(a | s) \nabla \log \pi(a | s) = b(s) \nabla \sum_a \pi(a | s) = 0$ 。动作相关基线不能直接使用这一步。
- (e) 精确枚举提供无 Monte Carlo 误差的参考。采样比较应固定旧数据并停止旧 log-prob 和优势的梯度。有限步优化可能在接近平坦区处停止，也可能受动量等因素影响继续变化；不能把某次优化器的停止位置当作裁剪目标的唯一最优解。

A.8 值函数方法与离线强化学习

习题8.1

- (a) $\varepsilon_1 - \varepsilon_2 \sim \mathcal{N}(0, 2\sigma^2)$ 。标准正态绝对值均值为 $\sqrt{2/\pi}$ ，故 $\mathbb{E}|\varepsilon_1 - \varepsilon_2| = 2\sigma/\sqrt{\pi}$ ，从而 $\mathbb{E}\max_i Q_i = \sigma/\sqrt{\pi}$ 。Jensen 只给出非负下界，精确结果还量化了噪声尺度的影响。
- (b) 条件于在线噪声后，所选 ζ_I 的均值仍为零。因此 $\mathbb{E}\tilde{Q}_I = \rho\mathbb{E}\varepsilon_I = \rho\sigma/\sqrt{\pi}$ 。目标估计与选择误差独立时消除本例的最大值高估；相关性为正时保留部分高估，相关性为负时可产生低估。
- (c) DQN 用目标最大值 6，目标为 $1 + .9 \cdot 6 = 6.4$ 。DDQN 在线选择第二个动作，再读取目标值 2，得到 2.8。真正终止时均只保留奖励 1。外部截断仍应使用实际后继状态自举，不能仅由截断标记清零目标。
- (d) 采样代码在每次试验中生成独立的两动作噪声，再按在线 `argmax gather` 目标估计。目标网络不应接收 critic 回归的梯度。数值实验验证特定噪声模型，真实网络之间的相关性需要另行估计。
- (e) 设真实值为 $q_1 > q_2$ ，独立目标噪声零均值，则 $\mathbb{E}\tilde{Q}_I = \Pr(I=1)q_1 + \Pr(I=2)q_2 = q_1 - \Pr(I=2)(q_1 - q_2)$ 。即使去除了目标噪声的选择高估，错误动作选择仍导致相对于真实最大值的低估。

习题8.2

- (a) 对 $F = \sum_a \pi_a Q_a - \alpha \sum_a \pi_a \log \pi_a + \lambda(\sum_a \pi_a - 1)$ 求导，有 $Q_a - \alpha(\log \pi_a + 1) + \lambda = 0$ 。因此 $\pi_a^* = e^{Q_a/\alpha}/Z$ ， $V^* = \alpha \log Z$ 。代入 $\log \pi_a^* = Q_a/\alpha - \log Z$ 可得 $F(\pi) = V^* - \alpha \text{KL}(\pi \| \pi^*)$ 。连续动作需 $0 < \int e^{Q(a)/\alpha} da < \infty$ 。
- (b) $da/du = d(1 - \tanh^2 u) > 0$ ，故

$$\log \pi(a) = -\frac{1}{2}\varepsilon^2 - \eta - \frac{1}{2} \log(2\pi) - \log d - \log(1 - \tanh^2 u).$$

稳定修正为 $\log(1 - \tanh^2 u) = 2[\log 2 - u - \text{softplus}(-2u)]$ ，避免先计算接近 1 的 $\tanh^2 u$ 再相减。

- (c) 记 $v = \tanh u$ 、 $j = d(1 - v^2)$ 、 $z = e^\eta \varepsilon$ 。沿重参数化路径，高斯项对 μ 的导数为零，对 η 为 -1 ；Jacobian 负对数对 u 的导数为 $2v$ 。因此

$$\partial_\mu L = 2\alpha v + 2(a - a^*)j, \quad \partial_\eta L = \alpha(-1 + 2vz) + 2(a - a^*)jz.$$

这是固定基础噪声的路径导数，不能把高斯密度在固定动作处的 score 直接代入。

- (d) 冻结 critic 权重仍保留 $\partial_a Q = -2(a - a^*)$ ；停止整个 $Q(a)$ 会删除上述 critic 项，只剩熵梯度。若 $a' = ka$ ， $H(a') = H(a) + \log |k|$ 。多维可逆线性变换增加 $\log |\det K|$ ，所以保持同一物理熵约束时应同步调整目标值。

- (e) 有限差分复用同一 ε ，同时固定 critic 参数与温度。检查 actor 更新时 critic 的参数不变化，但动作梯度存在；温度损失应使用停止梯度的策略熵统计。极端 u 的测试还需检查有限值，不能只比较正常范围内的误差。

习题8.3

- (a) $V < 0$ 时两个残差均正，导数为 $\tau[(V-0)+(V-2)] < 0$ ； $V > 2$ 时导数为 $(1-\tau)[V+(V-2)] > 0$ 。区间内目标为 $\frac{1}{2}[(1-\tau)V^2 + \tau(2-V)^2]$ ，导数为 $V - 2\tau$ ，故唯一最优值为 1.6。
- (b) 加权经验质量为 $\frac{1}{2}e^{-V/T}$ 与 $\frac{1}{2}e^{(2-V)/T}$ ，归一化后 $\pi(a_0) = 1/(1+e^{2/T})$ 、 $\pi(a_1) = e^{2/T}/(1+e^{2/T})$ 、 $\pi(a_2) = 0$ 。公共因子 $e^{-V/T}$ 消去。本例只有一个状态；多个状态下不对状态内权重归一化，会改变不同状态对共享参数的相对影响。
- (c) 环境甲令 $r(a_2) = 100$ ，环境乙令 $r(a_2) = -100$ ，其余保持不变。两者对已有数据的似然相同，任何只使用该数据的算法得到同样的信息。数据动作上的回归误差可为零，而对 a_2 的任意估计都无法由这些观测确认；策略在两个真实环境中的价值可能相差很大。
- (d) 正则项为 $\log(1 + e^2 + e^{q_2}) - 1$ ，梯度为 $\text{softmax}(Q) - (1/2, 1/2, 0)$ 。固定前两项后， $\partial_{q_2} L = e^{q_2}/(1 + e^2 + e^{q_2}) > 0$ ，最小化会降低 q_2 ，无正则边界时其下确界在 $q_2 \rightarrow -\infty$ 达到。这反映保守偏好，不能识别两个环境中哪个奖励是真值。
- (e) 数据和随机种子保持相同，差异只放在训练不可见的环境评价阶段。该实验用于验证信息限制与外推风险，不应通过测试奖励反向调节训练目标后仍称为纯离线比较。

A.9 语言模型后训练

习题9.1

- (a) 对 $j \neq i$ ，独立性给出 $\mathbb{E}[R_j g_i] = \mathbb{E}R_j \mathbb{E}g_i = 0$ ；而同一回答项为 $\mathbb{E}[R_i g_i]$ 。因此 $\mathbb{E}[\bar{R}g_i] = G^{-1}\mathbb{E}[R_i g_i]$ ，整个估计的期望为 $(1 - 1/G)\nabla J$ 。使用 $b_i = (G - 1)^{-1} \sum_{j \neq i} R_j$ 时， b_i 与当前回答独立，基线贡献为零。要求 $G > 1$ 。
- (b) 两奖励不同时，总体标准差为 $c/2$ ，优势为 $(1, -1)$ ；梯度平均为 $[(1-p) + p]/2 = 1/2$ 。两奖励不同的概率为 $2p(1-p)$ ，故期望为 $p(1-p)$ 。真实奖励梯度为 $cp(1-p)$ 。标准化消去了正奖励尺度，因此不同提示的奖励尺度变化会改变它们在整个训练中的相对权重。
- (c) 完整比率为 $R = \prod_t r_t = \exp(\sum_t \log r_t)$ ，GSPO 比率为 $s = \exp(L^{-1} \sum_t \log r_t) = R^{1/L}$ 。旧概率固定时， $\nabla s = (s/L) \sum_t \nabla \log \pi_\theta(y_t | y_{<t}, x)$ 。所有 token 比率为 2 时，长度 2 和 4 的完整比率为 4 和 16，GSPO 比率均为 2。长度归一化比率一般不满足完整序列的重要性换测度恒等式。

- (d) 因 $\mathbb{E}_{a \sim \pi} \pi_{\text{ref}}(a)/\pi(a) = 1$, $\mathbb{E}K_3 = \text{KL}(\pi \parallel \pi_{\text{ref}})$ 。固定样本反向给出 $(1 - \pi_{\text{ref}}/\pi)\nabla \log \pi$, 其期望为 $p - 1/2$ 。精确 KL 导数为 $p(1-p) \log[p/(1-p)]$ 。 $p = .8$ 时分别为 .3 与 $.16 \log 4 \approx .221807$ 。差别来自采样分布随参数变化的 score 项; 估计值无偏不自动保证直接反向得到无偏梯度。
- (e) 有限状态枚举应同时计算目标值和期望梯度, 不能只检查损失均值。标准差使用总体还是样本定义必须固定; $G = 1$ 不支持 leave-one-out, 同奖励组的除零规则须显式规定。回答掩码仅选择回答及约定 EOS, 不能把 prompt 长度纳入序列归一化。

习题9.2

- (a) 求解 $\sum_y \pi_y r_y - \beta \sum_y \pi_y \log(\pi_y/\pi_{\text{ref},y})$, 驻点满足 $r_y - \beta[\log(\pi_y/\pi_{\text{ref},y}) + 1] + \lambda = 0$ 。归一化后 $\pi_y \propto \pi_{\text{ref},y} e^{r_y/\beta}$, 所以 $r_y = \beta \log(\pi_y/\pi_{\text{ref},y}) + \beta \log Z$ 。奖励差消去 Z , 本题间隔为 $\delta = \beta \log[p/(1-p)]$ 。
- (b) $L(\delta) = -q \log \text{sigmoid}(\delta) - (1-q) \log \text{sigmoid}(-\delta)$, $L' = \text{sigmoid}(\delta) - q$, $L'' = \text{sigmoid}(\delta)(1 - \text{sigmoid}(\delta)) > 0$ 。故 $\delta^* = \log[q/(1-q)]$, $p^* = \text{sigmoid}(\beta^{-1} \log[q/(1-q)])$ 。 $q = .8$ 时三个结果为 $16/17, .8, 2/3$ 。在此模型中, 较大的 β 使策略更接近参考分布。
- (c) $q = 1$ 时 $L = -\log \text{sigmoid}(\delta)$ 严格递减, 下确界只在 $\delta \rightarrow \infty$ 取得。训练偏好分类正确只要求间隔为正, 仍存在继续增大间隔的梯度。有限数据的标签一致性也不等同于独立任务正确率, 需要额外评价与正则化控制。
- (d) 序列对数比分别为 $\log 2, \log 4$, 第二个更大; 按长度平均后变为 $\log 2, \log 4/4 = \log 2/2$, 第一个更大。生成序列的概率为条件 token 概率乘积, 所以其对数为求和。改为平均会引入长度相关变换, 不能当作同一 DPO 目标的数值实现细节。
- (e) 使用一个可直接参数化两个序列概率的模型检验解析最优值, 再测试实际 token gather。参考概率固定且回答序列相同。EOS 规则与截断规则需一致; 若长回答被截断, 评价的是截断后的序列概率, 不能沿用原完整回答的概率解释。

A.10 世界模型与模型预测控制

习题10.1

- (a) 设计矩阵每行为 $(s_t, u_t) = (s_t, s_t)$, 秩至多为 1, 只能辨识 $a + b$ 。例如 $(a, b) = (1, 1)$ 与 $(2, 0)$ 均给出 $s' = 2s$ 。目标 $\|y - X\theta\|^2 + \lambda\|\theta\|^2$ 的一阶条件为 $(X^\top X + \lambda I)\theta = X^\top y$; $\lambda > 0$ 时解唯一。它按先验偏好选择参数, 无法确定两组候选中哪组是真实系统。
- (b) 代入状态后, 一阶条件为 $(2 + \rho)u_0 + u_1 = 2$, $u_0 + (1 + \rho)u_1 = 1$ 。行列式为 $1 + 3\rho + \rho^2 > 0$, 因此

$$u_0^* = \frac{1 + 2\rho}{1 + 3\rho + \rho^2}, \quad u_1^* = \frac{\rho}{1 + 3\rho + \rho^2}.$$

$\rho = .1$ 时为 $(120/131, 10/131)$ 。MPC 执行首个动作，取得实际新观测后重新求解，不默认第二个预测动作仍是新问题的最优动作。

- (c) 对同一动作序列，加入并减去 $f(\hat{s}_t, u_t)$ ，得到 $e_{t+1} \leq \epsilon + L e_t$ 。 $e_0 = 0$ 时， $e_H \leq \epsilon \sum_{j=0}^{H-1} L^j$ 。 $L \neq 1$ 时为 $\epsilon(L^H - 1)/(L - 1)$ ； $L = 1$ 时为 $H\epsilon$ 。收缩系统有统一上界 $\epsilon/(1 - L)$ ，其余情况可随域线性或指数增长。
- (d) 若每步奖励误差满足 $|\hat{r}_t - r_t| \leq \epsilon_r + L_r(e_t + e_{t+1})$ ，终端项满足 $|\hat{V}_H - V_H| \leq \epsilon_V + L_V e_H$ ，则按折扣加总即得回报界。记真实最佳候选为 U^* 、模型最佳为 $\hat{U}$ ，

$$J(U^*) - J(\hat{U}) = [J(U^*) - \hat{J}(U^*)] + [\hat{J}(U^*) - \hat{J}(\hat{U})] + [\hat{J}(\hat{U}) - J(\hat{U})] \leq 2\delta.$$

中间项非正，且界只针对共同候选集。

- (e) 数据充分时要检查设计矩阵的最小奇异值或条件数，不能仅按样本数判断可辨识性。模型误差界要求覆盖规划实际使用的状态动作范围；一旦规划离开数据覆盖区，原有数值界可能不适用。真实动力学 MPC 提供在相同候选预算下的参考。

习题10.2

- (a) 状态 $(x, 1)$ 与 $(x, -1)$ 的当前观测相同，下一位置为 $x \pm \Delta$ 。由 $x_t - x_{t-1} = v_{t-1}\Delta$ ，得到 $v_t = (x_t - x_{t-1})/\Delta + u_{t-1}\Delta$ 。该式假设 Δ 已知、位置测量精确、动力学形式正确且动作时序与方程一致；噪声观测下应估计条件分布。
- (b) 指数中的二次型为 $(v - m_-)^2/P_- + (d - v)^2/R$ 。收集系数得后验精度 $P^{-1} = P_-^{-1} + R^{-1}$ ，均值 $m = P(m_-/P_- + d/R)$ 。 $R \rightarrow 0$ 时 $P \rightarrow 0, m \rightarrow d$ ； $R \rightarrow \infty$ 时 $P \rightarrow P_-, m \rightarrow m_-$ 。测量可靠性通过精度加权进入更新。
- (c) $\log p(d) = \log \mathbb{E}_q[p(d, v)/q(v | d)] \geq \mathbb{E}_q \log p(d | v) - \text{KL}(q \| p_-)$ 。若 $q = \mathcal{N}(m, P)$ ，先验 KL 为 $\frac{1}{2}[\log(P_-/P) + (P + (m - m_-)^2)/P_- - 1]$ 。训练后验条件于当前真实观测；想象先验仅条件于已有潜状态与动作。加入真实未来观测会改变预测任务和部署可用信息。
- (d) 独立指定 $g = 1$ 时成功率为 $1/2$ 。重标记后，给定任一出现的 g ，都有 $s' = g$ ，成功率为 1 。重标记使 $p(s' | g)$ 变成依赖选择事件的分布；原任务的独立目标没有这种条件关系。因此不能直接把重标记条件频率解释为原任务中的转移成功率。
- (e) 高斯后验可与枚举网格上的归一化密度作额外参考。HER 测试检查原状态、动作和后继状态完全不变，只改变目标相关字段。随机反例用于说明方法的条件限制，不应通过删除失败后继来获得表面上完美的目标策略。

A.11 生成式策略与视觉语言动作模型

习题11.1

- (a) 条件均值为零向量，风险 $\mathbb{E}\|A - \hat{A}\|^2 = H + \|\hat{A}\|^2$ ，最小值为 H 。零动作不满足执行条件。平方回归最小化平均距离，而环境要求动作落在有效集合；该集合可为非凸集。
- (b) 若 $\tilde{v} = d\tilde{A}/d\tau$ ，则 $v = D\tilde{v}$ 。物理平方误差为 $(\hat{A} - \tilde{A})^\top D^2(\hat{A} - \tilde{A})$ 。密度满足 $\log p_A(A) = \log p_{\hat{A}}(D^{-1}(A - \mu)) - \log |\det D|$ 。多时间位置重复同一动作维度尺度时，修正为 $-H \sum_j \log d_j$ 。
- (c) 常量序列的 DCT 仅有 DC 系数，分别为 $\pm\sqrt{H}$ 。设完整系数为 c ，保留量化后的前 K 项 $\hat{c}_k$ 。正交性给出

$$\|A - \hat{A}\|^2 = \sum_{k \geq K} c_k^2 + \sum_{k < K} (c_k - \hat{c}_k)^2 \leq \sum_{k \geq K} c_k^2 + K\delta^2/4.$$

界使用最近邻量化且无额外饱和误差。压缩保留 DC 模式，并不消除正负动作的多模态性。

- (d) 前缀至少为 $\lceil 50 \cdot .070 \rceil = 4$ 步，尚有 8 步可调整。设前缀掩码为 M 、已提交动作为 A^* ，中间状态应投影为 $M[(1 - \tau)\varepsilon + \tau A^*] + (1 - M)A_\tau$ 。 $\tau = 1$ 时前缀精确匹配。260 ms 对应 13 步，超过块长；该块不能为整段延迟提供新的动作覆盖，需要改变执行队列或推理配置。
- (e) 有效长度掩码排除轨迹结束后不存在的动作，不把缺失位置解释为零动作。执行测试应固定观测与动作时间戳，保证已提交前缀不可被迟到结果覆盖。分布实验和延迟测量分别记录，CPU 函数测试不能替代真实控制延迟实验。

习题11.2

- (a) $Q(a) = 1, Q(b) = 1.2$ ，数据价值为 1.1。正标签的联合质量为 $.5 \cdot 1 = .5$ 与 $.5 \cdot .2 = .1$ ，归一化后动作概率为 $(5/6, 1/6)$ 。新价值为 $5/6 + 1.2/6 = 31/30 \approx 1.0333$ ，低于 1.1。条件选择偏好较高的非零概率，未直接优化奖励期望。
- (b) 奖励改为 4 后， $Q(b) = .8$ ，数据价值为 .9，正标签概率不变，新价值为 $5/6 + .8/6 = 29/30 \approx .9667$ ，这次提高。真实优势以数据价值为基线：原例仅 b 的优势为正，后一例仅 a 为正。若能准确识别期望优势并只在数据支持内选择正优势动作，固定状态下有改进；多步任务还需考虑状态分布变化与估计误差。
- (c) $p_D(A | h, I = 1) = p_D(A | h) \Pr(I = 1 | A, h) / \Pr(I = 1 | h)$ ，要求分母非零。采样标签还受回报方差、有限时域自举误差、价值模型误差和阈值设置影响。RECAP 使用经验优势条件组织策略学习；将标签符号解释为真实策略改进，需要额外验证这些条件。
- (d) 编码器只接收离散监督的梯度；连续专家参数接收流匹配梯度，离散头参数接收交叉熵梯度。停止 h 的动作分支梯度不等同于冻结编码器的全部学习。若动作专家读取部署时尚不存在的目标 FAST token，会形成训练信息泄漏；必须在注意力支持中排除这条依赖。

- (e) 程序应精确恢复两组解析价值，而非用有限样本结果判定理论方向。双头测试单独反向每个目标，检查参数梯度集合。条件丢弃后应能使用实际部署可提供的输入，不能由隐藏目标字段补全缺失条件。

A.12 高效训练、长上下文与推理系统

习题12.1

- (a) 令 $m' = \max(m_1, m_2)$ 。两个旧尺度转换到共同尺度后，

$$\ell' = e^{m_1-m'} \ell_1 + e^{m_2-m'} \ell_2, \quad z' = e^{m_1-m'} z_1 + e^{m_2-m'} z_2.$$

展开每项即为所有分数在 m' 下的指数和，输出 $o = z'/\ell'$ 。实数运算下合并次序不影响结果，浮点舍入可能产生微小差异。

- (b) 完整输出为 $(2+3 \cdot 6)/4 = 5$ 。共同最大值为 $\log 3$ ，合并分母为 $1/3+1 = 4/3$ 、分子为 $2/3+6 = 20/3$ ，仍得到 5。全掩码块应视为零质量，不参与合并；全掩码行没有归一化分布，应按接口拒绝或返回明确无效标记。

- (c) $\partial p_i / \partial s_j = p_i(\mathbf{1}[i=j] - p_j)$ ，因此

$$\frac{\partial L}{\partial s_j} = \sum_i g^\top v_i p_i(\mathbf{1}[i=j] - p_j) = p_j g^\top v_j - p_j g^\top \sum_i p_i v_i.$$

行 log-sum-exp 与重算分数可恢复 p_j ；保存输出 o 后可计算归约项。注意力支持也必须在重计算中保持一致。

- (d) 设进程数为 R ，全局有效计数为 $N = \sum_r N_r > 0$ 。进程 r 的局部目标取 RS_r/N 。梯度平均归约后为

$$\frac{1}{R} \sum_r \nabla \left(\frac{RS_r}{N} \right) = \frac{1}{N} \sum_r \nabla S_r = \nabla \left(\frac{\sum_r S_r}{N} \right).$$

局部空进程贡献零梯度，但仍参与所需通信，不计算 S_r/N_r 。全局计数为零时统一跳过优化器更新，避免各进程控制流不一致。

- (e) 梯度累积参考应在同一全局有效计数下计算，并只执行一次优化器更新。随机 dropout 会使不同分块使用不同随机掩码，需要固定或单独控制。CPU 数值一致性支持算子正确性；GPU 加速需要实际预热、同步和硬件测量。

习题12.2

- (a) 被接受且输出 x 的质量为 $q(x)\alpha(x) = \min(p(x), q(x))$, 本题为 $(.2, .3, .1)$, 总和.6。剩余质量为 $(.4, 0, 0)$, 拒绝后残差分布为 $(1, 0, 0)$ 。最终质量为 $(.2, .3, .1) + .4(1, 0, 0) = p$ 。接受概率依次为 $(1, .6, 1/3)$ 。
- (b) $\sum_x \min(p_x, q_x) = \frac{1}{2} \sum_x (p_x + q_x - |p_x - q_x|) = 1 - \frac{1}{2} \|p - q\|_1$ 。若 $p = q$, 全部接受, 不调用零质量残差分布。 $q(x) = 0$ 的位置不会由草稿采到, 但可能通过残差产生。支持不重叠时全部拒绝, 残差即为 p 。
- (c) 每个位置应用的是给定当前正确前缀的单步概率恒等式, 因此可通过条件概率链归纳恢复目标联合分布。拒绝后, 后续草稿基于已被替换的前缀, 不再具有原验证条件; 应丢弃其 token 和对应缓存, 再从新前缀继续。遇到有效 EOS 后结束序列, 不额外输出额外 token 或继续处理已结束位置。
- (d) 每轮至少输出一个 token; 输出数超过 j 的概率为前 j 个草稿均接受, 即 a^j 。所以 $\mathbb{E}M = \sum_{j=0}^K a^j$, $a \neq 1$ 时为 $(1 - a^{K+1})/(1 - a)$, $a = 1$ 时为 $K + 1$ 。理想加速比为 $C_T \mathbb{E}M / (C_T + K C_D)$ 。它假设验证成本固定、无额外调度和缓存开销, 实际接受概率还依赖前缀, 因此只能用作成本分析的基准。
- (e) 用于接受比和残差的 p, q 必须是实际应用温度及支持截断后的归一化分布。两步测试用不同首 token 对应不同第二步目标分布, 能暴露错误复用被拒绝前缀概率的实现。随机频率测试需同时保留解析分布参考。

A.13 实验设计与实现规范

习题13.1

- (a) 联合计数为初始正确且最终正确 48、正确变错误 12、错误变正确 12、始终错误 28。初始和最终均为.6, 纠错率为 $12/40 = .3$, 改错率为 $12/60 = .2$ 。全概率展开给出 $p' = p(1 - r) + (1 - p)q$ 。应报告完整转移表, 不能由相同总体均值断言没有发生变化。
- (b) $\bar{D} = 0$, 经验二阶矩为 $(12 + 12)/100 = .24$, plug-in 标准误差为 $\sqrt{.24/100} \approx .04899$ 。采用无偏样本方差则为 $\sqrt{(.24 \cdot 100/99)/100} \approx .04924$ 。若误当独立二项均值, 会得到 $\sqrt{2 \cdot .6 \cdot .4/100} \approx .06928$ 。应按问题 ID 配对重采样。
- (c) 由 $.7 = .9p + .2(1 - p) = .7p + .2$, 得到 $p = 5/7 \approx .714286$ 。需要验证敏感度与特异度在测试总体上的稳定性, 并计入它们自身的估计误差。若答案风格或任务分布改变条件误差率, 原校准公式不能直接外推。

- (d) $\text{pass}@2$ 为 $1 - \binom{3}{2}/\binom{5}{2} = 1 - 3/10 = .7$ ，随机选一个的正确概率为 $2/5 = .4$ 。前者依赖候选集合中存在正确答案；实际提交还取决于选择器。需要另行测量选择器以及候选生成的完整计算成本。
- (e) Wilson 的零成功上界为 $z^2/(n + z^2)$ ， $n = 10, z = 1.96$ 时约为 .277533。 $k > n$ 无法由给定样本形成所需子集，应拒绝。预算比较应计入反馈或选择器调用、生成 token 和重试，并保留初始答案，防止只对选择后的样本计算指标。

习题13.2

- (a) 交集有 2 个元素、并集有 4 个，相似度为 $1/2$ 。随机排列中最先出现的并集元素等概率为四者之一；仅当其属于交集时最小元素相同，概率为 $1/2$ 。候选概率为 $1 - (1 - (1/2)^2)^2 = 7/16$ 。签名独立是该乘积计算的条件。
- (b) $J(A, B) = J(B, C) = 2/3 > .6$ ， $J(A, C) = 1/3 < .6$ 。因此相似边形成一个连通分量，但不是所有成员两两相似。同集合划分阻止相似链跨训练与测试，仍可保留所有样本；只保留一条则进一步减少数据和可能独有的信息，需要单独评价该过滤规则。
- (c) $\text{Var}(\bar{X}) = n^{-2}[n\sigma^2 + n(n-1)\rho\sigma^2] = \sigma^2[1 + (n-1)\rho]/n$ 。帧平均按轨迹长度加权，目标为按帧抽样的总体；轨迹均值平均按轨迹等权，目标不同。独立场景泛化应在场景层级定义抽样与不确定性。
- (d) 除模型和优化器外，保存调度器、随机数状态、数据位置或采样器状态、增强状态、当前累积梯度与累积计数。若有 EMA 或回放，也保存其参数和采样状态。恢复测试比较下一批输入、损失、梯度及更新后参数；中途 checkpoint 不能丢弃尚未执行的累积梯度。
- (e) 状态先记录为“原因未查明”。可设置等样本量的随机删除对照、匹配任务类别比例的过滤对照，以及人工审查标签一致性的固定子集。阈值在训练和验证数据上选择，最终测试集不参与选择。每次只改变明确因素；观察到某一干预效果后，结论仍限制在该干预和数据范围内。

附录 B 核心函数参考实现

本附录给出各目标函数的张量实现。函数覆盖梯度与数值计算；完整实验还需要模型、环境、数据加载、采样、优化器和评估循环。代码使用 PyTorch，输入的形状与边界约定应与正文一致。

B.1 策略梯度与动作价值目标

`compute_gae` 接收每次转移的实际后继价值。外部截断后，`next_value` 应由截断时的最终观测计算。函数将优势与回报目标置于停止梯度状态。PPO、Double DQN 与 expectile 分别对应式(7.31)、(8.4)与(8.21)。

```
"""Teaching kernels. Shapes are explicit; no environment wrapper is hidden."""
import torch
from torch import Tensor

def same_shape(*xs: Tensor) -> None:
    if not xs or any(x.shape != xs[0].shape for x in xs):
        raise ValueError("All tensors must have the same shape.")

@torch.no_grad()
def compute_gae(reward: Tensor, value: Tensor, next_value: Tensor,
                terminated: Tensor, truncated: Tensor,
                gamma: float = 0.99, lam: float = 0.95):
    """All arrays [T, B]. next_value uses the actual final observation.

    At a rollout buffer boundary, bootstrap is allowed but the trace ends.
    At an external truncation, bootstrap is allowed but the trace resets.
    """
    same_shape(reward, value, next_value, terminated, truncated)
    if reward.ndim != 2 or reward.shape[0] == 0:
        raise ValueError("Expected nonempty [T, B].")
    if terminated.dtype != torch.bool or truncated.dtype != torch.bool:
        raise TypeError("Boundary flags must be bool.")
    if not (0 <= gamma <= 1 and 0 <= lam <= 1):
        raise ValueError("gamma and lambda must be in [0, 1].")
    boot = (~terminated).to(value.dtype)
    trace = (~(terminated | truncated)).to(value.dtype)
    delta = reward + gamma * boot * next_value - value
    advantage = torch.empty_like(value)
    carry = torch.zeros_like(value[0])
    for t in reversed(range(reward.shape[0])):
        carry = delta[t] + gamma * lam * trace[t] * carry
```

```

        advantage[t] = carry
    return advantage, advantage + value

def ppo_policy_loss(logp: Tensor, old_logp: Tensor,
                    advantage: Tensor, eps: float = 0.2) -> Tensor:
    same_shape(logp, old_logp, advantage)
    if not 0 < eps < 1:
        raise ValueError("Expected 0 < eps < 1.")
    ratio = (logp - old_logp.detach()).exp()
    adv = advantage.detach()
    unclipped = ratio * adv
    clipped = ratio.clamp(1 - eps, 1 + eps) * adv
    return -torch.minimum(unclipped, clipped).mean()

@torch.no_grad()
def double_dqn_target(reward: Tensor, terminated: Tensor,
                     online_next_q: Tensor, target_next_q: Tensor,
                     gamma: float = 0.99) -> Tensor:
    same_shape(online_next_q, target_next_q)
    if online_next_q.ndim != 2:
        raise ValueError("Q arrays must be [B, A].")
    if reward.shape != online_next_q.shape[:1]:
        raise ValueError("reward must be [B], not [B, 1].")
    same_shape(reward, terminated)
    if terminated.dtype != torch.bool:
        raise TypeError("terminated must be bool.")
    index = online_next_q.argmax(dim=-1, keepdim=True)
    selected = target_next_q.gather(-1, index).squeeze(-1)
    return reward + gamma * (~terminated).to(reward.dtype) * selected

def expectile_loss(error: Tensor, tau: float = 0.7) -> Tensor:
    """For IQL: error = target_Q.detach() - V(s)."""
    if not 0 < tau < 1:
        raise ValueError("Expected 0 < tau < 1.")
    weight = torch.where(error >= 0, tau, 1 - tau)
    return (weight * error.square()).mean()

```

B.2 SAC 的概率密度与参数更新

`frozen_parameters` 只暂时关闭 critic 参数的梯度需求，保留损失对动作输入的导数。实现中的 `tanh` 高斯策略输出归一化动作；环境动作缩放对应的密度修正应按式(8.15)补充。

```

"""Continuous actions normalized to (-1, 1)."""
from contextlib import contextmanager
import math
import torch

```



```

import torch.nn.functional as F
from torch import Tensor, nn
from rl_core import same_shape

@contextmanager
def frozen_parameters(*modules: nn.Module):
    """Freeze weights, but retain derivatives with respect to inputs."""
    params = list({id(p): p for m in modules for p in m.parameters()}.values())
    flags = [p.requires_grad for p in params]
    try:
        for p in params:
            p.requires_grad_(False)
        yield
    finally:
        for p, flag in zip(params, flags):
            p.requires_grad_(flag)

def tanh_normal_sample(mean: Tensor, log_std: Tensor):
    """Inputs [B, A]. Returns action [B, A], logp [B]."""
    same_shape(mean, log_std)
    if mean.ndim != 2:
        raise ValueError("Expected [B, A].")
    # This clamp is a stated modeling choice, not a universal constant.
    dist = torch.distributions.Normal(mean, log_std.clamp(-10, 2).exp())
    u = dist.rsample()
    action = u.tanh()
    log_jac = 2 * (math.log(2.0) - u - F.softplus(-2 * u))
    logp = (dist.log_prob(u) - log_jac).sum(dim=-1)
    return action, logp

@torch.no_grad()
def sac_target(reward: Tensor, terminated: Tensor, next_logp: Tensor,
               next_q1: Tensor, next_q2: Tensor, alpha: Tensor,
               gamma: float = 0.99) -> Tensor:
    same_shape(reward, terminated, next_logp, next_q1, next_q2)
    if reward.ndim != 1 or terminated.dtype != torch.bool:
        raise ValueError("Use [B] values and bool terminated.")
    soft_q = torch.minimum(next_q1, next_q2) - alpha * next_logp
    return reward + gamma * (~terminated).to(reward.dtype) * soft_q

def sac_critic_loss(q1: Tensor, q2: Tensor, target: Tensor) -> Tensor:
    same_shape(q1, q2, target)
    y = target.detach()
    return 0.5 * ((q1 - y).square().mean() + (q2 - y).square().mean())

def sac_actor_loss(actor: nn.Module, q1: nn.Module, q2: nn.Module,
                    state: Tensor, alpha: Tensor):
    """actor(s)->(mean,log_std); critics(s,a)->[B]."""
    mean, log_std = actor(state)

```

```

    action, logp = tanh_normal_sample(mean, log_std)
    with frozen_parameters(q1, q2):
        v1, v2 = q1(state, action), q2(state, action)
        same_shape(logp, v1, v2)
        loss = (alpha.detach() * logp - torch.minimum(v1, v2)).mean()
    return loss, logp.detach()

def temperature_loss(log_alpha: Tensor, logp: Tensor,
                    target_entropy: float) -> Tensor:
    """Exact exp(log_alpha) version; gradient is scaled by alpha."""
    return -(log_alpha.exp() * (logp.detach() + target_entropy)).mean()

@torch.no_grad()
def polyak_update(source: nn.Module, target: nn.Module, rate: float):
    """target <- (1-rate)*target + rate*source; parameters only."""
    if not 0 <= rate <= 1:
        raise ValueError("rate must be in [0, 1].")
    src, dst = list(source.parameters()), list(target.parameters())
    if len(src) != len(dst) or any(a.shape != b.shape for a, b in zip(src, dst)):
        raise ValueError("Network parameter structures differ.")
    for a, b in zip(src, dst):
        b.lerp_(a, rate)

```

B.3 生成目标、数值积分与视频分块

`q_sample` 使用数据端到噪声端的 DDPM 约定；`linear_bridge` 和 `integrate` 使用噪声端到数据端的流匹配约定；`integrate` 的 `method` 参数可取 `euler` 或 `heun`。调用者需按目标提供时间系数。视频分块函数显式实现轴置换及逆变换。

```

"""No pretrained weights required. Flow time: noise=0, data=1."""
import torch
from torch import Tensor
from rl_core import same_shape

def batch_scalar(t: Tensor, x: Tensor) -> Tensor:
    if t.shape != x.shape[:1]:
        raise ValueError("t must be [B].")
    return t.reshape(t.shape[0], *([1] * (x.ndim - 1)))

def q_sample(x: Tensor, alpha_bar: Tensor, noise: Tensor) -> Tensor:
    same_shape(x, noise)
    if torch.any((alpha_bar < 0) | (alpha_bar > 1)):
        raise ValueError("alpha_bar must be in [0, 1].")
    a = batch_scalar(alpha_bar, x)
    return a.sqrt() * x + (1 - a).sqrt() * noise

```

```

def diagonal_normal_kl(mean: Tensor, logvar: Tensor) -> Tensor:
    """KL(q || N(0,I)), sum latent axes, mean batch."""
    same_shape(mean, logvar)
    if mean.ndim < 2:
        raise ValueError("Expected batch plus latent axes.")
    terms = 0.5 * (mean.square() + logvar.exp() - 1 - logvar)
    return terms.flatten(1).sum(1).mean()

def linear_bridge(noise: Tensor, data: Tensor, t: Tensor):
    same_shape(noise, data)
    weight = batch_scalar(t, data)
    return (1 - weight) * noise + weight * data, data - noise

def flow_matching_loss(model, data: Tensor, noise: Tensor,
                       t: Tensor, condition=None) -> Tensor:
    mixed, target = linear_bridge(noise, data, t)
    pred = model(mixed, t, condition)
    same_shape(pred, target)
    return (pred - target.detach()).square().mean()

@torch.no_grad()
def integrate(field, x: Tensor, steps: int, method: str = "heun"):
    """field(x, scalar_time); uniform grid from 0 to 1."""
    if steps < 1 or method not in {"euler", "heun"}:
        raise ValueError("Invalid solver settings.")
    h = 1.0 / steps
    for k in range(steps):
        t = k * h
        v = field(x, t)
        same_shape(x, v)
        proposal = x + h * v
        if method == "heun":
            v_next = field(proposal, (k + 1) * h)
            same_shape(x, v_next)
            x = x + 0.5 * h * (v + v_next)
        else:
            x = proposal
    return x

def video_patchify(x: Tensor, patch=(1, 4, 4)) -> Tensor:
    if x.ndim != 5:
        raise ValueError("Expected [B,C,F,H,W].")
    b, c, f, h, w = x.shape
    pf, ph, pw = patch
    if min(patch) < 1 or f % pf or h % ph or w % pw:
        raise ValueError("Patch dimensions must divide the video.")
    x = x.reshape(b, c, f // pf, pf, h // ph, ph, w // pw, pw)
    return x.permute(0, 2, 4, 6, 1, 3, 5, 7).reshape(b, -1, c * pf * ph * pw)

```

```
def video_unpatchify(tokens: Tensor, shape, patch=(1, 4, 4)) -> Tensor:
    b, c, f, h, w = shape
    pf, ph, pw = patch
    if min(patch) < 1:
        raise ValueError("Patch sizes must be positive.")
    expected = (b, (f // pf) * (h // ph) * (w // pw), c * pf * ph * pw)
    if min(patch) < 1 or f % pf or h % ph or w % pw or tokens.shape != expected:
        raise ValueError("Invalid patch grid or token shape.")
    x = tokens.reshape(b, f // pf, h // ph, w // pw, c, pf, ph, pw)
    return x.permute(0, 4, 1, 5, 2, 6, 3, 7).reshape(shape)
```

B.4 语言后训练与模型预测控制

序列概率函数执行一次下一 token 移位。grpo_loss 采用每回答平均，dpo_loss 接收回答对数概率之和。exact_token_kl 在固定前缀上计算当前策略相对参考策略的词表 KL。

```
"""Inputs contain prompt+response; mask marks response tokens, including EOS."""
import torch
import torch.nn.functional as F
from torch import Tensor
from rl_core import same_shape

def token_logp(logits: Tensor, ids: Tensor) -> Tensor:
    if logits.ndim != 3 or logits.shape[:2] != ids.shape or ids.shape[1] < 2:
        raise ValueError("Expected logits [B,L,V], ids [B,L], L>=2.")
    if ids.dtype != torch.long:
        raise TypeError("ids must be int64 with valid vocabulary IDs.")
    log_dist = F.log_softmax(logits[:, :-1].float(), dim=-1)
    return log_dist.gather(-1, ids[:, 1:, None]).squeeze(-1)

def masked_sequence_sum(values: Tensor, shifted_mask: Tensor) -> Tensor:
    same_shape(values, shifted_mask)
    if shifted_mask.dtype != torch.bool or values.ndim != 2:
        raise ValueError("Use [B,L-1] values and bool mask.")
    return values.masked_fill(~shifted_mask, 0).sum(-1)

def group_advantage(rewards: Tensor, eps: float = 1e-8) -> Tensor:
    """rewards [num_prompts, group_size]; all-equal group -> zeros."""
    if rewards.ndim != 2 or min(rewards.shape) < 1 or eps <= 0:
        raise ValueError("Expected nonempty [P,G] and eps>0.")
    r = rewards.detach().float()
    centered = r - r.mean(-1, keepdim=True)
    std = centered.square().mean(-1, keepdim=True).sqrt()
    return centered / (std + eps)
```

```

def exact_token_kl(logits: Tensor, ref_logits: Tensor) -> Tensor:
    """KL(current||reference) at fixed prefixes; output [...]."""
    same_shape(logits, ref_logits)
    lp = F.log_softmax(logits.float(), -1)
    ref_lp = F.log_softmax(ref_logits.detach().float(), -1)
    return (lp.exp() * (lp - ref_lp)).sum(-1)

def grpo_loss(logp: Tensor, old_logp: Tensor, advantage: Tensor,
              mask: Tensor, eps: float = 0.2, beta: float = 0.0,
              token_kl: Tensor | None = None) -> Tensor:
    """[B,L] logp/mask, [B] advantages; per-response normalization."""
    same_shape(logp, old_logp, mask)
    if logp.ndim != 2 or advantage.shape != logp.shape[:1]:
        raise ValueError("Invalid logp or advantage shapes.")
    if mask.dtype != torch.bool or torch.any(mask.sum(-1) == 0):
        raise ValueError("Each response must have a nonempty bool mask.")
    if not 0 < eps < 1 or beta < 0:
        raise ValueError("Invalid clipping or KL coefficient.")
    ratio = (logp - old_logp.detach()).exp()
    adv = advantage.detach()[:, None]
    surrogate = torch.minimum(ratio * adv, ratio.clamp(1-eps, 1+eps) * adv)
    loss = -surrogate
    if beta:
        if token_kl is None:
            raise ValueError("Supply an explicit KL term when beta>0.")
        same_shape(logp, token_kl)
        loss = loss + beta * token_kl
    per_response = loss.masked_fill(~mask, 0).sum(-1) / mask.sum(-1)
    return per_response.mean()

def dpo_loss(chosen: Tensor, rejected: Tensor, ref_chosen: Tensor,
             ref_rejected: Tensor, beta: float = 0.1) -> Tensor:
    """Arguments are response log-prob SUMS, all [B]."""
    same_shape(chosen, rejected, ref_chosen, ref_rejected)
    if chosen.ndim != 1 or beta <= 0:
        raise ValueError("Expected [B] sequence log-probs and beta>0.")
    margin = chosen - rejected - (ref_chosen - ref_rejected).detach()
    return -F.logsigmoid(beta * margin).mean()

```

随机采样 MPC 接收预先生成的候选动作，按模型回报选择首个动作。给定实现用于固定预测长度；环境终止与终端价值应依据任务加入 rollout。

```

"""Random-shooting MPC. No online fitting or environment stepping is hidden."""
import torch
from torch import Tensor

@torch.no_grad()
def choose_action(dynamics, reward_fn, state: Tensor,

```

```

        candidates: Tensor, gamma: float = 1.0):
    """state [S], candidates [N,H,A]; reward_fn(s,a,next_s)->[N].

    Returns (first_action [A], predicted_score scalar, candidate_index).
    The caller executes ONE real step and calls this function again.
    """
    if state.ndim != 1 or candidates.ndim != 3 or min(candidates.shape) < 1:
        raise ValueError("Expected state [S], nonempty candidates [N,H,A].")
    if not 0 <= gamma <= 1:
        raise ValueError("gamma must be in [0,1].")
    n, horizon, _ = candidates.shape
    s = state.expand(n, -1).clone()
    score = torch.zeros(n, dtype=state.dtype, device=state.device)
    for t in range(horizon):
        action = candidates[:, t]
        next_s = dynamics(s, action)
        if next_s.shape != s.shape:
            raise ValueError("dynamics must preserve [N,S].")
        reward = reward_fn(s, action, next_s)
        if reward.shape != (n,):
            raise ValueError("reward must be [N], not [N,1].")
        score += gamma**t * reward
        s = next_s
    if not torch.isfinite(score).all():
        raise ValueError("Nonfinite planner scores.")
    index = score.argmax()
    return candidates[index, 0].clone(), score[index], index

```

B.5 视觉语言架构、预测表征与高效计算

本节包含空间合并及逆变换、Gated DeltaNet 状态更新、注意力反向传播、分块在线 softmax、RMSNorm、Gram 矩阵约束、动作序列处理与比例区间估计。形状约定与各章公式一致。在线注意力函数使用 PyTorch 张量运算验证分块递推；性能实验需要按第12章的协议另行实现与测量。

```

"""Reference kernels for architecture, representation, policy and systems chapters.

These are readable CPU/PyTorch implementations, not optimized GPU kernels.
All masks are Boolean. Shapes and reduction conventions are part of each API.
"""
from __future__ import annotations
import math
from collections.abc import Sequence
import torch
from torch import Tensor
import torch.nn.functional as F

```

```

def packed_causal_mask(segment: Tensor) -> Tensor:
    """segment: [B,L] integer IDs, -1 = padding; return [B,L,L] support.

    IDs must identify unique samples within each packed row. Padding queries
    have no valid key and must be excluded before a softmax operation.
    """
    if segment.ndim != 2 or segment.dtype not in (torch.int32, torch.int64):
        raise TypeError("Expected integer segment IDs [B,L].")
    if (segment < -1).any():
        raise ValueError("Only -1 may represent padding.")
    length = segment.shape[1]
    pos = torch.arange(length, device=segment.device)
    causal = pos[None, :] <= pos[:, None]
    same = segment[:, :, None] == segment[:, None, :]
    valid = (segment[:, :, None] >= 0) & (segment[:, None, :] >= 0)
    return causal & same & valid

def spatial_merge(x: Tensor, factor: int = 2) -> Tensor:
    """[B,H,W,C] -> [B,H*W/s**2,s**2*C], local order (u,v,c)."""
    if x.ndim != 4 or factor < 1:
        raise ValueError("Expected [B,H,W,C] and positive factor.")
    b, h, w, c = x.shape
    if h % factor or w % factor:
        raise ValueError("The merge factor must divide H and W.")
    return (x.reshape(b, h//factor, factor, w//factor, factor, c)
            .permute(0, 1, 3, 2, 4, 5).reshape(b, h*w//factor**2, factor**2*c))

def spatial_unmerge(z: Tensor, shape: Sequence[int], factor: int = 2) -> Tensor:
    """Inverse of the rearrangement, before any dimensionality reduction."""
    if len(shape) != 4 or factor < 1:
        raise ValueError("Expected four target dimensions and positive factor.")
    b, h, w, c = shape
    if h % factor or w % factor or z.shape != (b, h*w//factor**2, factor**2*c):
        raise ValueError("Incompatible target shape.")
    return (z.reshape(b, h//factor, w//factor, factor, factor, c)
            .permute(0, 1, 3, 2, 4, 5).reshape(tuple(shape)))

def length_weighted_loss(loss: Tensor, mask: Tensor, eta: float = .5) -> Tensor:
    """Sum_i N_i*(-eta)*sum_t(loss_it) / sum_i N_i*(1-eta).

    eta=0 is token mean; eta=1 is sequence mean. Empty samples are rejected.
    """
    if loss.ndim != 2 or mask.shape != loss.shape or mask.dtype != torch.bool:
        raise ValueError("Expected loss and Boolean mask [B,L].")
    if not 0 <= eta <= 1:
        raise ValueError("eta must be in [0,1].")
    n = mask.sum(-1).to(loss.dtype)
    if (n == 0).any():

```



```

        raise ValueError("Each sample must contain supervised positions.")
    sums = loss.masked_fill(~mask, 0).sum(-1)
    return (n.pow(-eta) * sums).sum() / n.pow(1-eta).sum()

def delta_update(state: Tensor, key: Tensor, value: Tensor,
                 alpha: float | Tensor = 1., beta: float | Tensor = 1.) -> Tensor:
    """state [...,d_v,d_k], key [...,d_k], value [...,d_v].

    alpha,beta are scalar or have shape state.shape[:-2]. Keys are not
    automatically normalized, so non-unit-key behavior can be tested.
    """
    if state.shape[-1] != value.shape or state.shape[:-2]+state.shape[-1:] != key.shape:
        raise ValueError("State, key and value dimensions do not agree.")
    a = torch.as_tensor(alpha, dtype=state.dtype, device=state.device)
    b = torch.as_tensor(beta, dtype=state.dtype, device=state.device)
    leading = state.shape[:-2]
    if a.shape not in (torch.Size([]), leading) or b.shape not in (torch.Size([]), leading):
        raise ValueError("Gates must be scalar or match the leading state axes.")
    decayed = state * a[... , None, None]
    residual = value - (decayed @ key.unsqueeze(-1)).squeeze(-1)
    return decayed + b[... , None, None] * residual.unsqueeze(-1) * key.unsqueeze(-2)

def attention_backward(q: Tensor, k: Tensor, v: Tensor, grad_out: Tensor,
                     mask: Tensor | None = None) -> tuple[Tensor, Tensor, Tensor]:
    """Manual gradients for unbatched Q[Nq,d], K[Nk,d], V[Nk,dv]."""
    if q.ndim != 2 or k.ndim != 2 or v.ndim != 2 or q.shape[1] != k.shape[1] or k.shape[0] != v.shape[0]:
        raise ValueError("Incompatible attention matrices.")
    score = q @ k.T / math.sqrt(q.shape[-1])
    if mask is not None:
        if mask.shape != score.shape or mask.dtype != torch.bool or not mask.any(-1).all():
            raise ValueError("Every query needs a valid Boolean support row.")
        score = score.masked_fill(~mask, -torch.inf)
    prob = score.softmax(-1)
    out = prob @ v
    if grad_out.shape != out.shape:
        raise ValueError("Output gradient has the wrong shape.")
    grad_v = prob.T @ grad_out
    grad_p = grad_out @ v.T
    grad_s = prob * (grad_p - (prob * grad_p).sum(-1, keepdim=True))
    scale = math.sqrt(q.shape[-1])
    return grad_s @ k / scale, grad_s.T @ q / scale, grad_v

def online_attention(q: Tensor, k: Tensor, v: Tensor, block_size: int,
                   mask: Tensor | None = None) -> Tensor:
    """Exact unbatched block softmax reference, differentiable in PyTorch."""
    if block_size < 1 or q.ndim != 2 or k.ndim != 2 or v.ndim != 2:
        raise ValueError("Expected positive block size and matrices.")
    if q.shape[-1] != k.shape[-1] or k.shape[0] != v.shape[0] or k.shape[0] == 0:
        raise ValueError("Incompatible attention dimensions.")

```

```

if mask is not None:
    if mask.shape != (q.shape[0], k.shape[0]) or mask.dtype != torch.bool:
        raise ValueError("Mask must be Boolean [Nq,Nk].")
    if not mask.any(-1).all():
        raise ValueError("Fully masked query rows are undefined.")
m = q.new_zeros(q.shape[0], 1)
denom = q.new_zeros(q.shape[0], 1)
numerator = q.new_zeros(q.shape[0], v.shape[1])
for start in range(0, k.shape[0], block_size):
    score = q @ k[start:start+block_size].T / math.sqrt(q.shape[-1])
    if mask is not None:
        score = score.masked_fill(~mask[:, start:start+block_size], -torch.inf)
    block_max = score.max(-1, keepdim=True).values
    finite = torch.isfinite(block_max)
    # Use finite sentinels. exp(-inf) is 0; -inf-(-inf) is never evaluated.
    safe_max = torch.where(finite, block_max, torch.zeros_like(block_max))
    merged = torch.where(denom > 0, torch.maximum(m, safe_max), safe_max)
    merged = torch.where(finite, merged, m)
    correction = torch.exp(m - merged)
    weights = torch.exp(score - merged)
    numerator = correction*numerator + weights @ v[start:start+block_size]
    denom = correction*denom + weights.sum(-1, keepdim=True)
    m = merged
return numerator / denom

def sigmoid_pair_loss(score: Tensor) -> Tensor:
    """Square BxB paired scores, diagonal positives; normalization is /B."""
    if score.ndim != 2 or score.shape[0] != score.shape[1] or score.shape[0] == 0:
        raise ValueError("Scores must be a nonempty square matrix.")
    y = 2*torch.eye(score.shape[0], device=score.device, dtype=score.dtype)-1
    return F.softplus(-y*score).sum() / score.shape[0]

@torch.no_grad()
def ema_update(teacher: Tensor, student: Tensor, momentum: float) -> None:
    if teacher.shape != student.shape or not 0 <= momentum <= 1:
        raise ValueError("Invalid EMA shapes or coefficient.")
    teacher.mul_(momentum).add_(student, alpha=1-momentum)

def vicreg_stats(z: Tensor, threshold: float = 1., eps: float = 1e-4) -> tuple[Tensor, Tensor]:
    """Variance hinge and off-diagonal covariance penalty, each divided by d."""
    if z.ndim != 2 or z.shape[0] < 2 or eps < 0:
        raise ValueError("Covariance needs at least two samples and eps >= 0.")
    centered = z-z.mean(0)
    covariance = centered.T @ centered / (z.shape[0]-1)
    diagonal = covariance.diagonal()
    variance = F.relu(threshold-(diagonal+eps).sqrt()).mean()
    offdiag = covariance - torch.diag_embed(diagonal)
    return variance, offdiag.square().sum()/z.shape[1]

```

```

def gram_loss(z: Tensor, teacher_gram: Tensor) -> Tensor:
    """ $L = ||ZZ^T - G_T||_F^2 / N^2$ , teacher stop-gradient, no implicit normalization."""
    if z.ndim != 2 or teacher_gram.shape != (z.shape[0], z.shape[0]):
        raise ValueError("Expected Z[N,d], G[N,N].")
    return (z@z.T-teacher_gram.detach()).square().mean()

def gram_gradient(z: Tensor, teacher_gram: Tensor) -> Tensor:
    error = z@z.T-teacher_gram.detach()
    return 2*(error+error.T)@z/z.shape[0]**2

def weighted_context_ll(pred: Tensor, teacher: Tensor, masked: Tensor,
                        coordinates: Tensor, coefficient: float = .5) -> Tensor:
    """[B,N,d] targets, hidden mask [B,N], unique coordinates [N,k].

    L1 sums feature dimensions, averages visible positions then samples.
    Distances are Euclidean in the provided coordinate units.
    """
    if pred.ndim != 3 or pred.shape != teacher.shape or masked.shape != pred.shape[:2] or masked.dtype !=
        torch.bool:
        raise ValueError("Invalid prediction, teacher, or mask shape.")
    if coordinates.ndim != 2 or coordinates.shape[0] != pred.shape[1] or coefficient < 0:
        raise ValueError("Invalid coordinates or coefficient.")
    if torch.unique(coordinates, dim=0).shape[0] != coordinates.shape[0]:
        raise ValueError("Coordinates must be unique.")
    coordinates = coordinates.to(device=pred.device, dtype=pred.dtype)
    errors = (pred-teacher.detach()).abs().sum(-1)
    losses = []
    for b in range(pred.shape[0]):
        hidden = masked[b]
        if not hidden.any() or hidden.all():
            raise ValueError("Each sample needs hidden and visible positions.")
        distance = torch.cdist(coordinates[~hidden], coordinates[hidden]).min(-1).values
        losses.append((errors[b, ~hidden]*coefficient/distance.sqrt()).mean())
    return torch.stack(losses).mean()

def rms_norm(x: Tensor, gain: Tensor, eps: float = 1e-6) -> Tensor:
    if gain.shape != x.shape[-1:] or eps < 0:
        raise ValueError("Gain must match the feature axis; eps >= 0.")
    # This reference preserves dtype for float64 gradient checks.
    return gain*x*torch.rsqrt(x.square().mean(-1, keepdim=True)+eps)

def rms_vjp(x: Tensor, gain: Tensor, grad: Tensor, eps: float = 1e-6) -> Tensor:
    if x.shape != grad.shape:
        raise ValueError("Invalid upstream gradient.")
    r = (x.square().mean(-1, keepdim=True)+eps).sqrt()
    u = gain*grad
    return u/r - x*(u*x).sum(-1, keepdim=True)/(x.shape[-1]*r**3)

def dct_matrix(length: int, dtype: torch.dtype = torch.float64) -> Tensor:

```

```

    """Orthonormal DCT-II; transform along time with C @ actions."""
    if length < 1:
        raise ValueError("Length must be positive.")
    n = torch.arange(length, dtype=dtype)
    k = n[:, None]
    matrix = math.sqrt(2/length)*torch.cos(math.pi/length*(n+.5)*k)
    matrix[0] /= math.sqrt(2)
    return matrix

def masked_action_mse(pred: Tensor, target: Tensor, valid: Tensor) -> Tensor:
    """[B,H,d] tensors; [B,H] mask. Mean over all valid action components."""
    if pred.ndim != 3 or target.shape != pred.shape or valid.shape != pred.shape[:2] or valid.dtype != torch.
        bool:
        raise ValueError("Expected actions [B,H,d] and Boolean validity [B,H].")
    if not valid.any():
        raise ValueError("There are no valid actions.")
    error = (pred-target.detach()).square().masked_fill(~valid[..., None], 0)
    return error.sum() / (valid.sum()*pred.shape[-1])

def inpaint_known(x: Tensor, noise: Tensor, known: Tensor, mask: Tensor,
    time: float | Tensor) -> Tensor:
    """Project a same-shaped Boolean known-region mask onto a linear flow path."""
    if x.shape != noise.shape or x.shape != known.shape or x.shape != mask.shape or mask.dtype != torch.bool:
        raise ValueError("All tensors must have identical shape; mask is Boolean.")
    t = torch.as_tensor(time, dtype=x.dtype, device=x.device)
    if t.ndim != 0 or not 0 <= t.item() <= 1:
        raise ValueError("Expected scalar flow time in [0,1].")
    return torch.where(mask, (1-t)*noise+t*known, x)

def ddpm_posterior(x0: Tensor, xk: Tensor, beta: Tensor, previous_alpha_bar: Tensor) -> tuple[Tensor, Tensor
]:
    """Posterior mean and broadcast variance. Coefficients have shape [B]."""
    if x0.shape != xk.shape or x0.ndim < 2 or beta.shape != x0.shape[:1] or previous_alpha_bar.shape != beta.
        shape:
        raise ValueError("Invalid DDPM shapes.")
    if ((beta <= 0)|(beta >= 1)).any() or ((previous_alpha_bar <= 0)|(previous_alpha_bar > 1)).any():
        raise ValueError("Require beta in (0,1), previous_alpha_bar in (0,1).")
    shape = (x0.shape[0],)+(1,)*(x0.ndim-1)
    b = beta.reshape(shape)
    prev = previous_alpha_bar.reshape(shape)
    alpha = 1-b
    abar = alpha*prev
    var = b*(1-prev)/(1-abar)
    mean = b*prev.sqrt()/(1-abar)*x0 + alpha.sqrt()*(1-prev)/(1-abar)*xk
    return mean, var

def symlog(x: Tensor) -> Tensor:
    return x.sign()*x.abs().log1p()

```

```
def symexp(x: Tensor) -> Tensor:
    return x.sign()*x.abs().expm1()

def wilson_interval(successes: int, total: int, z: float = 1.96) -> tuple[float, float]:
    if total < 1 or not 0 <= successes <= total or z <= 0:
        raise ValueError("Require n>0, 0<=k<=n, z>0.")
    p = successes/total
    denom = 1+z*z/total
    center = (p+z*z/(2*total))/denom
    half = z*math.sqrt(p*(1-p)/total+z*z/(4*total*total))/denom
    return max(0., center-half), min(1., center+half)
```

B.6 解析流、离散后验与采样校正

解析高斯模型为流匹配提供可直接计算的参照。下面两个函数分别实现条件平均速度与有限时间流映射。它们用于检查积分误差、流映射组合关系和一致性边界，参见习题4.2。

```
def gaussian_velocity(x: Tensor, t: float | Tensor,
                    mean: float = 0., std: float = 1.) -> Tensor:
    """Independent Gaussian-endpoint CFM velocity; t broadcasts with x.

     $X_0 \sim N(0,1)$ ,  $X_1 \sim N(\text{mean}, \text{std}^2)$ ,  $X_t = (1-t)X_0 + tX_1$ .
    """
    if std <= 0 or not math.isfinite(std) or not math.isfinite(mean):
        raise ValueError("Finite mean and positive std required.")
    t = _time(t, x)
    q = (1 - t).square() + (t * std).square()
    cov = t * std**2 - (1 - t)
    return mean + cov / q * (x - t * mean)
```

```
def gaussian_flow_map(x: Tensor, start: float | Tensor,
                    end: float | Tensor, mean: float = 0.,
                    std: float = 1.) -> Tensor:
    """Exact ODE map, valid in either time direction on [0,1]."""
    if std <= 0 or not math.isfinite(std) or not math.isfinite(mean):
        raise ValueError("Finite mean and positive std required.")
    a, b = _time(start, x), _time(end, x)
    qa = (1 - a).square() + (a * std).square()
    qb = (1 - b).square() + (b * std).square()
    return b * mean + (qb / qa).sqrt() * (x - a * mean)
```

离散后验函数按前向联合概率归一化。分母为零的条件事件直接报错，调用者应在模型输出中限制初始类别的可达支持。

```
def discrete_posterior(qbar_prev: Tensor, step: Tensor,
                      source: int, observed: int) -> Tensor:
    """q(X[k-1] | X[k]=observed, X[0]=source), row-stochastic kernels.

    Zero-probability conditioning events are rejected, not epsilon-smoothed.
    """
    _stochastic_matrix(qbar_prev, "qbar_prev")
    _stochastic_matrix(step, "step")
    if qbar_prev.shape != step.shape:
        raise ValueError("Kernel shapes differ.")
    k = step.shape[0]
    if type(source) is not int or type(observed) is not int:
        raise TypeError("States are integer indices.")
    if not 0 <= source < k or not 0 <= observed < k:
        raise ValueError("State index out of range.")
    mass = qbar_prev[source] * step[:, observed]
    denominator = mass.sum()
    if denominator.item() <= 0:
        raise ValueError("Conditioning event has zero probability.")
    return mass / denominator
```

推测解码的三个返回值分别为逐类别接受概率、接受路径的概率质量与归一化残差分布。目标和草稿输入必须是已应用温度及其他采样变换后的概率分布。

```
@torch.no_grad()
def speculative_parts(p: Tensor, q: Tensor) -> tuple[Tensor, Tensor, Tensor]:
    """Return acceptance per token, accepted mass, normalized residual.

    If p==q the residual is the zero vector and must not be sampled.
    Acceptance at q==0 is defined as zero because the event cannot be drafted.
    """
    _prob_vector(p, "target")
    _prob_vector(q, "draft")
    if p.shape != q.shape:
        raise ValueError("Vocabularies differ.")
    accepted = torch.minimum(p, q)
    acceptance = torch.zeros_like(p)
    support = q > 0
    acceptance[support] = accepted[support] / q[support]
    residual_mass = (p - q).clamp_min(0)
    total = residual_mass.sum()
    residual = residual_mass / total if total.item() > 0 else residual_mass
    return acceptance, accepted, residual
```

同一文件还包含掩码交叉熵的手工反向传播、GSPO 序列比率、留一法优势、标量 Bayes 更新、质量条件策略、MinHash 和 pass@ k 。相应测试通过明确的函数接口调用这些实现。

B.7 测试协议

在代码目录运行：

```
python -m unittest -v test_core test_extended test_lecture
```

配套测试包含 158 项 CPU 单元测试，检查形状、数值、梯度和边界输入。测试输出保存在代码包的 `test_results.txt`。测试范围覆盖目标函数、概率归一化、梯度、索引与边界条件。`test_lecture.py` 另按 13 章组织 53 项检查，将习题中的解析结果和反例写为断言；既有模块的 105 项检查保留在另外两个测试文件中。

完整训练评价需另行报告环境回报、生成质量或控制成功率。单元测试结果与端到端实验结果在实验记录中分别列示。

附录 C 公式索引与符号表

C.1 公式索引

模块	公式	内容
线性变换	(1.1)、(1.3)	收缩维度、前导轴与广播梯度。
交叉熵	(1.6)、(9.1)	分类导数与序列对数概率求和。
条件均值	(1.12)	平方损失的最优回归函数。
随机梯度	(1.13)、(1.14)	似然比与重参数化估计。
CLIP 与 VLM	(2.1)、(2.9)	对比损失、监督移位与有效 token。
注意力	(2.8)、(3.15)	键轴归一化、收缩与相对位置。
策略梯度	(7.5)、(7.10)	折扣约定与方差基线。
GAE	(7.24)、(7.26)	自举、递归与轨迹边界。
PPO	(7.31)、(7.32)	旧策略比率与裁剪方向。
DQN 与 DDQN	(8.2)、(8.4)	目标网络、动作选择与数值评估。
SAC	(8.11)、(8.13)、(8.17)	critic、actor 与温度更新。
有界动作密度	(8.15)、(8.16)	$\tanh$ Jacobian 与稳定计算。
离线强化学习	(8.21)、(8.24)、(8.27)	expectile、优势加权与保守估计。
VAE	(4.1)、(4.7)	似然下界、后验与高斯 KL。
DDPM	(4.11)、(4.17)、(4.21)	前向边缘、后验与噪声预测。
得分模型	(4.26)、(4.28)、(4.29)	得分、反向 SDE 与概率流 ODE。
流匹配	(4.31)、(4.32)、(4.37)	条件路径与边缘速度。
采样与 CFG	(4.40)、(4.41)、(4.42)	步长、NFE 与条件组合。
视频生成	(5.1)、(5.2)、(5.4)	时间压缩、块顺序与自回归。
GRPO	(9.3)、(9.9)、(9.12)	组统计量、长度权重与 KL。
DPO	(9.22)、(9.25)	KL 正则化解与偏好似然。
动力学与 MPC	(10.5)、(10.6)、(10.7)	累积误差、滚动规划与分布拟合。
Dreamer	(10.11)、(10.18)、(10.22)	后验、先验与想象回报。
JEPA 与动作预测	(6.13)、(6.14)、(6.15)	目标表征、动作条件与规划距离。
现代 VLM	(3.12)、(3.17)、(3.20)	空间合并、多层注入与循环状态。
长度归约	(3.26)、(12.20)	样本长度权重与全局有效计数。
概率输运	(1.21)、(4.45)	密度守恒与轨迹对数密度。
自监督表征	(6.1)、(6.6)、(6.8)	二元匹配、教师与非退化约束。
密集表征	(6.9)、(6.12)、(6.18)	空间关系、多层与局部监督。

模块	公式	内容
动作模型	(11.6)、(11.12)、(11.20)	连续动作生成、梯度隔离与执行前缀。
系统计算	(12.4)、(12.7)、(12.9)	归一化、分块计算与缓存。
并行与预算	(12.21)、(12.23)、(12.27)	梯度平均、张量分片与规模分配。
流映射与一致性	(4.46)、(4.48)、(4.49)	组合律、边界条件与蒸馏。
离散扩散	(4.52)、(4.53)	前向核、后验与反向混合。
有限状态流	(4.56)、(4.57)	概率守恒与反向速率。
策略代理与 KL	(7.30)、(9.10)、(9.14)	状态分布近似、序列比率与梯度。
动作优势条件	(11.13)、(11.16)、(11.19)	经验标签、条件分布与动作持续时间。
推测解码	(12.14)	接受质量、残差分布与目标概率。
评价与数据	(13.4)、(13.5)、(13.7)	候选去重和多次采样指标。
修正与校准	(13.6)、(13.8)	条件转移率与评价误差。

C.2 符号与数值约定

符号	定义
B, L, F, T	批次大小、token 长度、视频帧数、环境轨迹长度。
d, h, N	特征维数、注意力头数、token 数或候选数；具体定义随公式给出。
t, k, τ	环境或序列时间、离散扩散步、连续生成时间。
θ, ϕ, ψ	可训练参数集合；每个损失明确其更新对象。
$\bar{\theta}$	目标或 EMA 参数，更新规则由对应算法确定。
$\text{sg}(\cdot)$	前向保留数值，反向停止梯度。
$\pi_{\text{old}}, \pi_{\text{ref}}$	采样行为策略、固定参考策略。
γ, λ	折扣因子、优势或回报估计中的混合系数。
b_t, c_t	GAE 的自举与递归掩码；世界模型继续标记按局部定义使用。
α, β, τ_c	熵温度、正则化或噪声参数、对比温度；依公式区分。
m, M, I	有效位置掩码、注意力支持或加性掩码、整数索引；三者分别定义。

自然对数用于所有对数概率与 KL。连续动作概率表示密度，变量变换包含 Jacobian 修正。求和与平均均写明归约轴。DDPM 采用数据 x_0 到噪声 x_K 的索引；线性流匹配采用噪声 x_0 到数据 x_1 的索引。端点命名在各自推导内部保持一致。

参考文献

- [1] Stanford CS336. Language Modeling from Scratch. Spring 2026. Accessed 5 September 2026.
- [2] Stanford CS224R. Homework 2: Online Reinforcement Learning. Spring 2026.
- [3] Wan Team. Wan2.2: Open and Advanced Large-Scale Video Generative Models. Model release and technical documentation, 2025–2026.
- [4] CMU 10-799. Diffusion & Flow Matching: Schedule. Spring 2026.
- [5] Stanford CS224R. Deep Reinforcement Learning. Spring 2026.
- [6] Stanford CS224R. Actor-Critic Algorithms. Lecture slides, 2026.
- [7] Stanford CS224R. Off-policy Actor-Critic. Lecture slides, 2026.
- [8] Berkeley CS285. HW3: Q-Learning and Actor-Critic Algorithms. Spring 2026.
- [9] Berkeley CS285. HW4: LLM RL. Spring 2026.
- [10] Vaswani, A. et al. Attention Is All You Need. NeurIPS, 2017.
- [11] Radford, A. et al. Learning Transferable Visual Models From Natural Language Supervision. ICML, 2021.
- [12] Qwen Team. Qwen3-VL Technical Report. arXiv:2511.21631v1, 2025.
- [13] Su, J. et al. RoFormer: Enhanced Transformer with Rotary Position Embedding. arXiv:2104.09864, 2021.
- [14] Hu, E. J. et al. LoRA: Low-Rank Adaptation of Large Language Models. ICLR, 2022.
- [15] Williams, R. J. Simple Statistical Gradient-Following Algorithms for Connectionist Reinforcement Learning. Machine Learning, 8:229–256, 1992.
- [16] Sutton, R. S., McAllester, D., Singh, S., Mansour, Y. Policy Gradient Methods for Reinforcement Learning with Function Approximation. NeurIPS, 1999.
- [17] Schulman, J. et al. High-Dimensional Continuous Control Using Generalized Advantage Estimation. ICLR, 2016.
- [18] Schulman, J. et al. Proximal Policy Optimization Algorithms. arXiv:1707.06347, 2017.
- [19] Mnih, V. et al. Playing Atari with Deep Reinforcement Learning. arXiv:1312.5602, 2013.
- [20] van Hasselt, H., Guez, A., Silver, D. Deep Reinforcement Learning with Double Q-learning. AAAI, 2016.

- [21] Haarnoja, T. et al. Soft Actor-Critic Algorithms and Applications. arXiv:1812.05905, 2018.
- [22] Kostrikov, I., Nair, A., Levine, S. Offline Reinforcement Learning with Implicit Q-Learning. ICLR, 2022.
- [23] Kumar, A. et al. Conservative Q-Learning for Offline Reinforcement Learning. NeurIPS, 2020.
- [24] Kingma, D. P., Welling, M. Auto-Encoding Variational Bayes. ICLR, 2014.
- [25] Ho, J., Jain, A., Abbeel, P. Denoising Diffusion Probabilistic Models. NeurIPS, 2020.
- [26] Song, J., Meng, C., Ermon, S. Denoising Diffusion Implicit Models. ICLR, 2021.
- [27] Song, Y. et al. Score-Based Generative Modeling through Stochastic Differential Equations. ICLR, 2021.
- [28] Lipman, Y. et al. Flow Matching for Generative Modeling. ICLR, 2023.
- [29] Lipman, Y. et al. Flow Matching Guide and Code. arXiv:2412.06264, 2024.
- [30] Ho, J., Salimans, T. Classifier-Free Diffusion Guidance. arXiv:2207.12598, 2022.
- [31] Rombach, R. et al. High-Resolution Image Synthesis with Latent Diffusion Models. CVPR, 2022.
- [32] Peebles, W., Xie, S. Scalable Diffusion Models with Transformers. ICCV, 2023.
- [33] Wan Team. Wan: Open and Advanced Large-Scale Video Generative Models. arXiv:2503.20314v2, 2025.
- [34] Huang, J. et al. Self Forcing: Bridging the Train-Test Gap in Autoregressive Video Diffusion. arXiv:2506.08009v2, 2025.
- [35] Shao, Z. et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models. arXiv:2402.03300v3, 2024.
- [36] Rafailov, R. et al. Direct Preference Optimization: Your Language Model is Secretly a Reward Model. NeurIPS, 2023.
- [37] Janner, M. et al. When to Trust Your Model: Model-Based Policy Optimization. NeurIPS, 2019.
- [38] Hafner, D., Pasukonis, J., Ba, J., Lillicrap, T. Mastering Diverse Domains through World Models. arXiv:2301.04104v2, 2024.
- [39] Assran, M. et al. V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning. arXiv:2506.09985v1, 2025.
- [40] Ye, S. et al. World Action Models are Zero-shot Policies. arXiv:2602.15922v1, 2026.
- [41] Farama Foundation. Gymnasium: Handling Time Limits. Documentation.
- [42] PyTorch. Autograd Mechanics. Version 2.10.
- [43] PyTorch. Probability Distributions. Version 2.10.

- [44] wdkns. Tensor Formula Viz. Technical specification.
- [45] Visual Instruction Tuning. 2023.
- [46] BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models. 2023.
- [47] Flamingo: a Visual Language Model for Few-Shot Learning. 2022.
- [48] InternVL3.5: Advancing Open-Source Multimodal Models in Versatility, Reasoning, and Efficiency. 2025.
- [49] Qwen3.5-397B-A17B: Model Card. 2026.
- [50] Gated Delta Networks: Improving Mamba2 with Delta Rule. 2024–2025.
- [51] SigLIP 2: Multilingual Vision-Language Encoders with Improved Semantic Understanding, Localization, and Dense Features. 2025.
- [52] Masked Autoencoders Are Scalable Vision Learners. 2021–2022.
- [53] Emerging Properties in Self-Supervised Vision Transformers. 2021.
- [54] Bootstrap Your Own Latent: A New Approach to Self-Supervised Learning. 2020.
- [55] VICReg: Variance-Invariance-Covariance Regularization for Self-Supervised Learning. 2021–2022.
- [56] DINOv3. 2025.
- [57] V-JEPA 2.1: Unlocking Dense Features in Video Self-Supervised Learning. 2026.
- [58] Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. 2023.
- [59] FAST: Efficient Action Tokenization for Vision-Language-Action Models. 2025.
- [60] $\pi_{0.7}$: a Steerable Generalist Robotic Foundation Model with Emergent Capabilities. 2026.
- [61] Real-Time Action Chunking with Large Models. 2025.
- [62] Root Mean Square Layer Normalization. 2019.
- [63] GLU Variants Improve Transformer. 2020.
- [64] FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. 2022.
- [65] FlashAttention-2: Faster Attention with Better Parallelism and Work Partitioning. 2023.
- [66] GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints. 2023.
- [67] Decoupled Weight Decay Regularization. 2017–2019.
- [68] Training Compute-Optimal Large Language Models. 2022.

- [69] A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning. 2010–2011.
- [70] DAPO: An Open-Source LLM Reinforcement Learning System at Scale. 2025.
- [71] Understanding R1-Zero-Like Training: A Critical Perspective. 2025.
- [72] Hindsight Experience Replay. 2017.
- [73] Stanford CS336 Assignment 2: Systems. Spring 2026.
- [74] Stanford CS336 Assignment 5: Alignment and Reasoning RL. Spring 2026.
- [75] PyTorch: Automatic Mixed Precision Examples. Version 2.10.
- [76] CMU 10-799. State-of-the-Art Architectures. Lecture 9, Spring 2026.
- [77] CMU 10-799. Distillation. Lecture 10, Spring 2026.
- [78] CMU 10-799. Discrete Diffusion. Lecture 12, Spring 2026.
- [79] CMU 10-799. Discrete Flow. Lecture 13, Spring 2026.
- [80] CMU 10-423/623/723. Vision-Language Models. Lecture 13, Spring 2026.
- [81] CMU 10-423/623/723. Video. Lecture 25, Spring 2026.
- [82] CMU 10-423/623/723. World Models. Lecture 26, Spring 2026.
- [83] Stanford CS224R. Reward Learning. Lecture slides, 2026.
- [84] Stanford CS224R. RL for Vision-Language-Action Models. Lecture slides, 2026.
- [85] Stanford CS224R. Reinforcement Learning from Human Feedback. Lecture slides, 2026.
- [86] Stanford CS231n. Self-Supervised Learning. Lecture 12, 2025.
- [87] Stanford CS336. Assignment 5: Alignment—Function Interfaces. Spring 2026.
- [88] Stanford CS336. Assignment 4: Data. Spring 2026.
- [89] Lee, H.-Y.. Self-Correction. Lecture slides, Spring 2026.
- [90] Lee, H.-Y.. Position Encoding. Lecture slides, Spring 2026.
- [91] Lee, H.-Y.. Inference. Lecture slides, Spring 2026.
- [92] Lee, H.-Y.. Agent Era. Lecture slides, Spring 2026.
- [93] Lee, H.-Y.. Evaluation. Lecture slides, Fall 2025.
- [94] Lee, H.-Y.. Speech Language Models. Lecture slides, Fall 2025.

- [95] Song, Y. et al.. Consistency Models. 2023.
- [96] Austin, J. et al.. Structured Denoising Diffusion Models in Discrete State-Spaces. 2021.
- [97] Zhou, C. et al.. Transfusion: Predict the Next Token and Diffuse Images with One Multi-Modal Model. 2024.
- [98] Leng, S. et al.. Mitigating Object Hallucinations in Large Vision-Language Models through Visual Contrastive Decoding. 2023–2024.
- [99] Wan Team. Wan2.2-T2V-A14B: Model Card. 2025.
- [100] Wan Team. Wan2.2-TI2V-5B: Model Card. 2025.
- [101] Bellemare, M. G., Dabney, W., Munos, R.. A Distributional Perspective on Reinforcement Learning. 2017.
- [102] Zheng, C. et al.. Group Sequence Policy Optimization. 2025.
- [103] Physical Intelligence. $\pi_{0.6}^*$: a VLA That Learns From Experience. 2025.
- [104] Chen, S. et al.. Extending Context Window of Large Language Models via Positional Interpolation. 2023.
- [105] Leviathan, Y., Kalman, M., Matias, Y.. Fast Inference from Transformers via Speculative Decoding. 2022–2023.
- [106] Broder, A. Z.. On the Resemblance and Containment of Documents. SEQUENCES, 1997.
- [107] Chen, M. et al.. Evaluating Large Language Models Trained on Code. 2021.